

Resultados de Probabilidade e Estatística

Cleiton Moya de Almeida

16 de setembro de 2026

Sumário

1	Álgebra Linear	4
1.1	Sistemas de equações lineares	4
1.2	Definições e propriedades de matrizes	5
1.3	Espaço vetorial Euclidiano	9
1.4	Espaço vetorial Geral	11
1.4.1	Espaços linha, coluna e nulo	13
1.5	Espaços com produto interno	14
1.6	Posto e nulidade	16
1.7	Autovalores e autovetores	17
1.8	Semelhança e Diagonalização	18
1.9	Diagonalização ortogonal	19
1.10	Formas lineares e quadráticas	20
1.11	Matrizes em blocos	22
1.12	Derivadas	23
2	Probabilidade	25
2.1	Distribuições	25
2.1.1	Distribuições discretas	25
2.1.2	Distribuições contínuas	26
2.2	Probabilidade e Independência	31
2.3	Esperança	32
2.4	Variância	32
2.5	Covariância	33
2.6	Transformações	34
2.7	Vetor aleatório	35
3	Inferência	38
3.1	Distribuições amostrais	38
3.1.1	Estatísticas de ordem	39
3.2	Redução de dados	40
3.3	Estimação Pontual I	42
3.4	Estimação Pontual II	43
3.5	Estimação intervalar	45
3.6	Testes de hipóteses I	49
3.7	Testes de hipóteses II	56

4	Normal multivariada	66
4.1	Distribuição normal multivariada	66
4.2	Distribuições de formas quadráticas	68
5	Regressão	70
6	Inferência Bayesiana	71
7	Probabilidade Avançada	77
7.1	Teoria de conjuntos	77
7.2	Funções	80
7.3	Noções de cardinalidade	82
7.4	Valor absoluto	82
7.5	Sequências de números reais	82
7.6	Sequências de conjuntos	83
7.7	Classes de Subconjuntos	84
7.8	Medida	92
7.9	Probabilidade	93
7.9.1	Convergência	93
7.10	Transformações mensuráveis	93
7.11	Variáveis aleatórias	95
7.12	Esperança	97
7.12.1	Variável aleatória simples	97
7.12.2	Variável aleatória não negativa	98
7.12.3	Variável aleatória integrável	100
7.13	Medida de Probabilidade Produto	101
7.13.1	Vetores aleatórios	101
7.13.2	Medida produto	102
7.14	Independência	104
7.14.1	Eventos	104
7.14.2	Classes de eventos	104
7.14.3	Variáveis aleatórias	105
7.14.4	Teoremas	105
7.15	Convergência	106
7.15.1	Definições	106
7.15.2	Teoremas	107
7.15.3	Desigualdades	107
7.15.4	Covariância e Variância	108
7.15.5	Leis dos Grandes Números	108

Notação

- Variável escalar:
 - (1) Não aleatória: minúscula, itálico (x, θ)
 - (2) Aleatória: maiúscula, itálico (X, θ)
 - Obs.: Exceto v.a. gregas (normalmente usadas em inferência Bayesiana), as quais são geralmente minúsculas.
- Vetor:
 - (1) Não aleatório: minúscula, negrito, itálico ($\boldsymbol{x}, \boldsymbol{\theta}$)
 - (2) Aleatório: maiúscula, negrito, itálico ($\boldsymbol{X}, \boldsymbol{\theta}$)
 - Obs.: Exceto v.a. gregas (normalmente usadas em inferência Bayesiana), as quais são geralmente minúsculas.
- Matriz (aleatória ou não): maiúscula, negrito, reto (não itálico) ($\boldsymbol{X}, \boldsymbol{\Sigma}$)

Capítulo 1

Álgebra Linear

1.1 Sistemas de equações lineares

Teorema 1.1.1 (*Sistemas de equações lineares*). Todo sistema de equações lineares tem ou nenhuma solução, ou exatamente uma solução ou infinitas soluções.

Nota: Um sistema que não possui solução é chamado de inconsistente; se existir pelo menos uma solução, dizemos que o sistema é consistente.

Teorema 1.1.2 (*Sistemas homogêneos*).

- (1) Um sistema homogêneo de equações lineares com mais incógnitas que equações (subdeterminado) tem infinitas soluções.
- (2) Se o sistema homogêneo tem n incógnitas e a forma escalonada reduzida por linhas (echelon) da matriz aumentada tem r linhas não nulas, então o sistema possui $n - r$ variáveis livres (parâmetros).

Nota:

- (1) Um sistema não-homogêneo com mais equações que incógnitas (sobre-determinado) não precisa ser consistente.
- (2) Todo sistema homogêneo é consistente, pois admite ao menos a solução trivial.

Teorema 1.1.3 (*Solução geral e particular*). Seja $\mathbf{x}_0$ qualquer solução de um sistema consistente $\mathbf{Ax} = \mathbf{b}$. Se $S = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$ é uma base para o espaço-nulo de $\mathbf{A}$, então toda solução de $\mathbf{Ax} = \mathbf{b}$ pode ser expressa como

$$\mathbf{x} = \mathbf{x}_0 + c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_k\mathbf{v}_k. \quad (1.1.1)$$

De forma contrária, para todas as escolhas de $c_1, c_2, \dots, c_k$, $\mathbf{x}$ é uma solução de $\mathbf{Ax} = \mathbf{b}$.

Nota: $\mathbf{x}_0$ é chamado de solução particular de $\mathbf{Ax} = \mathbf{b}$ e a parte restante de solução geral de $\mathbf{Ax} = \mathbf{0}$. Assim, a solução geral de um sistema consistente de equações lineares pode ser expressa como a soma de uma solução particular do sistema e a solução geral do sistema homogêneo correspondente.

Teorema 1.1.4 (*Sistema $m \times n$*). . Seja $\mathbf{A}_{m \times n}$ com $\text{pos}(\mathbf{A}) = r$.

- **Caso sobredeterminado:** se $m > n$, então $\exists \mathbf{b} \in \mathbb{R}^m$ tal que o sistema $\mathbf{A}\mathbf{x} = \mathbf{b}$ é inconsistente (sempre, pois $r \leq n < m \implies \text{Col}(\mathbf{A}) \subsetneq \mathbb{R}^m$).
 - (1) Para os $\mathbf{b} \in \text{Col}(\mathbf{A})$ (onde o sistema é consistente):
 - Se $r = n$ (posto-coluna completo): solução única ($n - r = 0$ parâmetros);
 - Se $r < n$: solução geral com $n - r > 0$ parâmetros (infinitas soluções).
- **Caso subdeterminado:** se $m < n$, então $\forall \mathbf{b} \in \mathbb{R}^m$, o sistema $\mathbf{A}\mathbf{x} = \mathbf{b}$ é inconsistente ou possui infinitas soluções (nunca única, pois $r \leq m < n$).
 - (1) Se $r = m$ (posto-linha completo): $\text{Col}(\mathbf{A}) = \mathbb{R}^m$, logo o sistema é *sempre* consistente, com $n - r > 0$ parâmetros;
 - (2) Se $r < m$: o sistema é consistente sse $\mathbf{b} \in \text{Col}(\mathbf{A})$; se consistente, possui $n - r$ parâmetros.

1.2 Definições e propriedades de matrizes

Definição 1.2.1. Definições de matrizes

- (1) Matriz singular: Se $\mathbf{A}$ não admite inversa, $\mathbf{A}$ é dita singular.
- (2) Matriz simétrica: $\mathbf{A} = \mathbf{A}^\top$
- (3) Matriz ortogonal: $\mathbf{A}^{-1} = \mathbf{A}^\top$
- (4) Matriz triangular superior (inferior): elementos abaixo (acima) da diagonal principal são nulos.
- (5) Matriz quadrada idempotente: $\mathbf{A}$ é idempotente se $\mathbf{A} = \mathbf{A}\mathbf{A}$
- (6) Traço: $\text{tr } \mathbf{A} = a_{11} + a_{22} + \cdots + a_{nn}$
- (7) $\mathbf{A}^0 = \mathbf{I}$
- (8) $\mathbf{A}^n = \underbrace{\mathbf{A}\mathbf{A} \cdots \mathbf{A}}_{n \text{ fatores}}$
- (9) $\mathbf{A}^{-n} = (\mathbf{A}^{-1})^n$ e
- (10) Polinômio matricial: Seja $\mathbf{A}$ uma matriz quadrada e $p(x) = a_0 + a_1x + \cdots + a_nx^n$. Definimos $p(\mathbf{A}) = a_0\mathbf{I} + a_1\mathbf{A} + \cdots + a_n\mathbf{A}^n$.
- (11) $\mathbf{u}$ e $\mathbf{v}$ são ortogonais se $\mathbf{u} \cdot \mathbf{v} = \mathbf{u}^\top \mathbf{v} = 0$

Teorema 1.2.1 (*Lei dos expoentes*).

- (1) $\mathbf{A}^r \mathbf{A}^s = \mathbf{A}^{r+s}$

$$(2) (\mathbf{A}^r)^s = \mathbf{A}^{rs}$$

Teorema 1.2.2 (*Propriedades da transposta*).

- (1) $(\mathbf{A}^\top)^\top = \mathbf{A}$
- (2) $(\mathbf{A} + \mathbf{B})^\top = \mathbf{A}^\top + \mathbf{B}^\top$
- (3) $(\mathbf{A} - \mathbf{B})^\top = \mathbf{A}^\top - \mathbf{B}^\top$
- (4) $(k\mathbf{A})^\top = k\mathbf{A}^\top$
- (5) $(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$

Teorema 1.2.3 (*Propriedades de matrizes inversas*).

- (1) Se $\mathbf{A}$ admite inversa, então a inversa é única
- (2) $(\mathbf{A}^{-1})^{-1} = \mathbf{A}$
- (3) $\mathbf{A}$ é invertível $\implies \mathbf{A}^n$ é invertível e $(\mathbf{A}^n)^{-1} = (\mathbf{A}^{-1})^n$
- (4) $\mathbf{A}$ é invertível $\iff \mathbf{A}^\top \mathbf{A}$ e $\mathbf{A} \mathbf{A}^\top$ são invertíveis
- (5) $(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}$
- (6) $(k\mathbf{A})^{-1} = \frac{1}{k} \mathbf{A}^{-1}$
- (7) $(\mathbf{A}^\top)^{-1} = (\mathbf{A}^{-1})^\top$
- (8) Sejam $\mathbf{A}$ e $\mathbf{B}$ são matrizes quadradas de mesma dimensão.
 $\mathbf{AB}$ é invertível $\iff \mathbf{A}$ e $\mathbf{B}$ também são.

Teorema 1.2.4 (*Inversa de matriz 2×2*). Seja $\mathbf{A}_{2 \times 2}$ definida por

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \quad (1.2.1)$$

Se $ad - bc \neq 0$, a inversa de $\mathbf{A}$ é dada por

$$\mathbf{A}^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix} \quad (1.2.2)$$

Teorema 1.2.5 (*Propriedades de matrizes triangulares*).

- (1) A transposta de uma matriz triangular inferior (superior) é triangular superior (inferior).
- (2) O produto de matrizes triangulares inferiores (superiores) é triangular inferior (superior).

- (3) Uma matriz triangular é invertível se, e somente se, as entradas na diagonal principal são todas não nulas.
- (4) A inversa de uma matriz triangular inferior (superior) é triangular inferior (superior).
- (5) $\mathbf{A}$ é triangular $\implies \det(\mathbf{A}) = a_{11}a_{22} \cdots a_{nn}$
- (6) $\mathbf{A}$ é triangular $\implies$ os autovalores de $\mathbf{A}$ são as entradas da diagonal principal

Teorema 1.2.6 (*Multiplicação matricial*).

$$(1) \mathbf{AB} = \mathbf{A} \begin{bmatrix} \mathbf{b}_1 & \mathbf{b}_2 & \cdots & \mathbf{b}_n \end{bmatrix} = \begin{bmatrix} \mathbf{Ab}_1 & \mathbf{Ab}_2 & \cdots & \mathbf{Ab}_n \end{bmatrix}$$

$$(2) \mathbf{AB} = \begin{bmatrix} \mathbf{a}_1 \\ \mathbf{a}_2 \\ \vdots \\ \mathbf{a}_n \end{bmatrix} \mathbf{B} = \begin{bmatrix} \mathbf{a}_1 \mathbf{B} \\ \mathbf{a}_2 \mathbf{B} \\ \vdots \\ \mathbf{a}_n \mathbf{B} \end{bmatrix}$$

Definição 1.2.2 (*Produto de Kronecker*). Sejam $\mathbf{A}$ uma matriz $m \times n$ e $\mathbf{B}$ uma matriz $p \times q$. O produto de Kronecker entre $\mathbf{A}$ e $\mathbf{B}$, denotado $\mathbf{A} \otimes \mathbf{B}$, é a matriz $mp \times nq$ definida em blocos por

$$\mathbf{A} \otimes \mathbf{B} = \begin{pmatrix} a_{11}\mathbf{B} & a_{12}\mathbf{B} & \cdots & a_{1n}\mathbf{B} \\ a_{21}\mathbf{B} & a_{22}\mathbf{B} & \cdots & a_{2n}\mathbf{B} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1}\mathbf{B} & a_{m2}\mathbf{B} & \cdots & a_{mn}\mathbf{B} \end{pmatrix},$$

em que a_{ij} denota o elemento (i, j) de $\mathbf{A}$, $i = 1, \dots, m$, $j = 1, \dots, n$.

Nota:

- (1) **Interpretação prática (o "molde"):** pense em $\mathbf{A}$ como um molde $m \times n$. Cada casa (i, j) do molde é substituída por uma cópia inteira de $\mathbf{B}$ ($p \times q$), escalada pelo número a_{ij} que estava naquela casa. Onde $\mathbf{A}$ tem um 0, o bloco correspondente é a matriz nula $p \times q$.
- (2) **Exemplo (matriz bloco-diagonal):** tomando $\mathbf{A} = \mathbf{I}_n$ (identidade $n \times n$) e $\mathbf{B} = \Sigma_0$ (matriz $p \times p$), a regra acima dá $1 \cdot \Sigma_0$ na diagonal e $0 \cdot \Sigma_0$ fora dela, de modo que

$$\mathbf{I}_n \otimes \Sigma_0 = \begin{pmatrix} \Sigma_0 & & \\ & \ddots & \\ & & \Sigma_0 \end{pmatrix}_{np \times np},$$

isto é, a matriz bloco-diagonal com n cópias de Σ_0 na diagonal.

Teorema 1.2.7 (*Propriedades do produto de Kronecker*). Sejam $\mathbf{A}, \mathbf{A}^*, \mathbf{C}$ e $\mathbf{B}, \mathbf{B}^*, \mathbf{D}$ matrizes com dimensões adequadas em cada item e $k \in \mathbb{R}$. Então:

- (1) $\mathbf{A} \otimes (\mathbf{B} + \mathbf{C}) = \mathbf{A} \otimes \mathbf{B} + \mathbf{A} \otimes \mathbf{C}$ e $(\mathbf{B} + \mathbf{C}) \otimes \mathbf{A} = \mathbf{B} \otimes \mathbf{A} + \mathbf{C} \otimes \mathbf{A}$ (Distributividade)

- (2) $(k\mathbf{A}) \otimes \mathbf{B} = \mathbf{A} \otimes (k\mathbf{B}) = k(\mathbf{A} \otimes \mathbf{B})$ (Homogeneidade)
- (3) $(\mathbf{A} \otimes \mathbf{B}) \otimes \mathbf{C} = \mathbf{A} \otimes (\mathbf{B} \otimes \mathbf{C})$ (Associatividade)
- (4) $\mathbf{A} \otimes \mathbf{0} = \mathbf{0} \otimes \mathbf{A} = \mathbf{0}$
- (5) $(\mathbf{A} \otimes \mathbf{B})(\mathbf{C} \otimes \mathbf{D}) = (\mathbf{AC}) \otimes (\mathbf{BD})$ (Produto misto)
- (6) Se $\mathbf{A}$ e $\mathbf{B}$ são inversíveis, $(\mathbf{A} \otimes \mathbf{B})^{-1} = \mathbf{A}^{-1} \otimes \mathbf{B}^{-1}$
- (7) $(\mathbf{A} \otimes \mathbf{B})^T = \mathbf{A}^T \otimes \mathbf{B}^T$
- (8) Se $\mathbf{A}$ é $n \times n$ e $\mathbf{B}$ é $m \times m$, então $|\mathbf{A} \otimes \mathbf{B}| = |\mathbf{A}|^m |\mathbf{B}|^n$, ou seja, $\det(\mathbf{A} \otimes \mathbf{B}) = (\det \mathbf{A})^m (\det \mathbf{B})^n$
- (9) Nas mesmas condições do item anterior, $\text{tr}(\mathbf{A} \otimes \mathbf{B}) = \text{tr}(\mathbf{A}) \text{tr}(\mathbf{B})$

Teorema 1.2.8 (*Propriedades de matrizes simétricas*).

- (1) $\mathbf{A}^T \mathbf{A}$ e $\mathbf{A} \mathbf{A}^T$ são simétricas
- (2) $\mathbf{A}, \mathbf{B}$ são simétricas $\implies \mathbf{A} + \mathbf{B}$ e $\mathbf{A} - \mathbf{B}$ são simétricas
- (3) $\mathbf{A}$ é simétrica $\implies \mathbf{A}^{-1}$ é simétrica
- (4) $\mathbf{A}$ é invertível $\implies \mathbf{A} \mathbf{A}^T$ e $\mathbf{A}^T \mathbf{A}$ são invertíveis.

Teorema 1.2.9 (*Propriedades de matrizes idempotentes*).

- (1) $\mathbf{A}$ é idempotente $\implies (\mathbf{I} - \mathbf{A})$ é idempotente
- (2) $\mathbf{A}$ é idempotente $\implies \text{pos}(\mathbf{A}) = \text{tr}(\mathbf{A})$
- (3) $\mathbf{A} - \mathbf{B}$ é idempotente $\implies \text{pos}(\mathbf{A} - \mathbf{B}) = \text{pos}(\mathbf{A}) - \text{pos}(\mathbf{B})$

Teorema 1.2.10 (*Propriedades da matriz Design e Matriz $\hat{H}$*). Sejam:

- $\mathbf{X}_{n \times (p+1)}$ com $n > p + 1$ e posto $p + 1$ (posto-coluna) completo;
- $\hat{\mathbf{H}}_{n \times n} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$.

Então:

- (1) $\mathbf{H}$ é idempotente.
- (2) $\mathbf{I} - \mathbf{H}$ é idempotente.
- (3) $\mathbf{H}$ e $\mathbf{I} - \mathbf{H}$ são ortogonais, isto é, $(\mathbf{I} - \mathbf{H})\mathbf{H} = \mathbf{0}$.
- (4) $\text{pos}(\mathbf{H}) = \text{pos}(\mathbf{X}) = p + 1$
- (5) $\text{pos}(\mathbf{I} - \mathbf{H}) = n - (p + 1)$

Teorema 1.2.11 (*Propriedades do traço*).

- (1) $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$
- (2) $\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB})$
- (3) $\text{tr}(\mathbf{A} + \mathbf{B}) = \text{tr}(\mathbf{A}) + \text{tr}(\mathbf{B})$
- (4) $\text{tr}(k\mathbf{A}) = k \text{tr}(\mathbf{A})$
- (5) Seja $\mathbf{A}_{m \times n}$. Então $\text{tr}(\mathbf{AA}^\top) = \sum_{i=1}^m \sum_{j=1}^n a_{ij}^2$
 - (a) Em particular se $A_{n \times n}$ é simétrica, então $\text{tr}(\mathbf{A}^2) = \text{tr}(\mathbf{AA}^\top)$

Teorema 1.2.12 (*Propriedades do determinante*).

- (1) $\det(\mathbf{A}) = \det(\mathbf{A}^\top)$
- (2) $\det(\mathbf{AB}) = \det \mathbf{A} \det \mathbf{B}$
- (3) $\det(k\mathbf{A}) = k^n \det(\mathbf{A})$
- (4) $\mathbf{A}$ é invertível $\iff \det \mathbf{A} \neq 0$
- (5) $\mathbf{A}$ é invertível $\implies \det(\mathbf{A}^{-1}) = \frac{1}{\det \mathbf{A}}$
- (6) Se $\mathbf{A}$ tem uma linha (coluna) de zeros, então $\det(\mathbf{A}) = 0$
- (7) Se $\mathbf{A}$ tem duas linhas (colunas) proporcionais, então $\det(\mathbf{A}) = 0$
- (8) $\mathbf{A}$ é triangular $\implies \det(\mathbf{A}) = a_{11}a_{22} \cdots a_{nn}$
- (9) $\mathbf{A}$ é ortogonal $\implies \det(\mathbf{A}) = \pm 1$
- (10) Seja $\mathbf{B}$ resultante de uma das seguintes operações em linhas (colunas) de $\mathbf{A}$.
 - (a) Multiplicar linha (coluna) por k : $\det(\mathbf{B}) = k \det(\mathbf{A})$
 - (b) Permutar linha (coluna): $\det(\mathbf{B}) = -\det(\mathbf{A})$
 - (c) Múltiplo de uma linha (coluna) é somado a uma outra linha (coluna): $\det(\mathbf{B}) = \det(\mathbf{A})$

1.3 Espaço vetorial Euclidiano

Definição 1.3.1. Seja $\mathbf{v} \in \mathbb{R}^n$.

- (1) Norma: $\|\mathbf{v}\| = \sqrt{v_1^2 + v_2^2 + \cdots + v_n^2}$

Definição 1.3.2 (*Produto escalar em $\mathbb{R}^2$ e $\mathbb{R}^3$*). Sejam $\mathbf{u}, \mathbf{v} \in \mathbb{R}^2$ ou $\mathbb{R}^3$ e θ o ângulo entre $\mathbf{u}$ e $\mathbf{v}$. O produto escalar entre $\mathbf{u}$ e $\mathbf{v}$ é definido como

$$\mathbf{u} \cdot \mathbf{v} = \|\mathbf{u}\| \|\mathbf{v}\| \cos \theta \quad (1.3.1)$$

Definição 1.3.3 (*Produto escalar em $\mathbb{R}^n$*). Sejam $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$. O produto escalar entre $\mathbf{u}$ e $\mathbf{v}$ (produto interno euclidiano) é definido como

$$\mathbf{u} \cdot \mathbf{v} = u_1 v_1 + u_2 v_2 + \cdots + u_n v_n \quad (1.3.2)$$

Nota:

- (1) Em notação matricial: $\mathbf{u} \cdot \mathbf{v} = \mathbf{u}^\top \mathbf{v} = \mathbf{v}^\top \mathbf{u}$
- (2) No caso especial em que $\mathbf{u} = \mathbf{v}$, segue que

$$\|\mathbf{v}\| = \sqrt{\mathbf{u} \cdot \mathbf{v}} = \sqrt{v_1^2 + v_2^2 + \cdots + v_n^2} \quad (1.3.3)$$

Definição 1.3.4. A distância entre $\mathbf{u} \in \mathbb{R}^n$ e $\mathbf{v} \in \mathbb{R}^n$ é definida por

$$d(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\| = \sqrt{(u_1 - v_1)^2 + \cdots + (u_n - v_n)^2} \quad (1.3.4)$$

Definição 1.3.5 (*Ortogonalidade de vetores*). Sejam $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$. $\mathbf{u}, \mathbf{v}$ são ortogonais se $\mathbf{u} \cdot \mathbf{v} = 0$.

Teorema 1.3.1 (*Propriedades da norma e produto interno*).

- (1) $\|\mathbf{v}\| \geq 0$
- (2) $\|\mathbf{v}\| = 0 \iff \mathbf{v} = \mathbf{0}$
- (3) $\|k\mathbf{v}\| = |k| \|\mathbf{v}\|$
- (4) $|\mathbf{u} \cdot \mathbf{v}| \leq \|\mathbf{u}\| \|\mathbf{v}\|$ (Desigualdade de Cauchy-Schwarz)
- (5) $\|\mathbf{u} + \mathbf{v}\| \leq \|\mathbf{u}\| + \|\mathbf{v}\|$ (Desigualdade triangular)
- (6) $\|\mathbf{u} + \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2$ (Teorema de Pitágoras em $\mathbb{R}^n$)
- (7) $d(\mathbf{u}, \mathbf{v}) \leq d(\mathbf{u}, \mathbf{w}) + d(\mathbf{w}, \mathbf{v})$ (Desigualdade triangular para distâncias)
- (8) $\|\mathbf{u} + \mathbf{v}\|^2 + \|\mathbf{u} - \mathbf{v}\|^2 = 2(\|\mathbf{u}\|^2 + \|\mathbf{v}\|^2)$ (Equações do paralelogramo para vetores)
- (9) $\mathbf{u} \cdot \mathbf{v} = \frac{1}{4} \|\mathbf{u} + \mathbf{v}\|^2 - \frac{1}{4} \|\mathbf{u} - \mathbf{v}\|^2$
- (10) $\mathbf{A} \mathbf{u} \cdot \mathbf{v} = \mathbf{u} \cdot \mathbf{A}^\top \mathbf{v}$
- (11) $\mathbf{u} \cdot \mathbf{A} \mathbf{v} = \mathbf{A}^\top \mathbf{u} \cdot \mathbf{v}$

Teorema 1.3.2 (*Teorema da projeção*). Se $\mathbf{a}$ e $\mathbf{u}$ são vetores em $\mathbb{R}^n$, e se $\mathbf{a} \neq \mathbf{0}$, então $\mathbf{u}$ pode ser expresso exatamente em uma única forma $\mathbf{u} = \mathbf{w}_1 + \mathbf{w}_2$, onde $\mathbf{w}_1$ é um múltiplo escalar de $\mathbf{a}$ e $\mathbf{w}_2$ é ortogonal a $\mathbf{a}$. Além disso,

$$\mathbf{w}_1 = \frac{\mathbf{u} \cdot \mathbf{a}}{\|\mathbf{a}\|^2} \mathbf{a} \quad \mathbf{w}_2 = \mathbf{u} - \mathbf{w}_1 \quad (1.3.5)$$

Nota:

- (1) $\mathbf{w}_1$ é chamado de projeção ortogonal de $\mathbf{u}$ em $\mathbf{a}$ e denotado por $\text{proj}_{\mathbf{a}} \mathbf{u}$;
- (2) $\mathbf{w}_2$ é chamado de componente de $\mathbf{u}$ ortogonal a $\mathbf{a}$.

Teorema 1.3.3.

$$\|\text{proj}_{\mathbf{a}} \mathbf{u}\| = \|\mathbf{u}\| |\cos(\theta)| \quad (1.3.6)$$

onde θ é o ângulo entre $\mathbf{u}$ e $\mathbf{a}$.

1.4 Espaço vetorial Geral

Definição 1.4.1 (*Combinação linear*). Seja $\mathbf{w}$ um vetor no espaço vetorial V . Dizemos que $\mathbf{w}$ é uma combinação linear de vetores $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ em V se $\mathbf{w}$ pode ser escrito na forma

$$\mathbf{w} = k_1 \mathbf{v}_1 + k_2 \mathbf{v}_2 + \dots + k_r \mathbf{v}_r \quad (1.4.1)$$

onde $k_1, k_2, \dots, k_r$ são escalares chamados coeficientes da combinação linear.

Definição 1.4.2 (*Complemento ortogonal*). Seja W um subespaço de $\mathbb{R}^n$. Então, o conjunto de vetores em $\mathbb{R}^n$ que são ortogonais a todos vetores em W é chamado de complemento ortogonal de W e é denotado por $W^\perp$.

Teorema 1.4.1 (*Propriedades do complemento ortogonal*). Seja W um subespaço de $\mathbb{R}^n$. Então,

- (1) $W^\perp$ é um subespaço de $\mathbb{R}^n$.
- (2) O único vetor comum a W e $W^\perp$ é $\mathbf{0}$.
- (3) O complemento ortogonal de $W^\perp$ é W .

Teorema 1.4.2. Seja $\mathbf{A}_{m \times n}$.

- (1) O espaço-nulo de $\mathbf{A}$ e o espaço-linha de $\mathbf{A}$ são complementos ortogonais em $\mathbb{R}^n$.
- (2) O espaço-nulo de $\mathbf{A}^\top$ e o espaço-coluna de $\mathbf{A}$ são complementos ortogonais em $\mathbb{R}^m$.

Teorema 1.4.3. Seja $S = \{\mathbf{w}_1, \dots, \mathbf{w}_k\}$ um conjunto não vazio de vetores em V . Então:

- (1) O conjunto W de todas as possíveis combinações lineares de vetores em S é um subespaço de V .
- (2) O conjunto W (do item acima) é o menor subespaço de V que contém todos os vetores de S , ou seja, qualquer outro subespaço contém todos os vetores de W .

Definição 1.4.3 (*Subespaço gerado*). Seja $S = \{\mathbf{w}_1, \dots, \mathbf{w}_k\}$ um conjunto não vazio de vetores em V e W o subespaço de todas as possíveis combinações lineares dos vetores em S . Este subespaço é chamado de *subespaço de V gerado por S* , e dizemos que $\mathbf{w}_1, \dots, \mathbf{w}_k$ geram W . Denotamos este subespaço por

$$W = \text{ger}\{\mathbf{w}_1, \dots, \mathbf{w}_k\} \quad \text{ou} \quad W = \text{ger}(V) \quad (1.4.2)$$

Definição 1.4.4 (*Conjunto LI*). Seja $S = \{\mathbf{v}_1, \dots, \mathbf{v}_r\}$ um conjunto de dois ou mais vetores de um espaço vetorial V . Dizemos que S é um conjunto linearmente independente (LI) se nenhum vetor em S pode ser expresso como combinação linear de outros.

Teorema 1.4.4. Seja $S = \{\mathbf{w}_1, \dots, \mathbf{w}_k\} \subset V$ um conjunto não vazio. V é LI se e somente se os coeficientes que satisfazem a equação

$$k_1\mathbf{r}_1 + \dots + k_r\mathbf{v}_r = \mathbf{0} \quad (1.4.3)$$

são $k_1 = k_2 = \dots = k_r = 0$.

Teorema 1.4.5 (4.3.2, Anton).

- (1) Um conjunto finito que contém $\mathbf{0}$ é linearmente dependente.
- (2) Um conjunto com exatamente um vetor é linearmente independente se e somente se esse vetor não é $\mathbf{0}$.
- (3) Um conjunto com exatamente dois vetores é linearmente independente se e somente se nenhum dos dois vetores é múltiplo escalar do outro.

Teorema 1.4.6 (4.3.3, Anton). Seja $S = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r\}$ um conjunto de vetores em $\mathbb{R}^n$. Se $r > n$, então S é linearmente dependente.

Definição 1.4.5 (*Base de espaço vetorial*). Se $S = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ é um conjunto de vetores em um espaço vetorial V de dimensão finita, então S é chamado uma **base** para V se:

- (1) S gera V .
- (2) S é linearmente independente.

Teorema 1.4.7 (*Unicidade da representação em base*). Se $S = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ é uma base para um espaço vetorial V , então todo vetor $\mathbf{v}$ em V pode ser expresso na forma $\mathbf{v} = c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_n\mathbf{v}_n$ de exatamente uma forma.

Teorema 1.4.8 (*Teorema do Mais/Menos*). Seja S um conjunto não vazio de vetores em um espaço vetorial V .

- (1) Se S é um conjunto linearmente independente, e se $\mathbf{v}$ é um vetor em V que está fora de $\text{ger}(S)$, então o conjunto $S \cup \{\mathbf{v}\}$ que resulta ao inserir $\mathbf{v}$ em S ainda é linearmente independente.
- (2) Se $\mathbf{v}$ é um vetor em S que é expressável como uma combinação linear dos demais vetores em S , e se $S - \{\mathbf{v}\}$ denota o conjunto obtido ao remover $\mathbf{v}$ de S , então S e $S - \{\mathbf{v}\}$ geram o mesmo espaço; ou seja,

$$\text{ger}(S) = \text{ger}(S - \{\mathbf{v}\}) \quad (1.4.4)$$

Teorema 1.4.9 (*Dimensão de subespaço*). Se W é um subespaço de um espaço vetorial V de dimensão finita, então:

- (1) W é de dimensão finita.
- (2) $\dim(W) \leq \dim(V)$.
- (3) $W = V$ se e somente se $\dim(W) = \dim(V)$.

Teorema 1.4.10 (*Base a partir de n vetores*). Seja V um espaço vetorial n -dimensional, e seja S um conjunto em V com exatamente n vetores. Então S é uma base para V se e somente se S gera V ou S é linearmente independente.

Teorema 1.4.11 (*Matriz de transição para a base canônica*). Seja $B' = \{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n\}$ uma base qualquer para o espaço vetorial $\mathbb{R}^n$ e seja $S = \{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n\}$ a base canônica para $\mathbb{R}^n$. Se os vetores dessas bases são escritos na forma de coluna, então

$$\mathbf{P}_{B' \rightarrow S} = [\mathbf{u}_1 \mid \mathbf{u}_2 \mid \dots \mid \mathbf{u}_n] \quad (1.4.5)$$

1.4.1 Espaços linha, coluna e nulo

Definição 1.4.6 (*Espaços linha, coluna e nulo*). Seja $\mathbf{A}_{m \times n}$.

- (1) O subespaço de $\mathbb{R}^n$ gerado pelos vetores linha de $\mathbf{A}$ é chamado de espaço-linha de $\mathbf{A}$.
- (2) O subespaço de $\mathbb{R}^m$ gerado pelos vetores coluna de $\mathbf{A}$ é chamado de espaço-coluna de $\mathbf{A}$.

- (3) O espaço-solução do sistema homogêneo $\mathbf{Ax} = \mathbf{0}$, o qual é um subespaço de $\mathbb{R}^n$, é chamado de espaço-nulo de $\mathbf{A}$.

Teorema 1.4.12. Um sistema de equações lineares $\mathbf{Ax} = \mathbf{b}$ é consistente se e somente se $\mathbf{b}$ está no espaço coluna de $\mathbf{A}$.

Teorema 1.4.13 (*Espaços nulo, linha e coluna*).

- (1) Operações elementares em linhas não alteram o espaço-nulo da matriz;
- (2) Operações elementares em linhas não alteram o espaço-linha da matriz. Porém, podem alterar o espaço-coluna;
- (3) Se $\mathbf{A}$ está na forma escalonada por linhas (*row echelon form*), então os vetores linha com líderes 1 formam uma base para o espaço-linha de $\mathbf{A}$, e os vetores coluna com os líderes 1 formam uma base para o espaço-coluna de $\mathbf{A}$;
- (4) Sejam $\mathbf{A}$ e $\mathbf{B}$ matrizes equivalentes por linhas. Então:
 - (a) Um dado conjunto de vetores colunas de $\mathbf{A}$ é LI $\iff$ os vetores colunas correspondentes em $\mathbf{B}$ são LI.
 - (b) Um dado conjunto de vetores colunas de $\mathbf{A}$ forma uma base para o espaço-coluna de $\mathbf{A}$ $\iff$ os vetores colunas correspondentes em $\mathbf{B}$ formam uma base para o espaço-coluna de $\mathbf{B}$.

1.5 Espaços com produto interno

Definição 1.5.1 (*Conjunto ortogonal e ortonormal*). Um conjunto de dois ou mais vetores em um espaço com produto interno real é dito **ortogonal** se todos os pares de vetores distintos no conjunto são ortogonais. Um conjunto ortogonal no qual cada vetor tem norma 1 é dito **ortonormal**.

Teorema 1.5.1 (*Independência linear de conjuntos ortogonais*). Se $S = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ é um conjunto ortogonal de vetores não nulos em um espaço com produto interno, então S é linearmente independente.

Teorema 1.5.2 (*Teorema da Projeção*). Se W é um subespaço de dimensão finita de um espaço com produto interno V , então todo vetor $\mathbf{u}$ em V pode ser expresso de exatamente uma forma como

$$\mathbf{u} = \mathbf{w}_1 + \mathbf{w}_2 \tag{1.5.1}$$

em que $\mathbf{w}_1$ está em W e $\mathbf{w}_2$ está em $W^\perp$.

Nota:

- (1) Os vetores $\mathbf{w}_1$ e $\mathbf{w}_2$ na equação acima são comumente denotados por

$$\mathbf{w}_1 = \text{proj}_W \mathbf{u} \quad \text{e} \quad \mathbf{w}_2 = \text{proj}_{W^\perp} \mathbf{u} \quad (1.5.2)$$

Estes são chamados de *projeção ortogonal de $\mathbf{u}$ em W* e *projeção ortogonal de $\mathbf{u}$ em $W^\perp$* , respectivamente. O vetor $\mathbf{w}_2$ também é chamado de *componente de $\mathbf{u}$ ortogonal a W* . Usando essa notação, a decomposição pode ser expressa como

$$\mathbf{u} = \text{proj}_W \mathbf{u} + \text{proj}_{W^\perp} \mathbf{u} \quad (1.5.3)$$

Teorema 1.5.3 (*Representação em base ortogonal/ortonormal e projeção sobre subespaço*).

- (1) Se $S = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ é uma base ortogonal para um espaço com produto interno V , e se $\mathbf{u}$ é um vetor qualquer em V , então

$$\mathbf{u} = \frac{\langle \mathbf{u}, \mathbf{v}_1 \rangle}{\|\mathbf{v}_1\|^2} \mathbf{v}_1 + \frac{\langle \mathbf{u}, \mathbf{v}_2 \rangle}{\|\mathbf{v}_2\|^2} \mathbf{v}_2 + \dots + \frac{\langle \mathbf{u}, \mathbf{v}_n \rangle}{\|\mathbf{v}_n\|^2} \mathbf{v}_n \quad (1.5.4)$$

- (2) Se $S = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ é uma base ortonormal para um espaço com produto interno V , e se $\mathbf{u}$ é um vetor qualquer em V , então

$$\mathbf{u} = \langle \mathbf{u}, \mathbf{v}_1 \rangle \mathbf{v}_1 + \langle \mathbf{u}, \mathbf{v}_2 \rangle \mathbf{v}_2 + \dots + \langle \mathbf{u}, \mathbf{v}_n \rangle \mathbf{v}_n \quad (1.5.5)$$

- (3) Seja W um subespaço de dimensão finita de um espaço com produto interno V . Se $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r\}$ é uma base ortogonal para W , e $\mathbf{u}$ é um vetor qualquer em V , então

$$\text{proj}_W \mathbf{u} = \frac{\langle \mathbf{u}, \mathbf{v}_1 \rangle}{\|\mathbf{v}_1\|^2} \mathbf{v}_1 + \frac{\langle \mathbf{u}, \mathbf{v}_2 \rangle}{\|\mathbf{v}_2\|^2} \mathbf{v}_2 + \dots + \frac{\langle \mathbf{u}, \mathbf{v}_r \rangle}{\|\mathbf{v}_r\|^2} \mathbf{v}_r \quad (1.5.6)$$

- (4) Se $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r\}$ é uma base ortonormal para W , e $\mathbf{u}$ é um vetor qualquer em V , então

$$\text{proj}_W \mathbf{u} = \langle \mathbf{u}, \mathbf{v}_1 \rangle \mathbf{v}_1 + \langle \mathbf{u}, \mathbf{v}_2 \rangle \mathbf{v}_2 + \dots + \langle \mathbf{u}, \mathbf{v}_r \rangle \mathbf{v}_r \quad (1.5.7)$$

Nota:

- (1) Usando a terminologia e notação da Definição 2 da Seção 4.4, segue dos itens 1 e 2 que o vetor de coordenadas de um vetor $\mathbf{u}$ em V em relação a uma base ortogonal $S = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ é

$$(\mathbf{u})_S = \left(\frac{\langle \mathbf{u}, \mathbf{v}_1 \rangle}{\|\mathbf{v}_1\|^2}, \frac{\langle \mathbf{u}, \mathbf{v}_2 \rangle}{\|\mathbf{v}_2\|^2}, \dots, \frac{\langle \mathbf{u}, \mathbf{v}_n \rangle}{\|\mathbf{v}_n\|^2} \right) \quad (1.5.8)$$

- (2) e em relação a uma base ortonormal $S = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ é

$$(\mathbf{u})_S = (\langle \mathbf{u}, \mathbf{v}_1 \rangle, \langle \mathbf{u}, \mathbf{v}_2 \rangle, \dots, \langle \mathbf{u}, \mathbf{v}_n \rangle) \quad (1.5.9)$$

Teorema 1.5.4 (*Decomposição espectral*). Se $\mathbf{A}$ é uma matriz simétrica diagonalizada ortogonalmente por

$$\mathbf{P} = [\mathbf{u}_1 \ \mathbf{u}_2 \ \cdots \ \mathbf{u}_n], \quad (1.5.10)$$

e se $\lambda_1, \lambda_2, \dots, \lambda_n$ são os autovalores de $\mathbf{A}$ correspondentes aos autovetores unitários $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$, então $\mathbf{A}$ pode ser expressa como

$$\mathbf{A} = \sum_{i=1}^n \lambda_i \mathbf{u}_i \mathbf{u}_i^T. \quad (1.5.11)$$

1.6 Posto e nulidade

Definição 1.6.1 (*Posto e nulidade*). Seja $\mathbf{A}$ qualquer;

- (1) Posto de $\mathbf{A}$ ($\text{pos}(\mathbf{A})$): dimensão comum do espaço-linha e do espaço-coluna de $\mathbf{A}$;
- (2) Nulidade de $\mathbf{A}$ ($\text{nul}(\mathbf{A})$): dimensão do espaço-nulo de $\mathbf{A}$.

Teorema 1.6.1 (*Propriedades do posto e nulidade*). Seja $\mathbf{A}_{m \times n}$

- (1) $\text{pos}(\mathbf{A}) = \text{pos}(\mathbf{A}^T)$
- (2) $\text{pos}(\mathbf{A}) = \text{pos}(\mathbf{A}^T \mathbf{A}) = \text{pos}(\mathbf{A} \mathbf{A}^T)$
- (3) $\text{pos}(\mathbf{A}) + \text{nul}(\mathbf{A}) = n$
- (4) $\text{pos}(\mathbf{A})$: núm. de variáveis líderes na solução geral de $\mathbf{A}\mathbf{x} = \mathbf{b}$
- (5) $\text{nul}(\mathbf{A})$: núm. de parâmetros na solução geral de $\mathbf{A}\mathbf{x} = \mathbf{b}$
- (6) Se $\text{pos}(\mathbf{A}) = p$, então $n - p$ raízes do polinômio característico são nulos

Teorema 1.6.2 (*Teorema da Consistência*). Sja $\mathbf{A}\mathbf{x} = \mathbf{b}$ é um sistema linear de m equações por n incógnitas com $\mathbf{b}$ fixado. As seguintes afirmações são equivalentes:

- (1) $\mathbf{A}\mathbf{x} = \mathbf{b}$ é consistente.
- (2) $\mathbf{b}$ está no espaço-coluna de $\mathbf{A}$.
- (3) $\mathbf{A}$ e $[\mathbf{A} \mid \mathbf{b}]$ tem o mesmo posto.

Teorema 1.6.3. Seja $\mathbf{A}\mathbf{x} = \mathbf{b}$ um sistema linear de m equações por n incógnitas. As seguintes afirmações são equivalentes:

- (1) $\mathbf{A}\mathbf{x} = \mathbf{b}$ é consistente para todo $\mathbf{b}$.
- (2) Os vetores-coluna $\mathbf{A}$ geram o $\mathbb{R}^m$.
- (3) $\text{pos}(\mathbf{A}) = m$.

Teorema 1.6.4. Seja $\mathbf{Ax} = \mathbf{b}$ um sistema linear consistente de m equações por n incógnitas. Se $\text{pos}(\mathbf{A}) = r$, então a solução geral do sistema contém $n - r$ parâmetros.

Teorema 1.6.5 (*Sistemas $m \times n$*). Seja $\mathbf{A}_{m \times n}$. As seguintes afirmações são equivalentes:

- (1) $\mathbf{Ax} = \mathbf{0}$ possui somente a solução trivial.
- (2) Os vetores-coluna de $\mathbf{A}$ são LI.
- (3) $\mathbf{Ax} = \mathbf{b}$ tem no máximo uma (uma ou nenhuma) solução para cada $\mathbf{b}$.

1.7 Autovalores e autovetores

Definição 1.7.1. Definições sobre autovalores e autovetores.

- (1) Seja $\mathbf{A}_{n \times n}$. Um vetor não nulo $\mathbf{x} \in \mathbb{R}^n$ é chamado de **autovetor** de $\mathbf{A}$ se

$$\mathbf{Ax} = \lambda \mathbf{x} \quad (1.7.1)$$

para algum escalar λ , o qual é chamado de **autovalor** de $\mathbf{A}$.

- (2) Equação característico: $\det(\lambda \mathbf{I} - \mathbf{A}) = 0$
- (3) Quando a equação característica é expandida, ela toma a forma

$$p(\lambda) = \lambda^n + c_1 \lambda^{n-1} + \cdots + c_n \quad (1.7.2)$$

e $p(\lambda)$ é denominado polinômio característico.

- (4) Espaço-solução do sistema $(\lambda \mathbf{I} - \mathbf{A})\mathbf{x} = \mathbf{0}$: **auto-espaço** de $\mathbf{A}$ associado a λ .
- (5) Multiplicidade algébrica de λ_0 : número de vezes que $(\lambda - \lambda_0)$ aparece como um fator do polinômio característico.
- (6) Multiplicidade geométrica de λ_0 : dimensão do auto-espaço associado a $\lambda - \lambda_0$

Teorema 1.7.1 (*Propriedades de autovalores e autovetores*). Seja $\mathbf{A}_{n \times n}$.

- (1) $\mathbf{A}$ é triangular $\implies$ os autovalores de $\mathbf{A}$ são as entradas da diagonal principal
- (2) $\mathbf{A}^k \mathbf{x} = \lambda^k \mathbf{x}$
- (3) $\mathbf{A}$ é invertível $\iff \lambda = 0$ não é um autovalor de $\mathbf{A}$

Teorema 1.7.2 (*Propriedades das raízes característica*). Seja $\mathbf{A}_{n \times n}$.

- (1) A soma das raízes características de $\mathbf{A}$ é $\text{tr}(\mathbf{A})$
- (2) O produto das raízes características de $\mathbf{A}$ é $\det(\mathbf{A})$
- (3) Se $\text{pos}(\mathbf{A}) = p$, então $n - p$ raízes do polinômio característico são nulos

1.8 Semelhança e Diagonalização

Definição 1.8.1 (*Matrizes semelhantes*). Sejam $\mathbf{A}$ e $\mathbf{B}$ quadradas. $\mathbf{B}$ é semelhante a $\mathbf{A}$ se existe uma matriz $\mathbf{P}$ tal que $\mathbf{B} = \mathbf{P}^{-1}\mathbf{A}\mathbf{P}$.

Nota: Se $\mathbf{B}$ é similar a $\mathbf{A}$, então $\mathbf{A}$ é similar a $\mathbf{B}$.

Teorema 1.8.1 (*Propriedades de matrizes semelhantes*). Sejam $\mathbf{A}$ e $\mathbf{B} = \mathbf{P}^{-1}\mathbf{A}\mathbf{P}$ semelhantes. As seguintes propriedades de $\mathbf{A}$ são preservadas em $\mathbf{B}$:

- (1) Determinante
- (2) Invertibilidade
- (3) Posto
- (4) Nulidade
- (5) Traço
- (6) Polinômio característico
- (7) Autovalores
- (8) Dimensões dos autoespaços.

Definição 1.8.2. $\mathbf{A}$ quadrada é dita diagonalizável se é semelhante a alguma matriz diagonal, isto é, se existe uma matriz invertível $\mathbf{P}$ tal que $\mathbf{P}^{-1}\mathbf{A}\mathbf{P}$ é diagonal. Neste caso, dizemos que a matriz $\mathbf{P}$ diagonaliza $\mathbf{A}$.

Teorema 1.8.2 (*Diagonalização*). Seja $\mathbf{A}_{n \times n}$.

- (1) $\mathbf{A}$ é diagonalizável $\iff \mathbf{A}$ tem n autovetores LI.
- (2) $\mathbf{A}$ é diagonalizável $\iff$ Para cada autovalor, a multiplicidade geométrica é igual à multiplicidade algébrica.
- (3) Se $\lambda_1, \dots, \lambda_k$ são autovalores distintos de $\mathbf{A}$ e $\mathbf{v}_1, \dots, \mathbf{v}_k$ são os autovetores correspondentes, então $\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ é um conjunto LI.
- (4) $\mathbf{A}$ tem n autovalores distintos $\implies \mathbf{A}$ é diagonalizável.
- (5) $\mathbf{A}$ é diagonalizável $\implies \mathbf{A}^k = \mathbf{P}\mathbf{D}^k\mathbf{P}^{-1}$.

1.9 Diagonalização ortogonal

Teorema 1.9.1 (*Matrizes ortogonais e bases ortonormais*). Seja $\mathbf{A}_{n \times n}$. As seguintes afirmações são equivalentes.

- (1) $\mathbf{A}$ é ortogonal.
- (2) os vetores linha de $\mathbf{A}$ formam uma base ortonormal em $\mathbb{R}^n$ com produto interno euclidiano.
- (3) os vetores coluna de $\mathbf{A}$ formam uma base ortonormal em $\mathbb{R}^n$ com produto interno euclidiano.
- (4) $\|\mathbf{A}\mathbf{x}\| = \|\mathbf{x}\| \quad \forall \mathbf{x} \in \mathbb{R}^n$
- (5) $\mathbf{A}\mathbf{x} \cdot \mathbf{A}\mathbf{y} = \mathbf{x} \cdot \mathbf{y} \quad \forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n$

Teorema 1.9.2 (*Propriedades de matrizes ortogonais*). Seja $\mathbf{A}_{n \times n}$.

- (1) $\mathbf{A}$ é ortogonal $\implies \mathbf{A}^\top$ é ortogonal.
- (2) $\mathbf{A}$ é ortogonal $\implies \mathbf{A}^{-1}$ é ortogonal.
- (3) $\mathbf{A}, \mathbf{B}$ são ortogonais $\implies \mathbf{AB}$ é ortogonal.
- (4) $\mathbf{A}$ é ortogonal $\implies \det(\mathbf{A}) = \pm 1$

Teorema 1.9.3 (*Mudança de bases ortonormais*). Seja V um espaço finito-dimensional com produto interno. Se $\mathbf{P}$ é a matriz de transição de uma base ortonormal de V para uma outra base ortonormal para V , então $\mathbf{P}$ é ortogonal.

Definição 1.9.1 (*Semelhança e diagonalização ortogonal*).

- (1) Se $\mathbf{A}, \mathbf{B}$ são matrizes quadradas, dizemos que $\mathbf{B}$ é ortogonalmente semelhante a $\mathbf{A}$ se existe uma matriz ortogonal $\mathbf{P}$ tal que $\mathbf{B} = \mathbf{P}^\top \mathbf{A} \mathbf{P}$.
- (2) Se $\mathbf{A}$ é ortogonalmente semelhante a alguma matriz diagonal $\mathbf{D}$, ou seja,

$$\mathbf{D} = \mathbf{P}^\top \mathbf{A} \mathbf{P} \quad \text{e} \quad \mathbf{A} = \mathbf{P} \mathbf{D} \mathbf{P}^\top \tag{1.9.1}$$

dizemos que $\mathbf{A}$ é ortogonalmente diagonalizável e que $\mathbf{P}$ diagonaliza (ortogonalmente) $\mathbf{A}$.

Nota: (1) Se $\mathbf{B}$ é ortogonalmente semelhante a $\mathbf{A}$, então $\mathbf{A}$ é ortogonalmente semelhante a $\mathbf{B}$.

Teorema 1.9.4 (*Diagonalização ortogonal*). As seguintes afirmações são equivalentes.

- (1) $\mathbf{A}$ é ortogonalmente diagonalizável.

- (2) $\mathbf{A}$ tem um conjunto ortonormal de n autovetores.
- (3) $\mathbf{A}$ é simétrica.

Teorema 1.9.5 (*Matrizes simétricas*). Seja $\mathbf{A}_{n \times n}$ simétrica com entradas reais. Então:

- (1) Os autovalores de $\mathbf{A}$ são todos reais.
- (2) Autovetores de autoespaços diferentes são ortogonais.

1.10 Formas lineares e quadráticas

Definição 1.10.1 (*Formas lineares e quadráticas*).

- (1) Forma linear: $b_1x_1 + b_2x_2 + \cdots + b_nx_n$
 - (a) $f(\mathbf{x}) = \mathbf{b}^\top \mathbf{x} = \mathbf{x}^\top \mathbf{b}$
- (2) Forma afim: $f(\mathbf{x}) = a + \mathbf{b}^\top \mathbf{x}$
- (3) Forma quadrática: $a_1x_1^2 + a_2x_2^2 + \cdots + a_nx_n^2$ (mais todos possíveis termos $a_kx_ix_j$, com $i \neq j$)
 - (a) Se $\mathbf{A}_{n \times n}$ é simétrica e $\mathbf{x}$ é vetor-coluna $n \times 1$, a forma quadrática associada a $\mathbf{A}$ é $Q_{\mathbf{A}} = \mathbf{x}^\top \mathbf{A} \mathbf{x}$

Nota:

- (1) Se $\mathbf{A}$ é a diagonal, então a forma quadrática não possui termos cruzados.

conteúdo...

Definição 1.10.2 (*Classificação de formas quadráticas e matrizes*). Sejam $\mathbf{A}_{n \times n}$ uma matriz simétrica e $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ a forma quadrática associada. Diz-se que $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ (equivalentemente, $\mathbf{A}$) é:

- (1) Positiva definida: se $\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$ para todo $\mathbf{x} \neq \mathbf{0}$.
- (2) Positiva semidefinida: se $\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0$ para todo $\mathbf{x} \neq \mathbf{0}$ e $\mathbf{x}^\top \mathbf{A} \mathbf{x} = 0$ para pelo menos um $\mathbf{x} \neq \mathbf{0}$.
- (3) Negativa definida: se $\mathbf{x}^\top \mathbf{A} \mathbf{x} < 0$ para todo $\mathbf{x} \neq \mathbf{0}$.
- (4) Negativa semidefinida: se $\mathbf{x}^\top \mathbf{A} \mathbf{x} \leq 0$ para todo $\mathbf{x} \neq \mathbf{0}$ e $\mathbf{x}^\top \mathbf{A} \mathbf{x} = 0$ para pelo menos um $\mathbf{x} \neq \mathbf{0}$.
- (5) Indefinida: se $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ assume valores positivos e negativos.

Nota:

- (1) Itens 1–2: Slide 20/31, arquivo 1_Notação_Matricial.pdf.
- (2) Itens 3–4 (versão para a forma quadrática): extensão direta, pelo sinal, da definição de $\mathbf{A}$ negativa (semi)definida via $-\mathbf{A}$, dada no Slide 16/31 do arquivo 1_Notação_Matricial.pdf.
- (3) Item 5 (indefinida): não consta nos slides; acréscimo a partir de Anton, *Elementary Linear Algebra*.

Teorema 1.10.1 (*Caracterização de matriz positiva definida*). Seja $\mathbf{A}_{n \times n}$ simétrica. As seguintes afirmações são equivalentes:

- (1) $\mathbf{A}$ é positiva definida.
- (2) $\mathbf{A} = \mathbf{P}^T \mathbf{P}$ para alguma matriz $\mathbf{P}$ não singular.
- (3) Todas as raízes características de $\mathbf{A}$ são positivas.
- (4) $a_{11} > 0$, $\begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} > 0$, $\dots$, $|\mathbf{A}| > 0$ (critério de Sylvester).

Nota:

- (1) Slide 14/31, arquivo 1_Notação_Matricial.pdf.

Teorema 1.10.2 (*Caracterização de matriz positiva semidefinida*). Seja $\mathbf{A}_{n \times n}$ simétrica. As seguintes afirmações são equivalentes:

- (1) $\mathbf{A}$ é positiva semidefinida.
- (2) Existe $\mathbf{B}_{n \times n}$ com $\text{pos}(\mathbf{B}) < n$ tal que $\mathbf{B}^T \mathbf{B} = \mathbf{A}$.
- (3) As raízes características de $\mathbf{A}$ são não negativas, com no mínimo uma igual a zero.

Nota:

- (1) Slide 15/31, arquivo 1_Notação_Matricial.pdf.

Teorema 1.10.3 (*Consequências da classificação*). Seja $\mathbf{A}_{n \times n}$ simétrica.

- (1) Se $\mathbf{A}$ é positiva definida, então $\text{pos}(\mathbf{A}) = n$, $a_{ii} > 0$ para todo $i = 1, \dots, n$, e $\mathbf{P}^T \mathbf{A} \mathbf{P}$ é positiva definida para toda matriz $\mathbf{P}_{n \times p}$ não singular.
- (2) Se $\mathbf{A}$ é positiva semidefinida, então $\text{pos}(\mathbf{A}) < n$, $a_{ii} \geq 0$ para todo $i = 1, \dots, n$, e $\mathbf{P}^T \mathbf{A} \mathbf{P}$ é positiva semidefinida para toda matriz $\mathbf{P}_{n \times p}$.

Nota:

- (1) Slides 14/31 e 15/31, arquivo 1_Notação_Matricial.pdf.

Teorema 1.10.4 (*Propriedades de $\mathbf{A}^T \mathbf{A}$*). Seja $\mathbf{A}_{m \times n}$. Então:

- (1) $\ker(\mathbf{A}) = \ker(\mathbf{A}^\top \mathbf{A})$; em particular, $\text{pos}(\mathbf{A}^\top \mathbf{A}) = \text{pos}(\mathbf{A})$.
- (2) $\mathbf{A}^\top \mathbf{A}$ é não negativa, isto é, $\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} \geq 0$ para todo $\mathbf{x} \in \mathbb{R}^n$.
- (3) $\mathbf{A}^\top \mathbf{A}$ é ortogonalmente diagonalizável, ou seja, existe $\mathbf{P}$ ortogonal tal que

$$\mathbf{P}^\top \mathbf{A}^\top \mathbf{A} \mathbf{P} = \mathbf{D},$$

em que $\mathbf{D} = \text{diag}(\lambda_1, \dots, \lambda_n)$ e $\lambda_1 \geq \dots \geq \lambda_n \geq 0$ são as raízes características de $\mathbf{A}^\top \mathbf{A}$.

- (4) $\mathbf{A}^\top \mathbf{A}$ é positiva definida se, e somente se, $\text{pos}(\mathbf{A}) = n$ (posto completo), equivalentemente, se, e somente se, as colunas de $\mathbf{A}$ são linearmente independentes. Caso contrário (isto é, se $\text{pos}(\mathbf{A}) < n$), $\mathbf{A}^\top \mathbf{A}$ é positiva semidefinida no sentido estrito da definição acima.
- (5) $\mathbf{A}^\top \mathbf{A}$ é invertível se, e somente se, $\text{pos}(\mathbf{A}) = n$; nesse caso, $\lambda_i > 0$ para todo $i = 1, \dots, n$.

Nota:

- (1) Este teorema não consta nos slides; acréscimo a partir de Anton, *Elementary Linear Algebra*. O item 4 foi reformulado em relação ao seu rascunho original para eliminar a inconsistência entre "positiva semidefinida" (afirmada incondicionalmente) e "positiva definida se, e somente se, posto completo".

Teorema 1.10.5 (Teorema dos Eixos Principais). Seja $\mathbf{A}_{n \times n}$ simétrica. Etnão, existe uma mudança de variável ortogonal que transforma a forma quadrática $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ na forma quadrática $\mathbf{y}^\top \mathbf{D} \mathbf{y}$ sem termos de produto cruzado. De forma específica, se $\mathbf{P}$ diagonaliza ortogonalmente $\mathbf{A}$, então se fizermos $\mathbf{x} = \mathbf{P} \mathbf{y}$ em $\mathbf{x}^\top \mathbf{A} \mathbf{x}$, temos

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{y}^\top \mathbf{D} \mathbf{y} = \lambda_1 y_1^2 + \lambda_2 y_2^2 + \dots + \lambda_n y_n^2 \quad (1.10.1)$$

onde $\lambda_1, \lambda_2, \dots, \lambda_n$ são os autovalores de $\mathbf{A}$ correspondentes aos autovetores que formam as colunas de $\mathbf{P}$.

1.11 Matrizes em blocos

Teorema 1.11.1. Seja $\mathbf{B}$ uma matriz particionada em blocos,

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}, \quad (1.11.1)$$

em que $\mathbf{B}_{11}$ e $\mathbf{B}_{22}$ são matrizes quadradas não-singulares. Então

$$\mathbf{B}^{-1} = \begin{bmatrix} (\mathbf{B}_{11} - \mathbf{B}_{12} \mathbf{B}_{22}^{-1} \mathbf{B}_{21})^{-1} & -\mathbf{B}_{11}^{-1} \mathbf{B}_{12} (\mathbf{B}_{22} - \mathbf{B}_{21} \mathbf{B}_{11}^{-1} \mathbf{B}_{12})^{-1} \\ -\mathbf{B}_{22}^{-1} \mathbf{B}_{21} (\mathbf{B}_{11} - \mathbf{B}_{12} \mathbf{B}_{22}^{-1} \mathbf{B}_{21})^{-1} & (\mathbf{B}_{22} - \mathbf{B}_{21} \mathbf{B}_{11}^{-1} \mathbf{B}_{12})^{-1} \end{bmatrix} \quad (1.11.2)$$

e

$$|\mathbf{B}| = |\mathbf{B}_{22}| |\mathbf{B}_{11} - \mathbf{B}_{12} \mathbf{B}_{22}^{-1} \mathbf{B}_{21}| = |\mathbf{B}_{11}| |\mathbf{B}_{22} - \mathbf{B}_{21} \mathbf{B}_{11}^{-1} \mathbf{B}_{12}|. \quad (1.11.3)$$

Teorema 1.11.2. Seja $\mathbf{B}$ uma matriz bloco diagonal,

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{B}_{22} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{B}_{33} \end{bmatrix}, \quad (1.11.4)$$

em que $\mathbf{B}_{11}$, $\mathbf{B}_{22}$ e $\mathbf{B}_{33}$ são matrizes quadradas não-singulares. Então

$$\mathbf{B}^{-1} = \begin{bmatrix} \mathbf{B}_{11}^{-1} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{B}_{22}^{-1} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{B}_{33}^{-1} \end{bmatrix} \quad (1.11.5)$$

e

$$|\mathbf{B}| = |\mathbf{B}_{11}| |\mathbf{B}_{22}| |\mathbf{B}_{33}|. \quad (1.11.6)$$

O resultado vale para matrizes bloco diagonal de maior dimensão.

1.12 Derivadas

Definição 1.12.1 (*Derivada de função escalar*). Considere uma função escalar $f : \mathbb{R}^n \rightarrow \mathbb{R}$, em que $\mathbf{b} \in \mathbb{R}^n$. Adotaremos como convenção a derivada da função f em relação ao vetor $\mathbf{b}$ como o gradiente

$$\frac{\partial f}{\partial \mathbf{b}} = \nabla_{\mathbf{b}} f = \begin{pmatrix} \frac{\partial f}{\partial b_1} \\ \frac{\partial f}{\partial b_2} \\ \vdots \\ \frac{\partial f}{\partial b_n} \end{pmatrix}. \quad (1.12.1)$$

Assim, $\frac{\partial f}{\partial \mathbf{b}}$ é um vetor de dimensão $n \times 1$.

Teorema 1.12.1. Considere a forma linear $f(\mathbf{x}) = \mathbf{b}^\top \mathbf{x} = \mathbf{x}^\top \mathbf{b}$, em que $\mathbf{b} \in \mathbb{R}^n$ é um vetor constante. Como $f(\mathbf{x}) = b_1 x_1 + b_2 x_2 + \cdots + b_n x_n$, temos

$$\frac{\partial f}{\partial x_i} = b_i, \quad i = 1, \dots, n. \quad (1.12.2)$$

Portanto,

$$\boxed{\frac{\partial}{\partial \mathbf{x}} (\mathbf{b}^\top \mathbf{x}) = \frac{\partial}{\partial \mathbf{x}} (\mathbf{x}^\top \mathbf{b}) = \mathbf{b}}. \quad (1.12.3)$$

Teorema 1.12.2. Considere $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$. A derivada em relação a x_k é

$$\frac{\partial f}{\partial x_k} = \underbrace{\sum_{j=1}^n a_{kj} x_j}_{\text{linha } k \text{ de } \mathbf{A}} + \underbrace{\sum_{i=1}^n a_{ik} x_i}_{\text{coluna } k \text{ de } \mathbf{A}}. \quad (1.12.4)$$

A derivada em $\mathbf{x}$ nesse caso é dada por

$$\boxed{\frac{\partial}{\partial \mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}.} \quad (1.12.5)$$

Em particular, se $\mathbf{A}$ é simétrica (forma quadrática), então $\mathbf{A}^\top = \mathbf{A}$, logo $(\mathbf{A} + \mathbf{A}^\top) \mathbf{x} = 2\mathbf{A} \mathbf{x}$ e, portanto,

$$\boxed{\frac{\partial}{\partial \mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A} \mathbf{x}.} \quad (1.12.6)$$

Teorema 1.12.3. Considere $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{b}^\top \mathbf{x}$. Então

$$\frac{\partial f}{\partial \mathbf{x}} = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x} + \mathbf{b}. \quad (1.12.7)$$

Se $\mathbf{A}$ é simétrica,

$$\boxed{\frac{\partial f}{\partial \mathbf{x}} = 2\mathbf{A} \mathbf{x} + \mathbf{b}.} \quad (1.12.8)$$

Capítulo 2

Probabilidade

2.1 Distribuições

Teorema 2.1.1 (*Família exponencial*). Pertencem à família exponencial:

- **Discretas:** Bernoulli ($0 < p < 1$), Binomial (n fixo, $0 < p < 1$), Poisson, Binomial Negativa ($0 < p < 1$), Geométrica;
- **Contínuas:** Exponencial, Normal, Gama, Qui-quadrado, Beta, Normal Inversa, Weibull.

2.1.1 Distribuições discretas

Uniforme discreta(N)

- $f_X(x \mid N) = \frac{1}{N} \mathbb{1}_{1,\dots,N}(x), \quad N \in \mathbb{N}$
- $\mathbb{E}[X] = \frac{N+1}{2}$
- $\text{Var}[X] = \frac{(N+1)(N-1)}{12}$
- $M_X(t) = \frac{1}{N} \sum_{i=1}^N e^{it}$

Bernoulli(p)

- $f_X(x \mid p) = p^x(1-p)^{1-x} \mathbb{1}_{\{0,1\}}(x), \quad 0 \leq p \leq 1$
- $\mathbb{E}[X] = p$
- $\text{Var}[X] = p(1-p)$
- $M_X(t) = (1-p) + pe^t$

Binomial(n,p)

- $f_X(x \mid n, p) = \binom{n}{x} p^x (n-p)^{1-x} \mathbb{1}_{\{0,1,\dots,n\}}(x), \quad 0 \leq p \leq 1$
- $\mathbb{E}[X] = np$
- $\text{Var}[X] = np(1-p)$
- $M_X(t) = [(1-p) + pe^t]^n$

Poisson(θ)

- $f_X(x \mid \theta) = \frac{\theta^x e^{-\theta}}{x!} \mathbb{1}_{\{0,1,\dots\}}(x), \quad \theta \geq 0$
- $\mathbb{E}[X] = \theta$
- $\text{Var}[X] = \theta$
- $M_X(t) = e^{\theta(e^t-1)}$

2.1.2 Distribuições contínuas

Uniforme(a,b)

- $f_X(x \mid a, b) = \frac{1}{b-a} \mathbb{1}_{(a,b)}(x), \quad a, b \in \mathbb{R}$
- $F_X(x) = \frac{x-a}{b-a} \mathbb{1}_{(a,b)}(x) + \mathbb{1}_{[b,\infty)}(x)$
- $\mathbb{E}[X] = \frac{a+b}{2}$
- $\text{Var}[X] = \frac{1}{12}(b-a)^2$
- $M_X(t) = \begin{cases} \frac{e^{tb} - e^{ta}}{t(b-a)}, & \text{para } t \neq 0 \\ 1, & \text{para } t = 0 \end{cases}$
- $\hat{a} = X_{(1)}, \hat{b} = X_{(n)}$

Exponencial(λ)

- $f_X(x \mid \lambda) = \lambda e^{-\lambda x} \mathbb{1}_{\mathbb{R}_+}(x), \quad \lambda > 0$
- $F_X(x) = (1 - e^{-\lambda x}) \mathbb{1}_{\mathbb{R}_+}(x)$
- $\mathbb{E}[X] = \frac{1}{\lambda}$
- $\text{Var}[X] = \frac{1}{\lambda^2}$
- $M_X(t) = \frac{\lambda}{\lambda - t}, \text{ para } t < \lambda$
- $\hat{\lambda} = 1/\bar{X}$

Normal(μ, σ^2)

- $f_X(x \mid \mu, \sigma^2) = \frac{1}{\sqrt{\mu, \sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\} \mathbb{1}_{\mathbb{R}}(x), \quad \mu \in \mathbb{R}, \sigma > 0$
- $\mathbb{E}[X] = \mu$
- $\text{Var}[X] = \sigma^2$
- $M_X(t) = e^{\mu t + \sigma^2 t^2 / 2}$, para $t < \lambda$
- $\hat{\mu} = \bar{X}, \hat{\sigma}^2 = \left(\frac{n+1}{n}\right) S^2$

Distribuição t t_n

- Se $Z \sim \mathcal{N}(0, 1)$ e $U \sim \chi_n^2$ são variáveis aleatórias independentes, então

$$T = \frac{Z}{\sqrt{\frac{U}{n}}} \quad (2.1.1)$$

tem distribuição t-Student com n graus de liberdade.

- $f_T(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right) \sqrt{n\pi}} \left(1 + \frac{t^2}{n}\right)^{-\left(\frac{n+1}{2}\right)}, \quad -\infty < t < \infty$
- Não existe função geradora de momentos.
- $\mathbb{E}[T] = 0$, para $n > 1$
- $\text{Var}[T] = \frac{n}{n-2}$, para $n > 2$

Distribuição t não central $t_{n,\mu}$

- Se $X \sim \mathcal{N}(\mu, 1)$ e $U \sim \chi_n^2$ são variáveis aleatórias independentes, então

$$T^* = \frac{X}{\sqrt{\frac{U}{n}}} \quad (2.1.2)$$

tem distribuição t de Student não central, com n graus de liberdade e parâmetro de não centralidade μ .

- $f_{T^*}(t) = \frac{n^{n/2} e^{-\mu^2/2}}{\Gamma\left(\frac{n}{2}\right) (n + t^2)^{(n+1)/2}} \sum_{k=0}^{\infty} \frac{\Gamma\left(\frac{n+k+1}{2}\right) \mu^k 2^{k/2} t^k}{k! (n + t^2)^{k/2}}$

Qui-quadrado χ_n^2

- $f_U(u \mid n) = \frac{1}{\Gamma\left(\frac{n}{2}\right) 2^{n/2}} u^{(n-2)/2} e^{-u/2} \mathbb{1}_{(0,\infty)}(u), \quad n \geq 1 \text{ inteiro}$
- $\mathbb{E}[U] = n$
- $\mathbb{E}[U^2] = n(n+2)$
- $\text{Var}[U] = 2n$
- $M_U(t) = (1-2t)^{-n/2}$, para $t < \frac{1}{2}$

Teorema 2.1.2 (*Qui-quadrado*).

- (1) Se $Z \sim \mathcal{N}(0, 1)$, então $Z^2 \sim \chi_1^2$;
- (2) Se $X_1, X_2, \dots, X_n$ são v.a.'s independentes tais que $X_i \sim \chi_{r_i}^2$, então $\sum_{i=1}^n X_i \sim \chi_r^2$, em que $r = \sum_{i=1}^n r_i$.

Qui-quadrado não central $\chi_{n,\lambda}^2$

- $f_U(u \mid n, \lambda) = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} \frac{u^{(n+2k-2)/2} e^{-u/2}}{\Gamma\left(\frac{n+2k}{2}\right) 2^{(n+2k)/2}} \mathbb{1}_{(0,\infty)}(u), \quad n \geq 1 \text{ inteiro}, \lambda \geq 0$
- $\mathbb{E}[U] = n + 2\lambda$
- $\text{Var}[U] = 2(n + 4\lambda)$
- $M_U(t) = (1-2t)^{-n/2} \exp\{-\lambda[1 - (1-2t)^{-1}]\}$, para $t < \frac{1}{2}$

Teorema 2.1.3 (*Propriedades da qui-quadrado não central*).

- (1) $W \sim \mathcal{N}(\delta, 1) \implies W^2 \sim \chi_{1,\lambda}^2, \quad \lambda = \frac{\delta^2}{2}$

Beta(α, β)

- $f_X(x \mid \alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1} \mathbb{1}_{\mathbb{R}_{[0,1]}}(x), \quad \alpha, \beta > 0$
- $\mathbb{E}[X] = \frac{\alpha}{\alpha + \beta}$
- $\text{Var}[X] = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$
- $M_X(t) = 1 + \sum_{k=1}^{\infty} \left(\prod_{r=0}^{k-1} \frac{\alpha + r}{\alpha + \beta + r} \right) \frac{t^k}{k!}$

Gama(α, θ) (*shape, scale*)

Obs.: parametrização padrão da função $\text{rgamma}(N, \text{shape}, \text{scale})$ do R.

- $f_X(x \mid \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-x/\theta} \mathbb{1}_{\mathbb{R}_+}(x), \quad \alpha, \theta > 0$
- $\mathbb{E}[X] = \alpha\theta$
- $\text{Var}[X] = \alpha\theta^2$
- Moda: $(\alpha - 1)\theta$, para $\alpha \geq 1$; 0, para $\alpha < 1$
- $M_X(t) = (1 - \theta t)^{-\alpha}$, para $t < \frac{1}{\theta}$

Gama(α, β) (*shape, rate*)

- $f_X(x \mid \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} \mathbb{1}_{\mathbb{R}_+}(x), \quad \alpha, \beta > 0$
- $\mathbb{E}[X] = \frac{\alpha}{\beta}$
- $\text{Var}[X] = \frac{\alpha}{\beta^2}$
- Moda = $\frac{\alpha-1}{\beta}$, para $\alpha \geq 1$; 0, para $\alpha < 1$
- $M_X(t) = \left(1 - \frac{t}{\beta}\right)^{-\alpha}$, para $t < \beta$

F de Fisher-Snedecor F_{n_1, n_2}

- Sejam U_1 e U_2 variáveis aleatórias independentes tais que $U_1 \sim \chi_{n_1}^2$ e $U_2 \sim \chi_{n_2}^2$. Então

$$W = \frac{\frac{U_1}{n_1}}{\frac{U_2}{n_2}} \quad (2.1.3)$$

tem distribuição F de Snedecor, com n_1 graus de liberdade no numerador e n_2 graus de liberdade no denominador.

- $f_W(w) = \frac{\Gamma\left(\frac{n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)} \frac{n_1^{n_1/2} n_2^{n_2/2} w^{(n_1-2)/2}}{(n_2 + wn_1)^{(n_1+n_2)/2}}, \quad w > 0$
- Não existe função geradora de momentos.
- $\mathbb{E}[W] = \frac{n_2}{n_2 - 2}$, para $n_2 > 2$
- $\text{Var}[W] = \frac{2n_2^2(n_1 + n_2 - 2)}{n_1(n_2 - 2)^2(n_2 - 4)}$, para $n_2 > 4$

- $\mathbb{E}[W^2] = \frac{n_2^2(n_1 + 2)}{n_1(n_2 - 2)(n_2 - 4)}$, para $n_2 > 4$

Teorema 2.1.4 (*Propriedades da distribuição F*).

- (1) Se $X \sim F_{p,q}$, então $1/X \sim F_{q,p}$ (a recíproca de uma F também tem distribuição F);
- (2) Se $X \sim t_q$, então $X^2 \sim F_{1,q}$;
- (3) Se $X \sim F_{p,q}$, então

$$\frac{(p/q)X}{1 + (p/q)X} \sim \text{Beta}\left(\frac{p}{2}, \frac{q}{2}\right).$$

- (4) Se $V \sim \chi_r^2$ e $W \sim \chi_s^2$ independentes, então

$$\frac{V/r}{W/s} \sim F_{r,s}.$$

F de Fisher-Snedecor não central $F_{n_1, n_2, \lambda}$

- Sejam U_1 e U_2 variáveis aleatórias independentes tais que $U_1 \sim \chi_{n_1, \lambda}^2$ e $U_2 \sim \chi_{n_2}^2$. Então

$$W = \frac{\frac{U_1}{n_1}}{\frac{U_2}{n_2}} \quad (2.1.4)$$

tem distribuição F não central, com n_1 graus de liberdade no numerador, n_2 graus de liberdade no denominador e parâmetro de não centralidade λ .

- $f_W(w) = \sum_{k=0}^{\infty} \frac{e^{-\lambda} \lambda^k}{k!} \frac{\Gamma\left(\frac{n_1+n_2+2k}{2}\right)}{\Gamma\left(\frac{n_1+2k}{2}\right) \Gamma\left(\frac{n_2}{2}\right)} \frac{n_1^{(n_1+2k)/2} n_2^{n_2/2} w^{(n_1+2k-2)/2}}{(n_2 + wn_1)^{(n_1+n_2+2k)/2}}, \quad w > 0$
- $\mathbb{E}[W] = \frac{n_2}{n_2 - 2} \left(1 + \frac{2\lambda}{n_1}\right)$, para $n_2 > 2$
- $\text{Var}[W] = \frac{2n_2^2}{n_1^2(n_2 - 2)} \left[\frac{(n_1 + 2\lambda)^2}{(n_2 - 2)(n_2 - 4)} + \frac{(n_1 + 4\lambda)}{(n_2 - 4)} \right]$, para $n_2 > 4$

F não central dupla $F_{n_1, n_2, \lambda_1, \lambda_2}$

- Sejam U_1 e U_2 variáveis aleatórias independentes tais que $U_1 \sim \chi_{n_1, \lambda_1}^2$ e $U_2 \sim \chi_{n_2, \lambda_2}^2$. Então

$$W = \frac{\frac{U_1}{n_1}}{\frac{U_2}{n_2}} \quad (2.1.5)$$

tem distribuição F não central dupla, com n_1 graus de liberdade no numerador, n_2 graus de liberdade no denominador e parâmetros de não centralidade λ_1 e λ_2 .

Teorema 2.1.5 (*Utilidade pública*). Sejam $x_1, x_2, \dots, x_n$ números reais quaisquer e $\bar{x}$ seu valor médio. Então,

- (1) $\min_a \sum_{i=1}^n (x_i - a)^2 = \sum_{i=1}^n (x_i - \bar{x})^2$;
- (2) $\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$;
- (3) $\sum_{i=1}^n (x_i - \mu)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2$.

Teorema 2.1.6 (*Utilidade pública 2*).

- (1) $\Gamma(z) = \int_0^\infty t^{z-1} e^{-t} dt$
- (2) $\Gamma(n) = (n-1)!$
- (3) $\Gamma(n+1) = n\Gamma(n)$
- (4) $\Gamma(n) = (n-1)\Gamma(n-1)$
- (5) $\Gamma(1/2) = \pi$
- (6) $B(x, y) = \frac{\Gamma(x)\Gamma(y)}{\Gamma(x+y)} = \int_0^1 t^{x-1}(1-t)^{y-1} dt$

2.2 Probabilidade e Independência

Teorema 2.2.1 (*Independência*).

- (1) $X_1 \perp\!\!\!\perp X_2 \implies \text{Cov}(X_1, X_2) = 0$
- (2) Sejam X_1, X_2 normais. $X_1 \perp\!\!\!\perp X_2 \iff \text{Cov}(X_1, X_2) = 0$

Teorema 2.2.2 (*Probabilidades condicionais*).

- (1) $\mathbb{P}[A, B \mid C] = \mathbb{P}[A \mid B, C] \mathbb{P}[B \mid C]$
 $= \mathbb{P}[B \mid A, C] \mathbb{P}[A \mid C]$
- (2) $\mathbb{P}[A \mid B, C] = \frac{\mathbb{P}[B \mid A, C] \mathbb{P}[A \mid C]}{\mathbb{P}[B \mid C]}$
 $= \frac{\mathbb{P}[C \mid A, B] \mathbb{P}[A \mid B]}{\mathbb{P}[C \mid B]}$
- (3) $\mathbb{P}[A, B \mid C, D] = \frac{\mathbb{P}[C \mid A, B, D] \mathbb{P}[A, B, D]}{\mathbb{P}[C, D]}$

Teorema 2.2.3 (*Independência condicional*).

- (1) $A \perp\!\!\!\perp B \mid C \iff \mathbb{P}[A \mid B, C] = \mathbb{P}[A \mid C]$
 $\iff \mathbb{P}[A, B \mid C] = \mathbb{P}[A \mid C] \mathbb{P}[B \mid C]$
 $\iff [A \mid C] \perp\!\!\!\perp [B \mid C]$

2.3 Esperança

Teorema 2.3.1 (*Propriedades da esperança*).

- (1) $\mathbb{E}[X_1 + X_2] = \mathbb{E}[X_1] + \mathbb{E}[X_2]$ (*linearidade*)
- (2) $\mathbb{E}[X] = \mathbb{E}[\mathbb{E}(X | Y)]$ (*lei da esperança total*)
- (3) $\mathbb{E}[X | Z] = \mathbb{E}[\mathbb{E}(X | Y, Z) | Z]$ (*Torre*)

2.4 Variância

Teorema 2.4.1 (*Propriedades da variância*).

- (1) $\text{Var}[X] = \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2] - \mu^2$
- (2) $\text{Var}[\mathbf{X}] = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu}_X)(\mathbf{X} - \boldsymbol{\mu}_X)^\top] = \mathbb{E}[\mathbf{X}\mathbf{X}^\top] - \boldsymbol{\mu}_X\boldsymbol{\mu}_X^\top$
- (3) $\text{Var}[X] = \mathbb{E}(\text{Var}[X|Y]) + \text{Var}(\mathbb{E}[X|Y])$
- (4) $\text{Var}[X | Z] = \mathbb{E}(\text{Var}[X|Y] | Z) + \text{Var}(\mathbb{E}[X|Y] | Z)$
- (5) $\text{Var}[X + a] = \text{Var}[X]$
- (6) $\text{Var}[aX + b] = a^2 \text{Var}[X]$
- (7) $\text{Var}[\mathbf{A}\mathbf{X} + \mathbf{b}] = \mathbf{A} \text{Var}[\mathbf{X}] \mathbf{A}^\top$
- (8) $\text{Var}[X + Y] = \text{Var}[X] + \text{Var}[Y] + 2 \text{Cov}[X, Y]$
- (9) $\text{Var}[\mathbf{X} + \mathbf{Y}] = \text{Var}[\mathbf{X}] + \text{Var}[\mathbf{Y}] + \text{Cov}[\mathbf{X}, \mathbf{Y}] + \text{Cov}[\mathbf{Y}, \mathbf{X}]$
- (10) $\text{Var}[aX + bY] = a^2 \text{Var}[X] + b^2 \text{Var}[y] + 2ab \text{Cov}[X, Y]$
- (11) $\text{Var}[\mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{Y}] = \mathbf{A} \text{Var}[\mathbf{X}] \mathbf{A}^\top + \mathbf{B} \text{Var}[\mathbf{Y}] \mathbf{B}^\top + \mathbf{A} \text{Cov}[\mathbf{X}, \mathbf{Y}] \mathbf{B}^\top + \mathbf{B} \text{Cov}[\mathbf{Y}, \mathbf{X}] \mathbf{A}^\top$
- (12) $\text{Var}[aX - bY] = a^2 \text{Var}[X] + b^2 \text{Var}[y] - 2ab \text{Cov}[X, Y]$
- (13) $\text{Var}[\mathbf{A}\mathbf{X} - \mathbf{B}\mathbf{Y}] = \mathbf{A} \text{Var}[\mathbf{X}] \mathbf{A}^\top + \mathbf{B} \text{Var}[\mathbf{Y}] \mathbf{B}^\top - \mathbf{A} \text{Cov}[\mathbf{X}, \mathbf{Y}] \mathbf{B}^\top - \mathbf{B} \text{Cov}[\mathbf{Y}, \mathbf{X}] \mathbf{A}^\top$
- (14)
$$\begin{aligned} \text{Var}\left(\sum_{i=1}^n X_i\right) &= \sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{\substack{i,j=1 \\ i < j}}^n \text{Cov}(X_i, X_j) \\ &= \sum_{i=1}^n \text{Var}(X_i) + \sum_{\substack{i,j=1 \\ i \neq j}}^n \text{Cov}(X_i, X_j) \\ &= \sum_{i,j=1}^n \text{Cov}(X_i, X_j) \end{aligned}$$
- (15) $X_1 \perp \dots \perp X_n \implies \text{Var}(\sum_{i=1}^n X_i) = \sum_{i=1}^n \text{Var}(X_i)$

2.5 Covariância

Teorema 2.5.1 (*Propriedades da covariância*).

$$(1) \text{Cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)] \\ = \mathbb{E}[XY] - \mu_X \mu_Y$$

$$(2) \text{Cov}(\mathbf{X}, \mathbf{Y}) = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu}_X)(\mathbf{Y} - \boldsymbol{\mu}_Y)^\top] \\ = \mathbb{E}[\mathbf{X}\mathbf{Y}^\top] - \boldsymbol{\mu}_X \boldsymbol{\mu}_Y^\top$$

$$(3) \text{Cov}[X, X] = \text{Var}[X]$$

$$(4) \text{Cov}[\mathbf{X}, \mathbf{X}] = \text{Var}[\mathbf{X}]$$

$$(5) \text{Cov}[X, Y] = \mathbb{E}[\text{Cov}(X, Y \mid Z)] + \text{Cov}(\mathbb{E}[X \mid Z], \mathbb{E}[Y \mid Z])$$

$$(6) \text{Cov}(X, a) = 0$$

$$(7) \text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y)$$

$$(8) \text{Cov}(\mathbf{A}\mathbf{X} + \mathbf{b}, \mathbf{C}\mathbf{Y} + \mathbf{d}) = \mathbf{A} \text{Cov}(\mathbf{X}, \mathbf{Y}) \mathbf{C}^\top$$

$$(9) \text{Cov}(aX + bY, cW + dV) = ac \text{Cov}(X, W) + ad \text{Cov}(X, V) + bc \text{Cov}(Y, W) + bd \text{Cov}(Y, V)$$

$$(10) \text{Cov}(\mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{Y}, \mathbf{C}\mathbf{W} + \mathbf{D}\mathbf{V}) = \mathbf{A} \text{Cov}(\mathbf{X}, \mathbf{W}) \mathbf{C}^\top \\ + \mathbf{A} \text{Cov}(\mathbf{X}, \mathbf{V}) \mathbf{D}^\top \\ + \mathbf{B} \text{Cov}(\mathbf{Y}, \mathbf{W}) \mathbf{C}^\top \\ + \mathbf{B} \text{Cov}(\mathbf{Y}, \mathbf{V}) \mathbf{D}^\top$$

$$(11) \text{Cov}(aX_1 + bX_2, cY) = ac \text{Cov}(X_1, Y) + bc \text{Cov}(X_2, Y)$$

$$(12) \text{Cov}(\mathbf{A}\mathbf{X}_1 + \mathbf{B}\mathbf{X}_2, \mathbf{C}\mathbf{Y}) = \mathbf{A} \text{Cov}(\mathbf{X}_1, \mathbf{Y}) \mathbf{C}^\top + \mathbf{B} \text{Cov}(\mathbf{X}_2, \mathbf{Y}) \mathbf{C}^\top$$

$$(13) |\text{Cov}(X, Y)| \leq \sqrt{\sigma^2(X) \sigma^2(Y)}$$

$$(14) \rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

$$(15) \text{Cov}(\mathbf{A}\mathbf{U}, \mathbf{B}\mathbf{V}) = \mathbf{A} \text{Cov}(\mathbf{U}, \mathbf{V}) \mathbf{B}^\top$$

Teorema 2.5.2 (*Independência e covariância*).

$$(1) \mathbf{X} \text{ e } \mathbf{Y} \text{ são independentes} \implies \text{Cov}[\mathbf{X}, \mathbf{Y}] = 0$$

$$(2) \text{ Sejam } \mathbf{X} \text{ e } \mathbf{Y} \text{ normais}$$

$$(a) \mathbf{X} \text{ e } \mathbf{Y} \text{ são independentes} \iff \text{Cov}[\mathbf{X}, \mathbf{Y}] = 0$$

2.6 Transformações

Teorema 2.6.1 (*Transformação univariada contínua*). Seja X com f.d.p $f_X(x)$ e $Y = g(X)$, onde g é uma função monótona. Sejam $\mathcal{X} = \{x : f_X(x) > 0\}$ e $\mathcal{Y} = \{y : y = g(x), x \in \mathcal{X}\}$. Suponha que $f_X(x)$ é contínua em $\mathcal{X}$ e $g^{-1}(y)$ tenha uma derivada contínua em y . Então, a f.d.p. de y é dada por

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right| \mathbb{1}_{\mathcal{Y}}(y).$$

Nota: Caso g seja monótona por partes (n partes),

$$f_Y(y) = \sum_{i=1}^n f_X(g_i^{-1}(y)) \left| \frac{d}{dy} g_i^{-1}(y) \right| \mathbb{1}_{\mathcal{Y}}(y).$$

Teorema 2.6.2 (*Transformação bivariada*).

$$f_{U,V}(u, v) = f_{X,Y}(h_1(u, v), h_2(u, v)) |J_H(u, v)|,$$

onde

$$J_H(u, v) = \begin{bmatrix} \frac{\partial h_1}{\partial u} & \frac{\partial h_1}{\partial v} \\ \frac{\partial h_2}{\partial u} & \frac{\partial h_2}{\partial v} \end{bmatrix}$$

e $h_1(u, v) = g_1^{-1}(u, v)$, $h_2(u, v) = g_2^{-1}(u, v)$.

Teorema 2.6.3 (*Transformações usuais*).

$$(1) Y = X^2 \implies f_Y(y) = \frac{1}{2\sqrt{y}} [f_X(\sqrt{y}) + f_X(-\sqrt{y})]$$

$$(2) Y = \log(X) \implies f_Y(y) = e^y f_X(e^y)$$

$$(3) X_i \sim \mathcal{N}(\mu_i, \sigma_i^2) \implies \sum_{i=1}^n (a_i X_i + b_i) \sim \mathcal{N}\left(\sum_{i=1}^n (a_i \mu_i + b_i), \sum_{i=1}^n a_i^2 \sigma_i^2\right)$$

$$(a) X \sim \mathcal{N}(\mu, \sigma^2) \implies Y = aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$$

$$(b) X \sim \mathcal{N}(0, 1) \implies Y = aX + b \sim \mathcal{N}(b, a^2)$$

$$(4) X_i \sim \text{Exp}(\lambda) \implies Y = \sum_{i=1}^n X_i \sim \text{Gamma}(n, \lambda)$$

$$(5) X \sim \text{Exp}(\lambda) \implies Y = cX \sim \text{Exp}(\lambda/c)$$

$$(6) Y = \frac{1}{X} \implies f_Y(y) = f_X\left(\frac{1}{y}\right) \frac{1}{y^2}$$

$$(7) X \sim \text{Beta}(\theta, 1) \implies X^\theta \sim \text{Uniforme}(0, 1)$$

$$\implies -\log X \sim \text{Exp}(\theta)$$

$$\implies -\sum_{i=1}^n \log X_i \sim \text{Gamma}(n, \theta)$$

$$(8) X_1, X_2 \sim \text{Uniforme}(0, \theta) \implies Y = X_1 + X_2 \sim \text{Triangular}(0, 2\theta, \theta)$$

2.7 Vetor aleatório

Definição 2.7.1. $\mathbf{X}$ é um **vetor aleatório** de dimensão $p \times 1$

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix}, \quad (2.7.1)$$

em que cada X_i é uma variável aleatória com **média** μ_i e **variância** $\sigma_i^2 = \sigma_{ii}$, para $i = 1, \dots, p$, em que

$$\mu_i = \mathbb{E}[X_i] \quad (\text{média populacional}) \quad (2.7.2)$$

$$\sigma_i^2 = \text{Var}[X_i] = \mathbb{E}[(X_i - \mu_i)^2] \quad (\text{variância populacional}) \quad (2.7.3)$$

Definição 2.7.2. A **covariância** e a **correlação** (populacionais) entre duas variáveis X_i e X_k , com $i, k = 1, \dots, p$ e $i \neq k$, são dadas, respectivamente, por

$$\text{Cov}[X_i, X_k] = \sigma_{ik} = \mathbb{E}[(X_i - \mu_i)(X_k - \mu_k)] \quad \text{e} \quad (2.7.4)$$

$$\text{Corr}(X_i, X_k) = \rho_{ik} = \frac{\sigma_{ik}}{\sqrt{\sigma_i^2} \sqrt{\sigma_k^2}} \quad (2.7.5)$$

Definição 2.7.3. Se $\mathbf{X}$ é um vetor aleatório de dimensão $p \times 1$ com f.d.p. $f(\mathbf{X})$, o **valor esperado** de uma função escalar $g(\mathbf{X})$ é definido por

$$\mathbb{E}[g(\mathbf{X})] = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} g(\mathbf{u}) f(\mathbf{u}) du_1 \cdots du_p. \quad (2.7.6)$$

Mais geralmente, o valor esperado de uma função vetorial de $\mathbf{X}$, $\mathbf{g}(\mathbf{X})$, é dado por

$$\mathbb{E}[\mathbf{g}(\mathbf{X})] = (\mathbb{E}[g_i(\mathbf{X})]), \quad (2.7.7)$$

ou seja, o valor esperado é calculado elemento a elemento da função vetorial $\mathbf{g}(\mathbf{X})$.

Definição 2.7.4 (*Vetor de médias e matriz de variância e covariância*). Seja $\mathbf{X}$ um vetor aleatório de dimensão $p \times 1$. O vetor de médias (populacionais) de $\mathbf{X}$ é $\boldsymbol{\mu}_{p \times 1}$ e a matriz de variâncias e covariâncias (populacionais) de $\mathbf{X}$ é $\boldsymbol{\Sigma}_{p \times p}$, em que

$$\boldsymbol{\mu} = \mathbb{E}[\mathbf{X}] = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} = \begin{bmatrix} \mathbb{E}[X_1] \\ \mathbb{E}[X_2] \\ \vdots \\ \mathbb{E}[X_p] \end{bmatrix} \quad \text{e} \quad \boldsymbol{\Sigma} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1p} \\ & \sigma_2^2 & \cdots & \sigma_{2p} \\ & & \ddots & \vdots \\ \text{sim.} & & & \sigma_p^2 \end{bmatrix} \quad (2.7.8)$$

Matricialmente,

$$\text{Var}[\mathbf{X}] = \boldsymbol{\Sigma} = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top] \quad (2.7.9)$$

Nota: Σ é simétrica pois $\text{Cov}[X_i, X_k] = \text{Cov}[X_k, X_i]$, para $i, k = 1, \dots, p$.

Definição 2.7.5 (*Matriz de correlações*). Seja $\mathbf{X}$ um vetor aleatório de dimensão $p \times 1$. A matriz de correlações (populacionais) de $\mathbf{X}$ é $\mathbf{P} = \mathbf{P}_{p \times p}$, em que

$$\mathbf{P} = \text{Corr}(\mathbf{X}) = \begin{bmatrix} 1 & \rho_{12} & \dots & \rho_{1p} \\ & 1 & \dots & \rho_{2p} \\ & & \ddots & \vdots \\ \text{sim.} & & & 1 \end{bmatrix} \quad (2.7.10)$$

Matricialmente,

$$\text{Corr}(\mathbf{X}) = \mathbf{P} = (\mathbf{V}^{1/2})^{-1} \Sigma (\mathbf{V}^{1/2})^{-1} = \mathbf{V}^{-1/2} \Sigma \mathbf{V}^{-1/2}, \quad (2.7.11)$$

em que

$$\mathbf{V}^{1/2} = \begin{bmatrix} \sqrt{\sigma_{11}} & 0 & \dots & 0 \\ 0 & \sqrt{\sigma_{22}} & \ddots & 0 \\ \vdots & \ddots & \ddots & 0 \\ 0 & \dots & 0 & \sqrt{\sigma_{pp}} \end{bmatrix} \quad (2.7.12)$$

Nota:

- (1) Pelo mesmo motivo que Σ é simétrica, $\mathbf{P}$ também é.
- (2) $-1 \leq \rho_{ik} \leq 1$ para $i \neq k$ e $i, k = 1, \dots, p$.

Definição 2.7.6 (*Variância e covariância em forma matricial*). Sejam $\mathbf{X}$ e $\mathbf{Y}$ vetores aleatórios p -dimensionais com $\mathbb{E}[\mathbf{X}] = \boldsymbol{\mu}_X$ e $\mathbb{E}[\mathbf{Y}] = \boldsymbol{\mu}_Y$. Define-se

- (1) $\text{Var}[\mathbf{X}] = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu}_X)(\mathbf{X} - \boldsymbol{\mu}_X)^\top]$,
- (2) $\text{Cov}[\mathbf{X}, \mathbf{Y}] = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu}_X)(\mathbf{Y} - \boldsymbol{\mu}_Y)^\top]$

Definição 2.7.7 (*Amostra aleatória*). Suponha que $\mathbf{X}$ tem uma distribuição de probabilidade multivariada e que vamos observar uma amostra aleatória dessa distribuição, ou seja, n observações independentes e que vêm todas da mesma distribuição:

$$\text{amostra aleatória: } \mathbf{X}_1, \dots, \mathbf{X}_n, \quad (2.7.13)$$

em que $\mathbf{X}_i^\top = (X_{i1}, X_{i2}, \dots, X_{ip})$.

Definição 2.7.8 (*Matriz aleatória*). Suponha que $\mathbf{X}_1, \dots, \mathbf{X}_n$ ainda não foram observados, mas podemos organizá-los em uma matriz aleatória

$$\mathbf{X} = \begin{bmatrix} X_{11} & X_{12} & \dots & X_{1p} \\ X_{21} & X_{22} & \dots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \dots & X_{np} \end{bmatrix}_{n \times p} = \begin{bmatrix} \mathbf{X}_1^\top \\ \mathbf{X}_2^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix} \quad (2.7.14)$$

Teorema 2.7.1 (*Estimadores para μ e Σ*). Seja $\mathbf{X}_1, \dots, \mathbf{X}_n$ a.a. de uma distribuição com $\mathbb{E}[\mathbf{X}] = \boldsymbol{\mu}$ e $\text{Var}[\bar{\mathbf{X}}] = \boldsymbol{\Sigma}$. Então

- (1) $\bar{\mathbf{X}}$ é um estimador não-viesado para $\boldsymbol{\mu}$, com $\text{Var}[\bar{\mathbf{X}}] = \frac{\boldsymbol{\Sigma}}{n}$ e
- (2) $\frac{n}{n-1}\mathbf{S}$ é um estimador não-viesado para $\boldsymbol{\Sigma}$, ou seja

$$\mathbb{E}\left[\frac{n}{n-1}\mathbf{S}\right] = \boldsymbol{\Sigma}. \quad (2.7.15)$$

Nota:

- (1) Os elementos de $\mathbf{S}$ são dados por

$$s_{ik} = \frac{1}{n} \sum_{j=1}^n (x_{ji} - \bar{x}_i)(x_{jk} - \bar{x}_k) \quad (2.7.16)$$

Capítulo 3

Inferência

3.1 Distribuições amostrais

Teorema 3.1.1. Sejam $X_1, X_2, \dots, X_n$ uma A.A. e seja g uma função real tal que $\mathbb{E}[g(X)]$ e $\text{Var}[g(X)]$ existam. Nesse caso,

$$\mathbb{E} \left[\sum_{i=1}^n g(X_i) \right] = n \mathbb{E}[g(X)],$$

e

$$\text{Var} \left[\sum_{i=1}^n g(X_i) \right] = n \text{Var}[g(X)].$$

Teorema 3.1.2. Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com média μ e variância $\sigma^2 < \infty$. Então,

- (1) $\mathbb{E}(\bar{X}) = \mu$;
- (2) $\text{Var}(\bar{X}) = \sigma^2/n$;
- (3) $\mathbb{E}(S^2) = \sigma^2$.

Teorema 3.1.3 (*Distribuição amostral da média*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com função geradora de momentos $M_X(t)$. Então, a FGM da média amostral será

$$M_{\bar{X}}(t) = [M_X(t/n)]^n.$$

Teorema 3.1.4 (*A.A. da Normal*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com distribuição $\mathcal{N}(\mu, \sigma^2)$. Então,

- (1) $\bar{X}$ e S^2 são independentes;
- (2) $\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$;

$$(3) \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Teorema 3.1.5 (*A.A. da t-Student*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. oriunda de uma população $\mathcal{N}(\mu, \sigma^2)$. Então

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

Nota: se $Z \sim \mathcal{N}(0, 1)$ e $V \sim \chi_k^2$ independentes, então

$$\frac{Z}{\sqrt{V/k}} \sim t_k.$$

Teorema 3.1.6 (*Razão de A.A. da Normal*). Sejam $X_1, X_2, \dots, X_n$ e $Y_1, Y_2, \dots, Y_m$ duas A.A.'s oriundas de populações $\mathcal{N}(\mu_X, \sigma_X^2)$ e $\mathcal{N}(\mu_Y, \sigma_Y^2)$, respectivamente. Então

$$\frac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2} \sim F_{n-1, m-1}.$$

Nota: O resultado acima decorre do fato de que, se $V \sim \chi_r^2$ e $W \sim \chi_s^2$ independentes, então

$$\frac{V/r}{W/s} \sim F_{r,s}.$$

3.1.1 Estatísticas de ordem

Teorema 3.1.7 (*Máximo e mínimo*).

- (1) $F_{X_{(n)}}(x) = [F_X(x)]^n$ (contínua e discreta)
- (2) $f_{X_{(n)}}(x) = n[F_X(x)]^{n-1} f_X(x)$ (contínua)
- (3) $F_{X_{(1)}}(x) = 1 - [1 - F_X(x)]^n$ (contínua e discreta)
- (4) $f_{X_{(1)}}(x) = n[1 - F_X(x)]^{n-1} f_X(x)$ (contínua)

Teorema 3.1.8 (*Contínua e discreta*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com f.d. F_X . Nesse caso, a f.d. da j-ésima estatística de ordem, $X_{(j)}$, será

$$F_{X_{(j)}}(x) = \sum_{k=j}^n \binom{n}{k} [F_X(x)]^k [1 - F_X(x)]^{n-k}.$$

Teorema 3.1.9 (*Discreta*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com f.d. F_X . Suponha que a população seja discreta com f.p. f_X e suporte $\{x_i \mid x_1 < x_2 < \dots < x_n\}$. Além disso, denote $P_0 = 0$ e $P_i = F_X(x_i) = f_X(x_1) + f_X(x_2) + \dots + f_X(x_i)$, $i = 1, 2, \dots, n$. Nesse caso, a função de probabilidade da j-ésima estatística de ordem será

$$f_{X_{(j)}}(x) = \mathbb{P}(X_{(j)} = x_i) = \sum_{k=j}^n \binom{n}{k} [P_i^k (1 - P_i^{n-k}) - P_{i-1}^k (1 - P_{i-1}^{n-k})].$$

Teorema 3.1.10 (*Contínua*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com f.d. F_X . Se a população for contínua com f.d.p. f_X , então a f.d.p. da j -ésima estatística de ordem $X_{(j)}$ será

$$f_{X_{(j)}}(x) = \frac{n!}{(j-1)!(n-j)!} f_X(x) [F_X(x)]^{j-1} [1 - F_X(x)]^{n-j}.$$

Teorema 3.1.11 (*Contínua*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com f.d. F_X e f.d.p. f_X . Então a f.d.p. conjunta de $(X_{(i)}, X_{(j)})$, $1 \leq i < j \leq n$, será

$$f_{X_{(i)}, X_{(j)}}(u, v) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} f_X(u) f_X(v) [F_X(u)]^{i-1} \times [F_X(v) - F_X(u)]^{j-i-1} [1 - F_X(v)]^{n-j} \mathbb{1}(u < v).$$

Nota: Argumentos análogos podem ser utilizados para derivar distribuições de v.a.'s com três ou mais estatísticas de ordem. Um dos v.a.'s mais utilizados corresponde a $(X_{(1)}, X_{(2)}, \dots, X_{(n)})$, cuja f.d.p. corresponde a

$$f_{X_{(1)}, \dots, X_{(n)}}(x_1, \dots, x_n) = n! f_X(x_1) \cdots f_X(x_n) \mathbb{1}(-\infty < x_1 < \dots < x_n < \infty).$$

3.2 Redução de dados

Definição 3.2.1 (*Princípio da suficiência*). Se T for uma estatística suficiente para θ , e se duas amostras observadas, $\mathbf{x}$ e $\mathbf{y}$, forem tais que $T(\mathbf{x}) = T(\mathbf{y})$, então as inferências a respeito de θ deverão ser as mesmas, independentemente de se usar $\mathbf{x}$ ou $\mathbf{y}$.

Nota: Como consequência, qualquer inferência sobre θ deverá depender da amostra $\mathbf{X}$ apenas através de $T(\mathbf{X})$.

Definição 3.2.2 (*Estatística suficiente*). Uma estatística $T(\mathbf{X})$ é chamada de estatística suficiente para θ se a distribuição condicional da amostra $\mathbf{X}$, dado o valor de $T(\mathbf{X})$, não depender de θ .

Teorema 3.2.1 (*Razão para suficiência*). Seja $p(\mathbf{x}|\theta)$ a f.p. (ou f.d.p.) conjunta de uma amostra $\mathbf{X}$, e $q(t|\theta)$ a f.p. (ou f.d.p.) de uma estatística $T(\mathbf{X})$. Então $T(\mathbf{X})$ será uma estatística suficiente para θ se, para todo $\mathbf{x} \in \mathcal{X}$, a razão

$$\frac{p(\mathbf{x}|\theta)}{q(T(\mathbf{x})|\theta)}$$

for constante como função de θ .

Teorema 3.2.2 (*Critério da fatoração*). Seja $f(\mathbf{x}|\theta)$ a f.p. (ou f.d.p.) conjunta de uma amostra $\mathbf{X}$. Uma estatística $T(\mathbf{X})$ é uma estatística suficiente para θ se, e somente se, existirem funções $g(t|\theta)$ e $h(\mathbf{x})$ de modo que, para todo $\mathbf{x} \in \mathcal{X}$ e todo $\theta \in \Theta$,

$$f(\mathbf{x}|\theta) = g(T(\mathbf{x})|\theta)h(\mathbf{x}).$$

Teorema 3.2.3 (*Suficiência na família exponencial*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. oriunda de uma população cuja f.d.p. (ou f.p.) $f(x|\theta)$ pertence à família exponencial

$$f(x|\theta) = \exp \left(\sum_{k=1}^s \eta_k(\theta) t_k(x) \right) a(\theta) h(x),$$

em que $\theta = (\theta_1, \theta_2, \dots, \theta_d)$, $d \leq s$. Então,

$$T(\mathbf{X}) = \left(\sum_{i=1}^n t_1(X_i), \sum_{i=1}^n t_2(X_i), \dots, \sum_{i=1}^n t_s(X_i) \right)$$

é uma estatística suficiente para θ .

Definição 3.2.3 (*Estatística suficiente mínima*). Uma estatística $T(\mathbf{X})$ é chamada estatística suficiente mínima se, para qualquer outra estatística suficiente $T'(\mathbf{X})$, $T(\mathbf{X})$ puder ser escrita como função de $T'(\mathbf{X})$.

Teorema 3.2.4 (*Critério para suficiência mínima*). Seja $f(\mathbf{x}|\theta)$ a f.p. (ou f.d.p.) conjunta de uma amostra $\mathbf{X}$. Suponhamos que, para quaisquer duas possíveis amostras observadas, $\mathbf{x}$ e $\mathbf{y}$, $f(\mathbf{x}|\theta)/f(\mathbf{y}|\theta)$ seja constante como função de θ se, e somente se, $T(\mathbf{x}) = T(\mathbf{y})$. Então $T(\mathbf{X})$ é uma estatística suficiente mínima.

Definição 3.2.4 (*Estatística ancilar*). Uma estatística $S(\mathbf{X})$ cuja distribuição não depende de θ é chamada de estatística ancilar.

Nota: Uma estatística $S(\mathbf{X})$ é dita ser ancilar de primeira ordem se $\mathbb{E}_\theta[S(\mathbf{X})]$ não depende de θ .

Definição 3.2.5 (*Estatística completa*). Seja $f(t|\theta)$ uma família de f.d.p.'s (ou f.p.'s) para uma estatística $T(\mathbf{X})$. A família de distribuições de probabilidade é chamada completa se, para qualquer função g ,

$$\mathbb{E}_\theta[g(T)] = 0 \implies \mathbb{P}_\theta[g(T) = 0] = 1,$$

para todo $\theta \in \Theta$. De forma equivalente, $T(\mathbf{X})$ é chamada de estatística completa.

Teorema 3.2.5 (*Basu*). Se $T(\mathbf{X})$ for uma estatística suficiente mínima e completa, então $T(\mathbf{X})$ será independente de toda estatística ancilar.

Teorema 3.2.6 (*Estatísticas completas na família exponencial*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. oriunda de uma população com f.d.p. (ou f.p.) pertencente à família exponencial

$$f(x|\theta) = \exp \left(\sum_{k=1}^s \eta_k(\theta) t_k(x) \right) a(\theta) h(x),$$

em que $\theta = (\theta_1, \theta_2, \dots, \theta_s)$. Então, a estatística

$$T(\mathbf{X}) = \left(\sum_{i=1}^n t_1(X_i), \sum_{i=1}^n t_2(X_i), \dots, \sum_{i=1}^n t_s(X_i) \right)$$

é completa, desde que Θ contenha um conjunto aberto em $\mathbb{R}^s$.

Teorema 3.2.7. Se uma estatística suficiente mínima existe, então qualquer estatística completa também será uma estatística suficiente mínima.

3.3 Estimação Pontual I

Definição 3.3.1 (*Estimador pontual*). Um estimador pontual é qualquer função de uma amostra.

Nota: Qualquer estatística é um estimador.

Definição 3.3.2 (*Estimativa*). Uma estimativa é um valor (valores) observado(s) de um estimador, obtido a partir de uma amostra observada.

Definição 3.3.3 (*Função de verossimilhança*). Sejam $X_1, X_2, \dots, X_n$ uma amostra oriunda de uma população com f.d.p. (ou f.p.) $f(x|\theta)$. A função de verossimilhança será

$$L(\theta|\mathbf{x}) = f(\mathbf{x}|\theta).$$

Qualquer estimador $\hat{\theta} \equiv \hat{\theta}_n(\mathbf{X}) \in \Theta$ tal que

$$L(\hat{\theta}|\mathbf{X}) = \sup_{\theta \in \Theta} L(\theta|\mathbf{X})$$

é chamado estimador de máxima verossimilhança (EMV) de θ .

Teorema 3.3.1 (*Pontos críticos*). Seja $g(x)$ uma função contínua e duplamente diferenciável em algum intervalo aberto I que contém a . Se $g'(a) = 0$, então $g(x)$ tem um máximo (mínimo) relativo em $x = a$, desde que $g''(a) < 0$ ($g''(a) > 0$). Ademais, o conjunto $\{a \in I \mid g'(a) = 0\}$ é chamado de conjunto dos pontos críticos de $g(x)$. Os únicos máximos (mínimos) possíveis de $g(x)$ para $c \leq x \leq d$ estão nos pontos críticos entre c e d , bem como em c e em d .

Teorema 3.3.2 (*Propriedade da invariância*). Seja $\hat{\theta}$ o EMV de θ . Então, para qualquer estimando $\tau(\theta)$, seu EMV será $\tau(\hat{\theta})$.

Teorema 3.3.3 (*Relação EMV e Suficiência*). Seja $L(\theta|\mathbf{x})$ a função de verossimilhança da amostra $X_1, X_2, \dots, X_n$, e seja $T = T(\mathbf{X})$ uma estatística suficiente para θ . O EMV de θ , se existir, será função de T .

Teorema 3.3.4 (*EMV na família exponencial*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. pertencente à família exponencial canônica, cuja f.d.p. (ou f.p.) conjunta pode ser escrita como

$$f(\mathbf{x}|\eta) = \exp \left(\eta \sum_{i=1}^n T(x_i) - nA(\eta) \right) h^*(\mathbf{x}).$$

Temos que o EMV de η será solução da equação

$$\frac{1}{n} \sum_{i=1}^n T(X_i) = \mathbb{E}[T(X_1)],$$

desde que essa solução pertença ao espaço paramétrico de η .

Nota: Devido à propriedade da invariância, o resultado permanece válido para o caso geral da família exponencial, em que cada X_i tem f.d.p. (ou f.p.)

$$f(x|\theta) = \exp\{\eta(\theta)T(x) - B(\theta)\}h(x).$$

Nota: O Teorema 4 pode ser generalizado para o caso multiparamétrico:

$$f(\mathbf{x}|\boldsymbol{\theta}) = \exp\left(\sum_{k=1}^s \eta_k(\boldsymbol{\theta})T_k(\mathbf{x}) - B(\boldsymbol{\theta})\right)h(\mathbf{x}).$$

3.4 Estimação Pontual II

Definição 3.4.1 (*Erro quadrático médio*). O erro quadrático médio (EQM) do estimador W de um parâmetro θ corresponde a

$$\mathbb{E}_\theta(W - \theta)^2,$$

que é função de θ .

Definição 3.4.2 (*Viés*). O viés (B – do inglês, bias) do estimador W de um parâmetro θ corresponde a

$$B_\theta(W) = \mathbb{E}_\theta(W) - \theta.$$

Quando $B_\theta(W) = 0$, diz-se que o estimador W é não viesado.

Definição 3.4.3 (*ENVVUM*). Um estimador W^* é dito ser o melhor estimador não viesado de $\tau(\theta)$ se $\mathbb{E}_\theta(W^*) = \tau(\theta)$ para todo $\theta \in \Theta$ e, para qualquer outro estimador não viesado W de $\tau(\theta)$, $\text{Var}_\theta(W^*) \leq \text{Var}_\theta(W)$ para todo $\theta \in \Theta$. Nesse caso, W^* é chamado de estimador não viesado de variância uniformemente mínima (ENVVUM) de $\tau(\theta)$.

Teorema 3.4.1 (*Desigualdade de Cramér-Rao (Teorema 1)*). Sejam $X_1, X_2, \dots, X_n$ uma amostra com f.d.p. conjunta $f(\mathbf{x}|\theta)$ e $W(\mathbf{X})$ um estimador que satisfaz

$$\frac{d}{d\theta} \mathbb{E}_\theta[W(\mathbf{X})] = \int_{\mathcal{X}} \frac{\partial}{\partial \theta} [W(\mathbf{x})f(\mathbf{x}|\theta)] d\mathbf{x} \quad \text{e} \quad \text{Var}_\theta[W(\mathbf{X})] < \infty.$$

Então,

$$\text{Var}_\theta[W(\mathbf{X})] \geq \frac{\left(\frac{d}{d\theta} \mathbb{E}_\theta[W(\mathbf{X})]\right)^2}{\mathbb{E}_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta) \right)^2 \right]}.$$

Nota:

- (1) O resultado do Teorema 1, bem como do Corolário 1, permanecerá válido quando as v.a.'s forem discretas. Nesse caso, troca-se a integral pelo somatório na suposição.
- (2) A quantidade

$$\frac{\left(\frac{d}{d\theta} \mathbb{E}_\theta[W(\mathbf{X})]\right)^2}{\mathbb{E}_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta) \right)^2 \right]},$$

exibida no Teorema 1, é conhecida como limite inferior de Cramér-Rao (LICR).

- (3) A quantidade

$$\mathbb{E}_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta) \right)^2 \right]$$

é conhecida como informação de Fisher da amostra. Quanto maior a informação de Fisher, mais informação temos sobre θ e, conseqüentemente, menor será o limite inferior de Cramér-Rao.

Teorema 3.4.2 (*Desigualdade de Cramér-Rao – caso i.i.d. (Corolário 1)*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com f.d.p. (ou f.p.) $f(x|\theta)$. Sob as suposições do Teorema 1,

$$\text{Var}_\theta[W(\mathbf{X})] \geq \frac{\left(\frac{d}{d\theta} \mathbb{E}_\theta[W(\mathbf{X})]\right)^2}{n \mathbb{E}_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(X|\theta) \right)^2 \right]}.$$

Teorema 3.4.3 (*Lema 1*). Se $f(x|\theta)$ satisfaz

$$\frac{d}{d\theta} \mathbb{E}_\theta \left[\frac{\partial}{\partial \theta} \log f(X|\theta) \right] = \int_{\mathbb{R}} \frac{\partial}{\partial \theta} \left[\frac{\partial}{\partial \theta} \log f(X|\theta) \right] f(x|\theta) dx,$$

então,

$$\mathbb{E}_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(X|\theta) \right)^2 \right] = - \mathbb{E}_\theta \left[\frac{\partial^2}{\partial \theta^2} \log f(X|\theta) \right].$$

Nota:

- (1) A suposição utilizada no Lema 1 é válida, por exemplo, no caso da família exponencial.
- (2) Em geral, se o suporte de X depender do parâmetro, a desigualdade de Cramér-Rao não se aplica.

Teorema 3.4.4 (*Corolário 2*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população X com f.d.p. (ou f.p.) $f(x|\theta)$, em que f satisfaz as condições do Teorema 1. Suponhamos que $L(\theta|\mathbf{x}) = \prod_{i=1}^n f(x_i|\theta)$ denote a função de verossimilhança. Se $W(\mathbf{X})$ for um estimador para $\tau(\theta)$, então $W(\mathbf{X})$ atingirá o limite inferior de Cramér-Rao se, e somente se,

$$\frac{\partial}{\partial \theta} \log L(\theta|\mathbf{x}) = a(\theta)[W(\mathbf{x}) - \tau(\theta)],$$

para alguma função $a(\theta)$.

Teorema 3.4.5 (*Rao-Blackwell (Teorema 2)*). Seja W qualquer estimador não viesado de $\tau(\theta)$, e T uma estatística suficiente para θ . Defina $\phi(T) = \mathbb{E}[W|T]$. Então $\mathbb{E}_\theta[\phi(T)] = \tau(\theta)$ e $\text{Var}_\theta[\phi(T)] \leq \text{Var}_\theta(W)$ para todo $\theta \in \Theta$. Em outras palavras, $\phi(T)$ é um melhor estimador não viesado uniformemente de $\tau(\theta)$.

Nota: Devemos considerar estimadores que sejam funções de estatísticas suficientes para determinar ENVVUM's.

Teorema 3.4.6 (*Unicidade do melhor ENV (Teorema 3)*). Se W for um ENVVUM de $\tau(\theta)$, então W será único.

Definição 3.4.4 (*Estimador não viesado de zero*). Seja U um estimador tal que $\mathbb{E}_\theta(U) = 0$, para todo $\theta \in \Theta$. Nesse caso, dizemos que U é um estimador não viesado de zero.

Teorema 3.4.7 (*Teorema 4*). Se $\mathbb{E}_\theta(W) = \tau(\theta)$, então W será o melhor estimador não viesado de $\tau(\theta)$ se, e somente se, W for não correlacionado com todos os estimadores não viesados de zero.

Nota: Um estimador não viesado de zero nada mais é do que uma perturbação aleatória. Se um estimador pudesse ser melhorado ao acrescentarmos uma perturbação a ele, esse estimador certamente seria problemático. Isso pode ser entendido como uma interpretação do Teorema 4. O Teorema 4 pode ser útil para mostrar quando um estimador não é ENVVUM.

Teorema 3.4.8 (*Teorema 5*). Seja T uma estatística suficiente e completa para um parâmetro θ , e seja $\phi(T)$ qualquer estimador baseado somente em T . Então, $\phi(T)$ é o único melhor estimador não viesado de seu valor esperado.

Nota: O teorema acima diz que, na presença de estatísticas suficientes e completas, se pudermos determinar qualquer estimador não viesado de $\tau(\theta)$, podemos determinar o melhor ENV. Basicamente, se T for uma estatística suficiente e completa para θ e $h(\mathbf{X})$ um ENV de $\tau(\theta)$, então $\phi(T) = \mathbb{E}[h(\mathbf{X})|T]$ será o melhor estimador não viesado de $\tau(\theta)$.

3.5 Estimação intervalar

Definição 3.5.1. Sejam $X_1, X_2, \dots, X_n$ uma amostra aleatória de uma população com f.d.p. $f(x | \theta)$. Sejam $T_1 \equiv T_1(\mathbf{X})$ e $T_2 \equiv T_2(\mathbf{X})$ duas estatísticas satisfazendo $T_1 \leq T_2$, de tal forma que $\mathbb{P}_\theta[T_1 \leq \tau(\theta) \leq T_2] = \gamma$, em que γ não depende de θ . Então, o intervalo $[T_1, T_2]$ é chamado de intervalo com 100 $\gamma\%$ de confiança para $\tau(\theta)$. A quantidade γ é chamada de nível de confiança, e T_1 e T_2 são chamadas de limites de confiança inferior e superior, respectivamente, para $\tau(\theta)$.

Definição 3.5.2. Sejam $X_1, X_2, \dots, X_n$ uma amostra aleatória de uma população com f.d.p. $f(x | \theta)$. Seja $T_1 \equiv T_1(\mathbf{X})$ uma estatística tal que $\mathbb{P}_\theta[T_1 \leq \tau(\theta)] = \gamma$. Então, T_1 é chamada de limite de confiança inferior unilateral para $\tau(\theta)$. Analogamente, seja $T_2 \equiv T_2(\mathbf{X})$ uma estatística tal que $\mathbb{P}_\theta[T_2 \geq \tau(\theta)] = \gamma$. Então, T_2 é chamada de

limite de confiança superior unilateral para $\tau(\theta)$. Em ambos os casos, γ não depende de θ .

Nota: Se um IC para θ tiver sido determinado, então pode-se determinar uma família de IC's. Em outras palavras, para um determinado estimador intervalar com $100\gamma\%$ de confiança para θ , pode-se obter um estimador intervalar com $100\gamma\%$ para $\tau(\theta)$, desde que τ seja uma função estritamente monótona. Se τ for uma função estritamente crescente e $[T_1, T_2]$ for um IC para θ , então $[\tau(T_1), \tau(T_2)]$ será um IC para $\tau(\theta)$, pois

$$\mathbb{P}_\theta[T_1 \leq \theta \leq T_2] = \mathbb{P}_\theta[\tau(T_1) \leq \tau(\theta) \leq \tau(T_2)]. \quad (3.5.1)$$

Definição 3.5.3. Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com f.d.p. $f(x | \theta)$, e seja $Q \equiv Q(\mathbf{X} | \theta)$. Dizemos que Q é uma quantidade pivotal se sua distribuição não depender de θ .

Teorema 3.5.1 (*Método da quantidade pivotal*). Se $Q(\mathbf{X} | \theta)$ é uma quantidade pivotal e possui uma f.d.p., então, para qualquer $0 < \gamma < 1$, haverá q_1 e q_2 dependendo de γ de tal modo que

$$\mathbb{P}(q_1 \leq Q(\mathbf{X} | \theta) \leq q_2) = \gamma. \quad (3.5.2)$$

Se para cada possível valor amostral $x_1, x_2, \dots, x_n$,

$$\{q_1 \leq Q(\mathbf{x} | \theta) \leq q_2\} \iff \{T_1(\mathbf{x}) \leq \tau(\theta) \leq T_2(\mathbf{x})\}, \quad (3.5.3)$$

então $[T_1(\mathbf{X}), T_2(\mathbf{X})]$ será um intervalo com $100\gamma\%$ de confiança para $\tau(\theta)$.

Nota: • O termo quantidade pivotal pode ser inapropriado, pois pode ser impossível “pivotar” a quantidade $Q(\mathbf{X} | \theta)$.

- Os valores de q_1 e q_2 não dependem de θ , pois a distribuição de $Q(\mathbf{X} | \theta)$ não depende.

Nota: No caso do método da quantidade pivotal, intervalos com $100\gamma\%$ de confiança são caracterizados por

$$\gamma = \mathbb{P}(q_1 \leq Q \leq q_2) = \int_{q_1}^{q_2} f_Q(t) dt = F_Q(q_2) - F_Q(q_1), \quad (3.5.4)$$

em que f_Q e F_Q correspondem à f.d.p. e f.d. da quantidade pivotal Q . Disso decorrem duas informações úteis:

- Como γ é fixado, podemos escrever $q_2 \equiv q_2(q_1)$, pois

$$\gamma = F_Q(q_2) - F_Q(q_1) \implies q_2 = F_Q^{-1}[\gamma + F_Q(q_1)]; \quad (3.5.5)$$

- Derivando ambos os lados de (3.5.4) em relação a q_1 , temos

$$\frac{d}{dq_1} \gamma = \frac{d}{dq_1} [F_Q(q_2) - F_Q(q_1)] \implies f_Q(q_2) \frac{dq_2}{dq_1} - f_Q(q_1) = 0. \quad (3.5.6)$$

Portanto,

$$\frac{dq_2}{dq_1} = \frac{f_Q(q_1)}{f_Q(q_2)}. \quad (3.5.7)$$

Teorema 3.5.2. Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população $X \sim \mathcal{N}(\theta, \sigma^2)$, $\theta \in \mathbb{R}$ e $\sigma^2 > 0$ conhecido. Então

$$Q = \frac{\bar{X} - \theta}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1) \quad (3.5.8)$$

é uma quantidade pivotal e

$$\left[\bar{X} - q_2 \frac{\sigma}{\sqrt{n}}, \bar{X} - q_1 \frac{\sigma}{\sqrt{n}} \right] \quad (3.5.9)$$

é um IC de $100\gamma\%$ para θ , em que q_1 e q_2 satisfazem $\mathbb{P}(q_1 \leq Q \leq q_2) = \gamma$. O comprimento desse intervalo é minimizado quando $q_1 = -q_2$.

Teorema 3.5.3 (*IC para a média — σ^2 desconhecido*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. oriunda de uma população $X \sim \mathcal{N}(\mu, \sigma^2)$, com σ^2 desconhecido. Então

$$Q = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1} \quad (3.5.10)$$

é uma quantidade pivotal, e o menor intervalo com $100\gamma\%$ de confiança para μ é

$$\left[\bar{X} - t_{n-1, (1+\gamma)/2} \frac{S}{\sqrt{n}}, \bar{X} + t_{n-1, (1+\gamma)/2} \frac{S}{\sqrt{n}} \right], \quad (3.5.11)$$

em que $t_{n-1, (1+\gamma)/2}$ é tal que $\mathbb{P}(T \leq t_{n-1, (1+\gamma)/2}) = (1 + \gamma)/2$, para $T \sim t_{n-1}$.

Teorema 3.5.4 (*IC para a variância — μ desconhecido*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. oriunda de uma população $X \sim \mathcal{N}(\mu, \sigma^2)$, com μ desconhecido. Então

$$Q = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2 \quad (3.5.12)$$

é uma quantidade pivotal, e

$$\left[\frac{(n-1)S^2}{q_2}, \frac{(n-1)S^2}{q_1} \right] \quad (3.5.13)$$

é um intervalo com $100\gamma\%$ de confiança para σ^2 , em que q_1 e q_2 satisfazem $\mathbb{P}(q_1 \leq Q \leq q_2) = \gamma$.

- Uma escolha usual (intervalo com caudas iguais) é tomar q_1 e q_2 tais que $\mathbb{P}(Q \leq q_1) = \mathbb{P}(Q \geq q_2) = (1 - \gamma)/2$, mas esse não é o intervalo de comprimento mínimo.
- O intervalo de comprimento mínimo é obtido sujeitando-se q_1 e q_2 à condição adicional $q_1^2 f_Q(q_1) = q_2^2 f_Q(q_2)$, cuja solução é obtida numericamente.

Teorema 3.5.5 (*IC para a diferença de médias — $\sigma_1^2 = \sigma_2^2 = \sigma^2$ desconhecido*). Sejam $X_{11}, X_{12}, \dots, X_{1n_1}$ uma A.A. de uma população $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$ e sejam $X_{21}, X_{22}, \dots, X_{2n_2}$ uma A.A. de uma população $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$, ambas as amostras independentes, com $\sigma_1^2 = \sigma_2^2 = \sigma^2$ desconhecido. Sejam

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}. \quad (3.5.14)$$

Então

$$Q = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right) S_p^2}} \sim t_{n_1+n_2-2} \quad (3.5.15)$$

é uma quantidade pivotal, e

$$\left[(\bar{X}_1 - \bar{X}_2) - q\sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right) S_p^2}, (\bar{X}_1 - \bar{X}_2) + q\sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right) S_p^2} \right] \quad (3.5.16)$$

é um intervalo com $100\gamma\%$ de confiança para $\mu_1 - \mu_2$, em que $q = t_{n_1+n_2-2, (1+\gamma)/2}$.

Teorema 3.5.6 (*IC para a diferença de médias — amostras pareadas, σ_D^2 desconhecida*). Sejam $(X_{11}, X_{12}), (X_{21}, X_{22}), \dots, (X_{n1}, X_{n2})$ uma A.A. oriunda de uma população normal bivariada com parâmetros $\mathbb{E}(X_1) = \mu_1$, $\mathbb{E}(X_2) = \mu_2$, $\text{Var}(X_1) = \sigma_1^2$, $\text{Var}(X_2) = \sigma_2^2$ e $\rho = \text{Cor}(X_1, X_2)$. Sejam $D_i = X_{i1} - X_{i2}$, $i = 1, 2, \dots, n$, com $D_i \sim \mathcal{N}(\mu_D, \sigma_D^2)$, em que $\mu_D = \mu_1 - \mu_2$ e $\sigma_D^2 = \sigma_1^2 + \sigma_2^2 - 2\text{Cov}(X_{i1}, X_{i2})$. Então

$$Q = \frac{\bar{D} - \mu_D}{S_D/\sqrt{n}} \sim t_{n-1} \quad (3.5.17)$$

é uma quantidade pivotal, e

$$\left[\bar{D} - t_{n-1, (1+\gamma)/2} \frac{S_D}{\sqrt{n}}, \bar{D} + t_{n-1, (1+\gamma)/2} \frac{S_D}{\sqrt{n}} \right] \quad (3.5.18)$$

é um intervalo com $100\gamma\%$ de confiança para $\mu_D = \mu_1 - \mu_2$.

Teorema 3.5.7 (*Existência de quantidade pivotal*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. oriunda de uma população com f.d.p. $f(x | \theta)$ e f.d.a. contínua $F(x | \theta)$. Então

$$Q = -\sum_{i=1}^n \log F(X_i | \theta) \sim \text{gama}(n, 1) \quad (3.5.19)$$

é uma quantidade pivotal, equivalente a

$$Q' = \prod_{i=1}^n F(X_i | \theta). \quad (3.5.20)$$

Ou seja, sempre que a amostra vier de uma população com f.d.a. contínua, há uma quantidade pivotal.

Nota: • Embora seja possível determinar uma quantidade pivotal sempre que uma amostra for oriunda de uma população com f.d.a. contínua, não há garantias de que seja possível determinar um IC a partir dela. Em outras palavras, pode ser impossível “pivotar” essa quantidade.

- Se $F(x | \theta)$ for uma função monótona em θ para cada x fixado, então $\prod_{i=1}^n F(X_i | \theta)$ também será. Essa é uma condição suficiente para que seja possível determinar intervalos de confiança.

Nota: Se θ for um parâmetro de localização, então a distribuição de $X_i - \theta$ não depende de θ ; exemplos de quantidade pivotal são $\sum_{i=1}^n X_i - n\theta$, $\bar{X} - \theta$, $X_{(k)} - \theta$, $\frac{X_{(1)} + X_{(n)}}{2} - \theta$, etc.

Se θ for um parâmetro de escala, a distribuição de X_i/θ não depende de θ ; exemplos de quantidade pivotal são $\sum_{i=1}^n X_i/\theta$, $X_{(k)}/\theta$, etc.

Teorema 3.5.8 (*Distribuição assintótica de EMV's*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. oriunda de uma população com f.d.a. $F(x | \theta)$. Denotemos por $\hat{\theta}_n$ o EMV de θ . Sob certas condições de regularidade,

$$\frac{\hat{\theta}_n - \theta}{\sqrt{\sigma_n^2(\theta)}} \xrightarrow{\mathcal{D}} \mathcal{N}(0, 1), \quad (3.5.21)$$

quando $n \rightarrow \infty$, em que $1/\sigma_n^2(\theta) = I_n(\theta)$ corresponde à informação de Fisher, ou seja,

$$I_n(\theta) = n \mathbb{E}_\theta \left\{ \left[\frac{\partial}{\partial \theta} \log f(X | \theta) \right]^2 \right\} = -n \mathbb{E}_\theta \left[\frac{\partial^2}{\partial \theta^2} \log f(X | \theta) \right]. \quad (3.5.22)$$

Nota: Seja $\hat{\theta}_n$ um estimador tal que

$$Q_n = \frac{\hat{\theta}_n - \theta}{\sigma_n(\theta)} \xrightarrow{\mathcal{D}} \mathcal{N}(0, 1), \quad (3.5.23)$$

quando $n \rightarrow \infty$, em que $\sigma_n(\theta)$ é uma função de θ que depende de n . Então Q_n pode ser tratada como uma quantidade pivotal aproximada, e um IC com um nível de aproximadamente 100 $\gamma\%$ de confiança pode ser determinado invertendo

$$-z_{(1+\gamma)/2} \leq Q_n \leq z_{(1+\gamma)/2}, \quad (3.5.24)$$

em que $\mathbb{P}(Z \leq z_{(1+\gamma)/2}) = (1 + \gamma)/2$, desde que a quantidade pivotal Q_n possa ser “pivotada” na desigualdade acima.

3.6 Testes de hipóteses I

Definição 3.6.1. Uma hipótese estatística é uma afirmação ou conjectura a respeito da distribuição de uma ou mais variáveis. Se uma hipótese estatística especifica completamente a distribuição dos dados, então ela é chamada de hipótese simples; caso contrário, ela é chamada de hipótese composta.

Exemplo 3.6.1 (*População normal – variância conhecida*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população $X \sim \mathcal{N}(\theta, 25)$. A hipótese estatística de que a média dessa população normal é menor do que ou igual a 17 é denotada por

$$\mathcal{H} : \theta \leq 17. \quad (3.6.1)$$

Essa hipótese é composta, porque não especifica completamente a distribuição dos dados. Por outro lado, a hipótese

$$\mathcal{H} : \theta = 17 \quad (3.6.2)$$

é simples, já que especifica completamente a distribuição populacional.

Definição 3.6.2. Um teste Υ de uma hipótese estatística $\mathcal{H}$ é uma regra, ou procedimento, para decidir se $\mathcal{H}$ deve ser rejeitada.

Exemplo 3.6.2 (*Cont. Exemplo 1*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população $X \sim \mathcal{N}(\theta, 25)$. Consideremos $\mathcal{H} : \theta \leq 17$.

Um possível teste, Υ , seria rejeitar $\mathcal{H}$ se, e somente se, $\bar{x} > 17 + 5/\sqrt{n}$.

Outro possível teste, Υ' , seria lançar uma moeda e rejeitar $\mathcal{H}$ se, e somente se, o resultado for cara.

Nota: Lembrete: utilizamos $\mathcal{X}$ para denotar o espaço amostral dos dados, ou seja,

$$\mathcal{X} = \{(x_1, x_2, \dots, x_n) \in \mathbb{R}^n \mid f(x_1, x_2, \dots, x_n \mid \theta) > 0\} = \{\mathbf{x} \in \mathbb{R}^n \mid f(\mathbf{x} \mid \theta) > 0\}. \quad (3.6.3)$$

Definição 3.6.3. Seja Υ o teste de uma hipótese $\mathcal{H}$ definido como rejeitar $\mathcal{H}$ se, e somente se, $(x_1, x_2, \dots, x_n) \in \mathcal{C}_\Upsilon$, em que $\mathcal{C}_\Upsilon$ corresponde a um subconjunto de $\mathcal{X}$. Então, Υ é chamado de teste não aleatorizado e $\mathcal{C}_\Upsilon$ é denominada região crítica do teste Υ .

Exemplo 3.6.3 (*Continuação – população normal*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população $X \sim \mathcal{N}(\theta, 25)$. Nesse caso, $\mathcal{X} = \mathbb{R}^n$.

Consideremos $\mathcal{H} : \theta \leq 17$ e o teste Υ : rejeitar $\mathcal{H}$ se, e somente se,

$$\bar{x} > 17 + 5/\sqrt{n}. \quad (3.6.4)$$

Nesse caso, Υ é não aleatorizado, e

$$\mathcal{C}_\Upsilon = \{\mathbf{x} \in \mathcal{X} \mid \bar{x} > 17 + 5/\sqrt{n}\}. \quad (3.6.5)$$

Nota: Um teste não aleatorizado Υ de $\mathcal{H}$ consiste em uma decomposição

$$\mathcal{X} = \mathcal{C}_\Upsilon \cup \bar{\mathcal{C}}_\Upsilon, \quad (3.6.6)$$

com $\mathcal{C}_\Upsilon \cap \bar{\mathcal{C}}_\Upsilon = \emptyset$, de modo que, se uma amostra observada $\mathbf{x} \in \mathcal{C}_\Upsilon$, então rejeita-se $\mathcal{H}$. Assim, um teste não aleatorizado é completamente especificado por sua região crítica correspondente.

Definição 3.6.4. Um teste Υ de uma hipótese $\mathcal{H}$ é chamado de teste aleatorizado se Υ for definido pela função

$$\Psi_{\Upsilon}(\mathbf{x}) = \mathbb{P}(\mathcal{H} \text{ ser rejeitada} \mid \mathbf{x} \text{ é observada}). \quad (3.6.7)$$

A função Ψ_{Υ} é chamada de função crítica do teste Υ .

Exemplo 3.6.4 (*População Bernoulli*). Sejam $X_1, X_2, \dots, X_{10}$ uma A.A. de uma população $X \sim \text{Bernoulli}(\theta)$. Suponha que estejamos interessados em testar a hipótese $\mathcal{H} : \theta < 1/2$.

Um possível teste Υ seria:

- aceitar $\mathcal{H}$ se $\sum_{i=1}^{10} x_i < 5$;
- rejeitar $\mathcal{H}$ se $\sum_{i=1}^{10} x_i > 5$;
- decidir entre rejeitar e aceitar $\mathcal{H}$ com o lançamento de uma moeda, se $\sum_{i=1}^{10} x_i = 5$.

O lançamento da moeda é o ensaio auxiliar de Bernoulli.

Esse teste Υ particiona $\mathcal{X}$ em três regiões:

$$A = \left\{ (x_1, x_2, \dots, x_{10}) \in \mathcal{X} \mid \sum_{i=1}^{10} x_i < 5 \right\}, \quad (3.6.8)$$

$$B = \left\{ (x_1, x_2, \dots, x_{10}) \in \mathcal{X} \mid \sum_{i=1}^{10} x_i = 5 \right\}, \quad (3.6.9)$$

$$C = \left\{ (x_1, x_2, \dots, x_{10}) \in \mathcal{X} \mid \sum_{i=1}^{10} x_i > 5 \right\}. \quad (3.6.10)$$

A função crítica do teste Υ é dada por

$$\Psi_{\Upsilon}(x_1, x_2, \dots, x_{10}) = \begin{cases} 1, & \text{se } (x_1, x_2, \dots, x_{10}) \in C; \\ 1/2, & \text{se } (x_1, x_2, \dots, x_{10}) \in B; \\ 0, & \text{se } (x_1, x_2, \dots, x_{10}) \in A. \end{cases} \quad (3.6.11)$$

Definição 3.6.5. A rejeição de $\mathcal{H}_0$ quando ela é verdadeira é chamada de erro do tipo I, e a aceitação de $\mathcal{H}_0$ quando ela é falsa é chamada de erro do tipo II. O tamanho de um erro do tipo I é definido como a probabilidade de se cometer um erro do tipo I. Similarmente, o tamanho de um erro do tipo II é a probabilidade de se cometer um erro do tipo II.

Definição 3.6.6. Seja Υ um teste com hipótese nula $\mathcal{H}_0$. A função poder do teste Υ , denotada por $\pi_{\Upsilon}(\theta)$, é definida como sendo a probabilidade de que $\mathcal{H}_0$ seja rejeitada quando a distribuição da qual a amostra foi selecionada tem parâmetro θ .

Exemplo 3.6.5 (*Continuação – população normal*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população $X \sim \mathcal{N}(\theta, 25)$.

Consideremos $\mathcal{H}_0 : \theta \leq 17$ e o teste Υ : rejeitar $\mathcal{H}_0$ se, e somente se, $\bar{x} > 17 + 5/\sqrt{n}$. Nesse caso,

$$\pi_{\Upsilon}(\theta) = \mathbb{P}_{\theta}(\bar{X} > 17 + 5/\sqrt{n}) = 1 - \Phi\left(\frac{17 + 5/\sqrt{n} - \theta}{5/\sqrt{n}}\right). \quad (3.6.12)$$

Nota: Pode-se escrever

$$\pi_{\Upsilon}(\theta) = \mathbb{P}_{\theta}(\text{rejeitar } \mathcal{H}_0), \quad (3.6.13)$$

em que θ é o verdadeiro parâmetro.

Se Υ for um teste não aleatorizado, então

$$\pi_{\Upsilon}(\theta) = \mathbb{P}_{\theta}(\mathbf{X} \in \mathcal{C}_{\Upsilon}), \quad (3.6.14)$$

em que $\mathcal{C}_{\Upsilon}$ corresponde à região crítica associada ao teste Υ .

Caso Υ seja um teste aleatorizado com função crítica Ψ_{Υ} , então

$$\begin{aligned} \pi_{\Upsilon}(\theta) &= \mathbb{P}_{\theta}(\text{rejeitar } \mathcal{H}_0) \\ &= \int_{\mathcal{X}} \mathbb{P}_{\theta}(\text{rejeitar } \mathcal{H}_0 \mid \mathbf{x}) f_{\mathbf{X}}(\mathbf{x} \mid \theta) d\mathbf{x} \\ &= \int_{\mathcal{X}} \Psi_{\Upsilon}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x} \mid \theta) d\mathbf{x} \\ &= \mathbb{E}_{\theta}[\Psi_{\Upsilon}(\mathbf{X})]. \end{aligned} \quad (3.6.15)$$

Definição 3.6.7. Seja Υ um teste da hipótese $\mathcal{H}_0 : \theta \in \Theta_0$, em que $\Theta_0 \subset \Theta$. O tamanho do teste Υ de $\mathcal{H}_0$ é definido como

$$\alpha = \sup_{\theta \in \Theta_0} \pi_{\Upsilon}(\theta). \quad (3.6.16)$$

O tamanho do teste no caso não aleatorizado também é conhecido como tamanho da região crítica e, comumente, como nível de significância.

Exemplo 3.6.6 (*Continuação – população normal*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população $X \sim \mathcal{N}(\theta, 25)$.

Consideremos $\mathcal{H}_0 : \theta \leq 17$ e o teste Υ : rejeitar $\mathcal{H}_0$ se, e somente se, $\bar{x} > 17 + 5/\sqrt{n}$.

Nesse caso, $\Theta_0 = \{\theta \in \Theta \mid \theta \leq 17\}$ e o tamanho do teste Υ será

$$\sup_{\theta \in \Theta_0} \pi_{\Upsilon}(\theta) = \sup_{\theta \leq 17} \left[1 - \Phi\left(\frac{17 + 5/\sqrt{n} - \theta}{5/\sqrt{n}}\right) \right] = 1 - \Phi(1) \approx 0,159. \quad (3.6.17)$$

Teorema 3.6.1. Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com f.d.p. $f(x \mid \theta)$, $\theta \in \Theta$, e $(T_1, T_2, \dots, T_s) = (T_1(\mathbf{X}), T_2(\mathbf{X}), \dots, T_s(\mathbf{X}))$ uma estatística suficiente para θ . Então, para qualquer teste Υ com função crítica Ψ_{Υ} , existe um teste, digamos Υ' , e uma função crítica correspondente, digamos $\Psi_{\Upsilon'}$, dependendo somente do conjunto de estatísticas suficientes, que satisfazem $\pi_{\Upsilon}(\theta) = \pi_{\Upsilon'}(\theta)$ para todo $\theta \in \Theta$.

Demonstração. Definamos

$$\Psi_{\Upsilon'}(t_1, t_2, \dots, t_s) = \mathbb{E}[\Psi_{\Upsilon}(X_1, X_2, \dots, X_n) \mid T_1 = t_1, T_2 = t_2, \dots, T_s = t_s]. \quad (3.6.18)$$

Portanto, $\Psi_{\Upsilon'}$ é uma função crítica. Além disso,

$$\begin{aligned} \pi_{\Upsilon'}(\theta) &= \mathbb{E}_{\theta}[\Psi_{\Upsilon'}(T_1, T_2, \dots, T_s)] \\ &= \mathbb{E}_{\theta}\{\mathbb{E}[\Psi_{\Upsilon}(X_1, X_2, \dots, X_n) \mid T_1, T_2, \dots, T_s]\} \\ &= \pi_{\Upsilon}(\theta). \end{aligned} \quad (3.6.19)$$

□

Definição 3.6.8. Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com f.d.p. f_0 ou f_1 . Um teste Υ de $\mathcal{H}_0 : X_i \sim f_0$ versus $\mathcal{H}_1 : X_i \sim f_1$ é chamado de teste da razão de verossimilhanças simples se Υ for caracterizado como

- rejeitar $\mathcal{H}_0$, se $\lambda(\mathbf{x}) < k$;
- aceitar $\mathcal{H}_0$, se $\lambda(\mathbf{x}) > k$;
- aceitar ou rejeitar $\mathcal{H}_0$, ou aleatorizar, se $\lambda(\mathbf{x}) = k$,

em que k é uma constante positiva e

$$\lambda(\mathbf{x}) = \lambda(x_1, x_2, \dots, x_n) = \frac{L(\theta_0 \mid \mathbf{x})}{L(\theta_1 \mid \mathbf{x})} \equiv \frac{L_0}{L_1}. \quad (3.6.20)$$

Definição 3.6.9. Um teste Υ^* de $\mathcal{H}_0 : \theta = \theta_0$ versus $\mathcal{H}_1 : \theta = \theta_1$ é definido ser um teste mais poderoso (TMP) de tamanho α ($0 < \alpha < 1$) se, e somente se,

- (i) $\pi_{\Upsilon^*}(\theta_0) = \alpha$;
- (ii) $\pi_{\Upsilon^*}(\theta_1) \geq \pi_{\Upsilon}(\theta_1)$ para qualquer outro teste Υ tal que $\pi_{\Upsilon}(\theta_0) \leq \alpha$.

Nota: Um teste Υ^* é mais poderoso de tamanho α se o tamanho do seu erro do tipo I for α e o tamanho do seu erro do tipo II for o menor, dentre todos os testes de tamanho α ou menos.

Teorema 3.6.2 (*Lema de Neyman-Pearson*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com f.d.p. $f(x \mid \theta)$, $\theta \in \{\theta_0, \theta_1\}$, e seja $0 < \alpha < 1$ fixado. Denotemos por k^* uma constante positiva e $\mathcal{C}^*$ um subconjunto de $\mathcal{X}$ satisfazendo:

- (i) $\mathbb{P}_{\theta_0}(\mathbf{X} \in \mathcal{C}^*) = \alpha$;
- (ii) $\lambda(\mathbf{x}) = \frac{L(\theta_0 \mid \mathbf{x})}{L(\theta_1 \mid \mathbf{x})} = \frac{L_0}{L_1} \leq k^*$, se $\mathbf{x} \in \mathcal{C}^*$, e $\lambda(\mathbf{x}) \geq k^*$, se $\mathbf{x} \in \bar{\mathcal{C}}^*$, em que $\bar{\mathcal{C}}^* = \mathcal{X} - \mathcal{C}^*$.

Então, o teste Υ^* com região crítica $\mathcal{C}^*$ é um teste mais poderoso de tamanho α para testar $\mathcal{H}_0 : \theta = \theta_0$ vs. $\mathcal{H}_1 : \theta = \theta_1$.

Nota: k^* e $\mathcal{C}^*$ satisfazendo (i) e (ii) no Teorema 2 nem sempre existem e, consequentemente, o teorema pode não fornecer um TMP de tamanho α , pelo menos da forma como foi estabelecido.

Quando a A.A. for composta por v.a.'s contínuas, k^* e $\mathcal{C}^*$ existirão. O problema é quando forem v.a.'s discretas.

Embora o Lema de Neyman-Pearson tenha sido definido apenas para testes não aleatorizados, ele pode ser generalizado, de forma a contemplar também testes aleatorizados.

Exemplo 3.6.7. Sejam $X_1, X_2, \dots, X_n$ uma A.A. oriunda de uma população $X \sim \exp(\theta)$, em que $\theta \in \{\theta_0, \theta_1\}$, com θ_0 e θ_1 números fixados.

Suponhamos aqui que queremos testar $\mathcal{H}_0 : \theta = \theta_0$ vs. $\mathcal{H}_1 : \theta = \theta_1$, e que $\theta_0 < \theta_1$.

Observe que

$$L_k = L(\theta_k \mid \mathbf{x}) = \theta_k^n e^{-\theta_k \sum_{i=1}^n x_i}, \quad k = 0, 1. \quad (3.6.21)$$

Nesse problema, portanto,

$$\begin{aligned} \lambda(\mathbf{x}) &= \frac{L_0}{L_1} = \frac{\theta_0^n e^{-\theta_0 \sum_{i=1}^n x_i}}{\theta_1^n e^{-\theta_1 \sum_{i=1}^n x_i}} \\ &= \left(\frac{\theta_0}{\theta_1}\right)^n \exp \left[(\theta_1 - \theta_0) \sum_{i=1}^n x_i \right]. \end{aligned} \quad (3.6.22)$$

Pelo Lema de Neyman-Pearson, o teste mais poderoso rejeita $\mathcal{H}_0$ se, e somente se, $\lambda(\mathbf{x}) \leq k^*$.

Assim,

$$\begin{aligned} \left(\frac{\theta_0}{\theta_1}\right)^n \exp \left[(\theta_1 - \theta_0) \sum_{i=1}^n x_i \right] &\leq k^* \iff \\ \log \left(\frac{\theta_0}{\theta_1}\right)^n + (\theta_1 - \theta_0) \sum_{i=1}^n x_i &\leq \log k^* \iff \\ \sum_{i=1}^n x_i &\leq \frac{1}{\theta_1 - \theta_0} \log \left[\left(\frac{\theta_1}{\theta_0}\right)^n k^* \right] \equiv k'. \quad (\text{constante}) \end{aligned} \quad (3.6.23)$$

A desigualdade $\lambda(\mathbf{x}) \leq k^*$ foi simplificada e expressa como a desigualdade equivalente $\sum_{i=1}^n x_i \leq k'$.

A condição (i) do Lema de Neyman-Pearson requer

$$\alpha = \mathbb{P}_{\theta_0} \left(\sum_{i=1}^n X_i \leq k' \right). \quad (3.6.24)$$

Observe que

$$\sum_{i=1}^n X_i \sim \text{gama}(n, \theta). \quad (3.6.25)$$

Portanto, o teste mais poderoso de tamanho α de $\mathcal{H}_0 : \theta = \theta_0$ vs. $\mathcal{H}_1 : \theta = \theta_1$ será aquele que rejeita $\mathcal{H}_0$ se $\sum_{i=1}^n x_i \leq k'$.

k' corresponde ao α -ésimo quantil de uma distribuição gama com parâmetros n e θ_0 .

Exemplo 3.6.8. Sejam $X_1, X_2, \dots, X_n$ uma A.A. oriunda de uma população $X \sim \text{Bernoulli}(\theta)$, em que $\theta \in \{\theta_0, \theta_1\}$, com θ_0 e θ_1 números fixados.

Suponhamos aqui que queremos testar $\mathcal{H}_0 : \theta = \theta_0$ vs. $\mathcal{H}_1 : \theta = \theta_1$, e que $\theta_0 < \theta_1$.

Observe que

$$L_k = L(\theta_k | \mathbf{x}) = \theta_k^{\sum_{i=1}^n x_i} (1 - \theta_k)^{n - \sum_{i=1}^n x_i}, \quad k = 0, 1. \quad (3.6.26)$$

Assim,

$$\begin{aligned} \lambda(\mathbf{x}) &= \frac{L_0}{L_1} = \frac{\theta_0^{\sum_{i=1}^n x_i} (1 - \theta_0)^{n - \sum_{i=1}^n x_i}}{\theta_1^{\sum_{i=1}^n x_i} (1 - \theta_1)^{n - \sum_{i=1}^n x_i}} \\ &= \left[\frac{\theta_0(1 - \theta_1)}{(1 - \theta_0)\theta_1} \right]^{\sum_{i=1}^n x_i} \left(\frac{1 - \theta_0}{1 - \theta_1} \right)^n. \end{aligned} \quad (3.6.27)$$

Pelo Lema de Neyman-Pearson, o teste mais poderoso rejeita $\mathcal{H}_0$ se, e somente se, $\lambda(\mathbf{x}) \leq k^*$.

Portanto,

$$\begin{aligned} \left[\frac{\theta_0(1 - \theta_1)}{(1 - \theta_0)\theta_1} \right]^{\sum_{i=1}^n x_i} \left(\frac{1 - \theta_0}{1 - \theta_1} \right)^n &\leq k^* \iff \\ \sum_{i=1}^n x_i \log \left[\frac{\theta_0(1 - \theta_1)}{(1 - \theta_0)\theta_1} \right] + n \log \left(\frac{1 - \theta_0}{1 - \theta_1} \right) &\leq \log k^* \iff \\ \sum_{i=1}^n x_i &\geq \frac{\log \left[k^* \left(\frac{1 - \theta_1}{1 - \theta_0} \right)^n \right]}{\log \left[\frac{\theta_0(1 - \theta_1)}{(1 - \theta_0)\theta_1} \right]} \equiv k'. \quad (\text{constante}) \end{aligned} \quad (3.6.28)$$

Portanto, um teste mais poderoso é aquele que rejeita $\mathcal{H}_0$ se $\sum_{i=1}^n x_i$ for grande.

Para fins de ilustração, suponhamos que $\theta_0 = 1/4$, $\theta_1 = 3/4$ e $n = 10$.

Devemos determinar k' tal que

$$\alpha = \mathbb{P}_{\theta_0=1/4}(\text{rejeitar } \mathcal{H}_0) = \mathbb{P}_{\theta_0=1/4} \left(\sum_{i=1}^{10} X_i \geq k' \right) = \sum_{i=k'}^{10} \binom{10}{i} (1/4)^i (3/4)^{10-i}. \quad (3.6.29)$$

Se $\alpha = 0,0197$, então $k' = 6$; se $\alpha = 0,0781$, então $k' = 5$.

Para $\alpha = 0,05$, não há região crítica $\mathcal{C}^*$ e constante k^* da forma como apresentado no Lema de Neyman-Pearson.

Para v.a.'s discretas, não é possível determinar k^* e $\mathcal{C}^*$ que satisfaçam as condições (i) e (ii) para todo $0 < \alpha < 1$.

Na prática, é comum simplesmente mudar o tamanho do teste para algum α que possa garantir o referido lema. Contudo, é importante destacar que existe um teste (aleatorizado) mais poderoso.

Para o exemplo em questão, se $\alpha = 0,05$, podemos considerar uma função crítica da forma

$$\Psi(\mathbf{x}) = \begin{cases} 1, & \text{se } \sum_{i=1}^{10} x_i \geq 6; \\ \gamma, & \text{se } \sum_{i=1}^{10} x_i = 5; \\ 0, & \text{se } \sum_{i=1}^{10} x_i \leq 4. \end{cases} \quad (3.6.30)$$

Nesse caso,

$$\alpha = \mathbb{E}_{\theta_0=1/4}[\Psi(\mathbf{X})] = 1 \cdot \mathbb{P}_{\theta_0=1/4} \left(\sum_{i=1}^n X_i \geq 6 \right) + \gamma \cdot \mathbb{P}_{\theta_0=1/4} \left(\sum_{i=1}^n X_i = 5 \right). \quad (3.6.31)$$

Então,

$$0,05 = 0,0197 + \gamma \cdot 0,0584, \quad (3.6.32)$$

o que implica que $\gamma = \frac{0,05 - 0,0197}{0,0584} = 0,0303/0,0584$.

Logo,

$$\Psi(\mathbf{x}) = \begin{cases} 1, & \text{se } \sum_{i=1}^{10} x_i \geq 6, \\ 0,0303/0,0584, & \text{se } \sum_{i=1}^{10} x_i = 5 \\ 0, & \text{se } \sum_{i=1}^{10} x_i \leq 4, \end{cases} \quad (3.6.33)$$

é o teste mais poderoso de tamanho $\alpha = 0,05$.

Definição 3.6.10. Seja $\hat{p}$ o menor nível de significância para o qual a hipótese nula $\mathcal{H}_0$ é rejeitada, com base em uma determinada amostra observada. Essa quantidade é chamada de nível descritivo (ou valor- p). Formalmente,

$$\hat{p} = \inf\{\alpha \in (0, 1) \mid \mathbf{x} \in \mathcal{C}_\alpha\}, \quad (3.6.34)$$

em que $\mathcal{C}_\alpha$ é uma região crítica construída com base em um teste de tamanho α , e $\mathbf{x}$ representa o vetor da amostra observada.

Nota: Quanto menor $\hat{p}$, mais evidência temos contra $\mathcal{H}_0$.

Exemplo 3.6.9 (*Cont. – Exemplo 7*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. oriunda de uma população $X \sim \exp(\theta)$, em que $\theta \in \{\theta_0, \theta_1\}$, com $\theta_0 < \theta_1$ números fixados.

Estamos interessados em testar $\mathcal{H}_0 : \theta = \theta_0$ vs. $\mathcal{H}_1 : \theta = \theta_1$.

Suponha que $n = 20$, $\theta_0 = 1$ e $\theta_1 = 2$. Da amostra observada, foi verificado que $\sum_{i=1}^{20} x_i = 6,18$.

Nesse caso, como o teste rejeita $\mathcal{H}_0$ para $\sum_{i=1}^{20} x_i \leq k'$, e $\sum_{i=1}^{20} X_i \sim \text{gama}(20, \theta)$, o nível descritivo será

$$\hat{p} = \mathbb{P}_{\theta=1} \left(\sum_{i=1}^{20} X_i \leq 6,18 \right) \approx 0,0277. \quad (3.6.35)$$

Portanto, ao nível de significância de 5%, rejeitamos a hipótese nula de que $\theta = 1$.

3.7 Testes de hipóteses II

Até o momento, estudamos testes envolvendo hipóteses simples, o que não é usual em situações reais. Agora vamos dar ênfase a testes que envolvem hipóteses compostas.

Vamos trabalhar sob a suposição de que temos uma amostra aleatória oriunda de uma população com f.d.p. (ou f.p., embora bem menos)

$$f(\mathbf{x} \mid \theta), \quad \theta \in \Theta. \quad (3.7.1)$$

Nosso interesse será testar hipóteses $\mathcal{H}_0 : \theta \in \Theta_0$ vs. $\mathcal{H}_1 : \theta \in \Theta_1$, em que $\Theta_0 \subset \Theta$, $\Theta_1 \subset \Theta$, $\Theta_0 \cup \Theta_1 = \Theta$ e $\Theta_0 \cap \Theta_1 = \emptyset$.

Definição 3.7.1 (*Razão de verossimilhanças generalizada – RVG*). Seja $L(\theta | \mathbf{x})$ a função de verossimilhança para uma amostra $X_1, X_2, \dots, X_n$, que tem f.d.p. (ou f.p.) conjunta $f(\mathbf{x} | \theta)$, $\theta \in \Theta$. Chamamos de razão de verossimilhanças generalizada a razão

$$\lambda = \lambda(\mathbf{x}) = \frac{\sup_{\theta \in \Theta_0} L(\theta | \mathbf{x})}{\sup_{\theta \in \Theta} L(\theta | \mathbf{x})}. \quad (3.7.2)$$

Observe que λ é uma função da amostra observada $\mathbf{x}$. Quando a RVG envolver as v.a.'s $\mathbf{X}$, então a denotaremos por $\Lambda = \lambda(\mathbf{X})$. Por vezes, podemos denotar Λ_n ou λ_n , quando quisermos enfatizar o tamanho amostral.

Note também que Λ é uma estatística, por ser uma função de $\mathbf{X}$ que não depende de quantidades desconhecidas.

A partir da Definição 1, temos que $0 \leq \lambda \leq 1$. Uma vez que numerador e denominador não podem ser negativos, $\lambda \geq 0$. Por outro lado, como $\Theta_0 \subset \Theta$, então $\sup_{\theta \in \Theta_0} L(\theta | \mathbf{x}) \leq \sup_{\theta \in \Theta} L(\theta | \mathbf{x})$, que implica $\lambda \leq 1$.

Valores pequenos de λ indicam evidências contra $\mathcal{H}_0$.

Uma generalização natural do teste da razão de verossimilhanças, visto para testar hipóteses simples, seria

$$\lambda^*(\mathbf{x}) = \frac{\sup_{\theta \in \Theta_0} L(\theta | \mathbf{x})}{\sup_{\theta \in \Theta_1} L(\theta | \mathbf{x})}. \quad (3.7.3)$$

Por ser mais simples de se calcular, o teste da razão de verossimilhanças generalizada é adotado na forma de $\lambda(\mathbf{x})$, exibida na Definição 1.

Vale destacar que os testes $\lambda(\mathbf{x})$ e $\lambda^*(\mathbf{x})$ estão relacionados da forma

$$\lambda(\mathbf{x}) = \min\{1, \lambda^*(\mathbf{x})\}. \quad (3.7.4)$$

Nota:

- (1) O parâmetro θ pode ser um escalar ou um vetor. Além disso, numerador e denominador de $\lambda(\mathbf{x})$ correspondem aos EMV's de θ em Θ_0 e Θ , respectivamente, aplicados à função de verossimilhança.

Valores λ da estatística Λ são usados para a tomada de decisão em um teste do tipo $\mathcal{H}_0 : \theta \in \Theta_0$ vs. $\mathcal{H}_1 : \theta \in \Theta_1$. Para isso, utilizamos o princípio do teste da razão de verossimilhanças generalizada: rejeitar $\mathcal{H}_0$ se, e somente se, $\lambda \leq \lambda_0$, em que λ_0 é uma constante tal que $0 < \lambda_0 < 1$. Essa constante é, geralmente, especificada fixando o tamanho do teste.

Alguns pontos negativos do TRVG:

- Às vezes é difícil determinar $\sup L(\theta | \mathbf{x})$;
- Às vezes é difícil determinar a distribuição de Λ , fundamental para calcular o poder do teste.

Nota:

- (1) O desenvolvimento de testes da RVG geralmente começa de uma forma um tanto complicada, até chegar em resultados mais simples.

Nota:

- (1) Por construção, testes da RVG dependem da amostra apenas através de estatísticas suficientes (mínimas).

Definição 3.7.2 (*Testes uniformemente mais poderosos – TUMP*). Um teste Υ^* de $\mathcal{H}_0 : \theta \in \Theta_0$ vs. $\mathcal{H}_1 : \theta \in \Theta_1$ é chamado de teste uniformemente mais poderoso de tamanho α se, e somente se,

- (i) $\sup_{\theta \in \Theta_0} \pi_{\Upsilon^*}(\theta) = \alpha$;
- (ii) $\pi_{\Upsilon^*}(\theta) \geq \pi_{\Upsilon}(\theta)$, para todo $\theta \in \Theta_1$ e para qualquer teste Υ com tamanho menor do que ou igual a α .

Nota:

- (1) O advérbio *uniformemente* está associado aos parâmetros $\theta \in \Theta_1$.

O Lema de Neyman-Pearson é fundamental para mostrarmos que um teste é UMP em casos como esse.

Há formas de estender o resultado apresentado para casos mais gerais. Os Teoremas 1 e 2 apresentados a seguir são fundamentais para isso.

Teorema 3.7.1. Sejam $X_1, X_2, \dots, X_n$ uma A.A. oriunda de uma população com f.d.p. $f(x | \theta)$, $\theta \in \Theta$, em que Θ é algum intervalo. Suponha que $f(x | \theta)$ pertence à família exponencial, ou seja,

$$f(x | \theta) = \exp\{\eta(\theta)T(x) - B(\theta)\}h(x). \quad (3.7.5)$$

Seja $T^*(\mathbf{x}) \equiv \sum_{i=1}^n T(x_i)$.

- (i) Se $\eta(\theta)$ for uma função monótona crescente de θ , e se existir uma constante k^* tal que $\mathbb{P}_{\theta_0}(T^*(\mathbf{X}) > k^*) = \alpha$, então o teste Υ^* com região crítica $\mathcal{C}^* = \{\mathbf{x} \in \mathbb{R}^n | T^*(\mathbf{x}) > k^*\}$ será um teste UMP de tamanho α para $\mathcal{H}_0 : \theta \leq \theta_0$ vs. $\mathcal{H}_1 : \theta > \theta_0$ ou $\mathcal{H}_0 : \theta = \theta_0$ vs. $\mathcal{H}_1 : \theta > \theta_0$;
- (ii) Se $\eta(\theta)$ for uma função monótona decrescente de θ , e se existir uma constante k^* tal que $\mathbb{P}_{\theta_0}(T^*(\mathbf{X}) < k^*) = \alpha$, então o teste Υ^* com região crítica $\mathcal{C}^* = \{\mathbf{x} \in \mathbb{R}^n | T^*(\mathbf{x}) < k^*\}$ será um teste UMP de tamanho α para $\mathcal{H}_0 : \theta \leq \theta_0$ vs. $\mathcal{H}_1 : \theta > \theta_0$ ou $\mathcal{H}_0 : \theta = \theta_0$ vs. $\mathcal{H}_1 : \theta > \theta_0$.

Definição 3.7.3 (*Razão de verossimilhanças monótona*). Uma família de f.d.p.'s $\{f(x | \theta) | \theta \in \Theta, \Theta \text{ intervalo}\}$ é dita ter razão de verossimilhanças monótona se, de uma amostra $X_1, X_2, \dots, X_n$, houver uma estatística $T \equiv T(\mathbf{X})$ tal que $\frac{L(\theta' | \mathbf{x})}{L(\theta'' | \mathbf{x})}$ seja uma função não crescente de $T(\mathbf{x})$, para todo $\theta' < \theta''$, ou uma função não decrescente de $T(\mathbf{x})$, para todo $\theta' < \theta''$.

Nota:

- (1) A razão de verossimilhanças monótona é apenas uma razão de duas funções de verossimilhança, e não uma razão de verossimilhanças generalizada.

Teorema 3.7.2. Sejam $X_1, X_2, \dots, X_n$ uma A.A. oriunda de uma população com f.d.p. $f(x | \theta)$, em que Θ é um intervalo. Suponha que a família de f.d.p.'s $\{f(x | \theta) | \theta \in \Theta\}$ tenha razão de verossimilhanças monótona na estatística $T(\mathbf{X})$. Nesse caso:

- (i) Se a razão de verossimilhanças monótona for não decrescente em $T(\mathbf{X})$, e se k^* for tal que $\mathbb{P}_{\theta_0}(T(\mathbf{X}) < k^*) = \alpha$, então o teste correspondendo à região crítica $\mathcal{C}^* = \{\mathbf{x} \in \mathbb{R}^n | T(\mathbf{x}) < k^*\}$ será UMP de tamanho α para $\mathcal{H}_0 : \theta \leq \theta_0$ vs. $\mathcal{H}_1 : \theta > \theta_0$;
- (ii) Se a razão de verossimilhanças monótona for não crescente em $T(\mathbf{x})$, e se k^* for tal que $\mathbb{P}_{\theta_0}(T(\mathbf{X}) > k^*) = \alpha$, então o teste correspondendo à região crítica $\mathcal{C}^* = \{\mathbf{x} \in \mathbb{R}^n | T(\mathbf{x}) > k^*\}$ será UMP de tamanho α para $\mathcal{H}_0 : \theta \leq \theta_0$ vs. $\mathcal{H}_1 : \theta > \theta_0$.

Nota:

- (1) As hipóteses utilizadas nos Teoremas 1 e 2 são do tipo $\mathcal{H}_0 : \theta \leq \theta_0$ vs. $\mathcal{H}_1 : \theta > \theta_0$. Contudo, esses mesmos teoremas podem ser reformulados para hipóteses na forma $\mathcal{H}_0 : \theta \geq \theta_0$ vs. $\mathcal{H}_1 : \theta < \theta_0$, desde que os sinais de desigualdade das regiões críticas sejam invertidos.

Nota:

- (1) Os referidos teoremas consideram apenas hipóteses unilaterais.

Vimos que testes UMP existem para hipóteses unilaterais, quando a razão de verossimilhanças é monótona em alguma estatística.

Há vários problemas de testes de hipóteses em que não há um teste UMP.

Podemos pensar, portanto, em restringir a classe de testes, com o intuito de determinar um teste ótimo. Nesse caso, uma alternativa interessante corresponde aos testes não viesados.

Definição 3.7.4. Um teste Υ da hipótese nula $\mathcal{H}_0 : \theta \in \Theta_0$ vs. a hipótese alternativa $\mathcal{H}_1 : \theta \in \Theta_1$ é chamado de teste não viesado se, e somente se,

$$\sup_{\theta \in \Theta_0} \pi_{\Upsilon}(\theta) \leq \inf_{\theta \in \Theta_1} \pi_{\Upsilon}(\theta). \quad (3.7.6)$$

Para testes não viesados, a probabilidade de rejeitar $\mathcal{H}_0$, quando essa hipótese for verdadeira, nunca será superior à probabilidade de rejeitá-la quando ela for falsa.

Se um teste não viesado for UMP, então ele será chamado de teste não viesado uniformemente mais poderoso.

Não entraremos em detalhe sobre essa classe de testes.

Suponhamos que a amostra aleatória $X_1, X_2, \dots, X_n$ seja oriunda de uma população $X \sim \mathcal{N}(\mu, \sigma^2)$.

Vamos analisar testes de hipóteses para a média μ e para a variância σ^2 .
O mais comum é estarmos interessados em testes unilaterais ou bilaterais.
No caso dos testes unilaterais, vamos abordar $\mathcal{H}_0 : \mu \leq \mu_0$ vs. $\mathcal{H}_1 : \mu > \mu_0$.
Há dois casos a serem considerados:

- σ^2 conhecido;
- σ^2 desconhecido.

Teorema 3.7.3 ($\mathcal{H}_0 : \mu \leq \mu_0$ vs. $\mathcal{H}_1 : \mu > \mu_0$ - σ^2 conhecido). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população $X \sim \mathcal{N}(\mu, \sigma^2)$, com σ^2 conhecido. Nesse caso, o espaço paramétrico corresponderá ao conjunto dos reais. Além disso,

$$\begin{aligned} f(x | \mu) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2}(x - \mu)^2 \right\} \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2}x^2 + \frac{\mu}{\sigma^2}x - \frac{\mu^2}{2\sigma^2} \right\} \\ &= \exp \left\{ \frac{\mu}{\sigma^2}x - \frac{\mu^2}{2\sigma^2} \right\} \frac{\exp \left\{ -\frac{x^2}{2\sigma^2} \right\}}{\sqrt{2\pi\sigma^2}} \\ &= \exp \{ \eta(\mu)T(x) - B(\mu) \} h(x). \end{aligned} \quad (3.7.7)$$

Como $\eta(\mu) = \mu/\sigma^2$ é uma função crescente de μ , então, pelo Teorema 1, o teste UMP é aquele que rejeita $\mathcal{H}_0$ se, e somente se, $\sum_{i=1}^n x_i > k^*$, em que a constante k^* é dada pela solução de

$$\alpha = \mathbb{P}_{\mu_0} \left(\sum_{i=1}^n X_i > k^* \right) = 1 - \Phi \left(\frac{k^* - n\mu_0}{\sqrt{n}\sigma} \right). \quad (3.7.8)$$

Portanto, $\frac{k^* - n\mu_0}{\sqrt{n}\sigma} = z_{1-\alpha}$, em que $z_{1-\alpha}$ corresponde ao $(1 - \alpha)$ -ésimo quantil da distribuição normal padrão.

Desse modo, o teste UMP rejeita $\mathcal{H}_0$ se $\sum_{i=1}^n x_i > n\mu_0 + \sqrt{n}\sigma z_{1-\alpha}$ ou, de forma equivalente, rejeita $\mathcal{H}_0$ se $\bar{x} > \mu_0 + \frac{\sigma}{\sqrt{n}} z_{1-\alpha}$.

Teorema 3.7.4 ($\mathcal{H}_0 : \mu \leq \mu_0$ vs. $\mathcal{H}_1 : \mu > \mu_0$ - σ^2 desconhecido). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população $X \sim \mathcal{N}(\mu, \sigma^2)$, com σ^2 desconhecido. Nesse caso, $\Theta = \{(\mu, \sigma^2) \in \mathbb{R}^2 \mid -\infty < \mu < \infty; \sigma^2 > 0\}$ e $\Theta_0 = \{(\mu, \sigma^2) \in \mathbb{R}^2 \mid \mu \leq \mu_0; \sigma^2 > 0\}$.

No caso em que $(\mu, \sigma^2) \in \Theta$, temos que os EMV's de μ e σ^2 correspondem a $\hat{\mu} = \bar{X}$ e $\hat{\sigma}^2 = \sum_{i=1}^n (X_i - \bar{X})^2/n$, respectivamente. Assim,

$$\begin{aligned} \sup_{(\mu, \sigma^2) \in \Theta} L(\mu, \sigma^2 | \mathbf{x}) &= L(\hat{\mu}, \hat{\sigma}^2 | \mathbf{x}) = \frac{1}{(2\pi\hat{\sigma}^2)^{n/2}} \exp \left[-\frac{1}{2\hat{\sigma}^2} \sum_{i=1}^n (x_i - \hat{\mu})^2 \right] \\ &= \left[\frac{n}{2\pi \sum_{i=1}^n (x_i - \bar{x})^2} \right]^{n/2} \exp \left(-\frac{n}{2} \right). \end{aligned} \quad (3.7.9)$$

Quando $(\mu, \sigma^2) \in \Theta_0$, pode-se mostrar (mostre!) que os EMV's dos parâmetros serão

$$\tilde{\mu} = \begin{cases} \bar{X}, & \text{se } \bar{X} \leq \mu_0; \\ \mu_0, & \text{se } \bar{X} > \mu_0 \end{cases} \quad \text{e} \quad \tilde{\sigma}^2 = \begin{cases} \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2, & \text{se } \bar{X} \leq \mu_0; \\ \frac{1}{n} \sum_{i=1}^n (X_i - \mu_0)^2, & \text{se } \bar{X} > \mu_0. \end{cases} \quad (3.7.10)$$

Desse modo,

$$\begin{aligned} \sup_{(\mu, \sigma^2) \in \Theta_0} L(\mu, \sigma^2 \mid \mathbf{x}) &= L(\tilde{\mu}, \tilde{\sigma}^2 \mid \mathbf{x}) = \frac{1}{(2\pi\tilde{\sigma}^2)^{n/2}} \exp \left[-\frac{1}{2\tilde{\sigma}^2} \sum_{i=1}^n (x_i - \tilde{\mu})^2 \right] \\ &= \begin{cases} \left[\frac{n}{2\pi \sum_{i=1}^n (x_i - \bar{x})^2} \right]^{n/2} \exp \left(-\frac{n}{2} \right), & \text{se } \bar{x} \leq \mu_0; \\ \left[\frac{n}{2\pi \sum_{i=1}^n (x_i - \mu_0)^2} \right]^{n/2} \exp \left(-\frac{n}{2} \right), & \text{se } \bar{x} > \mu_0. \end{cases} \end{aligned} \quad (3.7.11)$$

A razão de verossimilhanças será

$$\begin{aligned} \lambda(\mathbf{x}) &= \frac{\sup_{(\mu, \sigma^2) \in \Theta_0} L(\mu, \sigma^2 \mid \mathbf{x})}{\sup_{(\mu, \sigma^2) \in \Theta} L(\mu, \sigma^2 \mid \mathbf{x})} \\ &= \begin{cases} 1, & \text{se } \bar{x} \leq \mu_0; \\ \left[\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \mu_0)^2} \right]^{n/2}, & \text{se } \bar{x} > \mu_0. \end{cases} \end{aligned} \quad (3.7.12)$$

Antes de continuarmos, observe que

$$\begin{aligned} \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \mu_0)^2} &= \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x} + \bar{x} - \mu_0)^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu_0)^2} \\ &= \frac{1}{1 + n \frac{(\bar{x} - \mu_0)^2}{\sum_{i=1}^n (x_i - \bar{x})^2}} = \frac{1}{1 + n \frac{(\bar{x} - \mu_0)^2}{(n-1)s^2}} = \frac{1}{1 + \frac{1}{n-1} \frac{(\bar{x} - \mu_0)^2}{s^2/n}} \\ &= \left[1 + \frac{1}{n-1} \frac{(\bar{x} - \mu_0)^2}{s^2/n} \right]^{-1} = \left(1 + \frac{t^2}{n-1} \right)^{-1}, \end{aligned} \quad (3.7.13)$$

em que $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$. Logo,

$$\lambda(\mathbf{x}) = \begin{cases} 1, & \text{se } \bar{x} \leq \mu_0; \\ \left(1 + \frac{t^2}{n-1} \right)^{-n/2}, & \text{se } \bar{x} > \mu_0. \end{cases} \quad (3.7.14)$$

Desse modo, para $0 < \lambda_0 < 1$, rejeitamos $\mathcal{H}_0$ se, e somente se,

$$\lambda(\mathbf{x}) \leq \lambda_0 \iff t \geq k. \quad (3.7.15)$$

Denotemos $T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$. Sabemos que, se $\mu = \mu_0$, então $T \sim t_{n-1}$. Portanto, o valor de k é tal que

$$\alpha = \mathbb{P}_{\mu_0}(T \geq k) = \mathbb{P}_{\mu_0}(T \geq t_{n-1, 1-\alpha}), \quad (3.7.16)$$

em que $t_{n-1,1-\alpha}$ corresponde ao $(1 - \alpha)$ -ésimo quantil de uma t_{n-1} .

O teste rejeita $\mathcal{H}_0$ se, e somente se,

$$\frac{\bar{x} - \mu_0}{s/\sqrt{n}} \geq t_{n-1,1-\alpha}, \quad (3.7.17)$$

ou, de forma equivalente,

$$\bar{x} \geq \mu_0 + \frac{s}{\sqrt{n}} t_{n-1,1-\alpha}. \quad (3.7.18)$$

Teorema 3.7.5 ($\mathcal{H}_0 : \mu = \mu_0$ vs. $\mathcal{H}_1 : \mu \neq \mu_0 - \sigma^2$ desconhecido). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população $X \sim \mathcal{N}(\mu, \sigma^2)$, com σ^2 desconhecido. No caso em que σ^2 for desconhecido, o espaço paramétrico irrestrito e o espaço paramétrico sob $\mathcal{H}_0$ serão $\Theta = \{(\mu, \sigma^2) \in \mathbb{R}^2 \mid -\infty < \mu < \infty; \sigma^2 > 0\}$ e $\Theta_0 = \{(\mu, \sigma^2) \in \mathbb{R}^2 \mid \mu = \mu_0; \sigma^2 > 0\}$.

Já vimos que

$$\sup_{(\mu, \sigma^2) \in \Theta} L(\mu, \sigma^2 \mid \mathbf{x}) = \left[\frac{n}{2\pi \sum_{i=1}^n (x_i - \bar{x})^2} \right]^{n/2} \exp\left(-\frac{n}{2}\right). \quad (3.7.19)$$

Quando $(\mu, \sigma^2) \in \Theta_0$, não é difícil verificar (verifique!) que os EMV's dos parâmetros são, respectivamente,

$$\tilde{\mu} = \mu_0 \quad \text{e} \quad \tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu_0)^2. \quad (3.7.20)$$

Logo,

$$\begin{aligned} \sup_{(\mu, \sigma^2) \in \Theta_0} L(\mu, \sigma^2 \mid \mathbf{x}) &= L(\tilde{\mu}, \tilde{\sigma}^2 \mid \mathbf{x}) = \frac{1}{(2\pi\tilde{\sigma}^2)^{n/2}} \exp\left[-\frac{1}{2\tilde{\sigma}^2} \sum_{i=1}^n (x_i - \tilde{\mu})^2\right] \\ &= \left[\frac{n}{2\pi \sum_{i=1}^n (x_i - \mu_0)^2} \right]^{n/2} \exp\left(-\frac{n}{2}\right). \end{aligned} \quad (3.7.21)$$

De forma análoga ao que vimos anteriormente,

$$\begin{aligned} \lambda(\mathbf{x}) &= \frac{\sup_{(\mu, \sigma^2) \in \Theta_0} L(\mu, \sigma^2 \mid \mathbf{x})}{\sup_{(\mu, \sigma^2) \in \Theta} L(\mu, \sigma^2 \mid \mathbf{x})} = \left[\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \mu_0)^2} \right]^{n/2} \\ &= \left(1 + \frac{t^2}{n-1} \right)^{-n/2}, \end{aligned} \quad (3.7.22)$$

em que $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$.

Assim, para $0 < \lambda_0 < 1$,

$$\begin{aligned} \left(1 + \frac{t^2}{n-1} \right)^{-n/2} &\leq \lambda_0 \iff \\ |t| &\geq \sqrt{(n-1) \left(\lambda_0^{-2/n} - 1 \right)} \equiv k \iff \\ t &\leq -k \quad \text{ou} \quad t \geq k. \end{aligned} \quad (3.7.23)$$

Denotemos $T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$. Sabemos que, sob $\mathcal{H}_0$, $T \sim t_{n-1}$.

O valor de k será solução de

$$\begin{aligned}\alpha &= \mathbb{P}_{\mu_0}([T \leq -k] \text{ ou } [T \geq k]) = \mathbb{P}_{\mu_0}(T \leq -k) + \mathbb{P}_{\mu_0}(T \geq k) \\ &= 2\mathbb{P}_{\mu_0}(T \geq k).\end{aligned}\tag{3.7.24}$$

Portanto, $k = t_{n-1, 1-\alpha/2}$.

Desse modo, o teste da RVG rejeita $\mathcal{H}_0$ se, e somente se,

$$t \leq -t_{n-1, 1-\alpha/2} \quad \text{ou} \quad t \geq t_{n-1, 1-\alpha/2},\tag{3.7.25}$$

ou seja,

$$\bar{x} \leq \mu_0 - t_{n-1, 1-\alpha/2} \frac{s}{\sqrt{n}} \quad \text{ou} \quad \bar{x} \geq \mu_0 + t_{n-1, 1-\alpha/2} \frac{s}{\sqrt{n}}.\tag{3.7.26}$$

Vale destacar que esse teste não é UMP. Por outro lado, pode-se mostrar que é um teste não viesado uniformemente mais poderoso.

Assim como feito para testes para a média, vamos abordar testes unilaterais do tipo $\mathcal{H}_0 : \sigma^2 \leq \sigma_0^2$ vs. $\mathcal{H}_1 : \sigma^2 > \sigma_0^2$, bem como testes bilaterais.

Há dois casos a serem considerados:

- μ conhecido;
- μ desconhecido.

Teorema 3.7.6 ($\mathcal{H}_0 : \sigma^2 \leq \sigma_0^2$ vs. $\mathcal{H}_1 : \sigma^2 > \sigma_0^2 - \mu$ conhecido). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população $X \sim \mathcal{N}(\mu, \sigma^2)$, com μ conhecido. Nesse caso, o espaço paramétrico será um intervalo (conjunto dos reais positivos). Além disso,

$$\begin{aligned}f(x | \mu) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2}(x - \mu)^2 \right\} \\ &= \exp \left\{ -\frac{1}{2\sigma^2}(x - \mu)^2 - \frac{1}{2} \log \sigma^2 \right\} \frac{1}{\sqrt{2\pi}} \\ &= \exp\{\eta(\sigma^2)T(x) - B(\sigma^2)\}h(x).\end{aligned}\tag{3.7.27}$$

Seja $R = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma_0} \right)^2$. Já sabemos que, se a verdadeira variância for σ_0^2 , então $R \sim \chi_n^2$.

Observe que $\eta(\sigma^2) = -1/(2\sigma^2)$ é uma função crescente de σ^2 . Pelo Teorema 1, o teste UMP rejeita $\mathcal{H}_0$ se, e somente se, $\sum_{i=1}^n (x_i - \mu)^2 > k^*$, em que k^* é solução de

$$\alpha = \mathbb{P}_{\sigma_0^2} \left(\sum_{i=1}^n (X_i - \mu)^2 > k^* \right) = \mathbb{P}_{\sigma_0^2} (R > k^*/\sigma_0^2) = \mathbb{P}_{\sigma_0^2} (R > \chi_{n, 1-\alpha}^2).\tag{3.7.28}$$

Portanto, $\frac{k^*}{\sigma_0^2} = \chi_{n, 1-\alpha}^2$.

Assim, o teste UMP rejeita $\mathcal{H}_0$ se, e somente se, $\sum_{i=1}^n (x_i - \mu)^2 > \sigma_0^2 \chi_{n, 1-\alpha}^2$.

Teorema 3.7.7 ($\mathcal{H}_0 : \sigma^2 = \sigma_0^2$ vs. $\mathcal{H}_1 : \sigma^2 \neq \sigma_0^2 - \mu$ desconhecido). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população $X \sim \mathcal{N}(\mu, \sigma^2)$, com μ desconhecido. Nesse caso, $\Theta = \{(\mu, \sigma^2) \in \mathbb{R}^2 \mid -\infty < \mu < \infty; \sigma^2 > 0\}$ e $\Theta_0 = \{(\mu, \sigma^2) \in \mathbb{R}^2 \mid -\infty < \mu < \infty; \sigma^2 = \sigma_0^2\}$.

Já vimos que

$$\sup_{(\mu, \sigma^2) \in \Theta} L(\mu, \sigma^2 \mid \mathbf{x}) = \left(\frac{1}{2\pi\hat{\sigma}^2} \right)^{n/2} \exp\left(-\frac{n}{2}\right). \quad (3.7.29)$$

Quando $(\mu, \sigma^2) \in \Theta_0$, não é difícil verificar (verifique!) que os EMV's dos parâmetros são, respectivamente,

$$\tilde{\mu} = \bar{X} \quad \text{e} \quad \tilde{\sigma}^2 = \sigma_0^2. \quad (3.7.30)$$

Logo,

$$\begin{aligned} \sup_{(\mu, \sigma^2) \in \Theta_0} L(\mu, \sigma^2 \mid \mathbf{x}) &= L(\tilde{\mu}, \tilde{\sigma}^2 \mid \mathbf{x}) = \frac{1}{(2\pi\tilde{\sigma}^2)^{n/2}} \exp\left[-\frac{1}{2\tilde{\sigma}^2} \sum_{i=1}^n (x_i - \tilde{\mu})^2\right] \\ &= \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left[-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \bar{x})^2\right] = \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{n\hat{\sigma}^2}{2\sigma_0^2}\right). \end{aligned} \quad (3.7.31)$$

Assim,

$$\begin{aligned} \lambda(\mathbf{x}) &= \frac{\sup_{(\mu, \sigma^2) \in \Theta_0} L(\mu, \sigma^2 \mid \mathbf{x})}{\sup_{(\mu, \sigma^2) \in \Theta} L(\mu, \sigma^2 \mid \mathbf{x})} = \left(\frac{\hat{\sigma}^2}{\sigma_0^2} \right)^{n/2} \exp\left(-\frac{n}{2} \frac{\hat{\sigma}^2}{\sigma_0^2} + \frac{n}{2}\right) \\ &\equiv y^{n/2} \exp\left[-\frac{n}{2}(y - 1)\right], \end{aligned} \quad (3.7.32)$$

em que $y = \frac{\hat{\sigma}^2}{\sigma_0^2}$.

Assim, para $0 < \lambda_0 < 1$,

$$\begin{aligned} y^{n/2} \exp\left[-\frac{n}{2}(y - 1)\right] &\leq \lambda_0 \iff \\ y &\leq k_1 \quad \text{ou} \quad y \geq k_2, \end{aligned} \quad (3.7.33)$$

em que $y = \frac{\hat{\sigma}^2}{\sigma_0^2}$.

Seja $V = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma_0^2}$. Nesse caso, sob $\mathcal{H}_0$, $V \sim \chi_{n-1}^2$. Além disso, note que

$$\frac{\hat{\sigma}^2}{\sigma_0^2} = \frac{V}{n}.$$

Assim, os valores de k_1 e k_2 são soluções de

$$\begin{aligned} \alpha &= \mathbb{P}_{\sigma_0^2} \left(\left[\frac{\hat{\sigma}^2}{\sigma_0^2} \leq k_1 \right] \text{ ou } \left[\frac{\hat{\sigma}^2}{\sigma_0^2} \geq k_2 \right] \right) = \mathbb{P}_{\sigma_0^2} \left(\left[\frac{V}{n} \leq k_1 \right] \text{ ou } \left[\frac{V}{n} \geq k_2 \right] \right) \\ &= \mathbb{P}_{\sigma_0^2}(V \leq nk_1) + \mathbb{P}_{\mu_0}(V \geq nk_2) \\ &= \mathbb{P}_{\sigma_0^2}(V \leq \chi_{n-1, \alpha/2}^2) + \mathbb{P}_{\mu_0}(V \geq \chi_{n-1, 1-\alpha/2}^2) \quad (\text{uma possibilidade}). \end{aligned} \quad (3.7.34)$$

Nesse caso mais simples (que não é o melhor!), temos

$$k_1 = \frac{\chi_{n-1, \alpha/2}^2}{n} \quad \text{e} \quad k_2 = \frac{\chi_{n-1, 1-\alpha/2}^2}{n}. \quad (3.7.35)$$

Desse modo, o teste rejeita $\mathcal{H}_0$ se, e somente se,

$$\frac{\hat{\sigma}^2}{\sigma_0^2} \leq \frac{\chi_{n-1, \alpha/2}^2}{n} \quad \text{ou} \quad \frac{\hat{\sigma}^2}{\sigma_0^2} \geq \frac{\chi_{n-1, 1-\alpha/2}^2}{n}, \quad (3.7.36)$$

em que $\chi_{r, \beta}^2$ corresponde ao β -ésimo quantil de uma distribuição χ_r^2 .

À medida que o número de parâmetros do modelo aumenta, torna-se mais complicada a tarefa de estabelecer testes da RVG.

Por vezes, essa tarefa não é tão simples nem mesmo em situações uniparamétricas.

Uma forma de contornar esse problema é através de aproximação.

Teorema 3.7.8. Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com f.d.p. (ou f.p.) $f(x \mid \theta)$, em que θ pode ser escalar ou vetor. Sob certas condições de regularidade, se $\theta \in \Theta_0$, então

$$-2 \log \Lambda_n \xrightarrow{\mathcal{D}} \chi_r^2, \quad (3.7.37)$$

quando $n \rightarrow \infty$. O número de graus de liberdade r corresponde ao número de restrições em Θ_0 .

Nota:

- (1) O número de graus de liberdade r também pode ser interpretado como a dimensão de Θ menos a dimensão de Θ_0 .

Lembrando que Λ_n é uma v.a. que assume valores do tipo

$$\lambda_n = \frac{\sup_{\theta \in \Theta_0} L(\theta \mid \mathbf{x})}{\sup_{\theta \in \Theta} L(\theta \mid \mathbf{x})}, \quad (3.7.38)$$

que corresponde à RVG para uma amostra observada $\mathbf{x} = (x_1, x_2, \dots, x_n)$.

O princípio da RVG sugere que rejeitemos $\mathcal{H}_0$ para valores pequenos de λ_n . Portanto, no caso assintótico, o teste deve rejeitar a hipótese nula para valores grandes de $-2 \log \lambda_n$.

Levando em consideração a distribuição assintótica quando $\mathcal{H}_0$ for verdadeira, um teste com tamanho aproximadamente α rejeita $\mathcal{H}_0$ se, e somente se,

$$-2 \log \lambda_n \geq \chi_{r, 1-\alpha}^2, \quad (3.7.39)$$

em que $\chi_{r, 1-\alpha}^2$ corresponde ao $(1 - \alpha)$ -ésimo quantil de uma distribuição χ_r^2 .

Capítulo 4

Normal multivariada

4.1 Distribuição normal multivariada

Definição 4.1.1 (*Distribuição normal*). O vetor $\mathbf{X}_{p \times 1} = (X_1, \dots, X_p)^\top$ tem distribuição normal multivariada (p -variada) se sua fdp é dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}, \quad (4.1.1)$$

com $-\infty < x_i < \infty$, $i = 1, 2, \dots, p$ e $\boldsymbol{\Sigma}$ uma matriz positiva definida.

Nota:

- (1) Notação: $\mathbf{X}_p \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

Definição 4.1.2 (*Definição alternativa*). $\mathbf{X}$ tem distribuição normal p -variada se e somente se $\mathbf{a}^\top \mathbf{X}$ tem distribuição normal univariada, para qualquer vetor fixo $\mathbf{a}_{p \times 1}$.

Nota:

- (1) Se $\mathbf{X}$ é considerado um ponto aleatório no espaço p -dimensional, então $\mathbf{a}^\top \mathbf{X}$ pode ser considerado uma projeção de $\mathbf{X}$ em um subespaço unidimensional.

Teorema 4.1.1 (*Propriedades da Normal Multivariada*). Seja $\mathbf{X} \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

- (1) Função característica: $\varphi_x(\mathbf{t}) = \exp \left\{ i \mathbf{t}^\top \boldsymbol{\mu} - \frac{1}{2} \mathbf{t}^\top \boldsymbol{\Sigma} \mathbf{t} \right\}$, $\boldsymbol{\Sigma} > 0$
- (2) Elementos e subconjuntos: Cada X_i e qualquer subconjunto de elementos tem distribuição normal univariada ($\boldsymbol{\Sigma}$ é suposta de posto completo).

Teorema 4.1.2 (*Independência*). Sejam $\mathbf{X}_{p \times 1}$ e $\mathbf{Y}_{q \times 1}$ vetores aleatórios com distribuição normal multivariada.

- (1) $\mathbf{X}$ e $\mathbf{Y}$ são independentes $\iff \text{Cov}[\mathbf{X}, \mathbf{Y}] = \mathbf{0}$.

- (2) Se $\mathbf{X}$ e $\mathbf{Y}$ são conjuntamente normais, a independência de todos os pares (X_i, Y_j) , $i = 1, \dots, p$, $j = 1, \dots, q$, implica na independência de $\mathbf{X}$ e $\mathbf{Y}$.
- (3) Se $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ e $\mathbf{A}$ e $\mathbf{B}$ são duas matrizes fixas, então $\mathbf{AX}$ e $\mathbf{BX}$ são independentes se e somente se $\mathbf{A}\boldsymbol{\Sigma}\mathbf{B}^\top = \mathbf{0}$.
- (4) Considere $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ e a partição

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_{1(q \times 1)} \\ \mathbf{X}_{2((p-q) \times 1)} \end{bmatrix} \sim \mathcal{N}_p \left(\begin{bmatrix} \boldsymbol{\mu}_{1(q \times 1)} \\ \boldsymbol{\mu}_{2((p-q) \times 1)} \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix} \right). \quad (4.1.2)$$

Então $\mathbf{X}_1$ e $\mathbf{X}_2$ são independentes se e somente se $\boldsymbol{\Sigma}_{12} = \mathbf{0}$.

Teorema 4.1.3 (*Transformações*). Seja $\mathbf{X} \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ com $\boldsymbol{\Sigma} > \mathbf{0}$.

- (1) $\mathbf{Y}_{q \times 1} = \mathbf{A}_{q \times p} \mathbf{X} + \mathbf{b}_{q \times 1} \sim \mathcal{N}_q(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top)$
- (a) Se $\mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top$ é diagonal, então os elementos de $\mathbf{Y}$ são normais independentes.
- (2) $Y = \mathbf{a}_{1 \times p}^\top \mathbf{X} \sim \mathcal{N}(\mathbf{a}^\top \boldsymbol{\mu}, \mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a})$
- (3) $\mathbf{Z} = \boldsymbol{\Sigma}^{-1}(\mathbf{X} - \boldsymbol{\mu}) \implies \mathbf{Z} \sim \mathcal{N}_p(\mathbf{0}, \mathbf{I})$
- $$(\mathbf{X} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{X} - \boldsymbol{\mu}) = \sum_{i=1}^p Z_i^2 \sim \chi_p^2$$
- $$\mathbb{P}[(\mathbf{X} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{X} - \boldsymbol{\mu}) \leq \chi_{p,\alpha}^2] = 1 - \alpha$$
- (a) A quantidade $(\mathbf{X} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{X} - \boldsymbol{\mu})$ é chamada de Distância de Mahalanobis entre $\mathbf{X}$ e $\boldsymbol{\mu}$.
- (4) Suponha que $\mathbf{X}_i \sim \mathcal{N}(\mathbf{m}_i, \mathbf{V}_i)$ independentes, $i = 1, \dots, k$, e considere $\mathbf{A}_1, \dots, \mathbf{A}_k$ e $\mathbf{b}$ de dimensões adequadas.

$$\mathbf{Y} = \sum_{i=1}^k \mathbf{A}_i \mathbf{X}_i + \mathbf{b} \sim \mathcal{N} \left(\sum_{i=1}^k \mathbf{A}_i \mathbf{m}_i + \mathbf{b}, \sum_{i=1}^k \mathbf{A}_i \mathbf{V}_i \mathbf{A}_i^\top \right) \quad (4.1.3)$$

Teorema 4.1.4 (*Propriedade*). Os contornos de densidade constante no caso normal multivariado são elipsoides definidos por $\mathbf{x}$ tais que

$$(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = c^2. \quad (4.1.4)$$

Esses elipsoides têm centro em $\boldsymbol{\mu}$ e eixos em $\pm c\sqrt{\lambda_i} \mathbf{e}_i$ em que $(\lambda_i, \mathbf{e}_i)$ é um par de autovalor-autovetor de $\boldsymbol{\Sigma}$.

Teorema 4.1.5. Suponha que $\mathbf{X}$ seja particionado como segue:

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}, \quad \mathbf{m} = \begin{bmatrix} \mathbf{m}_1 \\ \mathbf{m}_2 \end{bmatrix}, \quad \mathbf{V} = \begin{bmatrix} \mathbf{V}_{11} & \mathbf{V}_{12} \\ \mathbf{V}_{21} & \mathbf{V}_{22} \end{bmatrix}.$$

- (1) $\mathbf{X}_i \sim \mathcal{N}(\mathbf{m}_i, \mathbf{V}_{ii})$, $i = 1, 2$. Em particular, se X_i é normal univariado, então $X_i \sim \mathcal{N}(m_i, V_{ii})$, para $i = 1 \dots, n$;
- (2) $(\mathbf{X}_1 | \mathbf{X}_2) \sim \mathcal{N}(\boldsymbol{\mu}_{12}, \mathbf{C}_{12})$ onde

$$\boldsymbol{\mu}_{12} = \mathbf{m}_1 + \mathbf{V}_{12} \mathbf{V}_{22}^{-1} (\mathbf{X}_2 - \mathbf{m}_2) \quad (4.1.5)$$

$$= \mathbf{m}_1 + \mathbf{A}_1 (\mathbf{X}_2 - \mathbf{m}_2) \quad (4.1.6)$$

e

$$\mathbf{C}_{12} = \mathbf{V}_{11} - \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{21} \quad (4.1.7)$$

$$= \mathbf{V}_{11} - \mathbf{A}_1 \mathbf{V}_{22} \mathbf{A}_1^\top \quad (4.1.8)$$

A matriz $\mathbf{A}_1 = \mathbf{V}_{12} \mathbf{V}_{22}^{-1}$ é chamada de *matriz de regressão* de $\mathbf{X}_1$ em $\mathbf{X}_2$.

- (3) $(\mathbf{X}_2 | \mathbf{X}_1) \sim \mathcal{N}(\boldsymbol{\mu}_{21}, \mathbf{C}_{21})$ onde

$$\boldsymbol{\mu}_{21} = \mathbf{m}_2 + \mathbf{V}_{21} \mathbf{V}_{11}^{-1} (\mathbf{X}_1 - \mathbf{m}_1) \quad (4.1.9)$$

$$= \mathbf{m}_2 + \mathbf{A}_2 (\mathbf{X}_1 - \mathbf{m}_1) \quad (4.1.10)$$

e

$$\mathbf{C}_{21} = \mathbf{V}_{22} - \mathbf{V}_{21} \mathbf{V}_{11}^{-1} \mathbf{V}_{12} \quad (4.1.11)$$

$$= \mathbf{V}_{22} - \mathbf{A}_2 \mathbf{V}_{11} \mathbf{A}_2^\top \quad (4.1.12)$$

- (4) No caso especial da normal bivariada em (1) acima, os momentos são todos escalares, e a correlação entre X_1 e X_2 é $\rho = \rho_{12} = V_{12}/\sqrt{V_{11}V_{22}}$. As regressões são determinadas pelos coeficientes de regressão A_1 e A_2 dados por

$$A_1 = \rho \sqrt{V_{11}/V_{22}} \quad \text{e} \quad A_2 = \rho \sqrt{V_{22}/V_{11}}.$$

Além disso,

$$\text{Var}[X_1 | X_2] = (1 - \rho^2)V_{11} \quad \text{e} \quad \text{Var}[X_2 | X_1] = (1 - \rho^2)V_{22}.$$

4.2 Distribuições de formas quadráticas

Teorema 4.2.1. Seja $\mathbf{X} \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Então:

- (1) $\mathbf{X}^\top \mathbf{A} \mathbf{X} \sim \chi_{\text{pos}(\mathbf{A}), \frac{1}{2} \boldsymbol{\mu}^\top \mathbf{A} \boldsymbol{\mu}}^2 \iff \mathbf{A} \boldsymbol{\Sigma}$ é idempotente.
- (2) $\mathbf{X}^\top \mathbf{A} \mathbf{X}$ e $\mathbf{B} \mathbf{X}$ são independentes $\iff \mathbf{B} \boldsymbol{\Sigma} \mathbf{A} = \mathbf{0}$
- (3) $\mathbf{X}^\top \mathbf{A} \mathbf{X}$ e $\mathbf{X}^\top \mathbf{B} \mathbf{X}$ são independentes $\iff \mathbf{A} \boldsymbol{\Sigma} \mathbf{B} = \mathbf{0}$ ou $\mathbf{B} \boldsymbol{\Sigma} \mathbf{A} = \mathbf{0}$

Teorema 4.2.2. Seja $\mathbf{X}$ um vetor aleatório p -dimensional com $\text{Var}[\mathbf{X}] = \boldsymbol{\Sigma}$, $\boldsymbol{\Sigma}$ de dimensão $p \times p$, e seja $\mathbf{A}$ uma matriz $p \times p$. Então:

- (1) $\mathbb{E}[\mathbf{X}^\top \mathbf{A} \mathbf{X}] = \text{tr}(\mathbf{A} \boldsymbol{\Sigma}) + \boldsymbol{\mu}^\top \mathbf{A} \boldsymbol{\mu}.$
- (2) $\text{Cov}[\mathbf{X}, \mathbf{X}^\top \mathbf{A} \mathbf{X}] = 2 \boldsymbol{\Sigma} \mathbf{A} \boldsymbol{\mu}.$

Teorema 4.2.3. Supondo válidas as condições

- (1) $\mathbf{X} \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}),$
- (2) $\mathbf{A}_i$ matriz $(p \times p)$ simétrica com $\text{pos}(\mathbf{A}_i) = n_i, i = 1, \dots, k,$
- (3) $\mathbf{A} = \sum_{i=1}^k \mathbf{A}_i$ com $\text{pos}(\mathbf{A}) = n$ de modo que

$$\mathbf{X}^\top \mathbf{A} \mathbf{X} = \mathbf{X}^\top \mathbf{A}_1 \mathbf{X} + \mathbf{X}^\top \mathbf{A}_2 \mathbf{X} + \dots + \mathbf{X}^\top \mathbf{A}_k \mathbf{X}, \quad (4.2.1)$$

Então:

- (1) $\mathbf{X}^\top \mathbf{A} \mathbf{X} \sim \chi_{n, \lambda}^2$ com $\lambda = \frac{1}{2} \boldsymbol{\mu}^\top \mathbf{A} \boldsymbol{\mu}$
- (2) $\mathbf{X}^\top \mathbf{A}_i \mathbf{X} \sim \chi_{n_i, \lambda_i}^2$ com $\lambda_i = \frac{1}{2} \boldsymbol{\mu}^\top \mathbf{A}_i \boldsymbol{\mu}$
- (3) $\mathbf{X}^\top \mathbf{A}_i \mathbf{X}$ é independente de $\mathbf{X}^\top \mathbf{A}_j \mathbf{X} \iff \mathbf{A} \boldsymbol{\Sigma}$ é idempotente e $n = \sum_{i=1}^k n_i$

Corolário 4.2.1 (*Teorema de Cochran e Fisher*). Supondo válidas as condições

- (1) $\mathbf{X} \sim \mathcal{N}_p(\boldsymbol{\mu}, \mathbf{I}_p),$
- (2) $\mathbf{A}_i$ matriz $(p \times p)$ com $\text{pos}(\mathbf{A}_i) = n_i, i = 1, \dots, k,$
- (3) $\mathbf{I}_p = \sum_{i=1}^k \mathbf{A}_i$ de modo que

$$\mathbf{X}^\top \mathbf{X} = \mathbf{X}^\top \mathbf{A}_1 \mathbf{X} + \mathbf{X}^\top \mathbf{A}_2 \mathbf{X} + \dots + \mathbf{X}^\top \mathbf{A}_k \mathbf{X}, \quad (4.2.2)$$

Então:

- (1) $\mathbf{X}^\top \mathbf{A}_i \mathbf{X} \sim \chi_{n_i, \lambda_i}^2$ com $\lambda_i = \frac{1}{2} \boldsymbol{\mu}^\top \mathbf{A}_i \boldsymbol{\mu}, \quad i = 1, \dots, k$
- (2) as formas quadráticas $\mathbf{X}^\top \mathbf{A}_i \mathbf{X}$ são independentes $\iff p = \sum_{i=1}^k n_i$

Capítulo 5

Regressão

Capítulo 6

Inferência Bayesiana

Teorema 6.0.1 (*Normal com σ^2 conhecido*). Seja $\mathbf{x} = (x_1, \dots, x_n)$.

(1) Verosimilhança:

$$(X_i|\mu) \sim \mathcal{N}(\mu, \sigma^2)$$

(2) Priori:

$$\mu \sim \mathcal{N}(\mu_0, \sigma_0^2)$$

(3) Posteriori:

$$(\mu|\mathbf{x}) \sim \mathcal{N}(\mu_1, \sigma_1^2)$$

$$\sigma_1^2 = \frac{1}{\frac{n}{\sigma^2} + \frac{1}{\sigma_0^2}} = \frac{\sigma^2 \sigma_0^2}{n\sigma_0^2 + \sigma^2} \quad (6.0.1)$$

$$\mu_1 = \sigma_1^2 \left(\frac{n\bar{x}}{\sigma^2} + \frac{\mu_0}{\sigma_0^2} \right) = \frac{\frac{n\bar{x}}{\sigma^2} + \frac{\mu_0}{\sigma_0^2}}{\frac{n}{\sigma^2} + \frac{1}{\sigma_0^2}} = \frac{n\bar{x}\sigma_0^2 + \mu_0\sigma^2}{n\sigma_0^2 + \sigma^2} \quad (6.0.2)$$

Fazendo $\tau = 1/\sigma^2$:

$$\tau_1 = \tau_0 + n\tau \quad (6.0.3)$$

$$\mu_1 = \frac{n\tau\bar{x} + \tau_0\mu_0}{n\tau + \tau_0} \quad (6.0.4)$$

Nota: A média a posteriori é uma combinação convexa da média a priori e da média amostral.

Teorema 6.0.2 (*Normal multivariada com Σ conhecido*). Seja $\mathbf{y} = (y_1, \dots, y_n)$.

(1) Verosimilhança:

$$p(\mathbf{y}|\boldsymbol{\mu}) = \prod_{n=1}^N \mathcal{N}(y_n | \boldsymbol{\mu}, \Sigma) \sim \mathcal{N}\left(\bar{\mathbf{y}} | \boldsymbol{\mu}, \frac{1}{N}\Sigma\right)$$

(2) Priori:

$$p(\boldsymbol{\mu}) \sim \mathcal{N}(\boldsymbol{\mu} \mid \tilde{\mathbf{m}}, \tilde{\mathbf{V}})$$

(3) Posteriori:

$$p(\boldsymbol{\mu} \mid \mathbf{y}) \sim \mathcal{N}(\boldsymbol{\mu} \mid \hat{\mathbf{m}}, \hat{\mathbf{V}})$$

$$\hat{\mathbf{V}}^{-1} = \tilde{\mathbf{V}}^{-1} + N\boldsymbol{\Sigma}^{-1} \quad (6.0.5)$$

$$\hat{\mathbf{m}} = \hat{\mathbf{V}} \left[\boldsymbol{\Sigma}^{-1}(N\bar{\mathbf{y}}) + \tilde{\mathbf{V}}^{-1}\tilde{\mathbf{m}} \right] \quad (6.0.6)$$

Teorema 6.0.3 (*Regressão linear bayesiana com $\boldsymbol{\Sigma}$ conhecido*). Seja $\mathbf{y} = (y_1, \dots, y_n)$.

(1) Verossimilhança:

$$p(\mathbf{y} \mid \boldsymbol{\mu}) \sim \mathcal{N}(\bar{\mathbf{y}} \mid \mathcal{F}\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

(2) Priori:

$$p(\boldsymbol{\mu}) \sim \mathcal{N}(\boldsymbol{\mu} \mid \tilde{\mathbf{m}}, \tilde{\mathbf{V}})$$

(3) Posteriori:

$$p(\boldsymbol{\mu} \mid \mathbf{y}) \sim \mathcal{N}(\boldsymbol{\mu} \mid \hat{\mathbf{m}}, \hat{\mathbf{V}})$$

$$\hat{\mathbf{V}}^{-1} = \tilde{\mathbf{V}}^{-1} + \mathcal{F}^T \boldsymbol{\Sigma}^{-1} \mathcal{F} \quad (6.0.7)$$

$$\hat{\mathbf{m}} = \hat{\mathbf{V}} \left[\mathcal{F}^T \boldsymbol{\Sigma}^{-1} \mathbf{y} + \tilde{\mathbf{V}}^{-1} \tilde{\mathbf{m}} \right] \quad (6.0.8)$$

Teorema 6.0.4 (*Distribuição condicional e regressão linear*). Suponha que o vetor- p $\mathbf{Y}$ e o vetor- n $\boldsymbol{\theta}$ estejam relacionados via a distribuição condicional

$$(\mathbf{Y} \mid \boldsymbol{\theta}) \sim \mathcal{N}(\mathbf{F}'\boldsymbol{\theta}, \mathbf{V}),$$

onde a matriz $(n \times p)$ $\mathbf{F}$ e a matriz $(p \times p)$ definida positiva simétrica $\mathbf{V}$ são constantes, e que a distribuição marginal de $\boldsymbol{\theta}$ seja dada por

$$\boldsymbol{\theta} \sim \mathcal{N}(\mathbf{a}, \mathbf{R}).$$

Segue que

$$\begin{bmatrix} \mathbf{Y} \\ \boldsymbol{\theta} \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mathbf{F}'\mathbf{a} \\ \mathbf{a} \end{bmatrix}, \begin{bmatrix} \mathbf{F}'\mathbf{R}\mathbf{F} + \mathbf{V} & \mathbf{F}'\mathbf{R} \\ \mathbf{R}\mathbf{F} & \mathbf{R} \end{bmatrix} \right).$$

Então $(\boldsymbol{\theta} \mid \mathbf{Y}) \sim \mathcal{N}(\mathbf{m}, \mathbf{C})$, onde

$$\mathbf{m} = \mathbf{a} + \mathbf{R}\mathbf{F}[\mathbf{F}'\mathbf{R}\mathbf{F} + \mathbf{V}]^{-1}[\mathbf{Y} - \mathbf{F}'\mathbf{a}]$$

e

$$\mathbf{C} = \mathbf{R} - \mathbf{R}\mathbf{F}[\mathbf{F}'\mathbf{R}\mathbf{F} + \mathbf{V}]^{-1}\mathbf{F}'\mathbf{R}.$$

Definindo $\mathbf{e} = \mathbf{Y} - \mathbf{F}'\mathbf{a}$, $\mathbf{Q} = \mathbf{F}'\mathbf{R}\mathbf{F} + \mathbf{V}$ e $\mathbf{A} = \mathbf{R}\mathbf{F}\mathbf{Q}^{-1}$, estas equações tornam-se

$$\mathbf{m} = \mathbf{a} + \mathbf{A}\mathbf{e} \quad \text{e} \quad \mathbf{C} = \mathbf{R} - \mathbf{A}\mathbf{Q}\mathbf{A}'.$$

Teorema 6.0.5 (*Normal-Gamma*).

- Verossimilhança:

$$Y_1, \dots, Y_k \sim \mathcal{N}(\mu, \phi^{-1})$$

- Priori:

$$(\mu, \phi) \sim \text{Normal-Gamma}(m, C, n, d) \quad (6.0.9)$$

$$\mu | \phi \sim \mathcal{N}(m, C\phi^{-1}) \quad (6.0.10)$$

$$\phi \sim \text{Gamma}(n/2, d/2) \quad (6.0.11)$$

- Posteriori:

$$(\mu, \phi) | \mathbf{y} \sim \text{Normal-Gamma}(m^*, C^*, n^*, d^*)$$

$$n^* = n + k \quad (6.0.12)$$

$$m^* = \frac{km/C + \sum_{i=1}^k y_i}{k + 1/C} \quad (6.0.13)$$

$$C^* = \frac{C}{2 + kC} \quad (6.0.14)$$

$$d^* = d + \sum_{i=1}^k (y_i - \bar{y})^2 + \frac{k(\bar{y} - m)^2}{1 + kC} \quad (6.0.15)$$

- Marginais:

$$\mu \sim t_n(m, R), \quad R = C \frac{d}{n} \quad (6.0.16)$$

$$\mu | \mathbf{y} \sim t_n(m^*, R^*), \quad R^* = C^* \frac{d^*}{n^*} \quad (6.0.17)$$

Teorema 6.0.6 (*Normal-Gamma Multivariada*).

- Verossimilhança:

$$\mathbf{Y}_1, \dots, \mathbf{Y}_k | \boldsymbol{\theta}, \phi \stackrel{iid}{\sim} \mathcal{N}(\boldsymbol{\theta}, \phi^{-1} \mathbf{I}_p)$$

- Priori:

$$(\boldsymbol{\theta}, \phi) \sim \text{Normal-Gamma}(\mathbf{m}, \mathbf{C}, n, d) \quad (6.0.18)$$

$$\boldsymbol{\theta} | \phi \sim \mathcal{N}(\mathbf{m}, \mathbf{C}\phi^{-1}) \quad (6.0.19)$$

$$\phi \sim \text{Gamma}(n/2, d/2) \quad (6.0.20)$$

- Posteriori:

$$(\boldsymbol{\theta}, \phi) | \mathbf{Y}_1, \dots, \mathbf{Y}_k \sim \text{Normal-Gamma}(\mathbf{m}^*, \mathbf{C}^*, n^*, d^*)$$

$$n^* = n + kp \quad (6.0.21)$$

$$\mathbf{m}^* = (\mathbf{C}^{-1} + k\mathbf{I}_p)^{-1}(\mathbf{C}^{-1}\mathbf{m} + k\bar{\mathbf{Y}}) \quad (6.0.22)$$

$$\mathbf{C}^* = (\mathbf{C}^{-1} + k\mathbf{I}_p)^{-1} \quad (6.0.23)$$

$$d^* = d + \sum_{j=1}^k (\mathbf{Y}_j - \bar{\mathbf{Y}})'(\mathbf{Y}_j - \bar{\mathbf{Y}}) + (\bar{\mathbf{Y}} - \mathbf{m})'(\mathbf{C}^{-1} + k\mathbf{I}_p)^{-1}(\bar{\mathbf{Y}} - \mathbf{m}) \quad (6.0.24)$$

(1) Caso particular $k = 1$: Após observar $\mathbf{Y}_1 = \mathbf{Y}$,

$$n^* = n + p \quad (6.0.25)$$

$$\mathbf{m}^* = (\mathbf{C}^{-1} + \mathbf{I}_p)^{-1}(\mathbf{C}^{-1}\mathbf{m} + \mathbf{Y}) \quad (6.0.26)$$

$$\mathbf{C}^* = (\mathbf{C}^{-1} + \mathbf{I}_p)^{-1} \quad (6.0.27)$$

$$d^* = d + (\mathbf{Y} - \mathbf{m})'(\mathbf{C}^{-1} + \mathbf{I}_p)^{-1}(\mathbf{Y} - \mathbf{m}) \quad (6.0.28)$$

- Marginais:

$$\boldsymbol{\theta} \sim T_n[\mathbf{m}, \mathbf{R}], \quad \mathbf{R} = \mathbf{C} \frac{d}{n} \quad (6.0.29)$$

$$\boldsymbol{\theta} | \mathbf{Y}_1, \dots, \mathbf{Y}_k \sim T_{n^*}[\mathbf{m}^*, \mathbf{R}^*], \quad \mathbf{R}^* = \mathbf{C}^* \frac{d^*}{n^*} \quad (6.0.30)$$

- Marginais univariadas: Se θ_i é o i -ésimo elemento de $\boldsymbol{\theta}$, então

$$\theta_i \sim t_n(m_i, R_{ii}), \quad R_{ii} = C_{ii} \frac{d}{n} \quad (6.0.31)$$

$$\theta_i | \mathbf{Y}_1, \dots, \mathbf{Y}_k \sim t_{n^*}(m_i^*, R_{ii}^*), \quad R_{ii}^* = C_{ii}^* \frac{d^*}{n^*} \quad (6.0.32)$$

onde $\bar{\mathbf{Y}} = \frac{1}{k} \sum_{j=1}^k \mathbf{Y}_j$

Nota:

- O vetor de parâmetros $\boldsymbol{\theta}$ tem dimensão $p \times 1$.
- Cada observação $\mathbf{Y}_j$ também tem dimensão $p \times 1$.
- $\mathbf{C}$ é uma matriz $p \times p$ simétrica positiva definida.
- Os graus de liberdade aumentam de n para $n^* = n + kp$ (cada observação vetorial contribui com p graus de liberdade).
- A notação $T_n[\mathbf{m}, \mathbf{R}]$ denota a distribuição t multivariada com n graus de liberdade, moda $\mathbf{m}$ e matriz de escala $\mathbf{R}$.

Teorema 6.0.7 (*Normal-Gamma para Regressão Linear*).

- Verossimilhança:

$$(Y_i | \boldsymbol{\theta}, \phi) \sim N[\mathbf{F}_i' \boldsymbol{\theta}, k_i \phi^{-1}], \quad i = 1, \dots, n$$

- Priori:

$$(\boldsymbol{\theta}, \phi) \sim \text{NG}(\mathbf{a}, \mathbf{R}, \nu, s) \quad (6.0.33)$$

$$\boldsymbol{\theta} | \phi \sim N[\mathbf{a}, \mathbf{R} \phi^{-1}] \quad (6.0.34)$$

$$\phi \sim \text{Gamma}(\nu/2, s/2) \quad (6.0.35)$$

- Posteriori para múltiplas observações:

$$(\boldsymbol{\theta}, \phi) | Y_1, \dots, Y_n \sim \text{NG}(\mathbf{a}^*, \mathbf{R}^*, \nu^*, s^*)$$

$$\nu^* = \nu + n \quad (6.0.36)$$

$$Q_i = \mathbf{F}_i' \mathbf{R} \mathbf{F}_i + k_i \quad (\text{variância preditiva}) \quad (6.0.37)$$

$$e_i = Y_i - \mathbf{F}_i' \mathbf{a} \quad (\text{erro de predição}) \quad (6.0.38)$$

$$\mathbf{R}^* = \mathbf{R} - \sum_{i=1}^n \frac{\mathbf{R} \mathbf{F}_i \mathbf{F}_i' \mathbf{R}}{Q_i} \quad (6.0.39)$$

$$\mathbf{a}^* = \mathbf{a} + \sum_{i=1}^n \frac{\mathbf{R} \mathbf{F}_i e_i}{Q_i} \quad (6.0.40)$$

$$s^* = s + \sum_{i=1}^n \frac{e_i^2}{Q_i} \quad (6.0.41)$$

(1) Caso particular $n = 1$: Após observar $(Y_1, \mathbf{F}_1)$ com $Y_1 = Y$, $\mathbf{F}_1 = \mathbf{F}$, $k_1 = k$,

$$\nu^* = \nu + 1 \quad (6.0.42)$$

$$f = \mathbf{F}' \mathbf{a} \quad (\text{predição priori}) \quad (6.0.43)$$

$$Q = \mathbf{F}' \mathbf{R} \mathbf{F} + k \quad (\text{variância preditiva priori}) \quad (6.0.44)$$

$$\mathbf{R}^* = \mathbf{R} - \frac{\mathbf{R} \mathbf{F} \mathbf{F}' \mathbf{R}}{Q} \quad (6.0.45)$$

$$\mathbf{a}^* = \mathbf{a} + \frac{\mathbf{R} \mathbf{F} (Y - f)}{Q} \quad (6.0.46)$$

$$s^* = s + \frac{(Y - f)^2}{Q} \quad (6.0.47)$$

– Distribuições condicionais e marginal posteriori ($n = 1$):

$$(\boldsymbol{\theta} | \phi, Y) \sim N[\mathbf{a}^*, \mathbf{R}^* \phi^{-1}] \quad (6.0.48)$$

$$(\phi | Y) \sim \text{Gamma} \left(\frac{\nu + 1}{2}, \frac{s + (Y - f)^2 / Q}{2} \right) \quad (6.0.49)$$

- Marginais:

$$\boldsymbol{\theta} \sim \text{T}_\nu[\mathbf{a}, \mathbf{R}S], \quad S = s/\nu \quad (6.0.50)$$

$$\boldsymbol{\theta} | Y_1, \dots, Y_n \sim \text{T}_{\nu^*}[\mathbf{a}^*, \mathbf{R}^* S^*], \quad S^* = s^*/\nu^* \quad (6.0.51)$$

- Marginais univariadas: Se θ_j é o j -ésimo elemento de $\boldsymbol{\theta}$, então

$$\theta_j \sim t_\nu(a_j, R_{jj}S) \quad (6.0.52)$$

$$\theta_j | Y_1, \dots, Y_n \sim t_{\nu^*}(a_j^*, R_{jj}^* S^*) \quad (6.0.53)$$

ou de forma padronizada:

$$\frac{\theta_j - a_j}{\sqrt{R_{jj}S}} \sim t_\nu(0, 1) \quad (6.0.54)$$

$$\frac{\theta_j - a_j^*}{\sqrt{R_{jj}^* S^*}} \sim t_{\nu^*}(0, 1) \quad (6.0.55)$$

- Distribuição preditiva: Para uma nova observação Y_{n+1} com covariáveis $\mathbf{F}_{n+1}$ e fator k_{n+1} ,

$$Y_{n+1}|Y_1, \dots, Y_n \sim t_{\nu^*}(f^*, Q^* S^*) \quad (6.0.56)$$

$$f^* = \mathbf{F}_{n+1}' \mathbf{a}^* \quad (6.0.57)$$

$$Q^* = \mathbf{F}_{n+1}' \mathbf{R}^* \mathbf{F}_{n+1} + k_{n+1} \quad (6.0.58)$$

Nota:

- O vetor de parâmetros $\boldsymbol{\theta}$ tem dimensão $p \times 1$.
- Cada Y_i é uma observação escalar com vetor de covariáveis $\mathbf{F}_i$ ($p \times 1$).
- k_i é o fator de escala da variância da i -ésima observação.
- $\mathbf{R}$ é uma matriz $p \times p$ simétrica positiva definida.
- $S = s/\nu = 1/E[\phi]$ é o inverso da precisão esperada.
- Os graus de liberdade aumentam de ν para $\nu^* = \nu + n$ (número de observações escalares).
- A notação $T_\nu[\mathbf{a}, \mathbf{R}S]$ denota a distribuição t multivariada com ν graus de liberdade, vetor de localização $\mathbf{a}$ e matriz de escala $\mathbf{R}S$.
- A atualização sequencial é possível: a posteriori após i observações serve como priori para a $(i + 1)$ -ésima observação.

Capítulo 7

Probabilidade Avançada

7.1 Teoria de conjuntos

Definição 7.1.1 (*Definições básicas*). Para A, B e $\{A_i : i \in I\}$ quaisquer:

- $A^c := \{\omega \in \Omega : \omega \notin A\} = \Omega - A$
- $A \subset B \iff \omega \in A \implies \omega \in B$
- $A \cup B := \{\omega \in \Omega : \omega \in A \text{ ou } \omega \in B\}$
- $\bigcup_{i \in I} A_i := \{\omega : \omega \in A_i \text{ para algum } i \in I\}$
- $A \cap B := \{\omega \in \Omega : \omega \in A \text{ e } \omega \in B\} = AB$
- $\bigcap_{i \in I} A_i := \{\omega : \omega \in A_i \text{ para todo } i \in I\}$
- $B - A := \{\omega \in \Omega : \omega \in B \text{ e } \omega \notin A\} = B \cap A^c$
- $A + B := A \cup B$, para A e B disjuntos
- Diferença simétrica:
$$\begin{aligned} A \triangle B &:= \{\omega \in \Omega : \omega \in A \cup B \text{ e } \omega \notin A \cap B\} \\ &= (A \cup B) - (A \cap B) \\ &= (A - B) + (B - A) \\ &= AB^c + BA^c \end{aligned}$$
- Produto cartesiano: $A \times B := \{(a, b) : a \in A \text{ e } b \in B\}$
- $(A \times B)^c := (\Omega_1 \times \Omega_2) - (A \times B) = \{(\omega_1, \omega_2) \in \Omega_1 \times \Omega_2 : \omega_1 \notin A \text{ ou } \omega_2 \notin B\}$
- Conjunto das partes: $\mathcal{P}(\Omega) := \{A : A \subset \Omega\}$
- Função indicadora:
$$I_A(\omega) := \begin{cases} 1 & \text{se } \omega \in A \\ 0 & \text{se } \omega \notin A \end{cases}$$

Teorema 7.1.1 (*Propriedades básicas*). Para A, B, C quaisquer:

- (1) $\emptyset \subset A$
- (2) Reflexiva: $A = A$
- (3) Simétrica: $A = B \implies B = A$
- (4) Transitiva: $A = B$ e $B = C \implies A = C$
- (5) Reflexiva: $A \subset A$
- (6) Simétrica: $A \subset B$ e $B \subset A \iff A = B$
- (7) Transitiva: $A \subset B$ e $B \subset C \implies A \subset C$
- (8) $A \subset B$ ou $A \subset C \implies A \subset B \cup C$
- (9) $A \cup B \subset C \iff A \subset C$ e $B \subset C$

Teorema 7.1.2 (*Operações básicas*). Para $A, B, \{A_i : i \in I\}, (A_n)_{n \geq 1}$ e $(B_n)_{n \geq 1}$ quaisquer:

- (1) Idempotente: $A \cup A = A, A \cap A = A$
- (2) Elemento neutro: $A \cup \emptyset = A, A \cap \Omega = A$
- (3) $A \cap \emptyset = \emptyset, A \cup \Omega = \Omega$
- (4) Comutativa: $A \cup B = A \cap B$ e $A \cup B = A \cap B$
- (5) Associativa:

- (a) $A \cup (B \cup C) = (A \cup B) \cup C$
- (b) $(\bigcup_{n=1}^{\infty} A_n) \cup (\bigcup_{n=1}^{\infty} B_n) = \bigcup_{n=1}^{\infty} (A_n \cup B_n)$
- (c) $A \cap (B \cap C) = (A \cap B) \cap C$
- (d) $(\bigcap_{n=1}^{\infty} A_n) \cap (\bigcap_{n=1}^{\infty} B_n) = \bigcap_{n=1}^{\infty} (A_n \cap B_n)$

- (6) Distributiva:

- (a) $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
- (b) $B \cap (\bigcup_{i \in I} A_i) = \bigcup_{i \in I} (A_i \cap B)$
- (c) $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$
- (d) $B \cup (\bigcap_{i \in I} A_i) = \bigcap_{i \in I} (A_i \cup B)$

- (7) $A \subset A \cup B$ e $B \subset A \cup B$
- (8) $A \cap B \subset A$ e $A \cap B \subset B$
- (9) $A \cup (A \cap B) = A$ e $B \cap (A \cup B) = B$
- (10) $A \subset B \iff A \cup B = B \iff A \cap B = A$

Teorema 7.1.3 (*Propriedades do complementar*). Para A, B e $\{A_i : i \in I\}$ quaisquer:

$$(1) (A^c)^c = A$$

$$(2) A \subset B \iff B^c \subset A^c$$

(3) Leis de De Morgan:

$$(a) (A \cup B)^c = (A^c \cap B^c)^c \text{ e } \left(\bigcup_{i \in I} A_i\right)^c = \bigcap_{i \in I} A_i^c$$

$$(b) (A \cap B)^c = (A^c \cup B^c)^c \text{ e } \left(\bigcap_{i \in I} A_i\right)^c = \bigcup_{i \in I} A_i^c$$

Teorema 7.1.4 (*Operações com diferença*). Para A, B, C , e $\{A_i : i \in I\}$ quaisquer:

$$(1) (A - B) \cup (A \cap B) = A$$

$$(2) (A \cup C) - B = (A - B) \cup (C - B)$$

$$(3) (A - B) - C = (A - C) - B$$

$$(4) (A - B) \cup C = (A \cup B \cup C) - (A \cap B)$$

$$(5) (A - B) \cap C = (A \cap C) - (B \cap C)$$

$$(6) C - (A \cup B) = (C - A) \cap (C - B)$$

$$(7) C - (A \cap B) = (C - A) \cup (C - B)$$

$$(8) A - B = \emptyset \iff A \subset B$$

$$(9) A - (A - B) = B \iff B \subset A$$

$$(10) \text{ Se } A \subset C \text{ e } B \subset C, \text{ então } A \subset B \iff (C - B) \subset (C - A)$$

$$(11) B - \bigcup_{i \in I} A_i = \bigcap_{i \in I} (B - A_i)$$

$$(12) B - \bigcap_{i \in I} A_i = \bigcup_{i \in I} (B - A_i)$$

Teorema 7.1.5 (*Propriedades da diferença simétrica*). Para A, B e $\{A_i : i \in I\}$ quaisquer:

$$(1) \text{ Comutativa: } A \Delta B = B \Delta A$$

$$(2) \text{ Associativa: } (A \Delta B) \Delta C = A \Delta (B \Delta C)$$

$$(3) \text{ Elemento neutro: } \exists \Phi : \forall A, A \Delta \Phi = A$$

$$(4) \text{ Elemento inverso: } \forall A, \exists B : A \Delta B = \emptyset$$

$$(5) (A \Delta B) \cap C = (A \cap C) \Delta (B \cap C)$$

$$(6) A \Delta B = A \Delta C \implies B = C$$

$$(7) \quad A \triangle B = \emptyset \iff A = B$$

$$(8) \quad A \cap B = \emptyset \iff A \triangle B = A \cup B$$

Teorema 7.1.6 (*Propriedades do produto cartesiano*). Para A, B e C quaisquer:

$$(1) \quad A \times \emptyset = \emptyset \times A = \emptyset$$

$$(2) \quad A \times (B \cap C) = (A \times B) \cap (A \times C)$$

$$(3) \quad A \times (B \cup C) = (A \times B) \cup (A \times C)$$

$$(4) \quad A \times (B - C) = (A \times B) - (A \times C)$$

$$(5) \quad (A \times B)^c = (A \times B^c) \cup (A^c \times \Omega_2) = (A^c \times B) \cup (\Omega_1 \times B^c)$$

Teorema 7.1.7 (*Propriedades de $\mathcal{P}(\cdot)$*). Para A, B quaisquer:

$$(1) \quad \mathcal{P}(A \cap B) = \mathcal{P}(A) \cap \mathcal{P}(B)$$

$$(2) \quad \mathcal{P}(A \cup B) \supset \mathcal{P}(A) \cup \mathcal{P}(B)$$

Teorema 7.1.8 (*Propriedades da função indicadora*). Para A, B quaisquer:

$$(1) \quad I_A \leq I_B \iff A \subset B$$

$$(2) \quad I_A = I_B \iff A = B$$

$$(3) \quad I_{A^c} = 1 - I_A$$

$$(4) \quad I_{A \cup B} = I_A + I_B - I_{A \cap B}$$

$$(5) \quad I_{A \triangle B} = |I_A - I_B|$$

$$(6) \quad I_{\bigcap_{i=1}^n A_i} = \prod_{i=1}^n I_{A_i}$$

$$(7) \quad I_{\bigcup_{i=1}^n A_i} = \sum_{i=1}^n I_{A_i} \text{ se } A_i \cap A_j = \emptyset \quad \forall i \neq j$$

7.2 Funções

Definição 7.2.1 (*Definições básicas de funções*). Seja $f: \Omega_1 \rightarrow \Omega_2$

- Injetora: $\omega_1 \neq \omega_2 \implies f(\omega_1) \neq f(\omega_2)$
- Sobrejetora: $\forall \omega_2 \in \Omega_2, \exists \omega_1 \in \Omega : f(\omega_1) = \omega_2$
- Bijetora: f é sobrejetora e injetora
- Gráfico: $G(f) := \{(\omega, f(\omega)) : \omega \in \Omega_1\}$

- Imagem direta: $f(A) := \{\omega_2 \in \Omega_2 : f(\omega_1) = \omega_2 \text{ para algum } \omega_1 \in A\}$
- Imagem inversa: $f^{-1}(B) := \{\omega_1 \in \Omega_1 : f(\omega_1) \in B\}$
- Composição: Seja $g : \Omega_2 \rightarrow \Omega_3$. $(g \circ f)(\omega_1) := g(f(\omega_1))$, $\omega_1 \in \Omega_1$
- Função inversa: Seja $g : \Omega_2 \rightarrow \Omega_1$. g é inversa de f se

$$(1) \quad g(f(\omega_1)) = \omega_1, \quad \forall \omega_1 \in \Omega_1$$

$$(2) \quad f(g(\omega_2)) = \omega_2, \quad \forall \omega_2 \in \Omega_2$$

Teorema 7.2.1 (*Propriedades de funções*). Seja $f : \Omega_1 \rightarrow \Omega_2$, $A, B, (A_n)_{n \geq 1} \subset \Omega_1$ e $C, D \subset \Omega_2$:

- (1) $f(\emptyset) = \emptyset$
- (2) $A \subset B \implies f(A) \subset f(B)$
- (3) $f(A \cup B) = f(A) \cup f(B)$
- (4) $f(A \cap B) \subset f(A) \cap f(B)$
- (5) f é injetora $\implies f(A \cap B) \supset f(A) \cap f(B) \implies f(A \cap B) = f(A) \cap f(B)$
- (6) $f(\bigcup_{n=1}^{\infty} A_n) = \bigcup_{n=1}^{\infty} f(A_n)$
- (7) $f(\bigcap_{n=1}^{\infty} A_n) \subset \bigcap_{n=1}^{\infty} f(A_n)$
- (8) $f(A) - f(B) \subset f(A - B)$
- (9) f é injetora $\implies f(A^c) \subset (f(A))^c$
- (10) f é sobrejetora $\implies f(A^c) \supset (f(A))^c$
- (11) f é bijetora $\implies f(A^c) = (f(A))^c$

Teorema 7.2.2 (*Propriedades de funções e imagens inversas*). Seja $f : \Omega_1 \rightarrow \Omega_2$, $A, B, (A_n)_{n \geq 1} \subset \Omega_2$ e $C \subset \Omega_1$:

- (1) f^{-1} é bijetora
- (2) $(f^{-1})^{-1} = f$
- (3) $A \subset B \implies f^{-1}(A) \subset f^{-1}(B)$
- (4) $f^{-1}(A \cup B) = f^{-1}(A) \cup f^{-1}(B)$
- (5) $f^{-1}(A \cap B) = f^{-1}(A) \cap f^{-1}(B)$
- (6) $f^{-1}(\bigcup_{n=1}^{\infty} A_n) = \bigcup_{n=1}^{\infty} f^{-1}(A_n)$
- (7) $f^{-1}(\bigcap_{n=1}^{\infty} A_n) = \bigcap_{n=1}^{\infty} f^{-1}(A_n)$

$$(8) \quad f^{-1}(A^c) = (f^{-1}(A))^c$$

$$(9) \quad C \subset f^{-1}(f(C))$$

$$(10) \quad f(f^{-1}(A)) \subset A$$

Teorema 7.2.3 (*Propriedades de composições de funções*). Seja $f: \Omega_1 \rightarrow \Omega_2$ e $g: \Omega_2 \rightarrow \Omega_3$:

$$(1) \quad f \text{ e } g \text{ são injetoras} \implies g \circ f \text{ é injetora}$$

$$(2) \quad f \text{ e } g \text{ são sobrejetoras} \implies g \circ f \text{ é sobrejetora}$$

$$(3) \quad f \text{ e } g \text{ são bijetoras} \implies g \circ f \text{ é bijetora e } (g \circ f)^{-1} = f^{-1} \circ g^{-1}$$

$$(4) \quad (g \circ f)^{-1}(U) = f^{-1}(g^{-1}(U)), \text{ para } U \subset \Omega_3$$

7.3 Noções de cardinalidade

7.4 Valor absoluto

Teorema 7.4.1. Valem as seguintes propriedades:

$$(1) \quad |a \cdot x| = |a| \cdot |x|$$

$$(2) \quad |x + y| \leq |x| + |y|$$

$$(3) \quad |x - y| \leq |x| + |y|$$

$$(4) \quad |x| - |y| \leq ||x| - |y|| \leq |x - y|$$

$$(5) \quad |x - z| \leq |x - y| + |y - z|$$

$$(6) \quad x \in (a - \epsilon, a + \epsilon) \iff a - \epsilon < x < a + \epsilon \iff |x - a| < \epsilon$$

7.5 Sequências de números reais

Teorema 7.5.1. Considere $(x_n)_{n \geq 1}$ uma sequência de números reais.

$$(1) \quad \text{Toda sequência limitada é convergente}$$

$$(2) \quad \text{Se existir, o limite de uma sequência é único}$$

$$(3) \quad \text{Se } x_n \rightarrow L, \text{ então toda subsequência de } (x_n)_{n \geq 1} \text{ converge para } L$$

$$(4) \quad \text{Toda sequência monótona e limitada é convergente}$$

$$(5) \quad \text{Uma sequência monótona que possui uma subsequência convergente é convergente}$$

Teorema 7.5.2. Considere $(x_n)_{n \geq 1}$ e $(y_n)_{n \geq 1}$ seqüências de números reais.

- (1) Se $x_n \rightarrow 0$ e $(y_n)_{n \geq 1}$ é limitada, então $x_n y_n \rightarrow 0$
- (2) $x_n \rightarrow x, y_n \rightarrow y \implies x_n + y_n \rightarrow x + y$
- (3) $x_n \rightarrow x, y_n \rightarrow y \implies x_n y_n \rightarrow xy$
- (4) $x_n \rightarrow x, y_n \neq 0 \rightarrow y \neq 0 \implies x_n / y_n \rightarrow x / y$
- (5) $x_n^2 \rightarrow 0 \iff x_n \rightarrow 0$

Teorema 7.5.3 (*Permanência do sinal*). Se $x_n \rightarrow L > 0$, então existe $n_0 \geq 1$ tal que $x_n > 0$ para todo $n \geq n_0$.

Corolário 7.5.1. Suponha $(x_n)_{n \geq 1}$ e $(y_n)_{n \geq 1}$ convergentes tais que, para algum $n_0 \geq 1$, $x_n \leq y_n$ para todo $n \geq n_0$. Então $\lim x_n \leq \lim y_n$.

Teorema 7.5.4 (*Sanduíche*). Se para algum $n_0 \geq 1$ tivermos que $x_n \leq z_n \leq y_n$ para todo $n \geq n_0$ e $x_n \rightarrow L$ e $y_n \rightarrow L$, então $z_n \rightarrow L$.

7.6 Sequências de conjuntos

Teorema 7.6.1. Alguns fatos úteis:

- (1) $\bigcap_{n=1}^{\infty} [-\infty, n] = \{-\infty\}$
- (2) $\bigcap_{n=1}^{\infty} (n, \infty] = \{+\infty\} = \overline{\mathbb{R}} - [-\infty, +\infty)$
- (3) $[-\infty, +\infty) = \bigcup_{n=1}^{\infty} [-\infty, n]$
- (4) $(-\infty, x] = [-\infty, x] - \{-\infty\}$

Definição 7.6.1 (*Limite inferior*). Seja $(A_n)_{n \geq 1}$ uma seqüência de subconjuntos de Ω . Definimos o limite inferior da seqüência $(A_n)_{n \geq 1}$ como

$$\liminf A_n = \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k.$$

Definição 7.6.2 (*Limite superior*). Seja $(A_n)_{n \geq 1}$ uma seqüência de subconjuntos de Ω . Definimos o limite superior da seqüência $(A_n)_{n \geq 1}$ como

$$\limsup A_n = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k.$$

Teorema 7.6.2. Considere $(A_n)_{n \geq 1}$ uma sequência de subconjuntos de Ω . Então,

- (1) $\liminf A_n \subset \limsup A_n$;
- (2) $(\liminf A_n)^C = \limsup A_n^C$;
- (3) $(\limsup A_n)^C = \liminf A_n^C$.

Definição 7.6.3 (*Sequência convergente de conjuntos*). Uma sequência $(A_n)_{n \geq 1}$ de subconjuntos de Ω é convergente para A se $\liminf A_n = \limsup A_n = A$. Usaremos a notação $\lim A_n = A$ ou $A_n \rightarrow A$ caso a sequência de conjuntos convirja.

Definição 7.6.4 (*Sequência monótona*). Uma sequência $(A_n)_{n \geq 1}$ de subconjuntos de Ω é dita monótona crescente se $A_n \subset A_{n+1}$ para todo $n \geq 1$ e é dita monótona decrescente se $A_n \supset A_{n+1}$ para todo $n \geq 1$. Dizemos que uma sequência é monótona se ela for monótona crescente ou decrescente.

Teorema 7.6.3. Seja $(A_n)_{n \geq 1}$ uma sequência de subconjuntos de Ω . As seguintes afirmações valem:

- (1) Se $(A_n)_{n \geq 1}$ for monótona crescente, então $\lim A_n$ existe e é igual a $\bigcup_{n=1}^{\infty} A_n$. Neste caso, denotaremos $A_n \uparrow A$, $A = \bigcup_{n=1}^{\infty} A_n$;
- (2) Se $(A_n)_{n \geq 1}$ for monótona decrescente, então $\lim A_n$ existe e é igual a $\bigcap_{n=1}^{\infty} A_n$. Neste caso, denotaremos $A_n \downarrow A$, $A = \bigcap_{n=1}^{\infty} A_n$.

7.7 Classes de Subconjuntos

Definição 7.7.1 (*Álgebra*). Uma classe $\mathcal{A}$ de subconjuntos de Ω é chamada de álgebra de subconjuntos de Ω se satisfizer as seguintes condições:

- (1) $\emptyset \in \mathcal{A}$;
- (2) $A \in \mathcal{A} \Rightarrow A^c \in \mathcal{A}$;
- (3) $A, B \in \mathcal{A} \Rightarrow A \cup B \in \mathcal{A}$.

Definição 7.7.2 (σ -álgebra). Uma classe $\mathcal{A}$ de subconjuntos de Ω é chamada de σ -álgebra de subconjuntos de Ω se satisfizer as seguintes condições:

- (1) $\emptyset \in \mathcal{A}$;
- (2) Se $A \in \mathcal{A}$ então $A^c \in \mathcal{A}$;
- (3) Se $A_1, A_2, \dots \in \mathcal{A}$, então $\bigcup_{n=1}^{\infty} A_n \in \mathcal{A}$.

Teorema 7.7.1. Considere $\{\mathcal{A}_i, i \in I\}$ uma família qualquer de álgebras (σ -álgebras) de subconjuntos de Ω . Então, $\mathcal{A} = \bigcap_{i \in I} \mathcal{A}_i$ é uma álgebra (σ -álgebra) de subconjuntos de Ω .

Definição 7.7.3 (*Álgebras e σ -álgebras geradas*). Considere $\mathcal{C}$ uma classe de subconjuntos de Ω . Definimos a álgebra gerada por $\mathcal{C}$, $\mathcal{A}(\mathcal{C})$, como a interseção

$$\mathcal{A}(\mathcal{C}) = \bigcap_{\mathcal{F} \in \mathcal{G}} \mathcal{F},$$

em que $\mathcal{G} = \{\mathcal{F} : \mathcal{C} \subset \mathcal{F} \text{ e } \mathcal{F} \text{ é uma álgebra de subconjuntos de } \Omega\}$. De forma análoga, definimos a σ -álgebra gerada por $\mathcal{C}$, $\sigma(\mathcal{C})$, como a interseção

$$\sigma(\mathcal{C}) = \bigcap_{\mathcal{F} \in \mathcal{G}'} \mathcal{F},$$

em que $\mathcal{G}' = \{\mathcal{F} : \mathcal{C} \subset \mathcal{F} \text{ e } \mathcal{F} \text{ é uma } \sigma\text{-álgebra de subconjuntos de } \Omega\}$.

Teorema 7.7.2. Dada uma classe $\mathcal{C}$ de subconjuntos de Ω , a álgebra (σ -álgebra) gerada por $\mathcal{C}$, $\mathcal{A}(\mathcal{C})$ ($\sigma(\mathcal{C})$), é a única classe de subconjuntos de Ω que satisfaz:

- (1) $\mathcal{A}(\mathcal{C})$ ($\sigma(\mathcal{C})$) é uma álgebra (σ -álgebra) que contém $\mathcal{C}$;
- (2) Se $\mathcal{A}'$ for uma álgebra (σ -álgebra) que contém $\mathcal{C}$, então $\mathcal{A}(\mathcal{C}) \subset \mathcal{A}'$ ($\sigma(\mathcal{C}) \subset \mathcal{A}'$).

Teorema 7.7.3. Seja Ω um conjunto não-vazio e $\mathcal{D} = \{D_1, \dots, D_n\}$ uma partição finita de Ω em que $D_i \neq \emptyset$ para todo $i = 1, \dots, n$. A álgebra gerada por $\mathcal{D}$, $\mathcal{A}(\mathcal{D})$, é idêntica à classe das uniões finitas disjuntas dos elementos de $\mathcal{D}$:

$$\mathcal{A} = \left\{ \sum_{i \in I} D_i : I \subset \{1, \dots, n\} \right\},$$

em que o símbolo $\sum$ denota uma união disjunta de conjuntos.

Definição 7.7.4 (*Semi-álgebra*). Para $\Omega \neq \emptyset$, uma classe de subconjuntos $\mathcal{S}$ é uma semi-álgebra de subconjuntos de Ω se satisfizer:

- (1) $\emptyset, \Omega \in \mathcal{S}$;
- (2) Se $A, B \in \mathcal{S}$, então $A \cap B \in \mathcal{S}$;
- (3) Se $A \in \mathcal{S}$, então $A^c = \sum_{i=1}^n B_i$, $B_i \in \mathcal{S}$, $i = 1, \dots, n$.

Teorema 7.7.4. Seja $\mathcal{S}$ uma semi-álgebra de subconjuntos de Ω , $\Omega \neq \emptyset$. A álgebra gerada por $\mathcal{S}$, $\mathcal{A}(\mathcal{S})$, é idêntica à classe das uniões finitas disjuntas de elementos de $\mathcal{S}$:

$$\mathcal{F} = \left\{ \sum_{i=1}^n S_i, S_i \in \mathcal{S}, i = 1, \dots, n \right\}.$$

Teorema 7.7.5. Seja $\mathcal{C}$ uma classe arbitrária de subconjuntos de Ω . Defina as seguintes classes de subconjuntos de Ω :

- (1) $\mathcal{C}_1$ a classe que contém $\emptyset$, Ω e todo $A \subset \Omega$ tal que $A \in \mathcal{C}$ ou $A^c \in \mathcal{C}$;
- (2) $\mathcal{C}_2$ a classe que contém todas as interseções finitas de elementos de $\mathcal{C}_1$;
- (3) $\mathcal{C}_3$ a classe formada pelas uniões finitas disjuntas de elementos de $\mathcal{C}_2$.

A classe $\mathcal{C}_3$ é idêntica à álgebra $\mathcal{A}(\mathcal{C})$ gerada por $\mathcal{C}$.

Definição 7.7.5 (σ -álgebra de Borel de $\mathbb{R}$). A σ -álgebra de Borel de $\mathbb{R}$, $\mathcal{B}(\mathbb{R})$, é definida como a σ -álgebra gerada pela classe $\{(-\infty, a] : a \in \mathbb{R}\}$ e seus elementos são chamados de borelianos da reta.

Definição 7.7.6 (*Classes monótonas*). Uma classe $\mathcal{M}$ de subconjuntos de Ω é chamada de classe monótona se é fechada por limites crescentes e decrescentes de conjuntos, isto é, se $(A_n)_{n \geq 1}$ for uma sequência de conjuntos em $\mathcal{M}$ tais que $A_n \uparrow A$ ou $A_n \downarrow A$, então $A \in \mathcal{M}$.

Teorema 7.7.6. Uma álgebra de subconjuntos $\mathcal{A}$ é uma σ -álgebra se, e somente, se for uma classe monótona.

Teorema 7.7.7. Considere $\{\mathcal{M}_i, i \in I\}$ uma família de classes monótonas de subconjuntos de Ω . Então, $\mathcal{M} = \bigcap_{i \in I} \mathcal{M}_i$ é uma classe monótona.

Definição 7.7.7 (*Classe monótona gerada*). Considere $\mathcal{C}$ uma classe de subconjuntos de Ω . Definimos a classe monótona gerada por $\mathcal{C}$, $\mathcal{M}(\mathcal{C})$, como a interseção

$$\mathcal{M}(\mathcal{C}) = \bigcap_{\mathcal{F} \in \mathcal{G}} \mathcal{F},$$

em que $\mathcal{G} = \{\mathcal{F} : \mathcal{C} \subset \mathcal{F} \text{ e } \mathcal{F} \text{ é uma classe monótona de subconjuntos de } \Omega\}$.

Teorema 7.7.8. Dada uma classe $\mathcal{C}$ de subconjuntos de Ω , a classe monótona gerada por $\mathcal{C}$, $\mathcal{M}(\mathcal{C})$, é a única classe $\mathcal{M}$ de subconjuntos de Ω que satisfaz:

- (1) $\mathcal{M}$ é uma classe monótona que contém $\mathcal{C}$;
- (2) Se $\mathcal{M}'$ for uma classe monótona que contém $\mathcal{C}$, então $\mathcal{M} \subset \mathcal{M}'$.

Teorema 7.7.9 (*Teorema das classes monótonas*). A σ -álgebra $\sigma(\mathcal{A})$ gerada por uma álgebra $\mathcal{A}$ é idêntica à classe monótona $\mathcal{M}(\mathcal{A})$ gerada por $\mathcal{A}$.

Definição 7.7.8 (π -sistema). Uma classe $\mathcal{I}$ de subconjuntos de Ω é dito π -sistema se $A \cap B \in \mathcal{I}$ para todo $A, B \in \mathcal{I}$.

Definição 7.7.9 (*d-sistema*). Uma classe $\mathcal{D}$ de subconjuntos de Ω é dita *d-sistema* se

- (1) $\Omega \in \mathcal{D}$;
- (2) $A, B \in \mathcal{D}, A \subset B \Rightarrow B - A \in \mathcal{D}$;
- (3) $A_n \uparrow A, A_n \in \mathcal{D} \Rightarrow A \in \mathcal{D}$.

Teorema 7.7.10. Uma classe $\mathcal{A}$ de subconjuntos de Ω é uma σ -álgebra se, e somente se, for um *d-sistema* e um π -sistema.

Teorema 7.7.11. Se $\{\mathcal{D}_i : i \in I\}$ é uma família qualquer de *d-sistemas* de Ω , então a interseção $\bigcap_{i \in I} \mathcal{D}_i$ é um *d-sistema*.

Definição 7.7.10 (*d-sistema gerado*). Para uma classe $\mathcal{C}$ de subconjuntos de Ω , definimos o *d-sistema gerado* por $\mathcal{C}$, $\mathcal{D}(\mathcal{C})$, como a interseção

$$\mathcal{D}(\mathcal{C}) = \bigcap_{\mathcal{D} \in \mathcal{G}} \mathcal{D},$$

em que $\mathcal{G} = \{\mathcal{D} : \mathcal{C} \subset \mathcal{D} \text{ e } \mathcal{D} \text{ é um } d\text{-sistema de subconjuntos de } \Omega\}$.

Teorema 7.7.12. Dada uma classe $\mathcal{C}$ de subconjuntos de Ω , o *d-sistema gerado* por $\mathcal{C}$, $\mathcal{D}(\mathcal{C})$, é a única classe $\mathcal{D}$ de subconjuntos de Ω que satisfaz:

- (1) $\mathcal{D}$ é uma *d-sistema* que contém $\mathcal{C}$;
- (2) Se $\mathcal{D}'$ for um *d-sistema* que contém $\mathcal{C}$, então $\mathcal{D} \subset \mathcal{D}'$.

Teorema 7.7.13. Se $\mathcal{I}$ for um π -sistema, então $\mathcal{D}(\mathcal{I})$ é um π -sistema.

Teorema 7.7.14 (*Lema de Dynkin*). Se $\mathcal{I}$ for um π -sistema, então $\mathcal{D}(\mathcal{I}) = \sigma(\mathcal{I})$.

Definição 7.7.11 (*Função de conjuntos*). Para $\mathcal{C}$ uma classe de subconjuntos de Ω , a função $\phi : \mathcal{C} \rightarrow [-\infty, +\infty]$ será chamada de função de conjuntos.

Definição 7.7.12 (*Finitamente aditiva*). Uma função de conjuntos $\phi : \mathcal{C} \rightarrow [-\infty, +\infty]$ é dita finitamente aditiva se

$$\phi(A_1 + \cdots + A_n) = \phi(A_1) + \cdots + \phi(A_n),$$

para quaisquer $A_1, \dots, A_n \in \mathcal{C}$ disjuntos tais que $A_1 + \cdots + A_n \in \mathcal{C}$.

Definição 7.7.13 (*Monótona*). Uma função de conjuntos $\phi : \mathcal{C} \rightarrow [-\infty, +\infty]$ será dita monótona se

$$\phi(B) \leq \phi(A),$$

para quaisquer $A, B \in \mathcal{C}$ tais que $B \subset A$.

Definição 7.7.14 (*σ -aditiva*). Uma função de conjuntos $\phi : \mathcal{C} \rightarrow [-\infty, +\infty]$, é dita σ -aditiva se

$$\phi \left(\sum_{n=1}^{\infty} A_n \right) = \sum_{n=1}^{\infty} \phi(A_n)$$

para toda sequência $(A_n)_{n \geq 1}$ de elementos disjuntos de $\mathcal{C}$ tais que $\sum_{n=1}^{\infty} A_n \in \mathcal{C}$.

Definição 7.7.15 (*Medida*). Seja $\mathcal{C}$ uma classe de subconjuntos de Ω tal que $\emptyset \in \mathcal{C}$. Dizemos que a função de conjuntos $\mu : \mathcal{C} \rightarrow [0, +\infty]$ é uma medida sobre $\mathcal{C}$ se valerem

- (1) $\mu(\emptyset) = 0$;
- (2) μ é σ -aditiva, i.e., para qualquer sequência $(A_n)_{n \geq 1}$ de elementos disjuntos de $\mathcal{C}$ tal que $\sum_{n=1}^{\infty} A_n \in \mathcal{C}$, temos que

$$\mu \left(\sum_{n=1}^{\infty} A_n \right) = \sum_{n=1}^{\infty} \mu(A_n).$$

Definição 7.7.16 (*Medida finitamente aditiva*). Seja $\mathcal{C}$ uma classe de subconjuntos de Ω tal que $\emptyset \in \mathcal{C}$. Dizemos que a função de conjuntos $\mu : \mathcal{C} \rightarrow [0, \infty]$ é uma medida finitamente aditiva sobre $\mathcal{C}$ se valerem

- (1) $\mu(\emptyset) = 0$;
- (2) Se $A_1, \dots, A_n \in \mathcal{C}$ forem elementos disjuntos tais que $\sum_{i=1}^n A_i \in \mathcal{C}$, então

$$\mu \left(\sum_{i=1}^n A_i \right) = \sum_{i=1}^n \mu(A_i).$$

Definição 7.7.17 (*Probabilidade*). Seja $\Omega \neq \emptyset$ e $\mathcal{A}$ uma álgebra de subconjuntos de Ω . Dizemos que $\mathbb{P} : \mathcal{A} \rightarrow [0, 1]$ é uma probabilidade sobre a álgebra $\mathcal{A}$ se:

- (1) $\mathbb{P}(\Omega) = 1$;
- (2) $\mathbb{P}$ é σ -aditiva, isto é, se $(A_n)_{n \geq 1}$ for uma sequência de elementos disjuntos de $\mathcal{A}$ tal que $\sum_{n=1}^{\infty} A_n \in \mathcal{A}$, então

$$\mathbb{P} \left(\sum_{n=1}^{\infty} A_n \right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

Definição 7.7.18 (*Probabilidade finitamente aditiva*). Seja $\Omega \neq \emptyset$ e $\mathcal{A}$ uma álgebra de subconjuntos de Ω . Dizemos que $\mathbb{P} : \mathcal{A} \rightarrow [0, 1]$ é uma probabilidade finitamente aditiva sobre a álgebra $\mathcal{A}$ se:

- (1) $\mathbb{P}(\Omega) = 1$;

(2) $\mathbb{P}$ é finitamente aditiva, isto é, se $A_1, A_2, \dots, A_n \in \mathcal{A}$ forem disjuntos, então

$$\mathbb{P}\left(\sum_{k=1}^n A_k\right) = \sum_{k=1}^n \mathbb{P}(A_k).$$

Teorema 7.7.15. Seja $\Omega \neq \emptyset$, $\mathcal{A}$ uma álgebra de subconjuntos de Ω e $\mathbb{P}$ uma probabilidade sobre $\mathcal{A}$. As seguintes propriedades valem:

(1) $\mathbb{P}(\emptyset) = 0$;

(2) $\mathbb{P}$ é finitamente aditiva, i.e., se $A_1, \dots, A_n \in \mathcal{A}$ são elementos disjuntos, então

$$\mathbb{P}\left(\sum_{i=1}^n A_i\right) = \sum_{i=1}^n \mathbb{P}(A_i);$$

(3) $\mathbb{P}$ é monótona, i.e., se $A \subset B$, $A, B \in \mathcal{A}$, então $\mathbb{P}(A) \leq \mathbb{P}(B)$;

(4) $\mathbb{P}(A \cup B) + \mathbb{P}(A \cap B) = \mathbb{P}(A) + \mathbb{P}(B)$ para quaisquer $A, B \in \mathcal{A}$. Em particular, $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$ para todo $A \in \mathcal{A}$;

(5) $\mathbb{P}$ é sub- σ -aditiva, isto é, se $(A_n)_{n \geq 1}$ for uma sequência de elementos de $\mathcal{A}$ tal que $\bigcup_{n=1}^{\infty} A_n \in \mathcal{A}$, então

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

Teorema 7.7.16. Seja $\Omega \neq \emptyset$, $\mathcal{A}$ uma álgebra de subconjuntos de Ω e $(A_n)_{n \geq 1}$ uma sequência de elementos de $\mathcal{A}$. As seguintes afirmações valem:

(1) Se $A_n \uparrow A$, $A \in \mathcal{A}$, então $\mathbb{P}(A_n) \nearrow \mathbb{P}(A)$;

(2) Se $A_n \downarrow A$, $A \in \mathcal{A}$, então $\mathbb{P}(A_n) \searrow \mathbb{P}(A)$.

Teorema 7.7.17. Considere $\Omega \neq \emptyset$ e $\mathcal{A}$ uma álgebra de subconjuntos de Ω . Uma medida de probabilidade finitamente aditiva $\mathbb{P}$ é σ -aditiva se, e somente se, $\mathbb{P}$ for contínua por cima no vazio, isto é, se $(A_n)_{n \geq 1}$ for uma sequência de elementos de $\mathcal{A}$ tal que $A_n \downarrow \emptyset$, então $\mathbb{P}(A_n) \searrow 0$.

Teorema 7.7.18. Seja $(\Omega, \mathcal{A}, \mathbb{P})$ um espaço de probabilidade e $(A_n)_{n \geq 1}$ uma sequência de elementos de $\mathcal{A}$. Então,

$$\mathbb{P}(\liminf A_n) \leq \liminf \mathbb{P}(A_n) \leq \limsup \mathbb{P}(A_n) \leq \mathbb{P}(\limsup A_n).$$

Em particular, se $\lim A_n = A$, isto é, $\liminf A_n = \limsup A_n = A$, então $\lim \mathbb{P}(A_n) = \mathbb{P}(A)$.

Teorema 7.7.19. Seja $(\Omega, \mathcal{A}, \mathbb{P})$ um espaço de probabilidade e $(A_n)_{n \geq 1}$ uma sequência de elementos de $\mathcal{A}$. Se $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$, então $\mathbb{P}(\limsup A_n) = 0$.

Definição 7.7.19 (*Função de distribuição*). Uma função $F : \mathbb{R} \rightarrow [0, 1]$ é dita função de distribuição se satisfaz:

- (1) F é uma função crescente, isto é, se $x_1 < x_2$, então $F(x_1) \leq F(x_2)$;
- (2) F é contínua à direita, isto é, se $(x_n)_{n \geq 1}$ for uma sequência de números reais tais que $x_n \downarrow x$, $x \in \mathbb{R}$, então $F(x_n) \searrow F(x)$;
- (3) Os limites de F em $-\infty$ e $+\infty$ são dados por

$$\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow +\infty} F(x) = 1.$$

Teorema 7.7.20. Seja $\Omega \neq \emptyset$ e $\mathcal{S}$ uma semi-álgebra de subconjuntos de Ω .

- (1) Se $\mathbb{P}$ for uma probabilidade finitamente aditiva sobre $\mathcal{S}$, então existe uma única probabilidade finitamente aditiva $\mathbb{P}'$ que estende $\mathbb{P}$, isto é, $\mathbb{P}'(A) = \mathbb{P}(A)$ para todo $A \in \mathcal{S}$;
- (2) Se $\mathbb{P}$ for uma probabilidade (σ -aditiva) sobre $\mathcal{S}$, então existe uma única probabilidade (σ -aditiva) $\mathbb{P}'$ que estende $\mathbb{P}$ de $\mathcal{S}$ para $\mathcal{A}(\mathcal{S})$.

Teorema 7.7.21. Sejam $\Omega \neq \emptyset$ e $\mathcal{S}$ uma semi-álgebra de subconjuntos de Ω .

- (1) Se μ for uma medida finitamente aditiva sobre $\mathcal{S}$, então existe uma única medida finitamente aditiva μ' que estende μ para $\mathcal{A}(\mathcal{S})$;
- (2) Se μ for uma medida (σ -aditiva) sobre $\mathcal{S}$, então existe uma única medida (σ -aditiva) μ' que estende μ para $\mathcal{A}(\mathcal{S})$;
- (3) Se μ for uma medida σ -finita sobre uma semi-álgebra $\mathcal{S}$, então a extensão μ' dada em (a) e (b) é σ -finita sobre $\mathcal{A}(\mathcal{S})$.

Teorema 7.7.22. Se $\{\mathcal{D}_i, i \in I\}$ é uma família qualquer de d -sistemas de Ω , então a interseção $\bigcap_{i \in I} \mathcal{D}_i$ é um d -sistema.

Teorema 7.7.23. A função de conjuntos $\mathbb{P}' : \mathcal{G} \rightarrow [0, +\infty]$ dada em (1.14) está bem definida.

Teorema 7.7.24. A classe de subconjuntos $\mathcal{G}$ definida em (1.13) e a função de conjuntos $\mathbb{P}' : \mathcal{G} \rightarrow [0, +\infty]$ definida em (1.14) satisfazem às seguintes propriedades:

- (1) $\emptyset, \Omega \in \mathcal{G}$, $\mathbb{P}'(\emptyset) = 0$, $\mathbb{P}'(\Omega) = 1$ e $0 \leq \mathbb{P}'(G) \leq 1$ para todo $G \in \mathcal{G}$;

(2) Se $G_1, G_2 \in \mathcal{G}$, então $G_1 \cup G_2, G_1 \cap G_2 \in \mathcal{G}$ e

$$\mathbb{P}'(G_1 \cup G_2) + \mathbb{P}'(G_1 \cap G_2) = \mathbb{P}'(G_1) + \mathbb{P}'(G_2).$$

Em particular, segue que $\mathbb{P}'$ é finitamente aditiva em $\mathcal{G}$;

(3) Se $G_1, G_2 \in \mathcal{G}$ e $G_1 \subset G_2$, então $\mathbb{P}'(G_1) \leq \mathbb{P}'(G_2)$;

(4) Se $(G_n)_{n \geq 1} \subset \mathcal{G}$ é tal que $G_n \uparrow G$, então $G \in \mathcal{G}$ e

$$\mathbb{P}'(G) = \lim_{n \rightarrow \infty} \mathbb{P}'(G_n).$$

Teorema 7.7.25. A função de conjuntos $\mathbb{P}^* : \mathcal{P}(\Omega) \rightarrow [0, +\infty]$ definida em (1.16) satisfaz as seguintes propriedades:

(1) Para todo $A \subset \Omega$, $0 \leq \mathbb{P}^*(A) \leq 1$;

(2) Para todo $G \in \mathcal{G}$, temos que $\mathbb{P}^*(G) = \mathbb{P}'(G)$;

(3) Para quaisquer $A, B \subset \Omega$, temos

$$\mathbb{P}^*(A \cup B) + \mathbb{P}^*(A \cap B) \leq \mathbb{P}^*(A) + \mathbb{P}^*(B).$$

Em particular, $\mathbb{P}^*(A) + \mathbb{P}^*(A^c) \geq 1$ para todo $A \subset \Omega$;

(4) Se $A \subset B$, $A, B \subset \Omega$, então

$$\mathbb{P}^*(A) \leq \mathbb{P}^*(B);$$

(5) Se $A_n \uparrow A$, $A_n \subset \Omega$ para $n \geq 1$, então

$$\mathbb{P}^*(A) = \lim_{n \rightarrow \infty} \mathbb{P}^*(A_n).$$

Teorema 7.7.26. A classe $\mathcal{D}$ definida em (1.21) é uma σ -álgebra de subconjuntos de Ω que contém $\sigma(\mathcal{A})$ e a restrição de $\mathbb{P}^*$ a $\mathcal{D}$ é uma probabilidade sobre $\mathcal{D}$.

Teorema 7.7.27 (*Teorema de extensão de Carathéodory*). Se $\mathbb{P}$ for uma probabilidade sobre uma álgebra $\mathcal{A}$, então existe uma única extensão $\bar{\mathbb{P}}$ de $\mathbb{P}$ para $\sigma(\mathcal{A})$.

Corolário 7.7.1. Se $\mathbb{P}$ for uma probabilidade sobre uma semi-álgebra $\mathcal{S}$ de subconjuntos de Ω , então existe uma única extensão $\bar{\mathbb{P}}$ de $\mathbb{P}$ para $\sigma(\mathcal{S})$.

Teorema 7.7.28 (*Teorema de Extensão de Carathéodory*). Seja $\Omega \neq \emptyset$ e $\mathcal{A}$ uma álgebra de subconjuntos de Ω .

(1) Se μ for uma medida sobre $\mathcal{A}$, então existe uma medida $\bar{\mu}$ que estende μ de $\mathcal{A}$ para $\sigma(\mathcal{A})$;

- (2) Se μ for uma medida σ -finita sobre $\mathcal{A}$, então $\bar{\mu}$ dada em (a) é a única medida que estende μ de $\mathcal{A}$ para $\sigma(\mathcal{A})$.

Corolário 7.7.2. Seja $\Omega \neq \emptyset$ e $\mathcal{S}$ uma semi-álgebra de subconjuntos de Ω .

- (1) Se μ for uma medida sobre $\mathcal{S}$, então existe uma medida $\bar{\mu}$ que estende μ de $\mathcal{S}$ para $\sigma(\mathcal{S})$;
- (2) Se μ for uma medida σ -finita sobre $\mathcal{S}$, então $\bar{\mu}$ dada em (a) é a única medida que estende μ de $\mathcal{S}$ para $\sigma(\mathcal{S})$.

7.8 Medida

Definição 7.8.1 (*Medida de Lebesgue*). Considere a semi-álgebra

$$\mathcal{S} = \{\emptyset, \mathbb{R}\} \cup \{(-\infty, a] : a \in \mathbb{R}\} \cup \{(b, \infty) : b \in \mathbb{R}\} \cup \{(a, b) : a < b, a, b \in \mathbb{R}\}$$

de subconjuntos de $\mathbb{R}$. Defina $\lambda: \mathcal{S} \rightarrow [0, \infty]$ como

$$\begin{aligned}\lambda(\emptyset) &= 0, \\ \lambda((a, b]) &= b - a, \quad a < b, \\ \lambda((-\infty, a]) &= +\infty, \\ \lambda((b, +\infty)) &= +\infty.\end{aligned}$$

Pode-se mostrar que λ é σ -aditiva em $\mathcal{S}$ e existe uma única extensão $\bar{\lambda}$ de λ para $\sigma(\mathcal{S}) = \mathcal{B}(\mathbb{R})$. Esta medida é chamada de *medida de Lebesgue* em $\mathbb{R}^1$.

Definição 7.8.2 (*Medida de Lebesgue-Stieltjes*). Considere $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbb{P}_F)$ um espaço de probabilidade e seja $F: \mathbb{R} \rightarrow [0, 1]$ uma função de distribuição associada à medida de probabilidade $\mathbb{P}_F$ definida conforme a definição 7.9.1.

Agora, considere a semi-álgebra

$$\mathcal{S} = \{\emptyset, \mathbb{R}\} \cup \{(-\infty, a] : a \in \mathbb{R}\} \cup \{(b, \infty) : b \in \mathbb{R}\} \cup \{(a, b) : a < b, a, b \in \mathbb{R}\}$$

de subconjuntos de $\mathbb{R}$ e defina $\mathbb{P}_S: \mathcal{S} \rightarrow [0, 1]$ como

$$\begin{aligned}\mathbb{P}_S(\emptyset) &= 0, \\ \mathbb{P}_S((a, b]) &= F(b) - F(a), \quad a < b, \\ \mathbb{P}_S((-\infty, a]) &= F(a), \\ \mathbb{P}_S((b, +\infty)) &= 1 - F(b).\end{aligned}$$

Note que $\sigma(\mathcal{S}) = \mathcal{B}(\mathbb{R})$. Pode-se mostrar que $\mathbb{P}_S$ é σ -aditiva sobre $\mathcal{S}$ e existe uma única probabilidade $\mathbb{P}_F$ sobre $\mathcal{B}(\mathbb{R})$ que estende $\mathbb{P}_S$. Esta medida de probabilidade $\mathbb{P}_F$ é denominada *medida de Lebesgue-Stieltjes* gerada por F .

7.9 Probabilidade

Definição 7.9.1 (*Função de distribuição associada a uma probabilidade*). Seja $\Omega = \mathbb{R}$, $\mathcal{A} = \mathcal{B}(\mathbb{R})$ e $\mathbb{P}$ uma probabilidade sobre $\mathcal{A}$. Podemos definir a função de distribuição $F: \mathbb{R} \rightarrow [0, 1]$ associada à probabilidade $\mathbb{P}$ como

$$F(x) = \mathbb{P}((-\infty, x]), \quad x \in \mathbb{R}$$

Teorema 7.9.1 (*Propriedades da função de distribuição*). As seguintes propriedades são válidas para F :

- (1) F é crescente, isto é, $x_1 < x_2 \implies F(x_1) \leq F(x_2)$;
- (2) F é contínua à direita, isto é se $(x_n)_{n \geq 1}$ for uma sequência de números reais tais que $x_n \downarrow x, x \in \mathbb{R}$, então $F(x_n) \searrow F(x)$;
- (3) Os limites de F em $-\infty$ e $+\infty$ são dados por

$$\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow +\infty} F(x) = 1.$$

7.9.1 Convergência

Teorema 7.9.2.

- (1) $A_n \uparrow A, A \in \mathcal{A} \implies \mathbb{P}(A_n) \nearrow \mathbb{P}(A)$
 $A_n \downarrow A, A \in \mathcal{A} \implies \mathbb{P}(A_n) \searrow \mathbb{P}(A)$
- (2) $\mathbb{P}$ é σ -aditiva $\iff (A_n \downarrow \emptyset \implies \mathbb{P}(A_n) \searrow \mathbb{P}(A))$ ($\mathbb{P}$ é contínua no vazio))
- (3) $\mathbb{P}(\liminf A_n) \leq \liminf \mathbb{P}(A_n) \leq \limsup \mathbb{P}(A_n) \leq \mathbb{P}(\limsup A_n)$
- (4) $A_n \rightarrow A \implies \mathbb{P}(A_n) \rightarrow P$
- (5) $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty \implies \mathbb{P}(\limsup A_n) = 0$

7.10 Transformações mensuráveis

Teorema 7.10.1 (2.1). Se $\mathcal{A}_2$ for uma σ -álgebra de subconjuntos de Ω_2 , então $X^{-1}(\mathcal{A}_2)$ é uma σ -álgebra de subconjuntos de Ω_1 .

Definição 7.10.1 (2.1 *Transformação mensurável*). Sejam $(\Omega_1, \mathcal{A}_1)$ e $(\Omega_2, \mathcal{A}_2)$ dois espaços mensuráveis e $X: \Omega_1 \rightarrow \Omega_2$. Dizemos que X é $\mathcal{A}_1 \setminus \mathcal{A}_2$ mensurável se $X^{-1}(\mathcal{A}_2) \subset \mathcal{A}_1$, isto é,

$$\begin{aligned} [X \in B] &= X^{-1}(B) \in \mathcal{A}_1, \quad \text{para todo } B \in \mathcal{A}_2 \\ &= \{\omega \in \Omega : X(\omega) \in B\} \in \mathcal{A}_1, \quad \text{para todo } B \in \mathcal{A}_2 \end{aligned} \tag{7.10.1}$$

Definição 7.10.2 (2.2 σ -álgebra gerada por X em Ω_1). A σ -álgebra $X^{-1}(\mathcal{A}_2)$ é a menor σ -álgebra $\mathcal{A}_1$ de subconjuntos de Ω_1 que torna X uma transformação $\mathcal{A}_1 \setminus \mathcal{A}_2$ mensurável e é denominada σ -álgebra gerada por X :

$$\sigma(X) := X^{-1}(\mathcal{A}_2) = \{X^{-1}(B) : B \in \mathcal{A}_2\} \quad (7.10.2)$$

Nota:

- (1) $\sigma(X) \subset \mathcal{A}_1$;
- (2) $\sigma(X)$ é a menor σ -álgebra em Ω_1 que torna X mensurável;
- (3) Para X ser mensurável, a σ -álgebra de partida $\mathcal{A}_1$ deve ser pelo menos tão grande quanto $\sigma(X)$, ou seja $\mathcal{A}_1 \supset \sigma(X)$.

Teorema 7.10.2 (2.4 σ -álgebra induzida por X em Ω_2). Seja $X: \Omega_1 \rightarrow \Omega_2$ e $\mathcal{A}_1$ uma σ -álgebra de subconjuntos de Ω_1 . A classe $X_*(\mathcal{A}_1) := \{B \subset \Omega_2 : X^{-1}(B) \in \mathcal{A}_1\}$ é uma σ -álgebra de subconjuntos de Ω_2 que será denominada σ -álgebra induzida por X à partir de $\mathcal{A}_1$.

Nota:

- (1) $\mathcal{A}_2 \subset X_*(\mathcal{A}_1)$;
- (2) $X_*(\mathcal{A}_1)$ é a maior σ -álgebra em Ω_2 que torna X mensurável;
- (3) Para X ser mensurável, a σ -álgebra de chegada $\mathcal{A}_2$ deve ser pelo menos tão pequena quanto $X_*(\mathcal{A}_1)$, ou seja $\mathcal{A}_2 \subset X_*(\mathcal{A}_1)$.

Teorema 7.10.3 (2.2). Para qualquer classe $\mathcal{C}_2$ de subconjuntos de Ω_2 , temos que

$$X^{-1}(\sigma(\mathcal{C}_2)) = \sigma(X^{-1}(\mathcal{C}_2)) \quad (7.10.3)$$

Teorema 7.10.4 (Condição suficiente para mensurabilidade). Sejam $(\Omega_1, \mathcal{A}_1)$ e $(\Omega_2, \mathcal{A}_2)$ dois espaços mensuráveis e $X: \Omega_1 \rightarrow \Omega_2$. Se $X^{-1}(\mathcal{C}_2) \subset \mathcal{A}_1$, onde $\mathcal{C}_2$ é a classe que gera $\mathcal{A}_2$, então X é $\mathcal{A}_1 \setminus \mathcal{A}_2$ mensurável.

Teorema 7.10.5 (2.3 Composição de transformações mensuráveis). Sejam $(\Omega_1, \mathcal{A}_1)$, $(\Omega_2, \mathcal{A}_2)$, $(\Omega_3, \mathcal{A}_3)$ espaços mensuráveis, $X: \Omega_1 \rightarrow \Omega_2$ e $Y: \Omega_2 \rightarrow \Omega_3$ transformações $\mathcal{A}_1 \setminus \mathcal{A}_2$ e $\mathcal{A}_2 \setminus \mathcal{A}_3$ mensuráveis, respectivamente. Então, $(Y \circ X): \Omega_1 \rightarrow \Omega_3$ é uma transformação $\mathcal{A}_1 \setminus \mathcal{A}_3$ mensurável.

Teorema 7.10.6 (2.5 Probabilidade induzida ou distribuição de X). Considere $(\Omega_1, \mathcal{A}_1, \mathbb{P}_1)$ um espaço de probabilidade, $\Omega_2 \neq \emptyset$ e $\mathcal{A}_2 = \{B \subset \Omega_2 : X^{-1}(B) \in \mathcal{A}_1\}$ a σ -álgebra induzida por X . Defina $\mathbb{P}_2: \mathcal{A}_2 \rightarrow [0, 1]$ como

$$\mathbb{P}_2(B) = \mathbb{P}_1([X \in B]), \quad B \in \mathcal{A}_2. \quad (7.10.4)$$

A função $\mathbb{P}_2$ é uma probabilidade sobre o espaço $(\Omega_2, \mathcal{A}_2)$ que é denominada *probabilidade induzida* ou *distribuição* de X , sendo o espaço de probabilidade $(\Omega_2, \mathcal{A}_2, \mathbb{P}_2)$ obtido chamado de *espaço de probabilidade induzido* por X à partir de $(\Omega_1, \mathcal{A}_1, \mathbb{P}_1)$.

7.11 Variáveis aleatórias

Lema 7.11.1 (*σ -álgebra de Borel estendida*). A σ -álgebra $\mathcal{B}(\overline{\mathbb{R}})$ é gerada pela classe dos intervalos

$$\mathcal{I} = \{[-\infty, x] : x \in \mathbb{R}\}$$

em que $[-\infty, x] = \{y \in \overline{\mathbb{R}} : y \leq x\}$ para $x \in \mathbb{R}$.

Definição 7.11.1 (*Variável aleatória*). Seja $(\Omega, \mathcal{A})$ um espaço mensurável. Uma função $X: \Omega \rightarrow \overline{\mathbb{R}}$ é chamada de *variável aleatória* se for $\mathcal{A} \setminus \mathcal{B}(\overline{\mathbb{R}})$ mensurável, isto é,

$$\begin{aligned} [X \in B] &= X^{-1}(B) \in \mathcal{A} \quad \text{para todo } B \in \mathcal{B}(\overline{\mathbb{R}}) \\ &= \{\omega \in \Omega : X(\omega) \in B\} \in \mathcal{A}, \quad \text{para todo } B \in \mathcal{B}(\overline{\mathbb{R}}) \end{aligned} \quad (7.11.1)$$

Nota: Toda função $X: \Omega \rightarrow \mathbb{R}$ que for $\mathcal{A} \setminus \mathcal{B}(\mathbb{R})$ mensurável também será considerada variável aleatória. Nesta condição, X será dita variável aleatória finita.

Definição 7.11.2 (*Notações em Probabilidade*). Sejam $(\Omega_1, \mathcal{A}_1)$ e $(\Omega_2, \mathcal{A}_2)$ espaços mensuráveis. As seguintes notações são usuais:

- (1) $[X \in B] := X^{-1}(B)$, para $B \in \mathcal{A}_2$
- (2) $[X = x] := X^{-1}(\{x\})$, para $x \in \mathcal{A}_2$
- (3) $[X \leq x] := X^{-1}((-\infty, x])$, para $(-\infty, x] \in \mathcal{A}_2$
- (4) $f: \mathbb{R} \rightarrow \mathbb{R} : [f \leq y] := f^{-1}((-\infty, y]) = \{x \in \mathbb{R} : f(x) \leq y\}$
- (5) $[X \leq x, Y \leq y] := X^{-1}((-\infty, x]) \cap Y^{-1}((-\infty, y])$
- (6) $[X < Y] = [X - Y < 0] := Z^{-1}((-\infty, 0))$, onde $Z = X - Y$
- (7) $F(x) = \mathbb{P}((-\infty, x])$
- (8) $F_X(x) = \mathbb{P}[X \leq x] = \mathbb{P}(X^{-1}((-\infty, x])) = \mathbb{P}_X((-\infty, x]) \equiv \mathbb{P}((-\infty, x]) = F(x)$
- (9) $[X = Y \text{ q.c.}] := \mathbb{P}[X = Y] = 1 \equiv \mathbb{P}[X = Y] = 0$

Teorema 7.11.1 (*Exemplos de variáveis aleatórias*). As seguintes funções são variáveis aleatórias:

- (1) Função constante: $X(\omega) = c$ para todo $\omega \in \Omega$;
- (2) Função indicadora: $I_A(\omega)$

Teorema 7.11.2. Para $(\Omega, \mathcal{A})$ um espaço mensurável e uma função $X: \Omega \rightarrow \overline{\mathbb{R}}$, as seguintes afirmações são equivalentes:

- (1) X é $\mathcal{A} \setminus \mathcal{B}(\overline{\mathbb{R}})$ mensurável;

- (2) $[X \in B] \in \mathcal{A}$ para todo $B \in \mathcal{B}(\mathbb{R})$,
 $[X = +\infty] = X^{-1}(\{+\infty\}) \in \mathcal{A}$,
 $[X = -\infty] = X^{-1}(\{-\infty\}) \in \mathcal{A}$;
- (3) $[X \in I] = X^{-1}(I) \in \mathcal{A}$ para todo $I \in \mathcal{I}$, em que $\sigma(\mathcal{I}) = \mathcal{B}(\overline{\mathbb{R}})$.

Lema 7.11.2 (*Mensurabilidade de funções contínuas*). Toda função $f: \mathbb{R} \rightarrow \mathbb{R}$ contínua é $\mathcal{B}(\mathbb{R}) \setminus \mathcal{B}(\mathbb{R})$ mensurável.

Teorema 7.11.3 (*Propriedades de variáveis aleatórias*). Considere $(\Omega, \mathcal{A})$ um espaço mensurável, X e Y variáveis aleatórias e $(X_n)_{n \geq 1}$ uma sequência de variáveis aleatórias. Então,

- (1) aX é variável aleatória, $a \in \mathbb{R}$;
- (2) $X \pm Y$ é variável aleatória;
- (3) $X \cdot Y$ é variável aleatória;
- (4) $\frac{X}{Y}$ é variável aleatória;
- (5) $[X = Y]$, $[X < Y]$, $[X > Y] \in \mathcal{A}$;
- (6) $\max(X, Y)$, $\min(X, Y)$ são variáveis aleatórias;
 - (a) $X^+ = \max(X, 0)$ é v.a.
 - (b) $X^- = \max(-X, 0) = -\min(0, X)$ é v.a.
 - (c) $X = X^+ - X^-$
 - (d) $|X| = X^+ + X^-$ é v.a.
- (7) $\inf_{n \geq 1} (X_n)$, $\sup_{n \geq 1} (X_n)$ são variáveis aleatórias;
- (8) $\liminf (X_n)$, $\limsup (X_n)$ são variáveis aleatórias;

Teorema 7.11.4 (*Exercício 2.7 - V.A. simples*). Considere X e Y variáveis aleatórias simples. As funções abaixo são v.a. simples.

- (1) $aX \pm bY$, $a, b \in \mathbb{R}$
- (2) $X \cdot Y$
- (3) $\max(X, Y)$, $\min(X, Y)$

Definição 7.11.3 (*Variável aleatória simples*). Considere $(\Omega, \mathcal{A})$ um espaço mensurável. Uma variável aleatória $X: \Omega \rightarrow \overline{\mathbb{R}}$ é chamada de *variável aleatória simples* se existirem $A_1, A_2, \dots, A_n \in \mathcal{A}$ que formam uma partição de Ω , $A_i \neq \emptyset$ para $i = 1, \dots, n$, e números reais $x_1, x_2, \dots, x_n$ tais que

$$X(\omega) = \sum_{i=1}^n x_i I_{A_i}(\omega), \quad \omega \in \Omega \quad (7.11.2)$$

Caso todos os valores de $x_1, \dots, x_n$ sejam distintos, dizemos que 7.11.2 é a *representação canônica* de X .

Teorema 7.11.5 (*2.12 v.a. não negativa como seq. de v.a. simples*). Considere $(\Omega, \mathcal{A})$ um espaço mensurável. Se X é uma variável aleatória não negativa, isto é, $X(\omega) \geq 0$ para todo $\omega \in \Omega$, então existe uma sequência de variáveis aleatórias simples e não negativas $(X_n)_{n \geq 1}$ tais que $X_n(\omega) \nearrow X(\omega)$ para todo $\omega \in \Omega$.

Corolário 7.11.1 (*2.1 v.a. como seq. de v.a. simples*). Considere $(\Omega, \mathcal{A})$ um espaço mensurável. Uma função $X: \Omega \rightarrow \overline{\mathbb{R}}$ é variável aleatória se, e somente se, existe uma sequência de variáveis aleatórias simples $(X_n)_{n \geq 1}$ tais que $X(\omega) = \lim_{n \rightarrow \infty} X_n(\omega)$ para todo $\omega \in \Omega$.

Teorema 7.11.6 (*2.13 v.a. aleatória mensurável como composição de funções*). Sejam $(\Omega_1, \mathcal{A}_1)$, $(\Omega_2, \mathcal{A}_2)$ espaços mensuráveis e $X: \Omega_1 \rightarrow \Omega_2$ uma função $\mathcal{A}_1 \setminus \mathcal{A}_2$ mensurável. Uma variável aleatória $Y: \Omega_1 \rightarrow \overline{\mathbb{R}}$ é $\sigma(X) \setminus \mathcal{B}(\overline{\mathbb{R}})$ mensurável se, e somente se, existe $f: \Omega_2 \rightarrow \overline{\mathbb{R}}$ $\mathcal{A}_2 \setminus \mathcal{B}(\overline{\mathbb{R}})$ mensurável tal que $Y = f(X)$.

Teorema 7.11.7 (*Exercício 2.5*). Toda função monótona $f: \mathbb{R} \rightarrow \mathbb{R}$ é Borel mensurável.

7.12 Esperança

7.12.1 Variável aleatória simples

Definição 7.12.1 (*Esperança de v.a. simples*). Para uma v.a. simples $X = \sum_{i=1}^n x_i I_{A_i}$, definimos sua esperança (integral) com respeito a $\mathbb{P}$ como:

$$\mathbb{E}[X] = \int X d\mathbb{P} = \sum_{i=1}^n x_i \mathbb{P}(A_i) \quad (7.12.1)$$

Definição 7.12.2 (*Esperança de v.a. simples sobre A*). Para uma v.a. simples e não negativa X , definimos a integral de X sobre A como:

$$\int_A X d\mathbb{P} = \int X I_A d\mathbb{P} = \mathbb{E}[X I_A] = \sum_{i=1}^n x_i \mathbb{P}(A_i \cap A). \quad (7.12.2)$$

Nota: O professor confirmou que a definição vale também para $X < 0$.

Teorema 7.12.1 (*Proposição 3.1 / Corolário 3.1*). As seguintes propriedades são válidas para esperança de variáveis aleatórias simples:

$$(1) \mathbb{E}[aX] = a \mathbb{E}[X], \quad a \in \mathbb{R}$$

$$\int aX d\mathbb{P} = a \int X d\mathbb{P}$$

$$(2) \mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$$

$$\int (X + Y) d\mathbb{P} = \int X d\mathbb{P} + \int Y d\mathbb{P}$$

$$(3) X \leq Y \implies \mathbb{E}[X] \leq \mathbb{E}[Y]$$

$$\int X d\mathbb{P} \leq \int Y d\mathbb{P}$$

$$(4) \mathbb{E}[c_1 X_1 + \dots + c_n X_n] = c_1 \mathbb{E}[X_1] + \dots + c_n \mathbb{E}[X_n] \quad c_1, \dots, c_n \in \mathbb{R}.$$

Teorema 7.12.2. Se X for uma v.a. simples e não negativa, então a aplicação $\nu: \mathcal{A} \rightarrow [0, \infty]$ definida como $\nu(A) = \int_A X d\mathbb{P}$ é uma medida sobre $(\Omega, \mathcal{A})$.

7.12.2 Variável aleatória não negativa

Definição 7.12.3 (*Esperança de v.a. não negativa*). Para uma v.a. não negativa $X \geq 0$, definimos sua esperança (integral) como:

$$\mathbb{E}[X] = \int X d\mathbb{P} = \lim_{n \rightarrow \infty} \mathbb{E}[X_n] \quad (7.12.3)$$

em que $(X_n)_{n \geq 1}$ é uma sequência de v.a. simples não negativas tais que $X_n \nearrow X$. Caso $\mathbb{E}[X] < \infty$, X é dita *variável aleatória integrável*.

Lema 7.12.1. Considere Y uma variável aleatória simples não negativa e $(X_n)_{n \geq 1}$ uma sequência crescente de variáveis aleatórias simples e não negativas tais que $Y \leq \lim_{n \rightarrow \infty} X_n$. Então, a sequência $(\mathbb{E}[X_n])_{n \geq 1}$ é convergente, e

$$\mathbb{E}[Y] \leq \lim_{n \rightarrow \infty} \mathbb{E}[X_n].$$

Teorema 7.12.3. As seguintes propriedades são válidas para esperança de variáveis aleatórias não negativas

- (1) $\mathbb{E}[aX] = a \mathbb{E}[X], \quad a \in \mathbb{R}$
- (2) $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$
- (3) $X \leq Y \implies \mathbb{E}[X] \leq \mathbb{E}[Y]$
- (4) $\mathbb{E}[c_1 X_1 + \cdots + c_n X_n] = c_1 \mathbb{E}[X_1] + \cdots + c_n \mathbb{E}[X_n] \quad c_1, \dots, c_n \in \mathbb{R};$
- (5) $\mathbb{E}[X] = \sup\{\mathbb{E}[Y] : 0 \leq Y \leq X, Y \text{ é uma v.a. simples}\}$
- (6) $\mathbb{E}[X] = 0 \iff X = 0 \text{ quase certamente.}$

Lema 7.12.2. Considere $Y \geq 0$ simples e $(X_n)_{n \geq 1}$ uma sequência de v.a.n.n. tal que $Y \leq \liminf X_n = \lim_{n \rightarrow \infty} \inf_{k \geq n} X_k$. Então,

$$\mathbb{E}[Y] \leq \liminf \mathbb{E}[X_n].$$

Teorema 7.12.4 (*Lema de Fatou*). Seja $(X_n)_{n \geq 1}$ uma sequência de v.a.n.n. Então,

$$\mathbb{E}[\liminf X_n] \leq \liminf \mathbb{E}[X_n].$$

Teorema 7.12.5 (*3.3 Teorema da Convergência Monótona*). Se $X \geq 0$ for uma variável aleatória e $(X_n)_{n \geq 1}$ uma sequência de v.a.n.n. tal que $X_n \nearrow X$. Então,

$$\mathbb{E}[X] = \lim_{n \rightarrow \infty} \mathbb{E}[X_n].$$

Corolário 7.12.1. Se $(X_n)_{n \geq 1}$ for uma sequência de v.a.n.n., então

$$\mathbb{E} \left[\sum_{n=1}^{\infty} \mathbb{E}[X_n] \right] = \sum_{n=1}^{\infty} \mathbb{E}[X_n].$$

Definição 7.12.4 (*Esperança de v.a.n.n sobre A*). Para uma v.a. não negativa X , definimos a integral de X sobre A como:

$$\int_A X d\mathbb{P} = \int X I_{A_i} d\mathbb{P} = \mathbb{E}[X I_{A_i}]. \quad (7.12.4)$$

Teorema 7.12.6. Se X for uma v.a. não negativa, então a aplicação $\nu: \mathcal{A} \rightarrow [0, \infty]$ definida como $\nu(A) = \int_A X d\mathbb{P}$ é uma medida sobre $(\Omega, \mathcal{A})$.

7.12.3 Variável aleatória integrável

Definição 7.12.5 (*Esperança de v.a. quase-integráveis e integráveis*). Uma variável aleatória X tal que $\mathbb{E}[X^+] < \infty$ ou $\mathbb{E}[X^-] < \infty$ é dita *quase integrável* e definimos sua esperança (integral) com respeito a $\mathbb{P}$ como:

$$\mathbb{E}[X] = \int X d\mathbb{P} = \int X^+ d\mathbb{P} - \int X^- d\mathbb{P} = \mathbb{E}[X^+] - \mathbb{E}[X^-] \quad (7.12.5)$$

A variável X é dita *integrável* se $\mathbb{E}[X^+] < \infty$ e $\mathbb{E}[X^-] < \infty$. Neste caso, dizemos que $X \in L_1$, em que L_1 é o conjunto das variáveis aleatórias integráveis.

Nota: A variável X é integrável se, e somente se, $\mathbb{E}[|X|] < \infty$.

Lema 7.12.3. Se $X_1, X_2 \geq 0$ são v.a. tais que X_1 ou X_2 são integráveis ($\mathbb{E}[X_1] < \infty$ ou $\mathbb{E}[X_2] < \infty$ e $[X_1 = \infty, X_2 = \infty] = \emptyset$), então a variável aleatória $X = X_1 - X_2$ é quase-integrável, e

$$\mathbb{E}[X] = \mathbb{E}[X_1] - \mathbb{E}[X_2].$$

Teorema 7.12.7. As seguintes propriedades são válidas para esperança de variáveis aleatórias quase-integráveis:

- (1) $\mathbb{E}[aX] = a \mathbb{E}[X], \quad a \in \mathbb{R}$
- (2) $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$
- (3) $X \leq Y \implies \mathbb{E}[X] \leq \mathbb{E}[Y]$

Definição 7.12.6 (*Integral de X sobre A*). Para uma v.a. integrável X , definimos a integral de X sobre A como:

$$\left| \int_A X d\mathbb{P} \right| \leq \int |X| d\mathbb{P} < \infty, \quad \text{para todo } A \in \mathcal{A} \quad (7.12.6)$$

Teorema 7.12.8. Se X for uma v.a. integrável, então a aplicação $\nu: \mathcal{A} \rightarrow \mathbb{R}$ definida como $\nu(A) = \int_A X d\mathbb{P}$ é uma função de conjuntos σ -aditiva.

Teorema 7.12.9. Considere X e Y variáveis aleatórias integráveis. Então, as afirmações a seguir são equivalentes:

- (1) $\int_A X d\mathbb{P} = \int_A Y d\mathbb{P}$ para todo $A \in \mathcal{A}$;
- (2) $\int_\Omega |X - Y| d\mathbb{P} = 0$;
- (3) $X = Y$ quase certamente.

Teorema 7.12.10 (3.6 Teorema da Convergência Dominada). Considere $(X_n)_{n \geq 1}$ uma sequência de v.a tais que $X_n(\omega) \rightarrow X(\omega)$ para todo $\omega \in \Omega$. Se existe uma variável aleatória integrável Y tal que $|X_n| \leq Y$ pra todo $n \geq 1$, então X_n é integrável para todo $n \geq 1$ e

$$\mathbb{E}[X] = \lim_{n \rightarrow \infty} \mathbb{E}[X_n].$$

Teorema 7.12.11 (*Mudança de variável*). Considere $X: \Omega \rightarrow \overline{\mathbb{R}}$ uma variável aleatória e $g: \overline{\mathbb{R}} \rightarrow \overline{\mathbb{R}}$ uma função Borel mensurável. Então, a variável aleatória $g(X): \Omega \rightarrow \overline{\mathbb{R}}$ definida como $(g(X))(\omega) = g(X(\omega))$, $\omega \in \Omega$ é tal que

$$\int_{\Omega} g(X(\omega)) d\mathbb{P} = \int_{\overline{\mathbb{R}}} g(x) d\mathbb{P}_X(x),$$

desde que uma das duas integrais esteja definida. A probabilidade $\mathbb{P}_X$ denota a medida de probabilidade induzida por X (distribuição de X) definida como $\mathbb{P}_X(B) = \mathbb{P}([X \in B])$, $B \in \mathcal{B}(\overline{\mathbb{R}})$.

Definição 7.12.7. Dizemos que uma variável aleatória $X: \Omega \rightarrow \overline{\mathbb{R}}$ possui uma densidade com respeito a uma medida μ definida em $(\overline{\mathbb{R}}, \mathcal{B}(\overline{\mathbb{R}}))$ se existe uma função $f_X: \overline{\mathbb{R}} \rightarrow [0, \infty]$ (densidade de X com respeito a μ) Borel mensurável tal que

$$\mathbb{P}_X(B) = \int_B f_X d\mu, \quad \text{para todo } B \in \mathcal{B}(\overline{\mathbb{R}}).$$

Nota:

- (a) Em geral, se ν e μ são duas medidas sobre o espaço mensurável $(\Omega_1, \mathcal{A}_1)$ e existe uma função $\mathcal{A}$ mensurável $f_X: \Omega \rightarrow [0, \infty]$ que satisfaz

$$\nu(A) = \int_A f d\mu, \quad \text{para todo } A \in \mathcal{A},$$

então f é dita *densidade* de ν com respeito a μ . Note que, se isto valer, então

$$\mu(A) = 0, A \in \mathcal{A} \implies \nu(A) = 0. \quad (7.12.7)$$

- (b) Sempre que ν e μ satisfizerem 7.12.7, dizemos que ν é *absolutamente contínua* com respeito a μ e denotamos isto por $\nu \ll \mu$. O célebre teorema e Radon-Nikodym garante a recíproca do resultado apresentado em (a).

7.13 Medida de Probabilidade Produto

7.13.1 Vetores aleatórios

Definição 7.13.1 (σ -álgebra produto). Considere $(\Omega, \mathcal{A}), (\Omega_1, \mathcal{A}_1), \dots, (\Omega_n, \mathcal{A}_n)$ espaços mensuráveis e seja $X_i: \Omega \rightarrow \Omega_i$, $i = 1, \dots, n$. Definimos a σ -álgebra gerada por $X_1, X_2, \dots, X_n$ como a menor σ -álgebra $\mathcal{A}$ de subconjuntos de Ω para a qual X_i é $\mathcal{A} \setminus \mathcal{A}_i$ -mensurável para todo $i = 1, \dots, n$, isto é,

$$\sigma(X_1, X_2, \dots, X_n) = \sigma(\{X_i^{-1}(B_i) : B_i \in \mathcal{A}_i, i = 1, 2, \dots, n\}). \quad (7.13.1)$$

Teorema 7.13.1 (*Condição suficiente para vetor aleatório*). X é um vetor aleatório se

$$[X \in [-\infty, x_1] \times \cdots \times [-\infty, x_n]] \in \mathcal{A} \quad \text{para quaisquer } x_1, \dots, x_n \in \mathbb{R}. \quad (7.13.2)$$

Definição 7.13.2 (*Vetor aleatório*). Seja $(\Omega, \mathcal{A})$ um espaço mensurável. Uma função $X : \Omega \rightarrow \mathbb{R}^n$ é chamada de *vetor aleatório* se for $\mathcal{A} \setminus \mathcal{B}(\mathbb{R}^n)$ -mensurável, isto é,

$$[X \in B] = X^{-1}(B) \in \mathcal{A} \quad \text{para todo } B \in \mathcal{B}(\mathbb{R}^n). \quad (7.13.3)$$

Uma função $X : \Omega \rightarrow \mathbb{R}^n$ é $\mathcal{A} \setminus \mathcal{B}(\mathbb{R}^n)$ -mensurável também é chamada de vetor aleatório.

Teorema 7.13.2. Uma função $X = (X_1, \dots, X_n) : \Omega \rightarrow \mathbb{R}^n$ é um vetor aleatório se, e somente se, $X_1, \dots, X_n$ são variáveis aleatórias.

Definição 7.13.3 (*Distribuição de um vetor aleatório*). Dado um espaço de probabilidade $(\Omega, \mathcal{A}, \mathbb{P})$ e $X = (X_1, \dots, X_n)$ um vetor aleatório, definimos a **distribuição de X** como a medida de probabilidade $\mathbb{P}_X$ sobre $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ dada por

$$\mathbb{P}_X(B) = \mathbb{P}([X \in B]), \quad B \in \mathcal{B}(\mathbb{R}^n). \quad (7.13.4)$$

Definição 7.13.4.

- (1) *Projeção coordenada*: $\pi_i(\omega, \dots, \omega_n) = \omega_i$
- (2) *Cilindro unidimensional de base A_i* : $\pi_i^{-1}(A_i) = \{\omega \in \Omega : \pi_i(\omega) \in A_i\}$
- (3) *Classe dos cilindros unidimensionais*: $\mathcal{C} = \{\pi_i^{-1}(A_i) : A_i \in \mathcal{A}, i = 1, \dots, n\}$
- (4) *Classe dos retângulos mensuráveis*: $\mathcal{R} = \{A_1 \times \cdots \times A_n : A_i \in \mathcal{A}, i = 1, \dots, n\}$
- (5) σ -álgebra produto sobre Ω^n : $\bigotimes_{i=1}^n \mathcal{A}_i = \mathcal{A}_1 \otimes \cdots \otimes \mathcal{A}_n = \sigma(\mathcal{C}) = \sigma(\mathcal{R}) = \sigma(\pi_1, \dots, \pi_n)$
- (6) $\mathcal{B}(\mathbb{R}^n) = \bigotimes_{i=1}^n \mathcal{B}(\mathbb{R})$

7.13.2 Medida produto

Definição 7.13.5 (*Medida de probabilidade produto*). Para $(\Omega_1, \mathcal{A}_1, \mathbb{P}_1), \dots, (\Omega_n, \mathcal{A}_n, \mathbb{P}_n)$ espaços de probabilidade, uma medida de probabilidade $\mathbb{P}$ sobre $(\Omega_1 \times \cdots \times \Omega_n, \mathcal{A}_1 \otimes \cdots \otimes \mathcal{A}_n)$ é dita *medida de probabilidade produto* se satisfizer

$$\mathbb{P}(A_1 \times \cdots \times A_n) = \mathbb{P}_1(A_1) \times \cdots \times \mathbb{P}_n(A_n) \quad (7.13.5)$$

para todo $A_1 \in \mathcal{A}_1, \dots, A_n \in \mathcal{A}_n$. A medida produto $\mathbb{P}$ será denotada por $\mathbb{P}_1 \times \cdots \times \mathbb{P}_n$.

Teorema 7.13.3. Considere $\mathbb{P}_1$ uma probabilidade sobre $(\Omega_1, \mathcal{A}_1)$ e $K : \Omega_1 \times \mathcal{A}_2 \rightarrow [0, 1]$ uma função de transição. Seja $\mathbb{P}$ a probabilidade sobre o espaço produto $(\Omega, \mathcal{A})$ definida como

$$\mathbb{P}(E) = \int_{\Omega_1} K(x, E_x) \mathbb{P}_1(dx), \quad E \in \mathcal{A}. \quad (7.13.6)$$

- (a) Se $f : \Omega \rightarrow [0, +\infty]$ for uma função $\mathcal{A}$ -mensurável, então a função $g : \Omega_1 \rightarrow \mathbb{R}$ definida por

$$g(x) = \int_{\Omega_2} f(x, y) K(x, dy), \quad x \in \Omega_1, \quad (7.13.7)$$

é $\mathcal{A}_1$ -mensurável e $g(x) \geq 0$ para todo $x \in \Omega_1$. Além disso,

$$\int_{\Omega_1 \times \Omega_2} f(x, y) \mathbb{P}(dx, dy) = \int_{\Omega_1} g(x) \mathbb{P}_1(dx) = \int_{\Omega_1} \left[\int_{\Omega_2} f(x, y) K(x, dy) \right] \mathbb{P}_1(dx). \quad (7.13.8)$$

- (b) Se $f : \Omega \rightarrow \mathbb{R}$ for uma função $\mathcal{A}$ -mensurável e quase-integrável com respeito a $\mathbb{P}$, então a função $g : \Omega_1 \rightarrow \mathbb{R}$ dada pela expressão anterior é definida quase certamente, é $\mathcal{A}_1$ -mensurável e quase-integrável com respeito a $\mathbb{P}_1$. Além disso, a identidade continua válida.

Teorema 7.13.4 (*Fubini-Tonelli*). Considere $(\Omega_1, \mathcal{A}_1, \mathbb{P}_1)$ e $(\Omega_2, \mathcal{A}_2, \mathbb{P}_2)$ dois espaços de probabilidade. Seja $(\Omega, \mathcal{A}, \mathbb{P})$ o espaço de probabilidade produto, sendo $\Omega = \Omega_1 \times \Omega_2$, $\mathcal{A} = \mathcal{A}_1 \otimes \mathcal{A}_2$ e $\mathbb{P} = \mathbb{P}_1 \times \mathbb{P}_2$.

- (a) (*Tonelli*) Se $f : \Omega \rightarrow [0, +\infty]$ é uma função $\mathcal{A}$ -mensurável, então as funções $g : \Omega_1 \rightarrow \mathbb{R}$ e $h : \Omega_2 \rightarrow \mathbb{R}$ definidas como

$$g(x) = \int_{\Omega_2} f(x, y) \mathbb{P}_2(dy), \quad x \in \Omega_1, \quad (7.13.9)$$

$$h(y) = \int_{\Omega_1} f(x, y) \mathbb{P}_1(dx), \quad y \in \Omega_2, \quad (7.13.10)$$

são não negativas e $\mathcal{A}_1$ e $\mathcal{A}_2$ -mensuráveis, respectivamente. Além disso,

$$\int_{\Omega_1 \times \Omega_2} f(x, y) \mathbb{P}(dx, dy) = \int_{\Omega_1} \left[\int_{\Omega_2} f(x, y) \mathbb{P}_2(dy) \right] \mathbb{P}_1(dx) \quad (7.13.11)$$

$$= \int_{\Omega_2} \left[\int_{\Omega_1} f(x, y) \mathbb{P}_1(dx) \right] \mathbb{P}_2(dy). \quad (7.13.12)$$

- (b) (*Fubini*) Se $f : \Omega \rightarrow \mathbb{R}$ é uma função $\mathcal{A}$ -mensurável e quase-integrável com respeito a $\mathbb{P}$, então $g : \Omega_1 \rightarrow \mathbb{R}$ ($h : \Omega_2 \rightarrow \mathbb{R}$) dada em (7.13.9) ((7.13.10)) é $\mathcal{A}_1$ -mensurável ($\mathcal{A}_2$ -mensurável) e quase-integrável com respeito a $\mathbb{P}_1$ ($\mathbb{P}_2$). Além disso, as relações (7.13.11) e (7.13.12) permanecem válidas.

Teorema 7.13.5. Considere (X, Y) um vetor aleatório que possui densidade $f_{X,Y}(x, y)$ com respeito à medida de Lebesgue no plano.

- (a) X e Y possuem densidade com respeito à medida de Lebesgue na reta dadas, respectivamente, por

$$f_X(x) = \int_{\mathbb{R}} f_{X,Y}(x, y) d\lambda(y), \quad (7.13.13)$$

$$f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x, y) d\lambda(x). \quad (7.13.14)$$

- (b) X e Y são variáveis aleatórias independentes se, e somente se, $f_{X,Y}(x, y) = f_X(x)f_Y(y)$ para quase todo $(x, y) \in \mathbb{R}^2$.

Nota: λ designa ao mesmo tempo as medidas de Lebesgue na reta e no plano.

7.14 Independência

7.14.1 Eventos

Definição 7.14.1 (*Independência de eventos*). Os eventos $A_1, A_2, \dots, A_n$ são independentes se

$$\mathbb{P}\left(\bigcap_{i \in I} A_i\right) = \prod_{i \in I} \mathbb{P}(A_i) \quad (7.14.1)$$

para todo $I \subset \{1, \dots, n\}$. Ou, de forma equivalente,

$$\mathbb{P}\left(\bigcap_{i=1}^n C_i\right) = \prod_{i=1}^n \mathbb{P}(C_i) \quad (7.14.2)$$

para quaisquer $C_1, \dots, C_n$ tais que $C_i = A_i$ ou $C_i = \Omega$, $i = 1, \dots, n$.

Definição 7.14.2 (*Famílias de eventos*). Uma família de eventos $\{A_t : t \in T\}$ é independente se toda subcoleção finita $\{A_{t_1}, \dots, A_{t_n}\}$ for independente para qualquer escolha de $\{t_1, \dots, t_n\} \subset T$, com t_i 's todos distintos.

7.14.2 Classes de eventos

Definição 7.14.3 (*Independência de classe de eventos*). As classes de eventos $\mathcal{A}_1, \mathcal{A}_2, \dots, \mathcal{A}_n$ são independentes se os eventos $A_1, A_2, \dots, A_n$ são independentes para quaisquer escolhas de $A_1 \in \mathcal{A}_1, A_2 \in \mathcal{A}_2, \dots, A_n \in \mathcal{A}_n$.

Nota: As σ -álgebras $\mathcal{A}_1, \mathcal{A}_2$ são independentes se, e somente se,

$$\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1)\mathbb{P}(A_2), \quad (7.14.3)$$

para quaisquer $A_1 \in \mathcal{A}_1$ e $A_2 \in \mathcal{A}_2$.

Definição 7.14.4 (*Famílias de classes de eventos*).

- Uma família de eventos $\{\mathcal{A}_t : t \in T\}$ é independente se toda subcoleção finita $\{\mathcal{A}_{t_1}, \dots, \mathcal{A}_{t_n}\}$ for independente para quaisquer escolhas de $\{t_1, \dots, t_n\} \subset T$, com t_i 's todos distintos.
- De forma alternativa, $\{\mathcal{A}_t : t \in T\}$ é independente se, e somente se, toda família de eventos $\{A_t : t \in T\}$ for independente, em que $A_t \in \mathcal{A}_t$ para todo $t \in T$.

7.14.3 Variáveis aleatórias

Definição 7.14.5 (*Independência de variáveis aleatórias*).

- As variáveis aleatórias $X_1, X_2, \dots, X_n$ são independentes se, e somente se, as sigma-álgebras geradas $\sigma(X_1), \sigma(X_2), \dots, \sigma(X_n)$ são independentes.
- De forma alternativa, $X_1, X_2, \dots, X_n$ são independentes se, e somente se,

$$\mathbb{P}(X_1 \in B_1, \dots, X_n \in B_n) = \prod_{i=1}^n \mathbb{P}(X_i \in B_i) \quad (7.14.4)$$

para quaisquer $B_1, \dots, B_n \in \mathcal{B}(\mathbb{R})$.

Definição 7.14.6 (*Famílias de variáveis aleatórias*).

- Uma família de variáveis aleatórias $\{X_t : t \in T\}$ é independente se, e somente se, a família de suas σ -álgebras gerada $\{\sigma(X_t) : t \in T\}$ é independente.
- De forma alternativa, $\{X_t : t \in T\}$ é independente se, e somente se, toda subfamília finita $\{X_{t_1}, \dots, X_{t_n}\}$ for independente para quaisquer escolhas de $\{t_1, \dots, t_n\} \subset T$, com t_i 's todos distintos.

7.14.4 Teoremas

Teorema 7.14.1 (*Extensão da Independência 1*). Considere $\mathcal{A}_1 = \sigma(\mathcal{I}_1)$ e $\mathcal{A}_2 = \sigma(\mathcal{I}_2)$, em que $\mathcal{I}_1, \mathcal{I}_2$ são π -sistemas. Então, $\mathcal{A}_1$ e $\mathcal{A}_2$ são independentes se, e somente se $\mathcal{I}_1$ e $\mathcal{I}_2$ são independentes, isto é,

$$\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1)\mathbb{P}(A_2), \quad (7.14.5)$$

para quaisquer $A_1 \in \mathcal{I}_1$ e $A_2 \in \mathcal{I}_2$.

Teorema 7.14.2 (*Extensão da Independência 2*). Sejam $\mathcal{I}_1, \dots, \mathcal{I}_n$ π -sistemas. $\mathcal{I}_1, \dots, \mathcal{I}_n$ são independentes se, e somente se, $\sigma(\mathcal{I}_1), \dots, \sigma(\mathcal{I}_n)$ são independentes.

Corolário 7.14.1. As variáveis aleatórias $X_1, \dots, X_n$ são independentes se, e somente se,

$$\mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n) = \prod_{i=1}^n \mathbb{P}(X_i \leq x_i), \quad (7.14.6)$$

para quaisquer $x_i \in \mathbb{R}$, $i = 1, \dots, n$.

Teorema 7.14.3 (*Lema de Borel-Cantelli*). Seja $(A_n)_{n \geq 1}$ uma sequência de eventos.

- (1) Se $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$, então $\mathbb{P}([A_n \text{ i.v.}]) = 0$;
- (2) Se $\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty$ e $(A_n)_{n \geq 1}$ é independente, então $\mathbb{P}([A_n \text{ i.v.}]) = 1$.

7.15 Convergência

7.15.1 Definições

Definição 7.15.1 (*Quase certa*).

- $(X_n)_{n \geq 1}$ converge quase certamente para X , isto é, $X_n \xrightarrow{\text{q.c.}} X$ se

$$\mathbb{P}([X_n \rightarrow X]) = 1, \quad (7.15.1)$$

em que $[X_n \rightarrow X] = A^c = \{\omega \in \Omega : X_n(\omega) \rightarrow X(\omega)\}$.

- Ou seja, $(X_n)_{n \geq 1}$ converge quase certamente para X se existe $A \in \mathcal{A}$ tal que $\mathbb{P}(A) = 0$ e $X_n \rightarrow X$ em A^c , quando $n \rightarrow \infty$.
- Alternativamente, $(X_n)_{n \geq 1}$ converge quase certamente para X se, e somente se

$$\mathbb{P}([|X_n - X| \geq \epsilon \text{ i.v.}]) = \mathbb{P}(\limsup[|X_n - X| \geq \epsilon]) = 0. \quad (7.15.2)$$

Nota: A convergência quase certa permite que alguns pontos de Ω escapem do critério de convergência, mas o conjunto destes pontos precisa ser negligenciável em termos probabilísticos, isto é, sua probabilidade dever ser zero.

Definição 7.15.2 (*Em probabilidade*). $(X_n)_{n \geq 1}$ converge em probabilidade para X , isto é, $X_n \xrightarrow{P} X$ se, para todo $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| \geq \epsilon) = 0. \quad (7.15.3)$$

Definição 7.15.3 (*Em média p*). Considere $(X_n)_{n \geq 1} \subset L^p, p \geq 1$. $(X_n)_{n \geq 1}$ converge em média p para X , $X_n \xrightarrow{L^p} X$ se $\|X_n - X\|_p \rightarrow 0$ quando $n \rightarrow \infty$, ou seja,

$$\lim_{n \rightarrow \infty} \mathbb{E}[|X_n - X|^p] = 0. \quad (7.15.4)$$

7.15.2 Teoremas

Teorema 7.15.1. Considere $(X_n)_{n \geq 1}$ e $(Y_n)_{n \geq 1}$ duas seqüências de variáveis aleatórias, X e Y variáveis aleatórias.

- (1) $X_n \xrightarrow{\mathcal{P}} X \implies aX_n \xrightarrow{\mathcal{P}} aX$
 $X_n \xrightarrow{\text{q.c.}} X \implies aX_n \xrightarrow{\text{q.c.}} aX$
- (2) $X_n \xrightarrow{\mathcal{P}} X, Y_n \xrightarrow{\mathcal{P}} Y \implies X_n + Y_n \xrightarrow{\mathcal{P}} X + Y$
 $X_n \xrightarrow{\text{q.c.}} X, Y_n \xrightarrow{\text{q.c.}} Y \implies X_n + Y_n \xrightarrow{\text{q.c.}} X + Y$

Teorema 7.15.2 (*Condição necessária e suficiente para convergência q.c.*).

$$X_n \xrightarrow{\text{q.c.}} X \iff \mathbb{P}(|X_n - X| \geq \epsilon \text{ i.v.}) = 0, \forall \epsilon > 0 \quad (7.15.5)$$

Teorema 7.15.3 (*Condição suficiente para convergência q.c.*).

$$\sum_{n=1}^{\infty} \mathbb{P}(|X_n - X| \geq \epsilon) < \infty, \forall \epsilon > 0 \implies X_n \xrightarrow{\text{q.c.}} X \quad (7.15.6)$$

Teorema 7.15.4 (*Relações entre convergências*).

- (1) $X_n \xrightarrow{\text{q.c.}} X \implies X_n \xrightarrow{\mathcal{P}} X$
- (2) $X_n \xrightarrow{L^p} X \implies X_n \xrightarrow{\mathcal{P}} X$

Teorema 7.15.5 (*Fatos úteis*).

- (1) $\{|X_n - Y_n| \geq \epsilon\} \subseteq \{|X_n - X| \geq \epsilon/2\} \cup \{|Y_n - X| \geq \epsilon/2\}$

7.15.3 Desigualdades

Teorema 7.15.6 (*Desigualdades e igualdades importantes*).

- (1) Hölder: $\mathbb{E}[|XY|] \leq (\mathbb{E}[|X|^p])^{\frac{1}{p}} \mathbb{E}[|Y|^q]^{\frac{1}{q}}$, para $X \in L^p, Y \in L^q, p, q > 0, \frac{1}{p} + \frac{1}{q} = 1$
- (2) Lyapunov: $(\mathbb{E}[|X|^q])^{\frac{1}{q}} \leq (\mathbb{E}[|X|^p])^{\frac{1}{p}}$, se $X \in L^p$ e $0 < q \leq p$
- (3) Minkowski: $(\mathbb{E}[|X + Y|^p])^{\frac{1}{p}} \leq (\mathbb{E}[|X|^p])^{\frac{1}{p}} + (\mathbb{E}[|Y|^p])^{\frac{1}{p}}$, para $X, Y \in L^p, p \geq 1$
- (4) Markov: $\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}$ para $X > 0$
- (5) Tchebychev: $\mathbb{P}(|X - c| \geq \epsilon) \leq \frac{\mathbb{E}[|X - c|^p]}{\epsilon^p}, \forall \epsilon > 0$, se $X \in L^p, p > 0$

(6) Jensen: $\mathbb{E}[g(X)] \geq g(\mathbb{E}[X])$, onde $g : \mathbb{R} \rightarrow \mathbb{R}$ é Borel mensurável convexa e $X, g(X) \in L^1$

(a) $\mathbb{E}[X^2] \geq (\mathbb{E}[X])^2$

(7) Cauchy-Schwarz: Se $X, Y \in L^2$, então $XY \in L^1$ e $\mathbb{E}[XY] \leq \mathbb{E}[|XY|] \leq \sqrt{\mathbb{E}[X^2] \mathbb{E}[Y^2]}$

(8) $\mathbb{E}[X] \leq \mathbb{E}[|X|]$

(9) $|\mathbb{E}[X]| \leq \mathbb{E}[|X|]$

(10) $\mathbb{E}[X] - \mu = \mathbb{E}[X - \mu]$

7.15.4 Covariância e Variância

Definição 7.15.4. Para $X, Y \in L^2$, definimos a covariância entre X e Y como

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \quad (7.15.7)$$

$$= \mathbb{E}[XY] - \mathbb{E}[X] \mathbb{E}[Y] \quad (7.15.8)$$

Nota: Se $X, Y \in L^2$ são independentes, então X e Y são não correlacionadas.

7.15.5 Leis dos Grandes Números