

Resultados de Probabilidade e Estatística

Cleiton Moya de Almeida

31 de agosto de 2026

Sumário

1	Álgebra Linear	4
1.1	Sistemas de equações lineares	4
1.2	Definições e propriedades de matrizes	5
1.3	Posto e nulidade	8
1.4	Autovalores e autovetores	9
1.5	Diagonalização	10
1.6	Matrizes em blocos	10
1.7	Formas lineares e quadráticas	11
1.8	Derivadas	13
2	Probabilidade	14
2.1	Distribuições	14
2.1.1	Distribuições discretas	14
2.1.2	Distribuições contínuas	15
2.2	Probabilidade e independência condicional	18
2.3	Esperança, variância e covariância	18
2.4	Transformações	20
2.5	Vetor aleatório	21
3	Inferência	24
3.1	Distribuições amostrais	24
3.1.1	Estatísticas de ordem	25
3.2	Redução de dados	26
3.3	Estimação Pontual I	28
3.4	Estimação Pontual II	29
4	Normal multivariada	33
4.1	Distribuições de formas quadráticas	33
4.2	Normal multivariada	33
5	Regressão	35
6	Inferência Bayesiana	36
7	Probabilidade Avançada	42
7.1	Teoria de conjuntos	42
7.2	Funções	45

7.3	Noções de cardinalidade	47
7.4	Valor absoluto	47
7.5	Sequências de números reais	47
7.6	Sequências de conjuntos	48
7.7	Classes de Subconjuntos	49
7.8	Medida	57
7.9	Probabilidade	58
7.9.1	Convergência	58
7.10	Transformações mensuráveis	58
7.11	Variáveis aleatórias	60
7.12	Esperança	62
7.12.1	Variável aleatória simples	62
7.12.2	Variável aleatória não negativa	63
7.12.3	Variável aleatória integrável	65
7.13	Medida de Probabilidade Produto	66
7.13.1	Vetores aleatórios	66
7.13.2	Medida produto	67
7.14	Independência	69
7.14.1	Eventos	69
7.14.2	Classes de eventos	69
7.14.3	Variáveis aleatórias	70
7.14.4	Teoremas	70
7.15	Convergência	71
7.15.1	Definições	71
7.15.2	Teoremas	72
7.15.3	Desigualdades	72
7.15.4	Covariância e Variância	73
7.15.5	Leis dos Grandes Números	73

Notação

- Variável escalar:
 - (1) Não aleatória: minúscula, itálico (x, θ)
 - (2) Aleatória: maiúscula, itálico (X, θ)
 - Obs.: Exceto v.a. gregas (normalmente usadas em inferência Bayesiana), as quais são geralmente minúsculas.
- Vetor:
 - (1) Não aleatório: minúscula, negrito, itálico ($\boldsymbol{x}, \boldsymbol{\theta}$)
 - (2) Aleatório: maiúscula, negrito, itálico ($\boldsymbol{X}, \boldsymbol{\theta}$)
 - Obs.: Exceto v.a. gregas (normalmente usadas em inferência Bayesiana), as quais são geralmente minúsculas.
- Matriz (aleatória ou não): maiúscula, negrito, reto (não itálico) ($\boldsymbol{X}, \boldsymbol{\Sigma}$)

Capítulo 1

Álgebra Linear

1.1 Sistemas de equações lineares

Teorema 1.1.1 (*Sistemas de equações lineares*). Todo sistema de equações lineares tem ou nenhuma solução, ou exatamente uma solução ou infinitas soluções.

Nota: Um sistema que não possui solução é chamado de inconsistente; se existir pelo menos uma solução, dizemos que o sistema é consistente.

Teorema 1.1.2 (*Sistemas homogêneos*).

- (1) Um sistema homogêneo de equações lineares com mais incógnitas que equações (subdeterminado) tem infinitas soluções.
- (2) Se o sistema homogêneo tem n incógnitas e a forma escalonada reduzida por linhas (echelon) da matriz aumentada tem r linhas não nulas, então o sistema possui $n - r$ variáveis livres (parâmetros).

Nota:

- (1) Um sistema não-homogêneo com mais equações que incógnitas (sobre-determinado) não precisa ser consistente.
- (2) Todo sistema homogêneo é consistente, pois admite ao menos a solução trivial.

Teorema 1.1.3 (*Solução geral e particular*). Seja $\mathbf{x}_0$ qualquer solução de um sistema consistente $\mathbf{Ax} = \mathbf{b}$. Se $S = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$ é uma base para o espaço-nulo de $\mathbf{A}$, então toda solução de $\mathbf{Ax} = \mathbf{b}$ pode ser expressa como

$$\mathbf{x} = \mathbf{x}_0 + c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_k\mathbf{v}_k. \quad (1.1.1)$$

De forma contrária, para todas as escolhas de $c_1, c_2, \dots, c_k$, $\mathbf{x}$ é uma solução de $\mathbf{Ax} = \mathbf{b}$.

Nota: $\mathbf{x}_0$ é chamado de solução particular de $\mathbf{Ax} = \mathbf{b}$ e a parte restante de solução geral de $\mathbf{Ax} = \mathbf{0}$. Assim, a solução geral de um sistema consistente de equações lineares pode ser expressa como a soma de uma solução particular do sistema e a solução geral do sistema homogêneo correspondente.

Teorema 1.1.4 (*Sistema $m \times n$*). . Seja $\mathbf{A}_{m \times n}$ com $\text{pos}(\mathbf{A}) = r$.

- **Caso sobredeterminado:** se $m > n$, então $\exists \mathbf{b} \in \mathbb{R}^m$ tal que o sistema $\mathbf{A}\mathbf{x} = \mathbf{b}$ é inconsistente (sempre, pois $r \leq n < m \implies \text{Col}(\mathbf{A}) \subsetneq \mathbb{R}^m$).
 - (1) Para os $\mathbf{b} \in \text{Col}(\mathbf{A})$ (onde o sistema é consistente):
 - Se $r = n$ (posto-coluna completo): solução única ($n - r = 0$ parâmetros);
 - Se $r < n$: solução geral com $n - r > 0$ parâmetros (infinitas soluções).
- **Caso subdeterminado:** se $m < n$, então $\forall \mathbf{b} \in \mathbb{R}^m$, o sistema $\mathbf{A}\mathbf{x} = \mathbf{b}$ é inconsistente ou possui infinitas soluções (nunca única, pois $r \leq m < n$).
 - (1) Se $r = m$ (posto-linha completo): $\text{Col}(\mathbf{A}) = \mathbb{R}^m$, logo o sistema é *sempre* consistente, com $n - r > 0$ parâmetros;
 - (2) Se $r < m$: o sistema é consistente sse $\mathbf{b} \in \text{Col}(\mathbf{A})$; se consistente, possui $n - r$ parâmetros.

1.2 Definições e propriedades de matrizes

Definição 1.2.1. Definições de matrizes

- (1) Matriz singular: Se $\mathbf{A}$ não admite inversa, $\mathbf{A}$ é dita singular.
- (2) Matriz simétrica: $\mathbf{A} = \mathbf{A}^\top$
- (3) Matriz ortogonal: $\mathbf{A}^{-1} = \mathbf{A}^\top$
- (4) Matriz triangular superior (inferior): elementos abaixo (acima) da diagonal principal são nulos.
- (5) Matriz quadrada idempotente: $\mathbf{A}$ é idempotente se $\mathbf{A} = \mathbf{A}\mathbf{A}$
- (6) Traço: $\text{tr } \mathbf{A} = a_{11} + a_{22} + \cdots + a_{nn}$
- (7) $\mathbf{A}^0 = \mathbf{I}$
- (8) $\mathbf{A}^n = \underbrace{\mathbf{A}\mathbf{A} \cdots \mathbf{A}}_{n \text{ fatores}}$
- (9) $\mathbf{A}^{-n} = (\mathbf{A}^{-1})^n$ e
- (10) Polinômio matricial: Seja $\mathbf{A}$ uma matriz quadrada e $p(x) = a_0 + a_1x + \cdots + a_nx^n$. Definimos $p(\mathbf{A}) = a_0\mathbf{I} + a_1\mathbf{A} + \cdots + a_n\mathbf{A}^n$.
- (11) $\mathbf{u}$ e $\mathbf{v}$ são ortogonais se $\mathbf{u} \cdot \mathbf{v} = \mathbf{u}^\top \mathbf{v} = 0$

Teorema 1.2.1 (*Lei dos expoentes*).

- (1) $\mathbf{A}^r \mathbf{A}^s = \mathbf{A}^{r+s}$

$$(2) (\mathbf{A}^r)^s = \mathbf{A}^{rs}$$

Teorema 1.2.2 (*Propriedades da transposta*).

- (1) $(\mathbf{A}^\top)^\top = \mathbf{A}$
- (2) $(\mathbf{A} + \mathbf{B})^\top = \mathbf{A}^\top + \mathbf{B}^\top$
- (3) $(\mathbf{A} - \mathbf{B})^\top = \mathbf{A}^\top - \mathbf{B}^\top$
- (4) $(k\mathbf{A})^\top = k\mathbf{A}^\top$
- (5) $(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$

Teorema 1.2.3 (*Propriedades de matrizes inversas*).

- (1) Se $\mathbf{A}$ admite inversa, então a inversa é única
- (2) $(\mathbf{A}^{-1})^{-1} = \mathbf{A}$
- (3) $\mathbf{A}$ é invertível $\implies \mathbf{A}^n$ é invertível e $(\mathbf{A}^n)^{-1} = (\mathbf{A}^{-1})^n$
- (4) $\mathbf{A}$ é invertível $\iff \mathbf{A}^\top \mathbf{A}$ e $\mathbf{A} \mathbf{A}^\top$ são invertíveis
- (5) $(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}$
- (6) $(k\mathbf{A})^{-1} = \frac{1}{k} \mathbf{A}^{-1}$
- (7) $(\mathbf{A}^\top)^{-1} = (\mathbf{A}^{-1})^\top$
- (8) Sejam $\mathbf{A}$ e $\mathbf{B}$ são matrizes quadradas de mesma dimensão.
 $\mathbf{AB}$ é invertível $\iff \mathbf{A}$ e $\mathbf{B}$ também são.

Teorema 1.2.4 (*Inversa de matriz 2×2*). Seja $\mathbf{A}_{2 \times 2}$ definida por

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \quad (1.2.1)$$

Se $ad - bc \neq 0$, a inversa de $\mathbf{A}$ é dada por

$$\mathbf{A}^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix} \quad (1.2.2)$$

Teorema 1.2.5 (*Propriedades de matrizes triangulares*).

- (1) A transposta de uma matriz triangular inferior (superior) é triangular inferior (superior).
- (2) O produto de matrizes triangulares inferiores (superiores) é triangular inferior (superior).

- (3) Uma matriz triangular é invertível se, e somente se, as entradas na diagonal principal são todas não nulas.
- (4) A inversa de uma matriz triangular inferior (superior) é triangular inferior (superior).
- (5) $\mathbf{A}$ é triangular $\implies \det(\mathbf{A}) = a_{11}a_{22} \cdots a_{nn}$
- (6) $\mathbf{A}$ é triangular $\implies$ os autovalores de $\mathbf{A}$ são as entradas da diagonal principal

Teorema 1.2.6 (*Propriedades de matrizes simétricas*).

- (1) $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$ são simétricas
- (2) $\mathbf{A}, \mathbf{B}$ são simétricas $\implies \mathbf{A} + \mathbf{B}$ e $\mathbf{A} - \mathbf{B}$ são simétricas
- (3) $\mathbf{A}$ é simétrica $\implies \mathbf{A}^{-1}$ é simétrica
- (4) $\mathbf{A}$ é invertível $\implies \mathbf{A}\mathbf{A}^\top$ e $\mathbf{A}^\top \mathbf{A}$ são invertíveis.

Teorema 1.2.7 (*Propriedades de matrizes idempotentes*).

- (1) $\mathbf{A}$ é idempotente $\implies \text{pos}(\mathbf{A}) = \text{tr}(\mathbf{A})$
- (2) $\mathbf{A} - \mathbf{B}$ é idempotente $\implies \text{pos}(\mathbf{A} - \mathbf{B}) = \text{pos}(\mathbf{A}) - \text{pos}(\mathbf{B})$

Teorema 1.2.8 (*Propriedades da matriz Design e Matriz $\hat{H}$*). Sejam:

- $\mathbf{X}_{n \times (p+1)}$ com $n > p + 1$ e posto $p + 1$ (posto-coluna) completo;
- $\hat{\mathbf{H}}_{n \times n} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$.

Então:

- (1) $\mathbf{H}$ é idempotente.
- (2) $\mathbf{I} - \mathbf{H}$ é idempotente.
- (3) $\mathbf{H}$ e $\mathbf{I} - \mathbf{H}$ são ortogonais, isto é, $(\mathbf{I} - \mathbf{H})\mathbf{H} = \mathbf{0}$.
- (4) $\text{pos}(\mathbf{H}) = \text{pos}(\mathbf{X}) = p + 1$
- (5) $\text{pos}(\mathbf{I} - \mathbf{H}) = n - (p + 1)$

Teorema 1.2.9 (*Propriedades do traço*).

- (1) $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$
- (2) $\text{tr}(\mathbf{A} + \mathbf{B}) = \text{tr}(\mathbf{A}) + \text{tr}(\mathbf{B})$

Teorema 1.2.10 (*Propriedades do determinante*).

- (1) $\det(\mathbf{A}) = \det(\mathbf{A}^\top)$
- (2) $\det(\mathbf{AB}) = \det \mathbf{A} \det \mathbf{B}$
- (3) $\det(k\mathbf{A}) = k^n \det(\mathbf{A})$
- (4) $\mathbf{A}$ é invertível $\iff \det \mathbf{A} \neq 0$
- (5) $\mathbf{A}$ é invertível $\implies \det(\mathbf{A}^{-1}) = \frac{1}{\det \mathbf{A}}$
- (6) Se $\mathbf{A}$ tem uma linha (coluna) de zeros, então $\det(\mathbf{A}) = 0$
- (7) Se $\mathbf{A}$ tem duas linhas (colunas) proporcionais, então $\det(\mathbf{A}) = 0$
- (8) $\mathbf{A}$ é triangular $\implies \det(\mathbf{A}) = a_{11}a_{22} \cdots a_{nn}$
- (9) $\mathbf{A}$ é ortogonal $\implies \det(\mathbf{A}) = \pm 1$
- (10) Seja $\mathbf{B}$ resultante de uma das seguintes operações em linhas (colunas) de $\mathbf{A}$.
 - (a) Multiplicar linha (coluna) por k : $\det(\mathbf{B}) = k \det(\mathbf{A})$
 - (b) Permutar linha (coluna): $\det(\mathbf{B}) = -\det(\mathbf{A})$
 - (c) Múltiplo de uma linha (coluna) é somado a uma outra linha (coluna): $\det(\mathbf{B}) = \det(\mathbf{A})$

1.3 Posto e nulidade

Definição 1.3.1 (*Posto e nulidade*). Seja $\mathbf{A}$ qualquer;

- (1) Posto de $\mathbf{A}$ ($\text{pos}(\mathbf{A})$): dimensão comum do espaço-linha e do espaço-coluna de $\mathbf{A}$;
- (2) Nulidade de $\mathbf{A}$ ($\text{nul}(\mathbf{A})$): dimensão do espaço-nulo de $\mathbf{A}$.

Teorema 1.3.1 (*Propriedades do posto e nulidade*). Seja $\mathbf{A}_{m \times n}$

- (1) $\text{pos}(\mathbf{A}) = \text{pos}(\mathbf{A}^\top)$
- (2) $\text{pos}(\mathbf{A}) = \text{pos}(\mathbf{A}^\top \mathbf{A}) = \text{pos}(\mathbf{A} \mathbf{A}^\top)$
- (3) $\text{pos}(\mathbf{A}) + \text{nul}(\mathbf{A}) = n$
- (4) $\text{pos}(\mathbf{A})$: núm. de variáveis líderes na solução geral de $\mathbf{Ax} = \mathbf{b}$
- (5) $\text{nul}(\mathbf{A})$: núm. de parâmetros na solução geral de $\mathbf{Ax} = \mathbf{b}$
- (6) Se $\text{pos}(\mathbf{A}) = p$, então $n - p$ raízes do polinômio característico são nulos

Teorema 1.3.2 (*Teorema da Consistência*). Sja $\mathbf{Ax} = \mathbf{b}$ é um sistema linear de m equações por n incógnitas com $\mathbf{b}$ fixado. As seguintes afirmações são equivalentes:

- (1) $\mathbf{Ax} = \mathbf{b}$ é consistente.
- (2) $\mathbf{b}$ está no espaço-coluna de $\mathbf{A}$.
- (3) $\mathbf{A}$ e $[\mathbf{A} \mid \mathbf{b}]$ tem o mesmo posto.

Teorema 1.3.3. Seja $\mathbf{Ax} = \mathbf{b}$ um sistema linear de m equações por n incógnitas. As seguintes afirmações são equivalentes:

- (1) $\mathbf{Ax} = \mathbf{b}$ é consistente para todo $\mathbf{b}$.
- (2) Os vetores-coluna $\mathbf{A}$ geram o $\mathbb{R}^m$.
- (3) $\text{pos}(\mathbf{A}) = m$.

Teorema 1.3.4. Seja $\mathbf{Ax} = \mathbf{b}$ um sistema linear consistente de m equações por n incógnitas. Se $\text{pos}(\mathbf{A}) = r$, então a solução geral do sistema contém $n - r$ parâmetros.

Teorema 1.3.5 (*Sistemas $m \times n$*). Seja $\mathbf{A}_{m \times n}$. As seguintes afirmações são equivalentes:

- (1) $\mathbf{Ax} = \mathbf{0}$ possui somente a solução trivial.
- (2) Os vetores-coluna de $\mathbf{A}$ são LI.
- (3) $\mathbf{Ax} = \mathbf{b}$ tem no máximo uma (uma ou nenhuma) solução para cada $\mathbf{b}$.

1.4 Autovalores e autovetores

Definição 1.4.1. Definições sobre autovalores e autovetores.

- (1) Seja $\mathbf{A}_{n \times n}$. Um vetor não nulo $\mathbf{x} \in \mathbb{R}^n$ é chamado de **autovetor** de $\mathbf{A}$ se

$$\mathbf{Ax} = \lambda \mathbf{x} \tag{1.4.1}$$

para algum escalar λ , o qual é chamado de **autovalor** de $\mathbf{A}$.

- (2) Equação característico: $\det(\lambda \mathbf{I} - \mathbf{A}) = 0$
- (3) Quando a equação característica é expandida, ela toma a forma

$$p(\lambda) = \lambda^n + c_1 \lambda^{n-1} + \cdots + c_n \tag{1.4.2}$$

e $p(\lambda)$ é denominado polinômio característico.

- (4) Espaço-solução do sistema $(\lambda \mathbf{I} - \mathbf{A})\mathbf{x} = \mathbf{0}$: **auto-espaço** de $\mathbf{A}$ associado a λ .
- (5) Multiplicidade algébrica de λ_0 : número de vezes que $(\lambda - \lambda_0)$ aparece como um fator do polinômio característico.

- (6) Multiplicidade geométrica de λ_0 : dimensão do auto-espaço associado a $\lambda - \lambda_0$

Teorema 1.4.1 (*Propriedades de autovalores e autovetores*). Seja $\mathbf{A}_{n \times n}$.

- (1) $\mathbf{A}$ é triangular $\implies$ os autovalores de $\mathbf{A}$ são as entradas da diagonal principal
- (2) $\mathbf{A}^k \mathbf{x} = \lambda^k \mathbf{x}$
- (3) $\mathbf{A}$ é invertível $\iff \lambda = 0$ não é um autovalor de $\mathbf{A}$

Teorema 1.4.2 (*Propriedades das raízes característica*). Seja $\mathbf{A}_{n \times n}$.

- (1) A soma das raízes características de $\mathbf{A}$ é $\text{tr}(\mathbf{A})$
- (2) O produto das raízes características de $\mathbf{A}$ é $\det(\mathbf{A})$
- (3) Se $\text{pos}(\mathbf{A}) = p$, então $n - p$ raízes do polinômio característico são nulos

1.5 Diagonalização

Teorema 1.5.1 (*Diagonalização*). Seja $\mathbf{A}_{n \times n}$.

- (1) $\mathbf{A}$ é diagonalizável $\iff \mathbf{A}$ tem n autovetores LI.
- (2) $\mathbf{A}$ é diagonalizável $\iff$ Para cada autovalor, a multiplicidade geométrica é igual à multiplicidade algébrica.
- (3) $\mathbf{A}$ tem n autovalores distintos $\implies \mathbf{A}$ é diagonalizável.

1.6 Matrizes em blocos

Teorema 1.6.1. Seja $\mathbf{B}$ uma matriz particionada em blocos,

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \mathbf{B}_{21} & \mathbf{B}_{22} \end{bmatrix}, \quad (1.6.1)$$

em que $\mathbf{B}_{11}$ e $\mathbf{B}_{22}$ são matrizes quadradas não-singulares. Então

$$\mathbf{B}^{-1} = \begin{bmatrix} (\mathbf{B}_{11} - \mathbf{B}_{12}\mathbf{B}_{22}^{-1}\mathbf{B}_{21})^{-1} & -\mathbf{B}_{11}^{-1}\mathbf{B}_{12}(\mathbf{B}_{22} - \mathbf{B}_{21}\mathbf{B}_{11}^{-1}\mathbf{B}_{12})^{-1} \\ -\mathbf{B}_{22}^{-1}\mathbf{B}_{21}(\mathbf{B}_{11} - \mathbf{B}_{12}\mathbf{B}_{22}^{-1}\mathbf{B}_{21})^{-1} & (\mathbf{B}_{22} - \mathbf{B}_{21}\mathbf{B}_{11}^{-1}\mathbf{B}_{12})^{-1} \end{bmatrix} \quad (1.6.2)$$

e

$$|\mathbf{B}| = |\mathbf{B}_{22}| |\mathbf{B}_{11} - \mathbf{B}_{12}\mathbf{B}_{22}^{-1}\mathbf{B}_{21}| = |\mathbf{B}_{11}| |\mathbf{B}_{22} - \mathbf{B}_{21}\mathbf{B}_{11}^{-1}\mathbf{B}_{12}|. \quad (1.6.3)$$

Teorema 1.6.2. Seja $\mathbf{B}$ uma matriz bloco diagonal,

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{B}_{22} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{B}_{33} \end{bmatrix}, \quad (1.6.4)$$

em que $\mathbf{B}_{11}$, $\mathbf{B}_{22}$ e $\mathbf{B}_{33}$ são matrizes quadradas não-singulares. Então

$$\mathbf{B}^{-1} = \begin{bmatrix} \mathbf{B}_{11}^{-1} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{B}_{22}^{-1} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{B}_{33}^{-1} \end{bmatrix} \quad (1.6.5)$$

e

$$|\mathbf{B}| = |\mathbf{B}_{11}| |\mathbf{B}_{22}| |\mathbf{B}_{33}|. \quad (1.6.6)$$

O resultado vale para matrizes bloco diagonal de maior dimensão.

1.7 Formas lineares e quadráticas

Definição 1.7.1 (*Formas lineares e quadráticas*).

(1) Forma linear: $b_1x_1 + b_2x_2 + \cdots + b_nx_n$

(a) $f(\mathbf{x}) = \mathbf{b}^\top \mathbf{x} = \mathbf{x}^\top \mathbf{b}$

(2) Forma afim: $f(\mathbf{x}) = a + \mathbf{b}^\top \mathbf{x}$

(3) Forma quadrática: $a_1x_1^2 + a_2x_2^2 + \cdots + a_nx_n^2$ (mais todos possíveis termos $a_kx_ix_j$, com $i \neq j$)

(a) Se $\mathbf{A}_{n \times n}$ é simétrica e $\mathbf{x}$ é vetor-coluna $n \times 1$, a forma quadrática associada a $\mathbf{A}$ é $Q_{\mathbf{A}} = \mathbf{x}^\top \mathbf{A} \mathbf{x}$

Nota:

(1) Se $\mathbf{A}$ é a diagonal, a forma quadrática não possui termos cruzados.

conteúdo...

Definição 1.7.2 (*Classificação de formas quadráticas e matrizes*). Uma forma quadrática $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ e a respectiva matriz $\mathbf{A}$ simétrica é dita:

(1) Positiva definida: se $\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$ para todo $\mathbf{x} \neq 0$

(2) Positiva semidefinida: se $\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0$ para todo $\mathbf{x} \neq 0$ e $\mathbf{x}^\top \mathbf{A} \mathbf{x} = 0$ para pelo menos um $\mathbf{x} \neq 0$

(3) Negativa definida: se $\mathbf{x}^\top \mathbf{A} \mathbf{x} < 0$ para todo $\mathbf{x} \neq 0$

(4) Negativa semidefinida: se $\mathbf{x}^\top \mathbf{A} \mathbf{x} \leq 0$ para todo $\mathbf{x} \neq 0$ e $\mathbf{x}^\top \mathbf{A} \mathbf{x} = 0$ para pelo menos um $\mathbf{x} \neq 0$

(5) Indefinida: $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ assume valores positivos e negativos.

Teorema 1.7.1. Seja $\mathbf{A}_{n \times n}$ simétrica.

- (1) $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ ($\mathbf{A}$) é positiva definida $\iff$ todos os autovalores de $\mathbf{A}$ são positivos.
- (2) $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ ($\mathbf{A}$) é negativa definida $\iff$ todos os autovalores de $\mathbf{A}$ são negativos.
- (3) $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ ($\mathbf{A}$) é indefinido $\iff$ $\mathbf{A}$ tem pelo menos um autovalor positivo e pelo menos um autovalor negativo.

Teorema 1.7.2. Seja $\mathbf{A}_{n \times n}$ simétrica. ($\mathbf{A}$) As seguintes afirmações são equivalentes.

- (1) $\mathbf{A}$ é positiva definida
- (2) Todos os autovalores de $\mathbf{A}$ são positivos.
- (3) Os determinantes de cada submatriz da diagonal principal são positivos (critério de Sylvester).

Teorema 1.7.3. Seja $\mathbf{A}_{n \times n}$ simétrica. Se $\mathbf{A}$ é positiva definida, então:

- (1) $\text{pos}(\mathbf{A}) = n$
- (2) $a_{ii} > 0$ para todo $i = 1, \dots, n$
- (3) $\mathbf{P}^\top \mathbf{A} \mathbf{P}$ é positiva definida para toda matriz $\mathbf{P}_{n \times p}$

Teorema 1.7.4. Seja $\mathbf{A}_{n \times n}$ simétrica. Se $\mathbf{A}$ é positiva semidefinida, então:

- (1) $\text{pos}(\mathbf{A}) < n$
- (2) $a_{ii} \geq 0$ para todo $i = 1, \dots, n$
- (3) $\mathbf{P}^\top \mathbf{A} \mathbf{P}$ é positiva semidefinida para toda matriz $\mathbf{P}_{n \times p}$

Teorema 1.7.5. Seja $\mathbf{A}_{m \times n}$. Então,

- (1) $\mathbf{A}^\top \mathbf{A}$ é positiva semidefinida.
- (2) $\mathbf{A}^\top \mathbf{A}$ é positiva se tem posto-coluna completo, ou seja, $\text{pos}(\mathbf{A})$.

1.8 Derivadas

Definição 1.8.1 (*Derivada de função escalar*). Considere uma função escalar $f : \mathbb{R}^n \rightarrow \mathbb{R}$, em que $\mathbf{b} \in \mathbb{R}^n$. Adotaremos como convenção a derivada da função f em relação ao vetor $\mathbf{b}$ como o gradiente

$$\frac{\partial f}{\partial \mathbf{b}} = \nabla_{\mathbf{b}} f = \begin{pmatrix} \frac{\partial f}{\partial b_1} \\ \frac{\partial f}{\partial b_2} \\ \vdots \\ \frac{\partial f}{\partial b_n} \end{pmatrix}. \quad (1.8.1)$$

Assim, $\frac{\partial f}{\partial \mathbf{b}}$ é um vetor de dimensão $n \times 1$.

Teorema 1.8.1. Considere a forma linear $f(\mathbf{x}) = \mathbf{b}^\top \mathbf{x} = \mathbf{x}^\top \mathbf{b}$, em que $\mathbf{b} \in \mathbb{R}^n$ é um vetor constante. Como $f(\mathbf{x}) = b_1 x_1 + b_2 x_2 + \cdots + b_n x_n$, temos

$$\frac{\partial f}{\partial x_i} = b_i, \quad i = 1, \dots, n. \quad (1.8.2)$$

Portanto,

$$\boxed{\frac{\partial}{\partial \mathbf{x}} (\mathbf{b}^\top \mathbf{x}) = \frac{\partial}{\partial \mathbf{x}} (\mathbf{x}^\top \mathbf{b}) = \mathbf{b}}. \quad (1.8.3)$$

Teorema 1.8.2. Considere $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$. A derivada em relação a x_k é

$$\frac{\partial f}{\partial x_k} = \underbrace{\sum_{j=1}^n a_{kj} x_j}_{\text{linha } k \text{ de } \mathbf{A}} + \underbrace{\sum_{i=1}^n a_{ik} x_i}_{\text{coluna } k \text{ de } \mathbf{A}}. \quad (1.8.4)$$

A derivada em $\mathbf{x}$ nesse caso é dada por

$$\boxed{\frac{\partial}{\partial \mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}}. \quad (1.8.5)$$

Em particular, se $\mathbf{A}$ é simétrica (forma quadrática), então $\mathbf{A}^\top = \mathbf{A}$, logo $(\mathbf{A} + \mathbf{A}^\top) \mathbf{x} = 2\mathbf{A} \mathbf{x}$ e, portanto,

$$\boxed{\frac{\partial}{\partial \mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{A} \mathbf{x}}. \quad (1.8.6)$$

Teorema 1.8.3. Considere $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{b}^\top \mathbf{x}$. Então

$$\frac{\partial f}{\partial \mathbf{x}} = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x} + \mathbf{b}. \quad (1.8.7)$$

Se $\mathbf{A}$ é simétrica,

$$\boxed{\frac{\partial f}{\partial \mathbf{x}} = 2\mathbf{A} \mathbf{x} + \mathbf{b}}. \quad (1.8.8)$$

Capítulo 2

Probabilidade

2.1 Distribuições

Teorema 2.1.1 (*Família exponencial*). Pertencem à família exponencial:

- **Discretas:** Bernoulli ($0 < p < 1$), Binomial (n fixo, $0 < p < 1$), Poisson, Binomial Negativa ($0 < p < 1$), Geométrica;
- **Contínuas:** Exponencial, Normal, Gama, Qui-quadrado, Beta, Normal Inversa, Weibull.

2.1.1 Distribuições discretas

Uniforme discreta(N)

- $f_X(x \mid N) = \frac{1}{N} \mathbb{1}_{1,\dots,N}(x), \quad N \in \mathbb{N}$
- $\mathbb{E}[X] = \frac{N+1}{2}$
- $\text{Var}[X] = \frac{(N+1)(N-1)}{12}$
- $M_X(t) = \frac{1}{N} \sum_{i=1}^N e^{it}$

Bernoulli(p)

- $f_X(x \mid p) = p^x(1-p)^{1-x} \mathbb{1}_{\{0,1\}}(x), \quad 0 \leq p \leq 1$
- $\mathbb{E}[X] = p$
- $\text{Var}[X] = p(1-p)$
- $M_X(t) = (1-p) + pe^t$

Binomial(n,p)

- $f_X(x \mid n, p) = \binom{n}{x} p^x (n-p)^{1-x} \mathbb{1}_{\{0,1,\dots,n\}}(x), \quad 0 \leq p \leq 1$
- $\mathbb{E}[X] = np$
- $\text{Var}[X] = np(1-p)$
- $M_X(t) = [(1-p) + pe^t]^n$

Poisson(θ)

- $f_X(x \mid \theta) = \frac{\theta^x e^{-\theta}}{x!} \mathbb{1}_{\{0,1,\dots\}}(x), \quad \theta \geq 0$
- $\mathbb{E}[X] = \theta$
- $\text{Var}[X] = \theta$
- $M_X(t) = e^{\theta(e^t-1)}$

2.1.2 Distribuições contínuas

Uniforme(a,b)

- $f_X(x \mid a, b) = \frac{1}{b-a} \mathbb{1}_{(a,b)}(x), \quad a, b \in \mathbb{R}$
- $F_X(x) = \frac{x-a}{b-a} \mathbb{1}_{(a,b)}(x) + \mathbb{1}_{[b,\infty)}(x)$
- $\mathbb{E}[X] = \frac{a+b}{2}$
- $\text{Var}[X] = \frac{1}{12}(b-a)^2$
- $M_X(t) = \begin{cases} \frac{e^{tb} - e^{ta}}{t(b-a)}, & \text{para } t \neq 0 \\ 1, & \text{para } t = 0 \end{cases}$
- $\hat{a} = X_{(1)}, \hat{b} = X_{(n)}$

Exponencial(λ)

- $f_X(x \mid \lambda) = \lambda e^{-\lambda x} \mathbb{1}_{\mathbb{R}_+}(x), \quad \lambda > 0$
- $F_X(x) = (1 - e^{-\lambda x}) \mathbb{1}_{\mathbb{R}_+}(x)$
- $\mathbb{E}[X] = \frac{1}{\lambda}$
- $\text{Var}[X] = \frac{1}{\lambda^2}$
- $M_X(t) = \frac{\lambda}{\lambda - t}, \text{ para } t < \lambda$
- $\hat{\lambda} = 1/\bar{X}$

Normal(μ, σ^2)

- $f_X(x \mid \mu, \sigma^2) = \frac{1}{\sqrt{\mu, \sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\} \mathbb{1}_{\mathbb{R}}(x), \quad \mu \in \mathbb{R}, \sigma > 0$
- $\mathbb{E}[X] = \mu$
- $\text{Var}[X] = \sigma^2$
- $M_X(t) = e^{\mu t + \sigma^2 t^2 / 2}$, para $t < \lambda$
- $\hat{\mu} = \bar{X}, \hat{\sigma}^2 = \left(\frac{n+1}{n}\right) S^2$

 χ_n^2

- $f_U(u \mid n) = \frac{1}{\Gamma\left(\frac{n}{2}\right) 2^{n/2}} u^{(n-2)/2} e^{-u/2} \mathbb{1}_{(0, \infty)}(u), \quad n \geq 1 \text{ inteiro}$
- $\mathbb{E}[U] = n$
- $\text{Var}[U] = 2n$
- $M_U(t) = (1 - 2t)^{-n/2}$, para $t < \frac{1}{2}$

 $\chi_{n,\lambda}^2$

- $f_U(u \mid n, \lambda) = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} \frac{u^{(n+2k-2)/2} e^{-u/2}}{\Gamma\left(\frac{n+2k}{2}\right) 2^{(n+2k)/2}} \mathbb{1}_{(0, \infty)}(u), \quad n \geq 1 \text{ inteiro}, \lambda \geq 0$
- $\mathbb{E}[U] = n + 2\lambda$
- $\text{Var}[U] = 2(n + 4\lambda)$
- $M_U(t) = (1 - 2t)^{-n/2} \exp \left\{ -\lambda [1 - (1 - 2t)^{-1}] \right\}$, para $t < \frac{1}{2}$

Beta(α, β)

- $f_X(x \mid \alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1} \mathbb{1}_{\mathbb{R}_{[0,1]}}(x), \quad \alpha, \beta > 0$
- $\mathbb{E}[X] = \frac{\alpha}{\alpha + \beta}$
- $\text{Var}[X] = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$
- $M_X(t) = 1 + \sum_{k=1}^{\infty} \left(\prod_{r=0}^{k-1} \frac{\alpha + r}{\alpha + \beta + r} \right) \frac{t^k}{k!}$

Gama(α, θ) (*shape, scale*)

Obs.: parametrização padrão da função $\text{rgamma}(N, \text{shape}, \text{scale})$ do R.

- $f_X(x \mid \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-x/\theta} \mathbb{1}_{\mathbb{R}_+}(x), \quad \alpha, \theta > 0$
- $\mathbb{E}[X] = \alpha\theta$
- $\text{Var}[X] = \alpha\theta^2$
- Moda: $(\alpha - 1)\theta$, para $\alpha \geq 1$; 0, para $\alpha < 1$
- $M_X(t) = (1 - \theta t)^{-\alpha}$, para $t < \frac{1}{\theta}$

Gama(α, β) (*shape, rate*)

- $f_X(x \mid \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} \mathbb{1}_{\mathbb{R}_+}(x), \quad \alpha, \beta > 0$
- $\mathbb{E}[X] = \frac{\alpha}{\beta}$
- $\text{Var}[X] = \frac{\alpha}{\beta^2}$
- Moda = $\frac{\alpha-1}{\beta}$, para $\alpha \geq 1$; 0, para $\alpha < 1$
- $M_X(t) = \left(1 - \frac{t}{\beta}\right)^{-\alpha}$, para $t < \beta$

Teorema 2.1.2 (*Utilidade pública*). Sejam $x_1, x_2, \dots, x_n$ números reais quaisquer e $\bar{x}$ seu valor médio. Então,

- (1) $\min_a \sum_{i=1}^n (x_i - a)^2 = \sum_{i=1}^n (x_i - \bar{x})^2$;
- (2) $\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$;
- (3) $\sum_{i=1}^n (x_i - \mu)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2$.

Teorema 2.1.3 (*Utilidade pública 2*).

- (1) $\Gamma(z) = \int_0^\infty t^{z-1} e^{-t} dt$
- (2) $\Gamma(n) = (n-1)!$
- (3) $\Gamma(n+1) = n\Gamma(n)$
- (4) $\Gamma(n) = (n-1)\Gamma(n-1)$
- (5) $\Gamma(1/2) = \pi$
- (6) $B(x, y) = \frac{\Gamma(x)\Gamma(y)}{\Gamma(x+y)} = \int_0^1 t^{x-1}(1-t)^{y-1} dt$

2.2 Probabilidade e independência condicional

Teorema 2.2.1 (*Probabilidades condicionais*).

- (1) $\mathbb{P}[A, B \mid C] = \mathbb{P}[A \mid B, C] \mathbb{P}[B \mid C]$
 $= \mathbb{P}[B \mid A, C] \mathbb{P}[A \mid C]$
- (2) $\mathbb{P}[A \mid B, C] = \frac{\mathbb{P}[B \mid A, C] \mathbb{P}[A \mid C]}{\mathbb{P}[B \mid C]}$
 $= \frac{\mathbb{P}[C \mid A, B] \mathbb{P}[A \mid B]}{\mathbb{P}[C \mid B]}$
- (3) $\mathbb{P}[A, B \mid C, D] = \frac{\mathbb{P}[C \mid A, B, D] \mathbb{P}[A, B, D]}{\mathbb{P}[C, D]}$

Teorema 2.2.2 (*Independência condicional*).

- (1) $A \perp\!\!\!\perp B \mid C \iff \mathbb{P}[A \mid B, C] = \mathbb{P}[A \mid C]$
 $\iff \mathbb{P}[A, B \mid C] = \mathbb{P}[A \mid C] \mathbb{P}[B \mid C]$
 $\iff [A \mid C] \perp\!\!\!\perp [B \mid C]$

2.3 Esperança, variância e covariância

Teorema 2.3.1 (*Propriedades da esperança*).

- (1) $\mathbb{E}[X] = \mathbb{E}[\mathbb{E}(X \mid Y)]$ (*lei da esperança total*)
- (2) $\mathbb{E}[X \mid Z] = \mathbb{E}[\mathbb{E}(X \mid Y, Z) \mid Z]$ (*Terre*)

Teorema 2.3.2 (*Propriedades da variância*).

- (1) $\text{Var}[X] = \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2] - \mu^2$
- (2) $\text{Var}[\mathbf{X}] = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu}_X)(\mathbf{X} - \boldsymbol{\mu}_X)^\top] = \mathbb{E}[\mathbf{X}\mathbf{X}^\top] - \boldsymbol{\mu}_X\boldsymbol{\mu}_X^\top$
- (3) $\text{Var}[X] = \mathbb{E}(\text{Var}[X \mid Y]) + \text{Var}(\mathbb{E}[X \mid Y])$
- (4) $\text{Var}[X \mid Z] = \mathbb{E}(\text{Var}[X \mid Y] \mid Z) + \text{Var}(\mathbb{E}[X \mid Y] \mid Z)$
- (5) $\text{Var}[X + a] = \text{Var}[X]$
- (6) $\text{Var}[aX + b] = a^2 \text{Var}[X]$
- (7) $\text{Var}[\mathbf{A}\mathbf{X} + \mathbf{b}] = \mathbf{A} \text{Var}[\mathbf{X}] \mathbf{A}^\top$
- (8) $\text{Var}[X + Y] = \text{Var}[X] + \text{Var}[Y] + 2 \text{Cov}[X, Y]$
- (9) $\text{Var}[\mathbf{X} + \mathbf{Y}] = \text{Var}[\mathbf{X}] + \text{Var}[\mathbf{Y}] + \text{Cov}[\mathbf{X}, \mathbf{Y}] + \text{Cov}[\mathbf{Y}, \mathbf{X}]$

$$(10) \text{ Var}[aX + bY] = a^2 \text{ Var}[X] + b^2 \text{ Var}[Y] + 2ab \text{ Cov}[X, Y]$$

$$(11) \text{ Var}[aX - bY] = a^2 \text{ Var}[X] + b^2 \text{ Var}[Y] - 2ab \text{ Cov}[X, Y]$$

$$(12) \text{ Var} \left(\sum_{i=1}^n X_i \right) = \sum_{i=1}^n \text{ Var}(X_i) + 2 \sum_{\substack{i,j=1 \\ i < j}}^n \text{ Cov}(X_i, X_j) \\ = \sum_{i=1}^n \text{ Var}(X_i) + \sum_{\substack{i,j=1 \\ i \neq j}}^n \text{ Cov}(X_i, X_j) \\ = \sum_{i,j=1}^n \text{ Cov}(X_i, X_j)$$

$$(13) X_1 \perp \dots \perp X_n \implies \text{ Var} \left(\sum_{i=1}^n X_i \right) = \sum_{i=1}^n \text{ Var}(X_i)$$

Teorema 2.3.3 (*Propriedades da covariância*).

$$(1) \text{ Cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)] \\ = \mathbb{E}[XY] - \mu_X \mu_Y$$

$$(2) \text{ Cov}(\mathbf{X}, \mathbf{Y}) = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu}_X)(\mathbf{Y} - \boldsymbol{\mu}_Y)^\top] \\ = \mathbb{E}[\mathbf{X}\mathbf{Y}^\top] - \boldsymbol{\mu}_X \boldsymbol{\mu}_Y^\top$$

$$(3) \text{ Cov}[X, X] = \text{ Var}[X]$$

$$(4) \text{ Cov}[\mathbf{X}, \mathbf{X}] = \text{ Var}[\mathbf{X}]$$

$$(5) \text{ Cov}[X, Y] = \mathbb{E}[\text{Cov}(X, Y \mid Z)] + \text{Cov}(\mathbb{E}[X \mid Z], \mathbb{E}[Y \mid Z])$$

$$(6) \text{ Cov}(X, a) = 0$$

$$(7) \text{ Cov}(aX + b, cY + d) = ac \text{ Cov}(X, Y)$$

$$(8) \text{ Cov}(\mathbf{A}\mathbf{X} + \mathbf{b}, \mathbf{C}\mathbf{Y} + \mathbf{d}) = \mathbf{A} \text{ Cov}(\mathbf{X}, \mathbf{Y}) \mathbf{C}^\top$$

$$(9) \text{ Cov}(aX + bY, cW + dV) = ac \text{ Cov}(X, W) + ad \text{ Cov}(X, V) + bc \text{ Cov}(Y, W) + bd \text{ Cov}(Y, V)$$

$$(10) \text{ Cov}(aX_1 + bX_2, cY) = ac \text{ Cov}(X_1, Y) + bc \text{ Cov}(X_2, Y)$$

$$(11) \text{ Cov}(\mathbf{A}\mathbf{X}_1 + \mathbf{B}\mathbf{X}_2, \mathbf{C}\mathbf{Y}) = \mathbf{A} \text{ Cov}(\mathbf{X}_1, \mathbf{Y}) \mathbf{C}^\top + \mathbf{B} \text{ Cov}(\mathbf{X}_2, \mathbf{Y}) \mathbf{C}^\top$$

$$(12) |\text{Cov}(X, Y)| \leq \sqrt{\sigma^2(X) \sigma^2(Y)}$$

$$(13) \rho_{X,Y} = \frac{\text{Cov}(X,Y)}{\sigma_X \sigma_Y}$$

$$(14) \text{ Cov}(\mathbf{A}\mathbf{U}, \mathbf{B}\mathbf{V}) = \mathbf{A} \text{ Cov}(\mathbf{U}, \mathbf{V}) \mathbf{B}^\top$$

$$\begin{aligned}
(15) \quad \text{Cov}(\mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{Y}, \mathbf{C}\mathbf{W} + \mathbf{D}\mathbf{V}) &= \mathbf{A} \text{Cov}(\mathbf{X}, \mathbf{W})\mathbf{C}^\top \\
&\quad + \mathbf{A} \text{Cov}(\mathbf{X}, \mathbf{V})\mathbf{D}^\top \\
&\quad + \mathbf{B} \text{Cov}(\mathbf{Y}, \mathbf{W})\mathbf{C}^\top \\
&\quad + \mathbf{B} \text{Cov}(\mathbf{Y}, \mathbf{V})\mathbf{D}^\top
\end{aligned}$$

Teorema 2.3.4 (*Independência e covariância*).

- (1) $\mathbf{X}$ e $\mathbf{Y}$ são independentes $\implies \text{Cov}[\mathbf{X}, \mathbf{Y}] = 0$
- (2) Sejam $\mathbf{X}$ e $\mathbf{Y}$ normais
 - (a) $\mathbf{X}$ e $\mathbf{Y}$ são independentes $\iff \text{Cov}[\mathbf{X}, \mathbf{Y}] = 0$

2.4 Transformações

Teorema 2.4.1 (*Transformação univariada contínua*). Seja X com f.d.p $f_X(x)$ e $Y = g(X)$, onde g é uma função monótona. Sejam $\mathcal{X} = \{x : f_X(x) > 0\}$ e $\mathcal{Y} = \{y : y = g(x), x \in \mathcal{X}\}$. Suponha que $f_X(x)$ é contínua em $\mathcal{X}$ e $g^{-1}(y)$ tenha uma derivada contínua em y . Então, a f.d.p. de y é dada por

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right| \mathbb{1}_{\mathcal{Y}}(y).$$

Nota: Caso g seja monótona por partes (n partes),

$$f_Y(y) = \sum_{i=1}^n f_X(g_i^{-1}(y)) \left| \frac{d}{dy} g_i^{-1}(y) \right| \mathbb{1}_{\mathcal{Y}}(y).$$

Teorema 2.4.2 (*Transformação bivariada*).

$$f_{U,V}(u, v) = f_{X,Y}(h_1(u, v), h_2(u, v)) |J_H(u, v)|,$$

onde

$$J_H(u, v) = \begin{bmatrix} \frac{\partial h_1}{\partial u} & \frac{\partial h_1}{\partial v} \\ \frac{\partial h_2}{\partial u} & \frac{\partial h_2}{\partial v} \end{bmatrix}$$

e $h_1(u, v) = g_1^{-1}(u, v)$, $h_2(u, v) = g_2^{-1}(u, v)$.

Teorema 2.4.3 (*Transformações usuais*).

- (1) $Y = X^2 \implies f_Y(y) = \frac{1}{2\sqrt{y}} [f_X(\sqrt{y}) + f_X(-\sqrt{y})]$
- (2) $Y = \log(X) \implies f_Y(y) = e^y f_X(e^y)$

$$(3) \quad X_i \sim \mathcal{N}(\mu_i, \sigma_i^2) \implies \sum_{i=1}^n (a_i X_i + b_i) \sim \mathcal{N}\left(\sum_{i=1}^n (a_i \mu_i + b_i), \sum_{i=1}^n a_i^2 \sigma_i^2\right)$$

$$(a) \quad X \sim \mathcal{N}(\mu, \sigma^2) \implies Y = aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$$

$$(b) \quad X \sim \mathcal{N}(0, 1) \implies Y = aX + b \sim \mathcal{N}(b, a^2)$$

$$(4) \quad X_i \sim \text{Exp}(\lambda) \implies Y = \sum_{i=1}^n X_i \sim \text{Gamma}(n, \lambda)$$

$$(5) \quad X \sim \text{Exp}(\lambda) \implies Y = cX \sim \text{Exp}(\lambda/c)$$

$$(6) \quad Y = \frac{1}{X} \implies f_Y(y) = f_X\left(\frac{1}{y}\right) \frac{1}{y^2}$$

$$(7) \quad X \sim \text{Beta}(\theta, 1) \implies X^\theta \sim \text{Uniforme}(0, 1)$$

$$\implies -\log X \sim \text{Exp}(\theta)$$

$$\implies -\sum_{i=1}^n \log X_i \sim \text{Gamma}(n, \theta)$$

$$(8) \quad X_1, X_2 \sim \text{Uniforme}(0, \theta) \implies Y = X_1 + X_2 \sim \text{Triangular}(0, 2\theta, \theta)$$

2.5 Vetor aleatório

Definição 2.5.1. $\mathbf{X}$ é um **vetor aleatório** de dimensão $p \times 1$

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix}, \quad (2.5.1)$$

em que cada X_i é uma variável aleatória com **média** μ_i e **variância** $\sigma_i^2 = \sigma_{ii}$, para $i = 1, \dots, p$, em que

$$\mu_i = \mathbb{E}[X_i] \quad (\text{média populacional}) \quad (2.5.2)$$

$$\sigma_i^2 = \text{Var}[X_i] = \mathbb{E}[(X_i - \mu_i)^2] \quad (\text{variância populacional}) \quad (2.5.3)$$

Definição 2.5.2. A **covariância** e a **correlação** (populacionais) entre duas variáveis X_i e X_k , com $i, k = 1, \dots, p$ e $i \neq k$, são dadas, respectivamente, por

$$\text{Cov}[X_i, X_k] = \sigma_{ik} = \mathbb{E}[(X_i - \mu_i)(X_k - \mu_k)] \quad \text{e} \quad (2.5.4)$$

$$\text{Corr}(X_i, X_k) = \rho_{ik} = \frac{\sigma_{ik}}{\sqrt{\sigma_i^2} \sqrt{\sigma_k^2}} \quad (2.5.5)$$

Definição 2.5.3. Se $\mathbf{X}$ é um vetor aleatório de dimensão $p \times 1$ com f.d.p. $f(\mathbf{X})$, o **valor esperado** de uma função escalar $g(\mathbf{X})$ é definido por

$$\mathbb{E}[g(\mathbf{X})] = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} g(\mathbf{u}) f(\mathbf{u}) du_1 \cdots du_p. \quad (2.5.6)$$

Mais geralmente, o valor esperado de uma função vetorial de $\mathbf{X}$, $\mathbf{g}(\mathbf{X})$, é dado por

$$\mathbb{E}[\mathbf{g}(\mathbf{X})] = (\mathbb{E}[g_i(\mathbf{X})]), \quad (2.5.7)$$

ou seja, o valor esperado é calculado elemento a elemento da função vetorial $\mathbf{g}(\mathbf{X})$.

Definição 2.5.4 (*Vetor de médias e matriz de variância e covariância*). Seja $\mathbf{X}$ um vetor aleatório de dimensão $p \times 1$. O vetor de médias (populacionais) de $\mathbf{X}$ é $\boldsymbol{\mu}_{p \times 1}$ e a matriz de variâncias e covariâncias (populacionais) de $\mathbf{X}$ é $\boldsymbol{\Sigma}_{p \times p}$, em que

$$\boldsymbol{\mu} = \mathbb{E}[\mathbf{X}] = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} = \begin{bmatrix} \mathbb{E}[X_1] \\ \mathbb{E}[X_2] \\ \vdots \\ \mathbb{E}[X_p] \end{bmatrix} \quad \text{e} \quad \boldsymbol{\Sigma} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1p} \\ & \sigma_2^2 & \cdots & \sigma_{2p} \\ & & \ddots & \vdots \\ \text{sim.} & & & \sigma_p^2 \end{bmatrix} \quad (2.5.8)$$

Matricialmente,

$$\text{Var}[\mathbf{X}] = \boldsymbol{\Sigma} = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top] \quad (2.5.9)$$

Nota: $\boldsymbol{\Sigma}$ é simétrica pois $\text{Cov}[X_i, X_k] = \text{Cov}[X_k, X_i]$, para $i, k = 1, \dots, p$.

Definição 2.5.5 (*Matriz de correlações*). Seja $\mathbf{X}$ um vetor aleatório de dimensão $p \times 1$. A matriz de correlações (populacionais) de $\mathbf{X}$ é $\mathbf{P} = \mathbf{P}_{p \times p}$, em que

$$\mathbf{P} = \text{Corr}(\mathbf{X}) = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ & 1 & \cdots & \rho_{2p} \\ & & \ddots & \vdots \\ \text{sim.} & & & 1 \end{bmatrix} \quad (2.5.10)$$

Matricialmente,

$$\text{Corr}(\mathbf{X}) = \mathbf{P} = (\mathbf{V}^{1/2})^{-1} \boldsymbol{\Sigma} (\mathbf{V}^{1/2})^{-1} = \mathbf{V}^{-1/2} \boldsymbol{\Sigma} \mathbf{V}^{-1/2}, \quad (2.5.11)$$

em que

$$\mathbf{V}^{1/2} = \begin{bmatrix} \sqrt{\sigma_{11}} & 0 & \cdots & 0 \\ 0 & \sqrt{\sigma_{22}} & \ddots & 0 \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & \sqrt{\sigma_{pp}} \end{bmatrix} \quad (2.5.12)$$

Nota:

- (1) Pelo mesmo motivo que $\boldsymbol{\Sigma}$ é simétrica, $\mathbf{P}$ também é.
- (2) $-1 \leq \rho_{ik} \leq 1$ para $i \neq k$ e $i, k = 1, \dots, p$.

Definição 2.5.6 (*Variância e covariância em forma matricial*). Sejam $\mathbf{X}$ e $\mathbf{Y}$ vetores aleatórios p -dimensionais com $\mathbb{E}[\mathbf{X}] = \boldsymbol{\mu}_X$ e $\mathbb{E}[\mathbf{Y}] = \boldsymbol{\mu}_Y$. Define-se

- (1) $\text{Var}[\mathbf{X}] = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu}_X)(\mathbf{X} - \boldsymbol{\mu}_X)^\top]$,
- (2) $\text{Cov}[\mathbf{X}, \mathbf{Y}] = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu}_X)(\mathbf{Y} - \boldsymbol{\mu}_Y)^\top]$

Definição 2.5.7 (*Amostra aleatória*). Suponha que $\mathbf{X}$ tem uma distribuição de probabilidade multivariada e que vamos observar uma amostra aleatória dessa distribuição, ou seja, n observações independentes e que vêm todas da mesma distribuição:

$$\text{amostra aleatória: } \mathbf{X}_1, \dots, \mathbf{X}_n, \quad (2.5.13)$$

em que $\mathbf{X}_i^\top = (X_{i1}, X_{i2}, \dots, X_{ip})$.

Definição 2.5.8 (*Matriz aleatória*). Suponha que $\mathbf{X}_1, \dots, \mathbf{X}_n$ ainda não foram observados, mas podemos organizá-los em uma matriz aleatória

$$\mathbf{X} = \begin{bmatrix} X_{11} & X_{12} & \dots & X_{1p} \\ X_{21} & X_{22} & \dots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \dots & X_{np} \end{bmatrix}_{n \times p} = \begin{bmatrix} \mathbf{X}_1^\top \\ \mathbf{X}_2^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix} \quad (2.5.14)$$

Teorema 2.5.1 (*Estimadores para μ e Σ*). Seja $\mathbf{X}_1, \dots, \mathbf{X}_n$ a.a. de uma distribuição com $\mathbb{E}[\mathbf{X}] = \boldsymbol{\mu}$ e $\text{Var}[\mathbf{X}] = \boldsymbol{\Sigma}$. Então

- (1) $\bar{\mathbf{X}}$ é um estimador não-viesado para $\boldsymbol{\mu}$, com $\text{Var}[\bar{\mathbf{X}}] = \frac{\boldsymbol{\Sigma}}{n}$ e
- (2) $\frac{n}{n-1} \mathbf{S}$ é um estimador não-viesado para $\boldsymbol{\Sigma}$, ou seja

$$\mathbb{E} \left[\frac{n}{n-1} \mathbf{S} \right] = \boldsymbol{\Sigma}. \quad (2.5.15)$$

Nota:

- (1) Os elementos de $\mathbf{S}$ são dados por

$$s_{ik} = \frac{1}{n} \sum_{j=1}^n (x_{ji} - \bar{x}_i)(x_{jk} - \bar{x}_k) \quad (2.5.16)$$

Capítulo 3

Inferência

3.1 Distribuições amostrais

Teorema 3.1.1. Sejam $X_1, X_2, \dots, X_n$ uma A.A. e seja g uma função real tal que $\mathbb{E}[g(X)]$ e $\text{Var}[g(X)]$ existam. Nesse caso,

$$\mathbb{E} \left[\sum_{i=1}^n g(X_i) \right] = n \mathbb{E}[g(X)],$$

e

$$\text{Var} \left[\sum_{i=1}^n g(X_i) \right] = n \text{Var}[g(X)].$$

Teorema 3.1.2. Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com média μ e variância $\sigma^2 < \infty$. Então,

- (1) $\mathbb{E}(\bar{X}) = \mu$;
- (2) $\text{Var}(\bar{X}) = \sigma^2/n$;
- (3) $\mathbb{E}(S^2) = \sigma^2$.

Teorema 3.1.3 (*Distribuição amostral da média*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com função geradora de momentos $M_X(t)$. Então, a FGM da média amostral será

$$M_{\bar{X}}(t) = [M_X(t/n)]^n.$$

Teorema 3.1.4 (*Qui-quadrado*).

- (1) Se $Z \sim \mathcal{N}(0, 1)$, então $Z^2 \sim \chi_1^2$;
- (2) Se $X_1, X_2, \dots, X_n$ são v.a.'s independentes tais que $X_i \sim \chi_{r_i}^2$, então $\sum_{i=1}^n X_i \sim \chi_r^2$, em que $r = \sum_{i=1}^n r_i$.

Teorema 3.1.5 (*Distribuição normal*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com distribuição $\mathcal{N}(\mu, \sigma^2)$. Então,

(1) $\bar{X}$ e S^2 são independentes;

(2) $\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$;

(3) $\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$.

Teorema 3.1.6 (*t-Student*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. oriunda de uma população $\mathcal{N}(\mu, \sigma^2)$. Então

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim \text{t-Student}(n-1).$$

Nota: se $Z \sim \mathcal{N}(0, 1)$ e $V \sim \chi_k^2$ independentes, então

$$\frac{Z}{\sqrt{V/k}} \sim \text{t-Student}(k).$$

Teorema 3.1.7 (*Propriedades da distribuição F*).

(1) Se $X \sim F_{p,q}$, então $1/X \sim F_{q,p}$ (a recíproca de uma F também tem distribuição F);

(2) Se $X \sim \text{t-Student}(q)$, então $X^2 \sim F_{1,q}$;

(3) Se $X \sim F_{p,q}$, então

$$\frac{(p/q)X}{1 + (p/q)X} \sim \text{Beta}\left(\frac{p}{2}, \frac{q}{2}\right).$$

Teorema 3.1.8. Sejam $X_1, X_2, \dots, X_n$ e $Y_1, Y_2, \dots, Y_m$ duas A.A.'s oriundas de populações $\mathcal{N}(\mu_X, \sigma_X^2)$ e $\mathcal{N}(\mu_Y, \sigma_Y^2)$, respectivamente. Então

$$\frac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2} \sim F_{n-1, m-1}.$$

Nota: O resultado acima decorre do fato de que, se $V \sim \chi_r^2$ e $W \sim \chi_s^2$ independentes, então

$$\frac{V/r}{W/s} \sim F_{r,s}.$$

3.1.1 Estatísticas de ordem

Teorema 3.1.9 (*Máximo e mínimo*).

(1) $F_{X_{(n)}}(x) = [F_X(x)]^n$ (contínua e discreta)

(2) $f_{X_{(n)}}(x) = n[F_X(x)]^{n-1} f_X(x)$ (contínua)

$$(3) F_{X_{(1)}}(x) = 1 - [1 - F_X(x)]^n \text{ (contínua e discreta)}$$

$$(4) f_{X_{(1)}}(x) = n [1 - F_X(x)]^{n-1} f_X(x) \text{ (contínua)}$$

Teorema 3.1.10 (*Contínua e discreta*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com f.d. F_X . Nesse caso, a f.d. da j -ésima estatística de ordem, $X_{(j)}$, será

$$F_{X_{(j)}}(x) = \sum_{k=j}^n \binom{n}{k} [F_X(x)]^k [1 - F_X(x)]^{n-k}.$$

Teorema 3.1.11 (*Discreta*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com f.d. F_X . Suponha que a população seja discreta com f.p. f_X e suporte $\{x_i \mid x_1 < x_2 < \dots < x_n\}$. Além disso, denote $P_0 = 0$ e $P_i = F_X(x_i) = f_X(x_1) + f_X(x_2) + \dots + f_X(x_i)$, $i = 1, 2, \dots, n$. Nesse caso, a função de probabilidade da j -ésima estatística de ordem será

$$f_{X_{(j)}}(x) = \mathbb{P}(X_{(j)} = x_i) = \sum_{k=j}^n \binom{n}{k} [P_i^k (1 - P_i^{n-k}) - P_{i-1}^k (1 - P_{i-1}^{n-k})].$$

Teorema 3.1.12 (*Contínua*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com f.d. F_X . Se a população for contínua com f.d.p. f_X , então a f.d.p. da j -ésima estatística de ordem $X_{(j)}$ será

$$f_{X_{(j)}}(x) = \frac{n!}{(j-1)!(n-j)!} f_X(x) [F_X(x)]^{j-1} [1 - F_X(x)]^{n-j}.$$

Teorema 3.1.13 (*Contínua*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com f.d. F_X e f.d.p. f_X . Então a f.d.p. conjunta de $(X_{(i)}, X_{(j)})$, $1 \leq i < j \leq n$, será

$$f_{X_{(i)}, X_{(j)}}(u, v) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} f_X(u) f_X(v) [F_X(u)]^{i-1} \times [F_X(v) - F_X(u)]^{j-i-1} [1 - F_X(v)]^{n-j} \mathbb{1}(u < v).$$

Nota: Argumentos análogos podem ser utilizados para derivar distribuições de v.a.'s com três ou mais estatísticas de ordem. Um dos v.a.'s mais utilizados corresponde a $(X_{(1)}, X_{(2)}, \dots, X_{(n)})$, cuja f.d.p. corresponde a

$$f_{X_{(1)}, \dots, X_{(n)}}(x_1, \dots, x_n) = n! f_X(x_1) \cdots f_X(x_n) \mathbb{1}(-\infty < x_1 < \dots < x_n < \infty).$$

3.2 Redução de dados

Definição 3.2.1 (*Princípio da suficiência*). Se T for uma estatística suficiente para θ , e se duas amostras observadas, $\mathbf{x}$ e $\mathbf{y}$, forem tais que $T(\mathbf{x}) = T(\mathbf{y})$, então as inferências a respeito de θ deverão ser as mesmas, independentemente de se usar $\mathbf{x}$ ou $\mathbf{y}$.

Nota: Como consequência, qualquer inferência sobre θ deverá depender da amostra $\mathbf{X}$ apenas através de $T(\mathbf{X})$.

Definição 3.2.2 (*Estatística suficiente*). Uma estatística $T(\mathbf{X})$ é chamada de estatística suficiente para θ se a distribuição condicional da amostra $\mathbf{X}$, dado o valor de $T(\mathbf{X})$, não depender de θ .

Teorema 3.2.1 (*Razão para suficiência*). Seja $p(\mathbf{x}|\theta)$ a f.p. (ou f.d.p.) conjunta de uma amostra $\mathbf{X}$, e $q(t|\theta)$ a f.p. (ou f.d.p.) de uma estatística $T(\mathbf{X})$. Então $T(\mathbf{X})$ será uma estatística suficiente para θ se, para todo $\mathbf{x} \in \mathcal{X}$, a razão

$$\frac{p(\mathbf{x}|\theta)}{q(T(\mathbf{x})|\theta)}$$

for constante como função de θ .

Teorema 3.2.2 (*Crítério da fatoração*). Seja $f(\mathbf{x}|\theta)$ a f.p. (ou f.d.p.) conjunta de uma amostra $\mathbf{X}$. Uma estatística $T(\mathbf{X})$ é uma estatística suficiente para θ se, e somente se, existirem funções $g(t|\theta)$ e $h(\mathbf{x})$ de modo que, para todo $\mathbf{x} \in \mathcal{X}$ e todo $\theta \in \Theta$,

$$f(\mathbf{x}|\theta) = g(T(\mathbf{x})|\theta)h(\mathbf{x}).$$

Teorema 3.2.3 (*Suficiência na família exponencial*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. oriunda de uma população cuja f.d.p. (ou f.p.) $f(x|\theta)$ pertence à família exponencial

$$f(x|\boldsymbol{\theta}) = \exp \left(\sum_{k=1}^s \eta_k(\boldsymbol{\theta}) t_k(x) \right) a(\boldsymbol{\theta}) h(x),$$

em que $\boldsymbol{\theta} = (\theta_1, \theta_2, \dots, \theta_d)$, $d \leq s$. Então,

$$T(\mathbf{X}) = \left(\sum_{i=1}^n t_1(X_i), \sum_{i=1}^n t_2(X_i), \dots, \sum_{i=1}^n t_s(X_i) \right)$$

é uma estatística suficiente para $\boldsymbol{\theta}$.

Definição 3.2.3 (*Estatística suficiente mínima*). Uma estatística $T(\mathbf{X})$ é chamada estatística suficiente mínima se, para qualquer outra estatística suficiente $T'(\mathbf{X})$, $T(\mathbf{X})$ puder ser escrita como função de $T'(\mathbf{X})$.

Teorema 3.2.4 (*Crítério para suficiência mínima*). Seja $f(\mathbf{x}|\theta)$ a f.p. (ou f.d.p.) conjunta de uma amostra $\mathbf{X}$. Suponhamos que, para quaisquer duas possíveis amostras observadas, $\mathbf{x}$ e $\mathbf{y}$, $f(\mathbf{x}|\theta)/f(\mathbf{y}|\theta)$ seja constante como função de θ se, e somente se, $T(\mathbf{x}) = T(\mathbf{y})$. Então $T(\mathbf{X})$ é uma estatística suficiente mínima.

Definição 3.2.4 (*Estatística ancilar*). Uma estatística $S(\mathbf{X})$ cuja distribuição não depende de θ é chamada de estatística ancilar.

Nota: Uma estatística $S(\mathbf{X})$ é dita ser ancilar de primeira ordem se $\mathbb{E}_\theta[S(\mathbf{X})]$ não depende de θ .

Definição 3.2.5 (*Estatística completa*). Seja $f(t|\theta)$ uma família de f.d.p.'s (ou f.p.'s) para uma estatística $T(\mathbf{X})$. A família de distribuições de probabilidade é chamada completa se, para qualquer função g ,

$$\mathbb{E}_\theta[g(T)] = 0 \implies \mathbb{P}_\theta[g(T) = 0] = 1,$$

para todo $\theta \in \Theta$. De forma equivalente, $T(\mathbf{X})$ é chamada de estatística completa.

Teorema 3.2.5 (*Basu*). Se $T(\mathbf{X})$ for uma estatística suficiente mínima e completa, então $T(\mathbf{X})$ será independente de toda estatística ancilar.

Teorema 3.2.6 (*Estatísticas completas na família exponencial*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. oriunda de uma população com f.d.p. (ou f.p.) pertencente à família exponencial

$$f(x|\boldsymbol{\theta}) = \exp \left(\sum_{k=1}^s \eta_k(\boldsymbol{\theta}) t_k(x) \right) a(\boldsymbol{\theta}) h(x),$$

em que $\boldsymbol{\theta} = (\theta_1, \theta_2, \dots, \theta_s)$. Então, a estatística

$$T(\mathbf{X}) = \left(\sum_{i=1}^n t_1(X_i), \sum_{i=1}^n t_2(X_i), \dots, \sum_{i=1}^n t_s(X_i) \right)$$

é completa, desde que Θ contenha um conjunto aberto em $\mathbb{R}^s$.

Teorema 3.2.7. Se uma estatística suficiente mínima existe, então qualquer estatística completa também será uma estatística suficiente mínima.

3.3 Estimação Pontual I

Definição 3.3.1 (*Estimador pontual*). Um estimador pontual é qualquer função de uma amostra.

Nota: Qualquer estatística é um estimador.

Definição 3.3.2 (*Estimativa*). Uma estimativa é um valor (valores) observado(s) de um estimador, obtido a partir de uma amostra observada.

Definição 3.3.3 (*Função de verossimilhança*). Sejam $X_1, X_2, \dots, X_n$ uma amostra oriunda de uma população com f.d.p. (ou f.p.) $f(x|\theta)$. A função de verossimilhança será

$$L(\theta|\mathbf{x}) = f(\mathbf{x}|\theta).$$

Qualquer estimador $\hat{\theta} \equiv \hat{\theta}_n(\mathbf{X}) \in \Theta$ tal que

$$L(\hat{\theta}|\mathbf{X}) = \sup_{\theta \in \Theta} L(\theta|\mathbf{X})$$

é chamado estimador de máxima verossimilhança (EMV) de θ .

Teorema 3.3.1 (*Pontos críticos*). Seja $g(x)$ uma função contínua e duplamente diferenciável em algum intervalo aberto I que contém a . Se $g'(a) = 0$, então $g(x)$ tem um máximo (mínimo) relativo em $x = a$, desde que $g''(a) < 0$ ($g''(a) > 0$). Ademais, o conjunto $\{a \in I \mid g'(a) = 0\}$ é chamado de conjunto dos pontos críticos de $g(x)$. Os únicos máximos (mínimos) possíveis de $g(x)$ para $c \leq x \leq d$ estão nos pontos críticos entre c e d , bem como em c e em d .

Teorema 3.3.2 (*Propriedade da invariância*). Seja $\hat{\theta}$ o EMV de θ . Então, para qualquer estimando $\tau(\theta)$, seu EMV será $\tau(\hat{\theta})$.

Teorema 3.3.3 (*Relação EMV e Suficiência*). Seja $L(\theta|\mathbf{x})$ a função de verossimilhança da amostra $X_1, X_2, \dots, X_n$, e seja $T = T(\mathbf{X})$ uma estatística suficiente para θ . O EMV de θ , se existir, será função de T .

Teorema 3.3.4 (*EMV na família exponencial*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. pertencente à família exponencial canônica, cuja f.d.p. (ou f.p.) conjunta pode ser escrita como

$$f(\mathbf{x}|\eta) = \exp \left(\eta \sum_{i=1}^n T(x_i) - nA(\eta) \right) h^*(\mathbf{x}).$$

Temos que o EMV de η será solução da equação

$$\frac{1}{n} \sum_{i=1}^n T(X_i) = \mathbb{E}[T(X_1)],$$

desde que essa solução pertença ao espaço paramétrico de η .

Nota: Devido à propriedade da invariância, o resultado permanece válido para o caso geral da família exponencial, em que cada X_i tem f.d.p. (ou f.p.)

$$f(x|\theta) = \exp\{\eta(\theta)T(x) - B(\theta)\}h(x).$$

Nota: O Teorema 4 pode ser generalizado para o caso multiparamétrico:

$$f(\mathbf{x}|\boldsymbol{\theta}) = \exp \left(\sum_{k=1}^s \eta_k(\boldsymbol{\theta})T_k(\mathbf{x}) - B(\boldsymbol{\theta}) \right) h(\mathbf{x}).$$

3.4 Estimação Pontual II

Definição 3.4.1 (*Erro quadrático médio*). O erro quadrático médio (EQM) do estimador W de um parâmetro θ corresponde a

$$\mathbb{E}_\theta(W - \theta)^2,$$

que é função de θ .

Definição 3.4.2 (*Viés*). O viés (B – do inglês, bias) do estimador W de um parâmetro θ corresponde a

$$B_\theta(W) = \mathbb{E}_\theta(W) - \theta.$$

Quando $B_\theta(W) = 0$, diz-se que o estimador W é não viesado.

Definição 3.4.3 (*ENNVUM*). Um estimador W^* é dito ser o melhor estimador não viesado de $\tau(\theta)$ se $\mathbb{E}_\theta(W^*) = \tau(\theta)$ para todo $\theta \in \Theta$ e, para qualquer outro estimador não viesado W de $\tau(\theta)$, $\text{Var}_\theta(W^*) \leq \text{Var}_\theta(W)$ para todo $\theta \in \Theta$. Nesse caso, W^* é chamado de estimador não viesado de variância uniformemente mínima (ENNVUM) de $\tau(\theta)$.

Teorema 3.4.1 (*Desigualdade de Cramér-Rao (Teorema 1)*). Sejam $X_1, X_2, \dots, X_n$ uma amostra com f.d.p. conjunta $f(\mathbf{x}|\theta)$ e $W(\mathbf{X})$ um estimador que satisfaz

$$\frac{d}{d\theta} \mathbb{E}_\theta[W(\mathbf{X})] = \int_{\mathcal{X}} \frac{\partial}{\partial \theta} [W(\mathbf{x}) f(\mathbf{x}|\theta)] d\mathbf{x} \quad \text{e} \quad \text{Var}_\theta[W(\mathbf{X})] < \infty.$$

Então,

$$\text{Var}_\theta[W(\mathbf{X})] \geq \frac{\left(\frac{d}{d\theta} \mathbb{E}_\theta[W(\mathbf{X})]\right)^2}{\mathbb{E}_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta) \right)^2 \right]}.$$

Nota:

- (1) O resultado do Teorema 1, bem como do Corolário 1, permanecerá válido quando as v.a.'s forem discretas. Nesse caso, troca-se a integral pelo somatório na suposição.
- (2) A quantidade

$$\frac{\left(\frac{d}{d\theta} \mathbb{E}_\theta[W(\mathbf{X})]\right)^2}{\mathbb{E}_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta) \right)^2 \right]},$$

exibida no Teorema 1, é conhecida como limite inferior de Cramér-Rao (LICR).

- (3) A quantidade

$$\mathbb{E}_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta) \right)^2 \right]$$

é conhecida como informação de Fisher da amostra. Quanto maior a informação de Fisher, mais informação temos sobre θ e, conseqüentemente, menor será o limite inferior de Cramér-Rao.

Teorema 3.4.2 (*Desigualdade de Cramér-Rao – caso i.i.d. (Corolário 1)*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população com f.d.p. (ou f.p.) $f(x|\theta)$. Sob as suposições do Teorema 1,

$$\text{Var}_\theta[W(\mathbf{X})] \geq \frac{\left(\frac{d}{d\theta} \mathbb{E}_\theta[W(\mathbf{X})]\right)^2}{n \mathbb{E}_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(X|\theta) \right)^2 \right]}.$$

Teorema 3.4.3 (*Lema 1*). Se $f(x|\theta)$ satisfaz

$$\frac{d}{d\theta} \mathbb{E}_\theta \left[\frac{\partial}{\partial \theta} \log f(X|\theta) \right] = \int_{\mathbb{R}} \frac{\partial}{\partial \theta} \left[\frac{\partial}{\partial \theta} \log f(X|\theta) \right] f(x|\theta) dx,$$

então,

$$\mathbb{E}_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(X|\theta) \right)^2 \right] = - \mathbb{E}_\theta \left[\frac{\partial^2}{\partial \theta^2} \log f(X|\theta) \right].$$

Nota:

- (1) A suposição utilizada no Lema 1 é válida, por exemplo, no caso da família exponencial.
- (2) Em geral, se o suporte de X depender do parâmetro, a desigualdade de Cramér-Rao não se aplica.

Teorema 3.4.4 (*Corolário 2*). Sejam $X_1, X_2, \dots, X_n$ uma A.A. de uma população X com f.d.p. (ou f.p.) $f(x|\theta)$, em que f satisfaz as condições do Teorema 1. Suponhamos que $L(\theta|\mathbf{x}) = \prod_{i=1}^n f(x_i|\theta)$ denote a função de verossimilhança. Se $W(\mathbf{X})$ for um estimador para $\tau(\theta)$, então $W(\mathbf{X})$ atingirá o limite inferior de Cramér-Rao se, e somente se,

$$\frac{\partial}{\partial \theta} \log L(\theta|\mathbf{x}) = a(\theta)[W(\mathbf{x}) - \tau(\theta)],$$

para alguma função $a(\theta)$.

Teorema 3.4.5 (*Rao-Blackwell (Teorema 2)*). Seja W qualquer estimador não viesado de $\tau(\theta)$, e T uma estatística suficiente para θ . Defina $\phi(T) = \mathbb{E}[W|T]$. Então $\mathbb{E}_\theta[\phi(T)] = \tau(\theta)$ e $\text{Var}_\theta[\phi(T)] \leq \text{Var}_\theta(W)$ para todo $\theta \in \Theta$. Em outras palavras, $\phi(T)$ é um melhor estimador não viesado uniformemente de $\tau(\theta)$.

Nota: Devemos considerar estimadores que sejam funções de estatísticas suficientes para determinar ENNVUM's.

Teorema 3.4.6 (*Unicidade do melhor ENV (Teorema 3)*). Se W for um ENNVUM de $\tau(\theta)$, então W será único.

Definição 3.4.4 (*Estimador não viesado de zero*). Seja U um estimador tal que $\mathbb{E}_\theta(U) = 0$, para todo $\theta \in \Theta$. Nesse caso, dizemos que U é um estimador não viesado de zero.

Teorema 3.4.7 (*Teorema 4*). Se $\mathbb{E}_\theta(W) = \tau(\theta)$, então W será o melhor estimador não viesado de $\tau(\theta)$ se, e somente se, W for não correlacionado com todos os estimadores não viesados de zero.

Nota: Um estimador não viesado de zero nada mais é do que uma perturbação aleatória. Se um estimador pudesse ser melhorado ao acrescentarmos uma perturbação a ele, esse estimador certamente seria problemático. Isso pode ser entendido como uma interpretação do Teorema 4. O Teorema 4 pode ser útil para mostrar quando um estimador não é ENNVUM.

Teorema 3.4.8 (*Teorema 5*). Seja T uma estatística suficiente e completa para um parâmetro θ , e seja $\phi(T)$ qualquer estimador baseado somente em T . Então, $\phi(T)$ é o único melhor estimador não viesado de seu valor esperado.

Nota: O teorema acima diz que, na presença de estatísticas suficientes e completas, se pudermos determinar qualquer estimador não viesado de $\tau(\theta)$, podemos determinar o melhor ENV. Basicamente, se T for uma estatística suficiente e completa para θ e $h(\mathbf{X})$ um ENV de $\tau(\theta)$, então $\phi(T) = \mathbb{E}[h(\mathbf{X})|T]$ será o melhor estimador não viesado de $\tau(\theta)$.

Capítulo 4

Normal multivariada

4.1 Distribuições de formas quadráticas

Teorema 4.1.1. Seja $\mathbf{X}_{p \times 1} \sim \mathcal{N}_p(\boldsymbol{\mu}_{p \times 1}, \boldsymbol{\Sigma}_{p \times p})$. Então:

- (1) $\mathbf{X}_{1 \times p}^T \mathbf{A}_{p \times p} \mathbf{X}_{p \times 1} \sim \chi_{\text{pos}(\mathbf{A}), \frac{1}{2} \boldsymbol{\mu}_{1 \times p}^T \mathbf{A}_{p \times p} \boldsymbol{\mu}_{p \times 1}}^2 \iff \mathbf{A}_{p \times p} \boldsymbol{\Sigma}_{p \times p}$ é idempotente.
- (2) $\mathbf{X}_{1 \times p}^T \mathbf{A}_{p \times p} \mathbf{X}_{p \times 1}$ e $\mathbf{B}_{q \times p} \mathbf{X}_{p \times 1}$ são independentes $\iff \mathbf{B}_{q \times p} \boldsymbol{\Sigma}_{p \times p} \mathbf{A}_{p \times p} = \mathbf{0}_{q \times p}$
- (3) $\mathbf{X}_{1 \times p}^T \mathbf{A}_{p \times p} \mathbf{X}_{p \times 1}$ e $\mathbf{X}_{1 \times p}^T \mathbf{B}_{p \times p} \mathbf{X}_{p \times 1}$ são independentes $\iff \mathbf{A}_{p \times p} \boldsymbol{\Sigma}_{p \times p} \mathbf{B}_{p \times p} = \mathbf{0}_{p \times p}$
ou $\mathbf{B}_{p \times p} \boldsymbol{\Sigma}_{p \times p} \mathbf{A}_{p \times p} = \mathbf{0}_{p \times p}$

Teorema 4.1.2. Seja $\mathbf{X}$ um vetor aleatório p -dimensional com $\text{Var}[\mathbf{X}] = \boldsymbol{\Sigma}$, $\boldsymbol{\Sigma}$ de dimensão $p \times p$, e seja $\mathbf{A}$ uma matriz $p \times p$. Então:

- (1) $\mathbb{E}[\mathbf{X}^T \mathbf{A} \mathbf{X}] = \text{tr}(\mathbf{A} \boldsymbol{\Sigma}) + \boldsymbol{\mu}^T \mathbf{A} \boldsymbol{\mu}$.
- (2) $\text{Cov}[\mathbf{X}, \mathbf{X}^T \mathbf{A} \mathbf{X}] = 2 \boldsymbol{\Sigma} \mathbf{A} \boldsymbol{\mu}$.

4.2 Normal multivariada

Teorema 4.2.1. Suponha que $\mathbf{X} \sim \mathcal{N}(\mathbf{m}, \mathbf{V})$. Para $\mathbf{A}$ e $\mathbf{b}$ de dimensões adequadas,

- (1) $\mathbf{Y} = \mathbf{A} \mathbf{X} + \mathbf{b} \implies \mathbf{Y} \sim \mathcal{N}(\mathbf{A} \mathbf{m} + \mathbf{b}, \mathbf{A} \mathbf{V} \mathbf{A}')$;
- (2) Se $\mathbf{A} \mathbf{V} \mathbf{A}'$ é diagonal, então os elementos de $\mathbf{Y}$ são normais independentes.

Teorema 4.2.2. Suponha que $\mathbf{X}_i \sim \mathcal{N}(\mathbf{m}_i, \mathbf{V}_i)$ independentes, $i = 1, \dots, k$, e considere $\mathbf{A}_1, \dots, \mathbf{A}_k$ e $\mathbf{b}$ de dimensões adequadas.

- (1) $\mathbf{Y} = \sum_{i=1}^k \mathbf{A}_i \mathbf{X}_i + \mathbf{b} \sim \mathcal{N}\left(\sum_{i=1}^k \mathbf{A}_i \mathbf{m}_i + \mathbf{b}, \sum_{i=1}^k \mathbf{A}_i \mathbf{V}_i \mathbf{A}_i'\right)$

Teorema 4.2.3. Suponha que $\mathbf{X}$ seja particionado como segue:

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}, \quad \mathbf{m} = \begin{bmatrix} \mathbf{m}_1 \\ \mathbf{m}_2 \end{bmatrix}, \quad \mathbf{V} = \begin{bmatrix} \mathbf{V}_{11} & \mathbf{V}_{12} \\ \mathbf{V}_{21} & \mathbf{V}_{22} \end{bmatrix}.$$

- (1) $\mathbf{X}_i \sim \mathcal{N}(\mathbf{m}_i, \mathbf{V}_{ii})$, $i = 1, 2$. Em particular, se X_i é normal univariado, então $X_i \sim \mathcal{N}(m_i, V_{ii})$, para $i = 1 \dots, n$;
- (2) $(\mathbf{X}_1 | \mathbf{X}_2) \sim \mathcal{N}(\boldsymbol{\mu}_{12}, \mathbf{C}_{12})$ onde

$$\boldsymbol{\mu}_{12} = \mathbf{m}_1 + \mathbf{V}_{12} \mathbf{V}_{22}^{-1} (\mathbf{X}_2 - \mathbf{m}_2) \quad (4.2.1)$$

$$= \mathbf{m}_1 + \mathbf{A}_1 (\mathbf{X}_2 - \mathbf{m}_2) \quad (4.2.2)$$

e

$$\mathbf{C}_{12} = \mathbf{V}_{11} - \mathbf{V}_{12} \mathbf{V}_{22}^{-1} \mathbf{V}_{21} \quad (4.2.3)$$

$$= \mathbf{V}_{11} - \mathbf{A}_1 \mathbf{V}_{22} \mathbf{A}_1' \quad (4.2.4)$$

A matriz $\mathbf{A}_1 = \mathbf{V}_{12} \mathbf{V}_{22}^{-1}$ é chamada de *matriz de regressão* de $\mathbf{X}_1$ em $\mathbf{X}_2$.

- (3) $(\mathbf{X}_2 | \mathbf{X}_1) \sim \mathcal{N}(\boldsymbol{\mu}_{21}, \mathbf{C}_{21})$ onde

$$\boldsymbol{\mu}_{21} = \mathbf{m}_2 + \mathbf{V}_{21} \mathbf{V}_{11}^{-1} (\mathbf{X}_1 - \mathbf{m}_1) \quad (4.2.5)$$

$$= \mathbf{m}_2 + \mathbf{A}_2 (\mathbf{X}_1 - \mathbf{m}_1) \quad (4.2.6)$$

e

$$\mathbf{C}_{21} = \mathbf{V}_{22} - \mathbf{V}_{21} \mathbf{V}_{11}^{-1} \mathbf{V}_{12} \quad (4.2.7)$$

$$= \mathbf{V}_{22} - \mathbf{A}_2 \mathbf{V}_{11} \mathbf{A}_2' \quad (4.2.8)$$

- (4) No caso especial da normal bivariada em (1) acima, os momentos são todos escalares, e a correlação entre X_1 e X_2 é $\rho = \rho_{12} = V_{12} / \sqrt{V_{11} V_{22}}$. As regressões são determinadas pelos coeficientes de regressão A_1 e A_2 dados por

$$A_1 = \rho \sqrt{V_{11} / V_{22}} \quad \text{e} \quad A_2 = \rho \sqrt{V_{22} / V_{11}}.$$

Além disso,

$$\text{Var}[X_1 | X_2] = (1 - \rho^2) V_{11} \quad \text{e} \quad \text{Var}[X_2 | X_1] = (1 - \rho^2) V_{22}.$$

Capítulo 5

Regressão

Capítulo 6

Inferência Bayesiana

Teorema 6.0.1 (*Normal com σ^2 conhecido*). Seja $\mathbf{x} = (x_1, \dots, x_n)$.

(1) Verossimilhança:

$$(X_i|\mu) \sim \mathcal{N}(\mu, \sigma^2)$$

(2) Priori:

$$\mu \sim \mathcal{N}(\mu_0, \sigma_0^2)$$

(3) Posteriori:

$$(\mu|\mathbf{x}) \sim \mathcal{N}(\mu_1, \sigma_1^2)$$

$$\sigma_1^2 = \frac{1}{\frac{n}{\sigma^2} + \frac{1}{\sigma_0^2}} = \frac{\sigma^2 \sigma_0^2}{n\sigma_0^2 + \sigma^2} \quad (6.0.1)$$

$$\mu_1 = \sigma_1^2 \left(\frac{n\bar{x}}{\sigma^2} + \frac{\mu_0}{\sigma_0^2} \right) = \frac{\frac{n\bar{x}}{\sigma^2} + \frac{\mu_0}{\sigma_0^2}}{\frac{n}{\sigma^2} + \frac{1}{\sigma_0^2}} = \frac{n\bar{x}\sigma_0^2 + \mu_0\sigma^2}{n\sigma_0^2 + \sigma^2} \quad (6.0.2)$$

Fazendo $\tau = 1/\sigma^2$:

$$\tau_1 = \tau_0 + n\tau \quad (6.0.3)$$

$$\mu_1 = \frac{n\tau\bar{x} + \tau_0\mu_0}{n\tau + \tau_0} \quad (6.0.4)$$

Nota: A média a posteriori é uma combinação convexa da média a priori e da média amostral.

Teorema 6.0.2 (*Normal multivariada com Σ conhecido*). Seja $\mathbf{y} = (y_1, \dots, y_n)$.

(1) Verossimilhança:

$$p(\mathbf{y}|\boldsymbol{\mu}) = \prod_{n=1}^N \mathcal{N}(y_n | \boldsymbol{\mu}, \Sigma) \sim \mathcal{N}\left(\bar{\mathbf{y}} | \boldsymbol{\mu}, \frac{1}{N}\Sigma\right)$$

(2) Priori:

$$p(\boldsymbol{\mu}) \sim \mathcal{N}(\boldsymbol{\mu} \mid \tilde{\mathbf{m}}, \tilde{\mathbf{V}})$$

(3) Posteriori:

$$p(\boldsymbol{\mu} \mid \mathbf{y}) \sim \mathcal{N}(\boldsymbol{\mu} \mid \hat{\mathbf{m}}, \hat{\mathbf{V}})$$

$$\hat{\mathbf{V}}^{-1} = \tilde{\mathbf{V}}^{-1} + N\boldsymbol{\Sigma}^{-1} \quad (6.0.5)$$

$$\hat{\mathbf{m}} = \hat{\mathbf{V}} \left[\boldsymbol{\Sigma}^{-1}(N\bar{\mathbf{y}}) + \tilde{\mathbf{V}}^{-1}\tilde{\mathbf{m}} \right] \quad (6.0.6)$$

Teorema 6.0.3 (*Regressão linear bayesiana com $\boldsymbol{\Sigma}$ conhecido*). Seja $\mathbf{y} = (y_1, \dots, y_n)$.

(1) Verosimilhança:

$$p(\mathbf{y} \mid \boldsymbol{\mu}) \sim \mathcal{N}(\bar{\mathbf{y}} \mid \mathcal{F}\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

(2) Priori:

$$p(\boldsymbol{\mu}) \sim \mathcal{N}(\boldsymbol{\mu} \mid \tilde{\mathbf{m}}, \tilde{\mathbf{V}})$$

(3) Posteriori:

$$p(\boldsymbol{\mu} \mid \mathbf{y}) \sim \mathcal{N}(\boldsymbol{\mu} \mid \hat{\mathbf{m}}, \hat{\mathbf{V}})$$

$$\hat{\mathbf{V}}^{-1} = \tilde{\mathbf{V}}^{-1} + \mathcal{F}^T \boldsymbol{\Sigma}^{-1} \mathcal{F} \quad (6.0.7)$$

$$\hat{\mathbf{m}} = \hat{\mathbf{V}} \left[\mathcal{F}^T \boldsymbol{\Sigma}^{-1} \mathbf{y} + \tilde{\mathbf{V}}^{-1} \tilde{\mathbf{m}} \right] \quad (6.0.8)$$

Teorema 6.0.4 (*Distribuição condicional e regressão linear*). Suponha que o vetor- p $\mathbf{Y}$ e o vetor- n $\boldsymbol{\theta}$ estejam relacionados via a distribuição condicional

$$(\mathbf{Y} \mid \boldsymbol{\theta}) \sim \mathcal{N}(\mathbf{F}'\boldsymbol{\theta}, \mathbf{V}),$$

onde a matriz $(n \times p)$ $\mathbf{F}$ e a matriz $(p \times p)$ definida positiva simétrica $\mathbf{V}$ são constantes, e que a distribuição marginal de $\boldsymbol{\theta}$ seja dada por

$$\boldsymbol{\theta} \sim \mathcal{N}(\mathbf{a}, \mathbf{R}).$$

Segue que

$$\begin{bmatrix} \mathbf{Y} \\ \boldsymbol{\theta} \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mathbf{F}'\mathbf{a} \\ \mathbf{a} \end{bmatrix}, \begin{bmatrix} \mathbf{F}'\mathbf{R}\mathbf{F} + \mathbf{V} & \mathbf{F}'\mathbf{R} \\ \mathbf{R}\mathbf{F} & \mathbf{R} \end{bmatrix} \right).$$

Então $(\boldsymbol{\theta} \mid \mathbf{Y}) \sim \mathcal{N}(\mathbf{m}, \mathbf{C})$, onde

$$\mathbf{m} = \mathbf{a} + \mathbf{R}\mathbf{F}[\mathbf{F}'\mathbf{R}\mathbf{F} + \mathbf{V}]^{-1}[\mathbf{Y} - \mathbf{F}'\mathbf{a}]$$

e

$$\mathbf{C} = \mathbf{R} - \mathbf{R}\mathbf{F}[\mathbf{F}'\mathbf{R}\mathbf{F} + \mathbf{V}]^{-1}\mathbf{F}'\mathbf{R}.$$

Definindo $\mathbf{e} = \mathbf{Y} - \mathbf{F}'\mathbf{a}$, $\mathbf{Q} = \mathbf{F}'\mathbf{R}\mathbf{F} + \mathbf{V}$ e $\mathbf{A} = \mathbf{R}\mathbf{F}\mathbf{Q}^{-1}$, estas equações tornam-se

$$\mathbf{m} = \mathbf{a} + \mathbf{A}\mathbf{e} \quad \text{e} \quad \mathbf{C} = \mathbf{R} - \mathbf{A}\mathbf{Q}\mathbf{A}'.$$

Teorema 6.0.5 (*Normal-Gamma*).

- Verossimilhança:

$$Y_1, \dots, Y_k \sim \mathcal{N}(\mu, \phi^{-1})$$

- Priori:

$$(\mu, \phi) \sim \text{Normal-Gamma}(m, C, n, d) \quad (6.0.9)$$

$$\mu|\phi \sim \mathcal{N}(m, C\phi^{-1}) \quad (6.0.10)$$

$$\phi \sim \text{Gamma}(n/2, d/2) \quad (6.0.11)$$

- Posteriori:

$$(\mu, \phi)|\mathbf{y} \sim \text{Normal-Gamma}(m^*, C^*, n^*, d^*)$$

$$n^* = n + k \quad (6.0.12)$$

$$m^* = \frac{km/C + \sum_{i=1}^k y_i}{k + 1/C} \quad (6.0.13)$$

$$C^* = \frac{C}{2 + kC} \quad (6.0.14)$$

$$d^* = d + \sum_{i=1}^k (y_i - \bar{y})^2 + \frac{k(\bar{y} - m)^2}{1 + kC} \quad (6.0.15)$$

- Marginais:

$$\mu \sim \text{t-Student}(n)(m, R), \quad R = C \frac{d}{n} \quad (6.0.16)$$

$$\mu|\mathbf{y} \sim \text{t-Student}(n)(m^*, R^*), \quad R^* = C^* \frac{d^*}{n^*} \quad (6.0.17)$$

Teorema 6.0.6 (*Normal-Gamma Multivariada*).

- Verossimilhança:

$$\mathbf{Y}_1, \dots, \mathbf{Y}_k | \boldsymbol{\theta}, \phi \stackrel{iid}{\sim} \mathcal{N}(\boldsymbol{\theta}, \phi^{-1} \mathbf{I}_p)$$

- Priori:

$$(\boldsymbol{\theta}, \phi) \sim \text{Normal-Gamma}(\mathbf{m}, \mathbf{C}, n, d) \quad (6.0.18)$$

$$\boldsymbol{\theta}|\phi \sim \mathcal{N}(\mathbf{m}, \mathbf{C}\phi^{-1}) \quad (6.0.19)$$

$$\phi \sim \text{Gamma}(n/2, d/2) \quad (6.0.20)$$

- Posteriori:

$$(\boldsymbol{\theta}, \phi)|\mathbf{Y}_1, \dots, \mathbf{Y}_k \sim \text{Normal-Gamma}(\mathbf{m}^*, \mathbf{C}^*, n^*, d^*)$$

$$n^* = n + kp \quad (6.0.21)$$

$$\mathbf{m}^* = (\mathbf{C}^{-1} + k\mathbf{I}_p)^{-1}(\mathbf{C}^{-1}\mathbf{m} + k\bar{\mathbf{Y}}) \quad (6.0.22)$$

$$\mathbf{C}^* = (\mathbf{C}^{-1} + k\mathbf{I}_p)^{-1} \quad (6.0.23)$$

$$d^* = d + \sum_{j=1}^k (\mathbf{Y}_j - \bar{\mathbf{Y}})'(\mathbf{Y}_j - \bar{\mathbf{Y}}) + (\bar{\mathbf{Y}} - \mathbf{m})'(\mathbf{C}^{-1} + k\mathbf{I}_p)^{-1}(\bar{\mathbf{Y}} - \mathbf{m}) \quad (6.0.24)$$

(1) Caso particular $k = 1$: Após observar $\mathbf{Y}_1 = \mathbf{Y}$,

$$n^* = n + p \quad (6.0.25)$$

$$\mathbf{m}^* = (\mathbf{C}^{-1} + \mathbf{I}_p)^{-1}(\mathbf{C}^{-1}\mathbf{m} + \mathbf{Y}) \quad (6.0.26)$$

$$\mathbf{C}^* = (\mathbf{C}^{-1} + \mathbf{I}_p)^{-1} \quad (6.0.27)$$

$$d^* = d + (\mathbf{Y} - \mathbf{m})'(\mathbf{C}^{-1} + \mathbf{I}_p)^{-1}(\mathbf{Y} - \mathbf{m}) \quad (6.0.28)$$

- Marginais:

$$\boldsymbol{\theta} \sim T_n[\mathbf{m}, \mathbf{R}], \quad \mathbf{R} = \mathbf{C} \frac{d}{n} \quad (6.0.29)$$

$$\boldsymbol{\theta} | \mathbf{Y}_1, \dots, \mathbf{Y}_k \sim T_{n^*}[\mathbf{m}^*, \mathbf{R}^*], \quad \mathbf{R}^* = \mathbf{C}^* \frac{d^*}{n^*} \quad (6.0.30)$$

- Marginais univariadas: Se θ_i é o i -ésimo elemento de $\boldsymbol{\theta}$, então

$$\theta_i \sim \text{t-Student}(n)(m_i, R_{ii}), \quad R_{ii} = C_{ii} \frac{d}{n} \quad (6.0.31)$$

$$\theta_i | \mathbf{Y}_1, \dots, \mathbf{Y}_k \sim \text{t-Student}(n^*)(m_i^*, R_{ii}^*), \quad R_{ii}^* = C_{ii}^* \frac{d^*}{n^*} \quad (6.0.32)$$

onde $\bar{\mathbf{Y}} = \frac{1}{k} \sum_{j=1}^k \mathbf{Y}_j$

Nota:

- O vetor de parâmetros $\boldsymbol{\theta}$ tem dimensão $p \times 1$.
- Cada observação $\mathbf{Y}_j$ também tem dimensão $p \times 1$.
- $\mathbf{C}$ é uma matriz $p \times p$ simétrica positiva definida.
- Os graus de liberdade aumentam de n para $n^* = n + kp$ (cada observação vetorial contribui com p graus de liberdade).
- A notação $T_n[\mathbf{m}, \mathbf{R}]$ denota a distribuição t multivariada com n graus de liberdade, moda $\mathbf{m}$ e matriz de escala $\mathbf{R}$.

Teorema 6.0.7 (*Normal-Gamma para Regressão Linear*).

- Verossimilhança:

$$(Y_i | \boldsymbol{\theta}, \phi) \sim N[\mathbf{F}_i' \boldsymbol{\theta}, k_i \phi^{-1}], \quad i = 1, \dots, n$$

- Priori:

$$(\boldsymbol{\theta}, \phi) \sim \text{NG}(\mathbf{a}, \mathbf{R}, \nu, s) \quad (6.0.33)$$

$$\boldsymbol{\theta} | \phi \sim N[\mathbf{a}, \mathbf{R} \phi^{-1}] \quad (6.0.34)$$

$$\phi \sim \text{Gamma}(\nu/2, s/2) \quad (6.0.35)$$

- Posteriori para múltiplas observações:

$$(\boldsymbol{\theta}, \phi) | Y_1, \dots, Y_n \sim \text{NG}(\mathbf{a}^*, \mathbf{R}^*, \nu^*, s^*)$$

$$\nu^* = \nu + n \quad (6.0.36)$$

$$Q_i = \mathbf{F}_i' \mathbf{R} \mathbf{F}_i + k_i \quad (\text{variância preditiva}) \quad (6.0.37)$$

$$e_i = Y_i - \mathbf{F}_i' \mathbf{a} \quad (\text{erro de predição}) \quad (6.0.38)$$

$$\mathbf{R}^* = \mathbf{R} - \sum_{i=1}^n \frac{\mathbf{R} \mathbf{F}_i \mathbf{F}_i' \mathbf{R}}{Q_i} \quad (6.0.39)$$

$$\mathbf{a}^* = \mathbf{a} + \sum_{i=1}^n \frac{\mathbf{R} \mathbf{F}_i e_i}{Q_i} \quad (6.0.40)$$

$$s^* = s + \sum_{i=1}^n \frac{e_i^2}{Q_i} \quad (6.0.41)$$

(1) Caso particular $n = 1$: Após observar $(Y_1, \mathbf{F}_1)$ com $Y_1 = Y$, $\mathbf{F}_1 = \mathbf{F}$, $k_1 = k$,

$$\nu^* = \nu + 1 \quad (6.0.42)$$

$$f = \mathbf{F}' \mathbf{a} \quad (\text{predição priori}) \quad (6.0.43)$$

$$Q = \mathbf{F}' \mathbf{R} \mathbf{F} + k \quad (\text{variância preditiva priori}) \quad (6.0.44)$$

$$\mathbf{R}^* = \mathbf{R} - \frac{\mathbf{R} \mathbf{F} \mathbf{F}' \mathbf{R}}{Q} \quad (6.0.45)$$

$$\mathbf{a}^* = \mathbf{a} + \frac{\mathbf{R} \mathbf{F} (Y - f)}{Q} \quad (6.0.46)$$

$$s^* = s + \frac{(Y - f)^2}{Q} \quad (6.0.47)$$

– Distribuições condicionais e marginal posteriori ($n = 1$):

$$(\boldsymbol{\theta} | \phi, Y) \sim N[\mathbf{a}^*, \mathbf{R}^* \phi^{-1}] \quad (6.0.48)$$

$$(\phi | Y) \sim \text{Gamma} \left(\frac{\nu + 1}{2}, \frac{s + (Y - f)^2 / Q}{2} \right) \quad (6.0.49)$$

- Marginais:

$$\boldsymbol{\theta} \sim \text{T}_\nu[\mathbf{a}, \mathbf{R}S], \quad S = s/\nu \quad (6.0.50)$$

$$\boldsymbol{\theta} | Y_1, \dots, Y_n \sim \text{T}_{\nu^*}[\mathbf{a}^*, \mathbf{R}^* S^*], \quad S^* = s^*/\nu^* \quad (6.0.51)$$

- Marginais univariadas: Se θ_j é o j -ésimo elemento de $\boldsymbol{\theta}$, então

$$\theta_j \sim t_\nu(a_j, R_{jj}S) \quad (6.0.52)$$

$$\theta_j | Y_1, \dots, Y_n \sim t_{\nu^*}(a_j^*, R_{jj}^* S^*) \quad (6.0.53)$$

ou de forma padronizada:

$$\frac{\theta_j - a_j}{\sqrt{R_{jj}S}} \sim t_\nu(0, 1) \quad (6.0.54)$$

$$\frac{\theta_j - a_j^*}{\sqrt{R_{jj}^* S^*}} \sim t_{\nu^*}(0, 1) \quad (6.0.55)$$

- Distribuição preditiva: Para uma nova observação Y_{n+1} com covariáveis $\mathbf{F}_{n+1}$ e fator k_{n+1} ,

$$Y_{n+1}|Y_1, \dots, Y_n \sim t_{\nu^*}(f^*, Q^* S^*) \quad (6.0.56)$$

$$f^* = \mathbf{F}_{n+1}' \mathbf{a}^* \quad (6.0.57)$$

$$Q^* = \mathbf{F}_{n+1}' \mathbf{R}^* \mathbf{F}_{n+1} + k_{n+1} \quad (6.0.58)$$

Nota:

- O vetor de parâmetros $\boldsymbol{\theta}$ tem dimensão $p \times 1$.
- Cada Y_i é uma observação escalar com vetor de covariáveis $\mathbf{F}_i$ ($p \times 1$).
- k_i é o fator de escala da variância da i -ésima observação.
- $\mathbf{R}$ é uma matriz $p \times p$ simétrica positiva definida.
- $S = s/\nu = 1/E[\phi]$ é o inverso da precisão esperada.
- Os graus de liberdade aumentam de ν para $\nu^* = \nu + n$ (número de observações escalares).
- A notação $T_\nu[\mathbf{a}, \mathbf{R}S]$ denota a distribuição t multivariada com ν graus de liberdade, vetor de localização $\mathbf{a}$ e matriz de escala $\mathbf{R}S$.
- A atualização sequencial é possível: a posteriori após i observações serve como priori para a $(i + 1)$ -ésima observação.

Capítulo 7

Probabilidade Avançada

7.1 Teoria de conjuntos

Definição 7.1.1 (*Definições básicas*). Para A, B e $\{A_i : i \in I\}$ quaisquer:

- $A^c := \{\omega \in \Omega : \omega \notin A\} = \Omega - A$
- $A \subset B \iff \omega \in A \implies \omega \in B$
- $A \cup B := \{\omega \in \Omega : \omega \in A \text{ ou } \omega \in B\}$
- $\bigcup_{i \in I} A_i := \{\omega : \omega \in A_i \text{ para algum } i \in I\}$
- $A \cap B := \{\omega \in \Omega : \omega \in A \text{ e } \omega \in B\} = AB$
- $\bigcap_{i \in I} A_i := \{\omega : \omega \in A_i \text{ para todo } i \in I\}$
- $B - A := \{\omega \in \Omega : \omega \in B \text{ e } \omega \notin A\} = B \cap A^c$
- $A + B := A \cup B$, para A e B disjuntos
- Diferença simétrica:
$$\begin{aligned} A \triangle B &:= \{\omega \in \Omega : \omega \in A \cup B \text{ e } \omega \notin A \cap B\} \\ &= (A \cup B) - (A \cap B) \\ &= (A - B) + (B - A) \\ &= AB^c + BA^c \end{aligned}$$
- Produto cartesiano: $A \times B := \{(a, b) : a \in A \text{ e } b \in B\}$
- $(A \times B)^c := (\Omega_1 \times \Omega_2) - (A \times B) = \{(\omega_1, \omega_2) \in \Omega_1 \times \Omega_2 : \omega_1 \notin A \text{ ou } \omega_2 \notin B\}$
- Conjunto das partes: $\mathcal{P}(\Omega) := \{A : A \subset \Omega\}$
- Função indicadora:
$$I_A(\omega) := \begin{cases} 1 & \text{se } \omega \in A \\ 0 & \text{se } \omega \notin A \end{cases}$$

Teorema 7.1.1 (*Propriedades básicas*). Para A, B, C quaisquer:

- (1) $\emptyset \subset A$
- (2) Reflexiva: $A = A$
- (3) Simétrica: $A = B \implies B = A$
- (4) Transitiva: $A = B$ e $B = C \implies A = C$
- (5) Reflexiva: $A \subset A$
- (6) Simétrica: $A \subset B$ e $B \subset A \iff A = B$
- (7) Transitiva: $A \subset B$ e $B \subset C \implies A \subset C$
- (8) $A \subset B$ ou $A \subset C \implies A \subset B \cup C$
- (9) $A \cup B \subset C \iff A \subset C$ e $B \subset C$

Teorema 7.1.2 (*Operações básicas*). Para $A, B, \{A_i : i \in I\}, (A_n)_{n \geq 1}$ e $(B_n)_{n \geq 1}$ quaisquer:

- (1) Idempotente: $A \cup A = A, A \cap A = A$
- (2) Elemento neutro: $A \cup \emptyset = A, A \cap \Omega = A$
- (3) $A \cap \emptyset = \emptyset, A \cup \Omega = \Omega$
- (4) Comutativa: $A \cup B = A \cap B$ e $A \cup B = A \cap B$
- (5) Associativa:
 - (a) $A \cup (B \cup C) = (A \cup B) \cup C$
 - (b) $(\bigcup_{n=1}^{\infty} A_n) \cup (\bigcup_{n=1}^{\infty} B_n) = \bigcup_{n=1}^{\infty} (A_n \cup B_n)$
 - (c) $A \cap (B \cap C) = (A \cap B) \cap C$
 - (d) $(\bigcap_{n=1}^{\infty} A_n) \cap (\bigcap_{n=1}^{\infty} B_n) = \bigcap_{n=1}^{\infty} (A_n \cap B_n)$
- (6) Distributiva:
 - (a) $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
 - (b) $B \cap (\bigcup_{i \in I} A_i) = \bigcup_{i \in I} (A_i \cap B)$
 - (c) $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$
 - (d) $B \cup (\bigcap_{i \in I} A_i) = \bigcap_{i \in I} (A_i \cup B)$
- (7) $A \subset A \cup B$ e $B \subset A \cup B$
- (8) $A \cap B \subset A$ e $A \cap B \subset B$
- (9) $A \cup (A \cap B) = A$ e $B \cap (A \cup B) = B$
- (10) $A \subset B \iff A \cup B = B \iff A \cap B = A$

Teorema 7.1.3 (*Propriedades do complementar*). Para A, B e $\{A_i : i \in I\}$ quaisquer:

$$(1) (A^c)^c = A$$

$$(2) A \subset B \iff B^c \subset A^c$$

(3) Leis de De Morgan:

$$(a) (A \cup B)^c = (A^c \cap B^c)^c \text{ e } \left(\bigcup_{i \in I} A_i\right)^c = \bigcap_{i \in I} A_i^c$$

$$(b) (A \cap B)^c = (A^c \cup B^c)^c \text{ e } \left(\bigcap_{i \in I} A_i\right)^c = \bigcup_{i \in I} A_i^c$$

Teorema 7.1.4 (*Operações com diferença*). Para A, B, C , e $\{A_i : i \in I\}$ quaisquer:

$$(1) (A - B) \cup (A \cap B) = A$$

$$(2) (A \cup C) - B = (A - B) \cup (C - B)$$

$$(3) (A - B) - C = (A - C) - B$$

$$(4) (A - B) \cup C = (A \cup B \cup C) - (A \cap B)$$

$$(5) (A - B) \cap C = (A \cap C) - (B \cap C)$$

$$(6) C - (A \cup B) = (C - A) \cap (C - B)$$

$$(7) C - (A \cap B) = (C - A) \cup (C - B)$$

$$(8) A - B = \emptyset \iff A \subset B$$

$$(9) A - (A - B) = B \iff B \subset A$$

$$(10) \text{ Se } A \subset C \text{ e } B \subset C, \text{ então } A \subset B \iff (C - B) \subset (C - A)$$

$$(11) B - \bigcup_{i \in I} A_i = \bigcap_{i \in I} (B - A_i)$$

$$(12) B - \bigcap_{i \in I} A_i = \bigcup_{i \in I} (B - A_i)$$

Teorema 7.1.5 (*Propriedades da diferença simétrica*). Para A, B e $\{A_i : i \in I\}$ quaisquer:

$$(1) \text{ Comutativa: } A \Delta B = B \Delta A$$

$$(2) \text{ Associativa: } (A \Delta B) \Delta C = A \Delta (B \Delta C)$$

$$(3) \text{ Elemento neutro: } \exists \Phi : \forall A, A \Delta \Phi = A$$

$$(4) \text{ Elemento inverso: } \forall A, \exists B : A \Delta B = \emptyset$$

$$(5) (A \Delta B) \cap C = (A \cap C) \Delta (B \cap C)$$

$$(6) A \Delta B = A \Delta C \implies B = C$$

$$(7) \quad A \triangle B = \emptyset \iff A = B$$

$$(8) \quad A \cap B = \emptyset \iff A \triangle B = A \cup B$$

Teorema 7.1.6 (*Propriedades do produto cartesiano*). Para A, B e C quaisquer:

$$(1) \quad A \times \emptyset = \emptyset \times A = \emptyset$$

$$(2) \quad A \times (B \cap C) = (A \times B) \cap (A \times C)$$

$$(3) \quad A \times (B \cup C) = (A \times B) \cup (A \times C)$$

$$(4) \quad A \times (B - C) = (A \times B) - (A \times C)$$

$$(5) \quad (A \times B)^c = (A \times B^c) \cup (A^c \times \Omega_2) = (A^c \times B) \cup (\Omega_1 \times B^c)$$

Teorema 7.1.7 (*Propriedades de $\mathcal{P}(\cdot)$*). Para A, B quaisquer:

$$(1) \quad \mathcal{P}(A \cap B) = \mathcal{P}(A) \cap \mathcal{P}(B)$$

$$(2) \quad \mathcal{P}(A \cup B) \supset \mathcal{P}(A) \cup \mathcal{P}(B)$$

Teorema 7.1.8 (*Propriedades da função indicadora*). Para A, B quaisquer:

$$(1) \quad I_A \leq I_B \iff A \subset B$$

$$(2) \quad I_A = I_B \iff A = B$$

$$(3) \quad I_{A^c} = 1 - I_A$$

$$(4) \quad I_{A \cup B} = I_A + I_B - I_{A \cap B}$$

$$(5) \quad I_{A \triangle B} = |I_A - I_B|$$

$$(6) \quad I_{\bigcap_{i=1}^n A_i} = \prod_{i=1}^n I_{A_i}$$

$$(7) \quad I_{\bigcup_{i=1}^n A_i} = \sum_{i=1}^n I_{A_i} \text{ se } A_i \cap A_j = \emptyset \quad \forall i \neq j$$

7.2 Funções

Definição 7.2.1 (*Definições básicas de funções*). Seja $f: \Omega_1 \rightarrow \Omega_2$

- Injetora: $\omega_1 \neq \omega_2 \implies f(\omega_1) \neq f(\omega_2)$
- Sobrejetora: $\forall \omega_2 \in \Omega_2, \exists \omega_1 \in \Omega : f(\omega_1) = \omega_2$
- Bijetora: f é sobrejetora e injetora
- Gráfico: $G(f) := \{(\omega, f(\omega)) : \omega \in \Omega_1\}$

- Imagem direta: $f(A) := \{\omega_2 \in \Omega_2 : f(\omega_1) = \omega_2 \text{ para algum } \omega_1 \in A\}$
- Imagem inversa: $f^{-1}(B) := \{\omega_1 \in \Omega_1 : f(\omega_1) \in B\}$
- Composição: Seja $g : \Omega_2 \rightarrow \Omega_3$. $(g \circ f)(\omega_1) := g(f(\omega_1))$, $\omega_1 \in \Omega_1$
- Função inversa: Seja $g : \Omega_2 \rightarrow \Omega_1$. g é inversa de f se

$$(1) \quad g(f(\omega_1)) = \omega_1, \quad \forall \omega_1 \in \Omega_1$$

$$(2) \quad f(g(\omega_2)) = \omega_2, \quad \forall \omega_2 \in \Omega_2$$

Teorema 7.2.1 (*Propriedades de funções*). Seja $f : \Omega_1 \rightarrow \Omega_2$, $A, B, (A_n)_{n \geq 1} \subset \Omega_1$ e $C, D \subset \Omega_2$:

- (1) $f(\emptyset) = \emptyset$
- (2) $A \subset B \implies f(A) \subset f(B)$
- (3) $f(A \cup B) = f(A) \cup f(B)$
- (4) $f(A \cap B) \subset f(A) \cap f(B)$
- (5) f é injetora $\implies f(A \cap B) \supset f(A) \cap f(B) \implies f(A \cap B) = f(A) \cap f(B)$
- (6) $f(\bigcup_{n=1}^{\infty} A_n) = \bigcup_{n=1}^{\infty} f(A_n)$
- (7) $f(\bigcap_{n=1}^{\infty} A_n) \subset \bigcap_{n=1}^{\infty} f(A_n)$
- (8) $f(A) - f(B) \subset f(A - B)$
- (9) f é injetora $\implies f(A^c) \subset (f(A))^c$
- (10) f é sobrejetora $\implies f(A^c) \supset (f(A))^c$
- (11) f é bijetora $\implies f(A^c) = (f(A))^c$

Teorema 7.2.2 (*Propriedades de funções e imagens inversas*). Seja $f : \Omega_1 \rightarrow \Omega_2$, $A, B, (A_n)_{n \geq 1} \subset \Omega_2$ e $C \subset \Omega_1$:

- (1) f^{-1} é bijetora
- (2) $(f^{-1})^{-1} = f$
- (3) $A \subset B \implies f^{-1}(A) \subset f^{-1}(B)$
- (4) $f^{-1}(A \cup B) = f^{-1}(A) \cup f^{-1}(B)$
- (5) $f^{-1}(A \cap B) = f^{-1}(A) \cap f^{-1}(B)$
- (6) $f^{-1}(\bigcup_{n=1}^{\infty} A_n) = \bigcup_{n=1}^{\infty} f^{-1}(A_n)$
- (7) $f^{-1}(\bigcap_{n=1}^{\infty} A_n) = \bigcap_{n=1}^{\infty} f^{-1}(A_n)$

$$(8) \quad f^{-1}(A^c) = (f^{-1}(A))^c$$

$$(9) \quad C \subset f^{-1}(f(C))$$

$$(10) \quad f(f^{-1}(A)) \subset A$$

Teorema 7.2.3 (*Propriedades de composições de funções*). Seja $f: \Omega_1 \rightarrow \Omega_2$ e $g: \Omega_2 \rightarrow \Omega_3$:

$$(1) \quad f \text{ e } g \text{ são injetoras} \implies g \circ f \text{ é injetora}$$

$$(2) \quad f \text{ e } g \text{ são sobrejetoras} \implies g \circ f \text{ é sobrejetora}$$

$$(3) \quad f \text{ e } g \text{ são bijetoras} \implies g \circ f \text{ é bijetora e } (g \circ f)^{-1} = f^{-1} \circ g^{-1}$$

$$(4) \quad (g \circ f)^{-1}(U) = f^{-1}(g^{-1}(U)), \text{ para } U \subset \Omega_3$$

7.3 Noções de cardinalidade

7.4 Valor absoluto

Teorema 7.4.1. Valem as seguintes propriedades:

$$(1) \quad |a \cdot x| = |a| \cdot |x|$$

$$(2) \quad |x + y| \leq |x| + |y|$$

$$(3) \quad |x - y| \leq |x| + |y|$$

$$(4) \quad |x| - |y| \leq ||x| - |y|| \leq |x - y|$$

$$(5) \quad |x - z| \leq |x - y| + |y - z|$$

$$(6) \quad x \in (a - \epsilon, a + \epsilon) \iff a - \epsilon < x < a + \epsilon \iff |x - a| < \epsilon$$

7.5 Sequências de números reais

Teorema 7.5.1. Considere $(x_n)_{n \geq 1}$ uma sequência de números reais.

$$(1) \quad \text{Toda sequência limitada é convergente}$$

$$(2) \quad \text{Se existir, o limite de uma sequência é único}$$

$$(3) \quad \text{Se } x_n \rightarrow L, \text{ então toda subsequência de } (x_n)_{n \geq 1} \text{ converge para } L$$

$$(4) \quad \text{Toda sequência monótona e limitada é convergente}$$

$$(5) \quad \text{Uma sequência monótona que possui uma subsequência convergente é convergente}$$

Teorema 7.5.2. Considere $(x_n)_{n \geq 1}$ e $(y_n)_{n \geq 1}$ seqüências de números reais.

- (1) Se $x_n \rightarrow 0$ e $(y_n)_{n \geq 1}$ é limitada, então $x_n y_n \rightarrow 0$
- (2) $x_n \rightarrow x, y_n \rightarrow y \implies x_n + y_n \rightarrow x + y$
- (3) $x_n \rightarrow x, y_n \rightarrow y \implies x_n y_n \rightarrow xy$
- (4) $x_n \rightarrow x, y_n \neq 0 \rightarrow y \neq 0 \implies x_n / y_n \rightarrow x / y$
- (5) $x_n^2 \rightarrow 0 \iff x_n \rightarrow 0$

Teorema 7.5.3 (*Permanência do sinal*). Se $x_n \rightarrow L > 0$, então existe $n_0 \geq 1$ tal que $x_n > 0$ para todo $n \geq n_0$.

Corolário 7.5.1. Suponha $(x_n)_{n \geq 1}$ e $(y_n)_{n \geq 1}$ convergentes tais que, para algum $n_0 \geq 1$, $x_n \leq y_n$ para todo $n \geq n_0$. Então $\lim x_n \leq \lim y_n$.

Teorema 7.5.4 (*Sanduíche*). Se para algum $n_0 \geq 1$ tivermos que $x_n \leq z_n \leq y_n$ para todo $n \geq n_0$ e $x_n \rightarrow L$ e $y_n \rightarrow L$, então $z_n \rightarrow L$.

7.6 Sequências de conjuntos

Teorema 7.6.1. Alguns fatos úteis:

- (1) $\bigcap_{n=1}^{\infty} [-\infty, n] = \{-\infty\}$
- (2) $\bigcap_{n=1}^{\infty} (n, \infty] = \{+\infty\} = \overline{\mathbb{R}} - [-\infty, +\infty)$
- (3) $[-\infty, +\infty) = \bigcup_{n=1}^{\infty} [-\infty, n]$
- (4) $(-\infty, x] = [-\infty, x] - \{-\infty\}$

Definição 7.6.1 (*Limite inferior*). Seja $(A_n)_{n \geq 1}$ uma seqüência de subconjuntos de Ω . Definimos o limite inferior da seqüência $(A_n)_{n \geq 1}$ como

$$\liminf A_n = \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k.$$

Definição 7.6.2 (*Limite superior*). Seja $(A_n)_{n \geq 1}$ uma seqüência de subconjuntos de Ω . Definimos o limite superior da seqüência $(A_n)_{n \geq 1}$ como

$$\limsup A_n = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k.$$

Teorema 7.6.2. Considere $(A_n)_{n \geq 1}$ uma sequência de subconjuntos de Ω . Então,

- (1) $\liminf A_n \subset \limsup A_n$;
- (2) $(\liminf A_n)^C = \limsup A_n^C$;
- (3) $(\limsup A_n)^C = \liminf A_n^C$.

Definição 7.6.3 (*Sequência convergente de conjuntos*). Uma sequência $(A_n)_{n \geq 1}$ de subconjuntos de Ω é convergente para A se $\liminf A_n = \limsup A_n = A$. Usaremos a notação $\lim A_n = A$ ou $A_n \rightarrow A$ caso a sequência de conjuntos convirja.

Definição 7.6.4 (*Sequência monótona*). Uma sequência $(A_n)_{n \geq 1}$ de subconjuntos de Ω é dita monótona crescente se $A_n \subset A_{n+1}$ para todo $n \geq 1$ e é dita monótona decrescente se $A_n \supset A_{n+1}$ para todo $n \geq 1$. Dizemos que uma sequência é monótona se ela for monótona crescente ou decrescente.

Teorema 7.6.3. Seja $(A_n)_{n \geq 1}$ uma sequência de subconjuntos de Ω . As seguintes afirmações valem:

- (1) Se $(A_n)_{n \geq 1}$ for monótona crescente, então $\lim A_n$ existe e é igual a $\bigcup_{n=1}^{\infty} A_n$. Neste caso, denotaremos $A_n \uparrow A$, $A = \bigcup_{n=1}^{\infty} A_n$;
- (2) Se $(A_n)_{n \geq 1}$ for monótona decrescente, então $\lim A_n$ existe e é igual a $\bigcap_{n=1}^{\infty} A_n$. Neste caso, denotaremos $A_n \downarrow A$, $A = \bigcap_{n=1}^{\infty} A_n$.

7.7 Classes de Subconjuntos

Definição 7.7.1 (*Álgebra*). Uma classe $\mathcal{A}$ de subconjuntos de Ω é chamada de álgebra de subconjuntos de Ω se satisfizer as seguintes condições:

- (1) $\emptyset \in \mathcal{A}$;
- (2) $A \in \mathcal{A} \Rightarrow A^c \in \mathcal{A}$;
- (3) $A, B \in \mathcal{A} \Rightarrow A \cup B \in \mathcal{A}$.

Definição 7.7.2 (σ -álgebra). Uma classe $\mathcal{A}$ de subconjuntos de Ω é chamada de σ -álgebra de subconjuntos de Ω se satisfizer as seguintes condições:

- (1) $\emptyset \in \mathcal{A}$;
- (2) Se $A \in \mathcal{A}$ então $A^c \in \mathcal{A}$;
- (3) Se $A_1, A_2, \dots \in \mathcal{A}$, então $\bigcup_{n=1}^{\infty} A_n \in \mathcal{A}$.

Teorema 7.7.1. Considere $\{\mathcal{A}_i, i \in I\}$ uma família qualquer de álgebras (σ -álgebras) de subconjuntos de Ω . Então, $\mathcal{A} = \bigcap_{i \in I} \mathcal{A}_i$ é uma álgebra (σ -álgebra) de subconjuntos de Ω .

Definição 7.7.3 (*Álgebras e σ -álgebras geradas*). Considere $\mathcal{C}$ uma classe de subconjuntos de Ω . Definimos a álgebra gerada por $\mathcal{C}$, $\mathcal{A}(\mathcal{C})$, como a interseção

$$\mathcal{A}(\mathcal{C}) = \bigcap_{\mathcal{F} \in \mathcal{G}} \mathcal{F},$$

em que $\mathcal{G} = \{\mathcal{F} : \mathcal{C} \subset \mathcal{F} \text{ e } \mathcal{F} \text{ é uma álgebra de subconjuntos de } \Omega\}$. De forma análoga, definimos a σ -álgebra gerada por $\mathcal{C}$, $\sigma(\mathcal{C})$, como a interseção

$$\sigma(\mathcal{C}) = \bigcap_{\mathcal{F} \in \mathcal{G}'} \mathcal{F},$$

em que $\mathcal{G}' = \{\mathcal{F} : \mathcal{C} \subset \mathcal{F} \text{ e } \mathcal{F} \text{ é uma } \sigma\text{-álgebra de subconjuntos de } \Omega\}$.

Teorema 7.7.2. Dada uma classe $\mathcal{C}$ de subconjuntos de Ω , a álgebra (σ -álgebra) gerada por $\mathcal{C}$, $\mathcal{A}(\mathcal{C})$ ($\sigma(\mathcal{C})$), é a única classe de subconjuntos de Ω que satisfaz:

- (1) $\mathcal{A}(\mathcal{C})$ ($\sigma(\mathcal{C})$) é uma álgebra (σ -álgebra) que contém $\mathcal{C}$;
- (2) Se $\mathcal{A}'$ for uma álgebra (σ -álgebra) que contém $\mathcal{C}$, então $\mathcal{A}(\mathcal{C}) \subset \mathcal{A}'$ ($\sigma(\mathcal{C}) \subset \mathcal{A}'$).

Teorema 7.7.3. Seja Ω um conjunto não-vazio e $\mathcal{D} = \{D_1, \dots, D_n\}$ uma partição finita de Ω em que $D_i \neq \emptyset$ para todo $i = 1, \dots, n$. A álgebra gerada por $\mathcal{D}$, $\mathcal{A}(\mathcal{D})$, é idêntica à classe das uniões finitas disjuntas dos elementos de $\mathcal{D}$:

$$\mathcal{A} = \left\{ \sum_{i \in I} D_i : I \subset \{1, \dots, n\} \right\},$$

em que o símbolo $\sum$ denota uma união disjunta de conjuntos.

Definição 7.7.4 (*Semi-álgebra*). Para $\Omega \neq \emptyset$, uma classe de subconjuntos $\mathcal{S}$ é uma semi-álgebra de subconjuntos de Ω se satisfizer:

- (1) $\emptyset, \Omega \in \mathcal{S}$;
- (2) Se $A, B \in \mathcal{S}$, então $A \cap B \in \mathcal{S}$;
- (3) Se $A \in \mathcal{S}$, então $A^c = \sum_{i=1}^n B_i$, $B_i \in \mathcal{S}$, $i = 1, \dots, n$.

Teorema 7.7.4. Seja $\mathcal{S}$ uma semi-álgebra de subconjuntos de Ω , $\Omega \neq \emptyset$. A álgebra gerada por $\mathcal{S}$, $\mathcal{A}(\mathcal{S})$, é idêntica à classe das uniões finitas disjuntas de elementos de $\mathcal{S}$:

$$\mathcal{F} = \left\{ \sum_{i=1}^n S_i, S_i \in \mathcal{S}, i = 1, \dots, n \right\}.$$

Teorema 7.7.5. Seja $\mathcal{C}$ uma classe arbitrária de subconjuntos de Ω . Defina as seguintes classes de subconjuntos de Ω :

- (1) $\mathcal{C}_1$ a classe que contém $\emptyset$, Ω e todo $A \subset \Omega$ tal que $A \in \mathcal{C}$ ou $A^c \in \mathcal{C}$;
- (2) $\mathcal{C}_2$ a classe que contém todas as interseções finitas de elementos de $\mathcal{C}_1$;
- (3) $\mathcal{C}_3$ a classe formada pelas uniões finitas disjuntas de elementos de $\mathcal{C}_2$.

A classe $\mathcal{C}_3$ é idêntica à álgebra $\mathcal{A}(\mathcal{C})$ gerada por $\mathcal{C}$.

Definição 7.7.5 (σ -álgebra de Borel de $\mathbb{R}$). A σ -álgebra de Borel de $\mathbb{R}$, $\mathcal{B}(\mathbb{R})$, é definida como a σ -álgebra gerada pela classe $\{(-\infty, a] : a \in \mathbb{R}\}$ e seus elementos são chamados de borelianos da reta.

Definição 7.7.6 (*Classes monótonas*). Uma classe $\mathcal{M}$ de subconjuntos de Ω é chamada de classe monótona se é fechada por limites crescentes e decrescentes de conjuntos, isto é, se $(A_n)_{n \geq 1}$ for uma sequência de conjuntos em $\mathcal{M}$ tais que $A_n \uparrow A$ ou $A_n \downarrow A$, então $A \in \mathcal{M}$.

Teorema 7.7.6. Uma álgebra de subconjuntos $\mathcal{A}$ é uma σ -álgebra se, e somente, se for uma classe monótona.

Teorema 7.7.7. Considere $\{\mathcal{M}_i, i \in I\}$ uma família de classes monótonas de subconjuntos de Ω . Então, $\mathcal{M} = \bigcap_{i \in I} \mathcal{M}_i$ é uma classe monótona.

Definição 7.7.7 (*Classe monótona gerada*). Considere $\mathcal{C}$ uma classe de subconjuntos de Ω . Definimos a classe monótona gerada por $\mathcal{C}$, $\mathcal{M}(\mathcal{C})$, como a interseção

$$\mathcal{M}(\mathcal{C}) = \bigcap_{\mathcal{F} \in \mathcal{G}} \mathcal{F},$$

em que $\mathcal{G} = \{\mathcal{F} : \mathcal{C} \subset \mathcal{F} \text{ e } \mathcal{F} \text{ é uma classe monótona de subconjuntos de } \Omega\}$.

Teorema 7.7.8. Dada uma classe $\mathcal{C}$ de subconjuntos de Ω , a classe monótona gerada por $\mathcal{C}$, $\mathcal{M}(\mathcal{C})$, é a única classe $\mathcal{M}$ de subconjuntos de Ω que satisfaz:

- (1) $\mathcal{M}$ é uma classe monótona que contém $\mathcal{C}$;
- (2) Se $\mathcal{M}'$ for uma classe monótona que contém $\mathcal{C}$, então $\mathcal{M} \subset \mathcal{M}'$.

Teorema 7.7.9 (*Teorema das classes monótonas*). A σ -álgebra $\sigma(\mathcal{A})$ gerada por uma álgebra $\mathcal{A}$ é idêntica à classe monótona $\mathcal{M}(\mathcal{A})$ gerada por $\mathcal{A}$.

Definição 7.7.8 (π -sistema). Uma classe $\mathcal{I}$ de subconjuntos de Ω é dito π -sistema se $A \cap B \in \mathcal{I}$ para todo $A, B \in \mathcal{I}$.

Definição 7.7.9 (*d-sistema*). Uma classe $\mathcal{D}$ de subconjuntos de Ω é dita *d-sistema* se

- (1) $\Omega \in \mathcal{D}$;
- (2) $A, B \in \mathcal{D}, A \subset B \Rightarrow B - A \in \mathcal{D}$;
- (3) $A_n \uparrow A, A_n \in \mathcal{D} \Rightarrow A \in \mathcal{D}$.

Teorema 7.7.10. Uma classe $\mathcal{A}$ de subconjuntos de Ω é uma σ -álgebra se, e somente se, for um *d-sistema* e um π -sistema.

Teorema 7.7.11. Se $\{\mathcal{D}_i : i \in I\}$ é uma família qualquer de *d-sistemas* de Ω , então a interseção $\bigcap_{i \in I} \mathcal{D}_i$ é um *d-sistema*.

Definição 7.7.10 (*d-sistema gerado*). Para uma classe $\mathcal{C}$ de subconjuntos de Ω , definimos o *d-sistema gerado* por $\mathcal{C}$, $\mathcal{D}(\mathcal{C})$, como a interseção

$$\mathcal{D}(\mathcal{C}) = \bigcap_{\mathcal{D} \in \mathcal{G}} \mathcal{D},$$

em que $\mathcal{G} = \{\mathcal{D} : \mathcal{C} \subset \mathcal{D} \text{ e } \mathcal{D} \text{ é um } d\text{-sistema de subconjuntos de } \Omega\}$.

Teorema 7.7.12. Dada uma classe $\mathcal{C}$ de subconjuntos de Ω , o *d-sistema gerado* por $\mathcal{C}$, $\mathcal{D}(\mathcal{C})$, é a única classe $\mathcal{D}$ de subconjuntos de Ω que satisfaz:

- (1) $\mathcal{D}$ é uma *d-sistema* que contém $\mathcal{C}$;
- (2) Se $\mathcal{D}'$ for um *d-sistema* que contém $\mathcal{C}$, então $\mathcal{D} \subset \mathcal{D}'$.

Teorema 7.7.13. Se $\mathcal{I}$ for um π -sistema, então $\mathcal{D}(\mathcal{I})$ é um π -sistema.

Teorema 7.7.14 (*Lema de Dynkin*). Se $\mathcal{I}$ for um π -sistema, então $\mathcal{D}(\mathcal{I}) = \sigma(\mathcal{I})$.

Definição 7.7.11 (*Função de conjuntos*). Para $\mathcal{C}$ uma classe de subconjuntos de Ω , a função $\phi : \mathcal{C} \rightarrow [-\infty, +\infty]$ será chamada de função de conjuntos.

Definição 7.7.12 (*Finitamente aditiva*). Uma função de conjuntos $\phi : \mathcal{C} \rightarrow [-\infty, +\infty]$ é dita finitamente aditiva se

$$\phi(A_1 + \cdots + A_n) = \phi(A_1) + \cdots + \phi(A_n),$$

para quaisquer $A_1, \dots, A_n \in \mathcal{C}$ disjuntos tais que $A_1 + \cdots + A_n \in \mathcal{C}$.

Definição 7.7.13 (*Monótona*). Uma função de conjuntos $\phi : \mathcal{C} \rightarrow [-\infty, +\infty]$ será dita monótona se

$$\phi(B) \leq \phi(A),$$

para quaisquer $A, B \in \mathcal{C}$ tais que $B \subset A$.

Definição 7.7.14 (*σ -aditiva*). Uma função de conjuntos $\phi : \mathcal{C} \rightarrow [-\infty, +\infty]$, é dita σ -aditiva se

$$\phi \left(\sum_{n=1}^{\infty} A_n \right) = \sum_{n=1}^{\infty} \phi(A_n)$$

para toda sequência $(A_n)_{n \geq 1}$ de elementos disjuntos de $\mathcal{C}$ tais que $\sum_{n=1}^{\infty} A_n \in \mathcal{C}$.

Definição 7.7.15 (*Medida*). Seja $\mathcal{C}$ uma classe de subconjuntos de Ω tal que $\emptyset \in \mathcal{C}$. Dizemos que a função de conjuntos $\mu : \mathcal{C} \rightarrow [0, +\infty]$ é uma medida sobre $\mathcal{C}$ se valerem

- (1) $\mu(\emptyset) = 0$;
- (2) μ é σ -aditiva, i.e., para qualquer sequência $(A_n)_{n \geq 1}$ de elementos disjuntos de $\mathcal{C}$ tal que $\sum_{n=1}^{\infty} A_n \in \mathcal{C}$, temos que

$$\mu \left(\sum_{n=1}^{\infty} A_n \right) = \sum_{n=1}^{\infty} \mu(A_n).$$

Definição 7.7.16 (*Medida finitamente aditiva*). Seja $\mathcal{C}$ uma classe de subconjuntos de Ω tal que $\emptyset \in \mathcal{C}$. Dizemos que a função de conjuntos $\mu : \mathcal{C} \rightarrow [0, \infty]$ é uma medida finitamente aditiva sobre $\mathcal{C}$ se valerem

- (1) $\mu(\emptyset) = 0$;
- (2) Se $A_1, \dots, A_n \in \mathcal{C}$ forem elementos disjuntos tais que $\sum_{i=1}^n A_i \in \mathcal{C}$, então

$$\mu \left(\sum_{i=1}^n A_i \right) = \sum_{i=1}^n \mu(A_i).$$

Definição 7.7.17 (*Probabilidade*). Seja $\Omega \neq \emptyset$ e $\mathcal{A}$ uma álgebra de subconjuntos de Ω . Dizemos que $\mathbb{P} : \mathcal{A} \rightarrow [0, 1]$ é uma probabilidade sobre a álgebra $\mathcal{A}$ se:

- (1) $\mathbb{P}(\Omega) = 1$;
- (2) $\mathbb{P}$ é σ -aditiva, isto é, se $(A_n)_{n \geq 1}$ for uma sequência de elementos disjuntos de $\mathcal{A}$ tal que $\sum_{n=1}^{\infty} A_n \in \mathcal{A}$, então

$$\mathbb{P} \left(\sum_{n=1}^{\infty} A_n \right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

Definição 7.7.18 (*Probabilidade finitamente aditiva*). Seja $\Omega \neq \emptyset$ e $\mathcal{A}$ uma álgebra de subconjuntos de Ω . Dizemos que $\mathbb{P} : \mathcal{A} \rightarrow [0, 1]$ é uma probabilidade finitamente aditiva sobre a álgebra $\mathcal{A}$ se:

- (1) $\mathbb{P}(\Omega) = 1$;

(2) $\mathbb{P}$ é finitamente aditiva, isto é, se $A_1, A_2, \dots, A_n \in \mathcal{A}$ forem disjuntos, então

$$\mathbb{P}\left(\sum_{k=1}^n A_k\right) = \sum_{k=1}^n \mathbb{P}(A_k).$$

Teorema 7.7.15. Seja $\Omega \neq \emptyset$, $\mathcal{A}$ uma álgebra de subconjuntos de Ω e $\mathbb{P}$ uma probabilidade sobre $\mathcal{A}$. As seguintes propriedades valem:

(1) $\mathbb{P}(\emptyset) = 0$;

(2) $\mathbb{P}$ é finitamente aditiva, i.e., se $A_1, \dots, A_n \in \mathcal{A}$ são elementos disjuntos, então

$$\mathbb{P}\left(\sum_{i=1}^n A_i\right) = \sum_{i=1}^n \mathbb{P}(A_i);$$

(3) $\mathbb{P}$ é monótona, i.e., se $A \subset B$, $A, B \in \mathcal{A}$, então $\mathbb{P}(A) \leq \mathbb{P}(B)$;

(4) $\mathbb{P}(A \cup B) + \mathbb{P}(A \cap B) = \mathbb{P}(A) + \mathbb{P}(B)$ para quaisquer $A, B \in \mathcal{A}$. Em particular, $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$ para todo $A \in \mathcal{A}$;

(5) $\mathbb{P}$ é sub- σ -aditiva, isto é, se $(A_n)_{n \geq 1}$ for uma sequência de elementos de $\mathcal{A}$ tal que $\bigcup_{n=1}^{\infty} A_n \in \mathcal{A}$, então

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

Teorema 7.7.16. Seja $\Omega \neq \emptyset$, $\mathcal{A}$ uma álgebra de subconjuntos de Ω e $(A_n)_{n \geq 1}$ uma sequência de elementos de $\mathcal{A}$. As seguintes afirmações valem:

(1) Se $A_n \uparrow A$, $A \in \mathcal{A}$, então $\mathbb{P}(A_n) \nearrow \mathbb{P}(A)$;

(2) Se $A_n \downarrow A$, $A \in \mathcal{A}$, então $\mathbb{P}(A_n) \searrow \mathbb{P}(A)$.

Teorema 7.7.17. Considere $\Omega \neq \emptyset$ e $\mathcal{A}$ uma álgebra de subconjuntos de Ω . Uma medida de probabilidade finitamente aditiva $\mathbb{P}$ é σ -aditiva se, e somente se, $\mathbb{P}$ for contínua por cima no vazio, isto é, se $(A_n)_{n \geq 1}$ for uma sequência de elementos de $\mathcal{A}$ tal que $A_n \downarrow \emptyset$, então $\mathbb{P}(A_n) \searrow 0$.

Teorema 7.7.18. Seja $(\Omega, \mathcal{A}, \mathbb{P})$ um espaço de probabilidade e $(A_n)_{n \geq 1}$ uma sequência de elementos de $\mathcal{A}$. Então,

$$\mathbb{P}(\liminf A_n) \leq \liminf \mathbb{P}(A_n) \leq \limsup \mathbb{P}(A_n) \leq \mathbb{P}(\limsup A_n).$$

Em particular, se $\lim A_n = A$, isto é, $\liminf A_n = \limsup A_n = A$, então $\lim \mathbb{P}(A_n) = \mathbb{P}(A)$.

Teorema 7.7.19. Seja $(\Omega, \mathcal{A}, \mathbb{P})$ um espaço de probabilidade e $(A_n)_{n \geq 1}$ uma sequência de elementos de $\mathcal{A}$. Se $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$, então $\mathbb{P}(\limsup A_n) = 0$.

Definição 7.7.19 (*Função de distribuição*). Uma função $F : \mathbb{R} \rightarrow [0, 1]$ é dita função de distribuição se satisfaz:

- (1) F é uma função crescente, isto é, se $x_1 < x_2$, então $F(x_1) \leq F(x_2)$;
- (2) F é contínua à direita, isto é, se $(x_n)_{n \geq 1}$ for uma sequência de números reais tais que $x_n \downarrow x$, $x \in \mathbb{R}$, então $F(x_n) \searrow F(x)$;
- (3) Os limites de F em $-\infty$ e $+\infty$ são dados por

$$\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow +\infty} F(x) = 1.$$

Teorema 7.7.20. Seja $\Omega \neq \emptyset$ e $\mathcal{S}$ uma semi-álgebra de subconjuntos de Ω .

- (1) Se $\mathbb{P}$ for uma probabilidade finitamente aditiva sobre $\mathcal{S}$, então existe uma única probabilidade finitamente aditiva $\mathbb{P}'$ que estende $\mathbb{P}$, isto é, $\mathbb{P}'(A) = \mathbb{P}(A)$ para todo $A \in \mathcal{S}$;
- (2) Se $\mathbb{P}$ for uma probabilidade (σ -aditiva) sobre $\mathcal{S}$, então existe uma única probabilidade (σ -aditiva) $\mathbb{P}'$ que estende $\mathbb{P}$ de $\mathcal{S}$ para $\mathcal{A}(\mathcal{S})$.

Teorema 7.7.21. Sejam $\Omega \neq \emptyset$ e $\mathcal{S}$ uma semi-álgebra de subconjuntos de Ω .

- (1) Se μ for uma medida finitamente aditiva sobre $\mathcal{S}$, então existe uma única medida finitamente aditiva μ' que estende μ para $\mathcal{A}(\mathcal{S})$;
- (2) Se μ for uma medida (σ -aditiva) sobre $\mathcal{S}$, então existe uma única medida (σ -aditiva) μ' que estende μ para $\mathcal{A}(\mathcal{S})$;
- (3) Se μ for uma medida σ -finita sobre uma semi-álgebra $\mathcal{S}$, então a extensão μ' dada em (a) e (b) é σ -finita sobre $\mathcal{A}(\mathcal{S})$.

Teorema 7.7.22. Se $\{\mathcal{D}_i, i \in I\}$ é uma família qualquer de d -sistemas de Ω , então a interseção $\bigcap_{i \in I} \mathcal{D}_i$ é um d -sistema.

Teorema 7.7.23. A função de conjuntos $\mathbb{P}' : \mathcal{G} \rightarrow [0, +\infty]$ dada em (1.14) está bem definida.

Teorema 7.7.24. A classe de subconjuntos $\mathcal{G}$ definida em (1.13) e a função de conjuntos $\mathbb{P}' : \mathcal{G} \rightarrow [0, +\infty]$ definida em (1.14) satisfazem às seguintes propriedades:

- (1) $\emptyset, \Omega \in \mathcal{G}$, $\mathbb{P}'(\emptyset) = 0$, $\mathbb{P}'(\Omega) = 1$ e $0 \leq \mathbb{P}'(G) \leq 1$ para todo $G \in \mathcal{G}$;

(2) Se $G_1, G_2 \in \mathcal{G}$, então $G_1 \cup G_2, G_1 \cap G_2 \in \mathcal{G}$ e

$$\mathbb{P}'(G_1 \cup G_2) + \mathbb{P}'(G_1 \cap G_2) = \mathbb{P}'(G_1) + \mathbb{P}'(G_2).$$

Em particular, segue que $\mathbb{P}'$ é finitamente aditiva em $\mathcal{G}$;

(3) Se $G_1, G_2 \in \mathcal{G}$ e $G_1 \subset G_2$, então $\mathbb{P}'(G_1) \leq \mathbb{P}'(G_2)$;

(4) Se $(G_n)_{n \geq 1} \subset \mathcal{G}$ é tal que $G_n \uparrow G$, então $G \in \mathcal{G}$ e

$$\mathbb{P}'(G) = \lim_{n \rightarrow \infty} \mathbb{P}'(G_n).$$

Teorema 7.7.25. A função de conjuntos $\mathbb{P}^* : \mathcal{P}(\Omega) \rightarrow [0, +\infty]$ definida em (1.16) satisfaz as seguintes propriedades:

(1) Para todo $A \subset \Omega$, $0 \leq \mathbb{P}^*(A) \leq 1$;

(2) Para todo $G \in \mathcal{G}$, temos que $\mathbb{P}^*(G) = \mathbb{P}'(G)$;

(3) Para quaisquer $A, B \subset \Omega$, temos

$$\mathbb{P}^*(A \cup B) + \mathbb{P}^*(A \cap B) \leq \mathbb{P}^*(A) + \mathbb{P}^*(B).$$

Em particular, $\mathbb{P}^*(A) + \mathbb{P}^*(A^c) \geq 1$ para todo $A \subset \Omega$;

(4) Se $A \subset B$, $A, B \subset \Omega$, então

$$\mathbb{P}^*(A) \leq \mathbb{P}^*(B);$$

(5) Se $A_n \uparrow A$, $A_n \subset \Omega$ para $n \geq 1$, então

$$\mathbb{P}^*(A) = \lim_{n \rightarrow \infty} \mathbb{P}^*(A_n).$$

Teorema 7.7.26. A classe $\mathcal{D}$ definida em (1.21) é uma σ -álgebra de subconjuntos de Ω que contém $\sigma(\mathcal{A})$ e a restrição de $\mathbb{P}^*$ a $\mathcal{D}$ é uma probabilidade sobre $\mathcal{D}$.

Teorema 7.7.27 (*Teorema de extensão de Carathéodory*). Se $\mathbb{P}$ for uma probabilidade sobre uma álgebra $\mathcal{A}$, então existe uma única extensão $\bar{\mathbb{P}}$ de $\mathbb{P}$ para $\sigma(\mathcal{A})$.

Corolário 7.7.1. Se $\mathbb{P}$ for uma probabilidade sobre uma semi-álgebra $\mathcal{S}$ de subconjuntos de Ω , então existe uma única extensão $\bar{\mathbb{P}}$ de $\mathbb{P}$ para $\sigma(\mathcal{S})$.

Teorema 7.7.28 (*Teorema de Extensão de Carathéodory*). Seja $\Omega \neq \emptyset$ e $\mathcal{A}$ uma álgebra de subconjuntos de Ω .

(1) Se μ for uma medida sobre $\mathcal{A}$, então existe uma medida $\bar{\mu}$ que estende μ de $\mathcal{A}$ para $\sigma(\mathcal{A})$;

- (2) Se μ for uma medida σ -finita sobre $\mathcal{A}$, então $\bar{\mu}$ dada em (a) é a única medida que estende μ de $\mathcal{A}$ para $\sigma(\mathcal{A})$.

Corolário 7.7.2. Seja $\Omega \neq \emptyset$ e $\mathcal{S}$ uma semi-álgebra de subconjuntos de Ω .

- (1) Se μ for uma medida sobre $\mathcal{S}$, então existe uma medida $\bar{\mu}$ que estende μ de $\mathcal{S}$ para $\sigma(\mathcal{S})$;
- (2) Se μ for uma medida σ -finita sobre $\mathcal{S}$, então $\bar{\mu}$ dada em (a) é a única medida que estende μ de $\mathcal{S}$ para $\sigma(\mathcal{S})$.

7.8 Medida

Definição 7.8.1 (*Medida de Lebesgue*). Considere a semi-álgebra

$$\mathcal{S} = \{\emptyset, \mathbb{R}\} \cup \{(-\infty, a] : a \in \mathbb{R}\} \cup \{(b, \infty) : b \in \mathbb{R}\} \cup \{(a, b) : a < b, a, b \in \mathbb{R}\}$$

de subconjuntos de $\mathbb{R}$. Defina $\lambda: \mathcal{S} \rightarrow [0, \infty]$ como

$$\begin{aligned}\lambda(\emptyset) &= 0, \\ \lambda((a, b]) &= b - a, \quad a < b, \\ \lambda((-\infty, a]) &= +\infty, \\ \lambda((b, +\infty)) &= +\infty.\end{aligned}$$

Pode-se mostrar que λ é σ -aditiva em $\mathcal{S}$ e existe uma única extensão $\bar{\lambda}$ de λ para $\sigma(\mathcal{S}) = \mathcal{B}(\mathbb{R})$. Esta medida é chamada de *medida de Lebesgue* em $\mathbb{R}^1$.

Definição 7.8.2 (*Medida de Lebesgue-Stieltjes*). Considere $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbb{P}_F)$ um espaço de probabilidade e seja $F: \mathbb{R} \rightarrow [0, 1]$ uma função de distribuição associada à medida de probabilidade $\mathbb{P}_F$ definida conforme a definição 7.9.1.

Agora, considere a semi-álgebra

$$\mathcal{S} = \{\emptyset, \mathbb{R}\} \cup \{(-\infty, a] : a \in \mathbb{R}\} \cup \{(b, \infty) : b \in \mathbb{R}\} \cup \{(a, b) : a < b, a, b \in \mathbb{R}\}$$

de subconjuntos de $\mathbb{R}$ e defina $\mathbb{P}_S: \mathcal{S} \rightarrow [0, 1]$ como

$$\begin{aligned}\mathbb{P}_S(\emptyset) &= 0, \\ \mathbb{P}_S((a, b]) &= F(b) - F(a), \quad a < b, \\ \mathbb{P}_S((-\infty, a]) &= F(a), \\ \mathbb{P}_S((b, +\infty)) &= 1 - F(b).\end{aligned}$$

Note que $\sigma(\mathcal{S}) = \mathcal{B}(\mathbb{R})$. Pode-se mostrar que $\mathbb{P}_S$ é σ -aditiva sobre $\mathcal{S}$ e existe uma única probabilidade $\mathbb{P}_F$ sobre $\mathcal{B}(\mathbb{R})$ que estende $\mathbb{P}_S$. Esta medida de probabilidade $\mathbb{P}_F$ é denominada *medida de Lebesgue-Stieltjes* gerada por F .

7.9 Probabilidade

Definição 7.9.1 (*Função de distribuição associada a uma probabilidade*). Seja $\Omega = \mathbb{R}$, $\mathcal{A} = \mathcal{B}(\mathbb{R})$ e $\mathbb{P}$ uma probabilidade sobre $\mathcal{A}$. Podemos definir a função de distribuição $F: \mathbb{R} \rightarrow [0, 1]$ associada à probabilidade $\mathbb{P}$ como

$$F(x) = \mathbb{P}((-\infty, x]), \quad x \in \mathbb{R}$$

Teorema 7.9.1 (*Propriedades da função de distribuição*). As seguintes propriedades são válidas para F :

- (1) F é crescente, isto é, $x_1 < x_2 \implies F(x_1) \leq F(x_2)$;
- (2) F é contínua à direita, isto é se $(x_n)_{n \geq 1}$ for uma sequência de números reais tais que $x_n \downarrow x, x \in \mathbb{R}$, então $F(x_n) \searrow F(x)$;
- (3) Os limites de F em $-\infty$ e $+\infty$ são dados por

$$\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow +\infty} F(x) = 1.$$

7.9.1 Convergência

Teorema 7.9.2.

- (1) $A_n \uparrow A, A \in \mathcal{A} \implies \mathbb{P}(A_n) \nearrow \mathbb{P}(A)$
 $A_n \downarrow A, A \in \mathcal{A} \implies \mathbb{P}(A_n) \searrow \mathbb{P}(A)$
- (2) $\mathbb{P}$ é σ -aditiva $\iff (A_n \downarrow \emptyset \implies \mathbb{P}(A_n) \searrow \mathbb{P}(A))$ ($\mathbb{P}$ é contínua no vazio)
- (3) $\mathbb{P}(\liminf A_n) \leq \liminf \mathbb{P}(A_n) \leq \limsup \mathbb{P}(A_n) \leq \mathbb{P}(\limsup A_n)$
- (4) $A_n \rightarrow A \implies \mathbb{P}(A_n) \rightarrow P$
- (5) $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty \implies \mathbb{P}(\limsup A_n) = 0$

7.10 Transformações mensuráveis

Teorema 7.10.1 (2.1). Se $\mathcal{A}_2$ for uma σ -álgebra de subconjuntos de Ω_2 , então $X^{-1}(\mathcal{A}_2)$ é uma σ -álgebra de subconjuntos de Ω_1 .

Definição 7.10.1 (2.1 *Transformação mensurável*). Sejam $(\Omega_1, \mathcal{A}_1)$ e $(\Omega_2, \mathcal{A}_2)$ dois espaços mensuráveis e $X: \Omega_1 \rightarrow \Omega_2$. Dizemos que X é $\mathcal{A}_1 \setminus \mathcal{A}_2$ mensurável se $X^{-1}(\mathcal{A}_2) \subset \mathcal{A}_1$, isto é,

$$\begin{aligned} [X \in B] &= X^{-1}(B) \in \mathcal{A}_1, \quad \text{para todo } B \in \mathcal{A}_2 \\ &= \{\omega \in \Omega : X(\omega) \in B\} \in \mathcal{A}_1, \quad \text{para todo } B \in \mathcal{A}_2 \end{aligned} \tag{7.10.1}$$

Definição 7.10.2 (2.2 σ -álgebra gerada por X em Ω_1). A σ -álgebra $X^{-1}(\mathcal{A}_2)$ é a menor σ -álgebra $\mathcal{A}_1$ de subconjuntos de Ω_1 que torna X uma transformação $\mathcal{A}_1 \setminus \mathcal{A}_2$ mensurável e é denominada σ -álgebra gerada por X :

$$\sigma(X) := X^{-1}(\mathcal{A}_2) = \{X^{-1}(B) : B \in \mathcal{A}_2\} \quad (7.10.2)$$

Nota:

- (1) $\sigma(X) \subset \mathcal{A}_1$;
- (2) $\sigma(X)$ é a menor σ -álgebra em Ω_1 que torna X mensurável;
- (3) Para X ser mensurável, a σ -álgebra de partida $\mathcal{A}_1$ deve ser pelo menos tão grande quanto $\sigma(X)$, ou seja $\mathcal{A}_1 \supset \sigma(X)$.

Teorema 7.10.2 (2.4 σ -álgebra induzida por X em Ω_2). Seja $X: \Omega_1 \rightarrow \Omega_2$ e $\mathcal{A}_1$ uma σ -álgebra de subconjuntos de Ω_1 . A classe $X_*(\mathcal{A}_1) := \{B \subset \Omega_2 : X^{-1}(B) \in \mathcal{A}_1\}$ é uma σ -álgebra de subconjuntos de Ω_2 que será denominada σ -álgebra induzida por X à partir de $\mathcal{A}_1$.

Nota:

- (1) $\mathcal{A}_2 \subset X_*(\mathcal{A}_1)$;
- (2) $X_*(\mathcal{A}_1)$ é a maior σ -álgebra em Ω_2 que torna X mensurável;
- (3) Para X ser mensurável, a σ -álgebra de chegada $\mathcal{A}_2$ deve ser pelo menos tão pequena quanto $X_*(\mathcal{A}_1)$, ou seja $\mathcal{A}_2 \subset X_*(\mathcal{A}_1)$.

Teorema 7.10.3 (2.2). Para qualquer classe $\mathcal{C}_2$ de subconjuntos de Ω_2 , temos que

$$X^{-1}(\sigma(\mathcal{C}_2)) = \sigma(X^{-1}(\mathcal{C}_2)) \quad (7.10.3)$$

Teorema 7.10.4 (Condição suficiente para mensurabilidade). Sejam $(\Omega_1, \mathcal{A}_1)$ e $(\Omega_2, \mathcal{A}_2)$ dois espaços mensuráveis e $X: \Omega_1 \rightarrow \Omega_2$. Se $X^{-1}(\mathcal{C}_2) \subset \mathcal{A}_1$, onde $\mathcal{C}_2$ é a classe que gera $\mathcal{A}_2$, então X é $\mathcal{A}_1 \setminus \mathcal{A}_2$ mensurável.

Teorema 7.10.5 (2.3 Composição de transformações mensuráveis). Sejam $(\Omega_1, \mathcal{A}_1)$, $(\Omega_2, \mathcal{A}_2)$, $(\Omega_3, \mathcal{A}_3)$ espaços mensuráveis, $X: \Omega_1 \rightarrow \Omega_2$ e $Y: \Omega_2 \rightarrow \Omega_3$ transformações $\mathcal{A}_1 \setminus \mathcal{A}_2$ e $\mathcal{A}_2 \setminus \mathcal{A}_3$ mensuráveis, respectivamente. Então, $(Y \circ X): \Omega_1 \rightarrow \Omega_3$ é uma transformação $\mathcal{A}_1 \setminus \mathcal{A}_3$ mensurável.

Teorema 7.10.6 (2.5 Probabilidade induzida ou distribuição de X). Considere $(\Omega_1, \mathcal{A}_1, \mathbb{P}_1)$ um espaço de probabilidade, $\Omega_2 \neq \emptyset$ e $\mathcal{A}_2 = \{B \subset \Omega_2 : X^{-1}(B) \in \mathcal{A}_1\}$ a σ -álgebra induzida por X . Defina $\mathbb{P}_2: \mathcal{A}_2 \rightarrow [0, 1]$ como

$$\mathbb{P}_2(B) = \mathbb{P}_1([X \in B]), \quad B \in \mathcal{A}_2. \quad (7.10.4)$$

A função $\mathbb{P}_2$ é uma probabilidade sobre o espaço $(\Omega_2, \mathcal{A}_2)$ que é denominada *probabilidade induzida* ou *distribuição* de X , sendo o espaço de probabilidade $(\Omega_2, \mathcal{A}_2, \mathbb{P}_2)$ obtido chamado de *espaço de probabilidade induzido* por X à partir de $(\Omega_1, \mathcal{A}_1, \mathbb{P}_1)$.

7.11 Variáveis aleatórias

Lema 7.11.1 (*σ -álgebra de Borel estendida*). A σ -álgebra $\mathcal{B}(\overline{\mathbb{R}})$ é gerada pela classe dos intervalos

$$\mathcal{I} = \{[-\infty, x] : x \in \mathbb{R}\}$$

em que $[-\infty, x] = \{y \in \overline{\mathbb{R}} : y \leq x\}$ para $x \in \mathbb{R}$.

Definição 7.11.1 (*Variável aleatória*). Seja $(\Omega, \mathcal{A})$ um espaço mensurável. Uma função $X: \Omega \rightarrow \overline{\mathbb{R}}$ é chamada de *variável aleatória* se for $\mathcal{A} \setminus \mathcal{B}(\overline{\mathbb{R}})$ mensurável, isto é,

$$\begin{aligned} [X \in B] &= X^{-1}(B) \in \mathcal{A} \quad \text{para todo } B \in \mathcal{B}(\overline{\mathbb{R}}) \\ &= \{\omega \in \Omega : X(\omega) \in B\} \in \mathcal{A}, \quad \text{para todo } B \in \mathcal{B}(\overline{\mathbb{R}}) \end{aligned} \quad (7.11.1)$$

Nota: Toda função $X: \Omega \rightarrow \mathbb{R}$ que for $\mathcal{A} \setminus \mathcal{B}(\mathbb{R})$ mensurável também será considerada variável aleatória. Nesta condição, X será dita variável aleatória finita.

Definição 7.11.2 (*Notações em Probabilidade*). Sejam $(\Omega_1, \mathcal{A}_1)$ e $(\Omega_2, \mathcal{A}_2)$ espaços mensuráveis. As seguintes notações são usuais:

- (1) $[X \in B] := X^{-1}(B)$, para $B \in \mathcal{A}_2$
- (2) $[X = x] := X^{-1}(\{x\})$, para $x \in \mathcal{A}_2$
- (3) $[X \leq x] := X^{-1}((-\infty, x])$, para $(-\infty, x] \in \mathcal{A}_2$
- (4) $f: \mathbb{R} \rightarrow \mathbb{R} : [f \leq y] := f^{-1}((-\infty, y]) = \{x \in \mathbb{R} : f(x) \leq y\}$
- (5) $[X \leq x, Y \leq y] := X^{-1}((-\infty, x]) \cap Y^{-1}((-\infty, y])$
- (6) $[X < Y] = [X - Y < 0] := Z^{-1}((-\infty, 0))$, onde $Z = X - Y$
- (7) $F(x) = \mathbb{P}((-\infty, x])$
- (8) $F_X(x) = \mathbb{P}[X \leq x] = \mathbb{P}(X^{-1}((-\infty, x])) = \mathbb{P}_X((-\infty, x]) \equiv \mathbb{P}((-\infty, x]) = F(x)$
- (9) $[X = Y \text{ q.c.}] := \mathbb{P}[X = Y] = 1 \equiv \mathbb{P}[X = Y] = 0$

Teorema 7.11.1 (*Exemplos de variáveis aleatórias*). As seguintes funções são variáveis aleatórias:

- (1) Função constante: $X(\omega) = c$ para todo $\omega \in \Omega$;
- (2) Função indicadora: $I_A(\omega)$

Teorema 7.11.2. Para $(\Omega, \mathcal{A})$ um espaço mensurável e uma função $X: \Omega \rightarrow \overline{\mathbb{R}}$, as seguintes afirmações são equivalentes:

- (1) X é $\mathcal{A} \setminus \mathcal{B}(\overline{\mathbb{R}})$ mensurável;

- (2) $[X \in B] \in \mathcal{A}$ para todo $B \in \mathcal{B}(\mathbb{R})$,
 $[X = +\infty] = X^{-1}(\{+\infty\}) \in \mathcal{A}$,
 $[X = -\infty] = X^{-1}(\{-\infty\}) \in \mathcal{A}$;
- (3) $[X \in I] = X^{-1}(I) \in \mathcal{A}$ para todo $I \in \mathcal{I}$, em que $\sigma(\mathcal{I}) = \mathcal{B}(\overline{\mathbb{R}})$.

Lema 7.11.2 (*Mensurabilidade de funções contínuas*). Toda função $f: \mathbb{R} \rightarrow \mathbb{R}$ contínua é $\mathcal{B}(\mathbb{R}) \setminus \mathcal{B}(\mathbb{R})$ mensurável.

Teorema 7.11.3 (*Propriedades de variáveis aleatórias*). Considere $(\Omega, \mathcal{A})$ um espaço mensurável, X e Y variáveis aleatórias e $(X_n)_{n \geq 1}$ uma sequência de variáveis aleatórias. Então,

- (1) aX é variável aleatória, $a \in \mathbb{R}$;
- (2) $X \pm Y$ é variável aleatória;
- (3) $X \cdot Y$ é variável aleatória;
- (4) $\frac{X}{Y}$ é variável aleatória;
- (5) $[X = Y]$, $[X < Y]$, $[X > Y] \in \mathcal{A}$;
- (6) $\max(X, Y)$, $\min(X, Y)$ são variáveis aleatórias;
 - (a) $X^+ = \max(X, 0)$ é v.a.
 - (b) $X^- = \max(-X, 0) = -\min(0, X)$ é v.a.
 - (c) $X = X^+ - X^-$
 - (d) $|X| = X^+ + X^-$ é v.a.
- (7) $\inf_{n \geq 1} (X_n)$, $\sup_{n \geq 1} (X_n)$ são variáveis aleatórias;
- (8) $\liminf (X_n)$, $\limsup (X_n)$ são variáveis aleatórias;

Teorema 7.11.4 (*Exercício 2.7 - V.A. simples*). Considere X e Y variáveis aleatórias simples. As funções abaixo são v.a. simples.

- (1) $aX \pm bY$, $a, b \in \mathbb{R}$
- (2) $X \cdot Y$
- (3) $\max(X, Y)$, $\min(X, Y)$

Definição 7.11.3 (*Variável aleatória simples*). Considere $(\Omega, \mathcal{A})$ um espaço mensurável. Uma variável aleatória $X: \Omega \rightarrow \overline{\mathbb{R}}$ é chamada de *variável aleatória simples* se existirem $A_1, A_2, \dots, A_n \in \mathcal{A}$ que formam uma partição de Ω , $A_i \neq \emptyset$ para $i = 1, \dots, n$, e números reais $x_1, x_2, \dots, x_n$ tais que

$$X(\omega) = \sum_{i=1}^n x_i I_{A_i}(\omega), \quad \omega \in \Omega \quad (7.11.2)$$

Caso todos os valores de $x_1, \dots, x_n$ sejam distintos, dizemos que 7.11.2 é a *representação canônica* de X .

Teorema 7.11.5 (*2.12 v.a. não negativa como seq. de v.a. simples*). Considere $(\Omega, \mathcal{A})$ um espaço mensurável. Se X é uma variável aleatória não negativa, isto é, $X(\omega) \geq 0$ para todo $\omega \in \Omega$, então existe uma sequência de variáveis aleatórias simples e não negativas $(X_n)_{n \geq 1}$ tais que $X_n(\omega) \nearrow X(\omega)$ para todo $\omega \in \Omega$.

Corolário 7.11.1 (*2.1 v.a. como seq. de v.a. simples*). Considere $(\Omega, \mathcal{A})$ um espaço mensurável. Uma função $X: \Omega \rightarrow \overline{\mathbb{R}}$ é variável aleatória se, e somente se, existe uma sequência de variáveis aleatórias simples $(X_n)_{n \geq 1}$ tais que $X(\omega) = \lim_{n \rightarrow \infty} X_n(\omega)$ para todo $\omega \in \Omega$.

Teorema 7.11.6 (*2.13 v.a. aleatória mensurável como composição de funções*). Sejam $(\Omega_1, \mathcal{A}_1)$, $(\Omega_2, \mathcal{A}_2)$ espaços mensuráveis e $X: \Omega_1 \rightarrow \Omega_2$ uma função $\mathcal{A}_1 \setminus \mathcal{A}_2$ mensurável. Uma variável aleatória $Y: \Omega_1 \rightarrow \overline{\mathbb{R}}$ é $\sigma(X) \setminus \mathcal{B}(\overline{\mathbb{R}})$ mensurável se, e somente se, existe $f: \Omega_2 \rightarrow \overline{\mathbb{R}}$ $\mathcal{A}_2 \setminus \mathcal{B}(\overline{\mathbb{R}})$ mensurável tal que $Y = f(X)$.

Teorema 7.11.7 (*Exercício 2.5*). Toda função monótona $f: \mathbb{R} \rightarrow \mathbb{R}$ é Borel mensurável.

7.12 Esperança

7.12.1 Variável aleatória simples

Definição 7.12.1 (*Esperança de v.a. simples*). Para uma v.a. simples $X = \sum_{i=1}^n x_i I_{A_i}$, definimos sua esperança (integral) com respeito a $\mathbb{P}$ como:

$$\mathbb{E}[X] = \int X d\mathbb{P} = \sum_{i=1}^n x_i \mathbb{P}(A_i) \quad (7.12.1)$$

Definição 7.12.2 (*Esperança de v.a. simples sobre A*). Para uma v.a. simples e não negativa X , definimos a integral de X sobre A como:

$$\int_A X d\mathbb{P} = \int X I_A d\mathbb{P} = \mathbb{E}[X I_A] = \sum_{i=1}^n x_i \mathbb{P}(A_i \cap A). \quad (7.12.2)$$

Nota: O professor confirmou que a definição vale também para $X < 0$.

Teorema 7.12.1 (*Proposição 3.1 / Corolário 3.1*). As seguintes propriedades são válidas para esperança de variáveis aleatórias simples:

$$(1) \mathbb{E}[aX] = a \mathbb{E}[X], \quad a \in \mathbb{R}$$

$$\int aX d\mathbb{P} = a \int X d\mathbb{P}$$

$$(2) \mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$$

$$\int (X + Y) d\mathbb{P} = \int X d\mathbb{P} + \int Y d\mathbb{P}$$

$$(3) X \leq Y \implies \mathbb{E}[X] \leq \mathbb{E}[Y]$$

$$\int X d\mathbb{P} \leq \int Y d\mathbb{P}$$

$$(4) \mathbb{E}[c_1 X_1 + \dots + c_n X_n] = c_1 \mathbb{E}[X_1] + \dots + c_n \mathbb{E}[X_n] \quad c_1, \dots, c_n \in \mathbb{R}.$$

Teorema 7.12.2. Se X for uma v.a. simples e não negativa, então a aplicação $\nu: \mathcal{A} \rightarrow [0, \infty]$ definida como $\nu(A) = \int_A X d\mathbb{P}$ é uma medida sobre $(\Omega, \mathcal{A})$.

7.12.2 Variável aleatória não negativa

Definição 7.12.3 (*Esperança de v.a. não negativa*). Para uma v.a. não negativa $X \geq 0$, definimos sua esperança (integral) como:

$$\mathbb{E}[X] = \int X d\mathbb{P} = \lim_{n \rightarrow \infty} \mathbb{E}[X_n] \quad (7.12.3)$$

em que $(X_n)_{n \geq 1}$ é uma sequência de v.a. simples não negativas tais que $X_n \nearrow X$. Caso $\mathbb{E}[X] < \infty$, X é dita *variável aleatória integrável*.

Lema 7.12.1. Considere Y uma variável aleatória simples não negativa e $(X_n)_{n \geq 1}$ uma sequência crescente de variáveis aleatórias simples e não negativas tais que $Y \leq \lim_{n \rightarrow \infty} X_n$. Então, a sequência $(\mathbb{E}[X_n])_{n \geq 1}$ é convergente, e

$$\mathbb{E}[Y] \leq \lim_{n \rightarrow \infty} \mathbb{E}[X_n].$$

Teorema 7.12.3. As seguintes propriedades são válidas para esperança de variáveis aleatórias não negativas

- (1) $\mathbb{E}[aX] = a \mathbb{E}[X], \quad a \in \mathbb{R}$
- (2) $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$
- (3) $X \leq Y \implies \mathbb{E}[X] \leq \mathbb{E}[Y]$
- (4) $\mathbb{E}[c_1 X_1 + \cdots + c_n X_n] = c_1 \mathbb{E}[X_1] + \cdots + c_n \mathbb{E}[X_n] \quad c_1, \dots, c_n \in \mathbb{R};$
- (5) $\mathbb{E}[X] = \sup\{\mathbb{E}[Y] : 0 \leq Y \leq X, Y \text{ é uma v.a. simples}\}$
- (6) $\mathbb{E}[X] = 0 \iff X = 0 \text{ quase certamente.}$

Lema 7.12.2. Considere $Y \geq 0$ simples e $(X_n)_{n \geq 1}$ uma sequência de v.a.n.n. tal que $Y \leq \liminf X_n = \lim_{n \rightarrow \infty} \inf_{k \geq n} X_k$. Então,

$$\mathbb{E}[Y] \leq \liminf \mathbb{E}[X_n].$$

Teorema 7.12.4 (*Lema de Fatou*). Seja $(X_n)_{n \geq 1}$ uma sequência de v.a.n.n. Então,

$$\mathbb{E}[\liminf X_n] \leq \liminf \mathbb{E}[X_n].$$

Teorema 7.12.5 (*3.3 Teorema da Convergência Monótona*). Se $X \geq 0$ for uma variável aleatória e $(X_n)_{n \geq 1}$ uma sequência de v.a.n.n. tal que $X_n \nearrow X$. Então,

$$\mathbb{E}[X] = \lim_{n \rightarrow \infty} \mathbb{E}[X_n].$$

Corolário 7.12.1. Se $(X_n)_{n \geq 1}$ for uma sequência de v.a.n.n., então

$$\mathbb{E} \left[\sum_{n=1}^{\infty} \mathbb{E}[X_n] \right] = \sum_{n=1}^{\infty} \mathbb{E}[X_n].$$

Definição 7.12.4 (*Esperança de v.a.n.n sobre A*). Para uma v.a. não negativa X , definimos a integral de X sobre A como:

$$\int_A X d\mathbb{P} = \int X I_{A_i} d\mathbb{P} = \mathbb{E}[X I_{A_i}]. \quad (7.12.4)$$

Teorema 7.12.6. Se X for uma v.a. não negativa, então a aplicação $\nu: \mathcal{A} \rightarrow [0, \infty]$ definida como $\nu(A) = \int_A X d\mathbb{P}$ é uma medida sobre $(\Omega, \mathcal{A})$.

7.12.3 Variável aleatória integrável

Definição 7.12.5 (*Esperança de v.a. quase-integráveis e integráveis*). Uma variável aleatória X tal que $\mathbb{E}[X^+] < \infty$ ou $\mathbb{E}[X^-] < \infty$ é dita *quase integrável* e definimos sua esperança (integral) com respeito a $\mathbb{P}$ como:

$$\mathbb{E}[X] = \int X d\mathbb{P} = \int X^+ d\mathbb{P} - \int X^- d\mathbb{P} = \mathbb{E}[X^+] - \mathbb{E}[X^-] \quad (7.12.5)$$

A variável X é dita *integrável* se $\mathbb{E}[X^+] < \infty$ e $\mathbb{E}[X^-] < \infty$. Neste caso, dizemos que $X \in L_1$, em que L_1 é o conjunto das variáveis aleatórias integráveis.

Nota: A variável X é integrável se, e somente se, $\mathbb{E}[|X|] < \infty$.

Lema 7.12.3. Se $X_1, X_2 \geq 0$ são v.a. tais que X_1 ou X_2 são integráveis ($\mathbb{E}[X_1] < \infty$ ou $\mathbb{E}[X_2] < \infty$ e $[X_1 = \infty, X_2 = \infty] = \emptyset$), então a variável aleatória $X = X_1 - X_2$ é quase-integrável, e

$$\mathbb{E}[X] = \mathbb{E}[X_1] - \mathbb{E}[X_2].$$

Teorema 7.12.7. As seguintes propriedades são válidas para esperança de variáveis aleatórias quase-integráveis:

- (1) $\mathbb{E}[aX] = a \mathbb{E}[X], \quad a \in \mathbb{R}$
- (2) $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$
- (3) $X \leq Y \implies \mathbb{E}[X] \leq \mathbb{E}[Y]$

Definição 7.12.6 (*Integral de X sobre A*). Para uma v.a. integrável X , definimos a integral de X sobre A como:

$$\left| \int_A X d\mathbb{P} \right| \leq \int |X| d\mathbb{P} < \infty, \quad \text{para todo } A \in \mathcal{A} \quad (7.12.6)$$

Teorema 7.12.8. Se X for uma v.a. integrável, então a aplicação $\nu: \mathcal{A} \rightarrow \mathbb{R}$ definida como $\nu(A) = \int_A X d\mathbb{P}$ é uma função de conjuntos σ -aditiva.

Teorema 7.12.9. Considere X e Y variáveis aleatórias integráveis. Então, as afirmações a seguir são equivalentes:

- (1) $\int_A X d\mathbb{P} = \int_A Y d\mathbb{P}$ para todo $A \in \mathcal{A}$;
- (2) $\int_\Omega |X - Y| d\mathbb{P} = 0$;
- (3) $X = Y$ quase certamente.

Teorema 7.12.10 (3.6 Teorema da Convergência Dominada). Considere $(X_n)_{n \geq 1}$ uma sequência de v.a tais que $X_n(\omega) \rightarrow X(\omega)$ para todo $\omega \in \Omega$. Se existe uma variável aleatória integrável Y tal que $|X_n| \leq Y$ pra todo $n \geq 1$, então X_n é integrável para todo $n \geq 1$ e

$$\mathbb{E}[X] = \lim_{n \rightarrow \infty} \mathbb{E}[X_n].$$

Teorema 7.12.11 (*Mudança de variável*). Considere $X: \Omega \rightarrow \overline{\mathbb{R}}$ uma variável aleatória e $g: \overline{\mathbb{R}} \rightarrow \overline{\mathbb{R}}$ uma função Borel mensurável. Então, a variável aleatória $g(X): \Omega \rightarrow \overline{\mathbb{R}}$ definida como $(g(X))(\omega) = g(X(\omega))$, $\omega \in \Omega$ é tal que

$$\int_{\Omega} g(X(\omega)) d\mathbb{P} = \int_{\overline{\mathbb{R}}} g(x) d\mathbb{P}_X(x),$$

desde que uma das duas integrais esteja definida. A probabilidade $\mathbb{P}_X$ denota a medida de probabilidade induzida por X (distribuição de X) definida como $\mathbb{P}_X(B) = \mathbb{P}([X \in B])$, $B \in \mathcal{B}(\overline{\mathbb{R}})$.

Definição 7.12.7. Dizemos que uma variável aleatória $X: \Omega \rightarrow \overline{\mathbb{R}}$ possui uma densidade com respeito a uma medida μ definida em $(\overline{\mathbb{R}}, \mathcal{B}(\overline{\mathbb{R}}))$ se existe uma função $f_X: \overline{\mathbb{R}} \rightarrow [0, \infty]$ (densidade de X com respeito a μ) Borel mensurável tal que

$$\mathbb{P}_X(B) = \int_B f_X d\mu, \quad \text{para todo } B \in \mathcal{B}(\overline{\mathbb{R}}).$$

Nota:

- (a) Em geral, se ν e μ são duas medidas sobre o espaço mensurável $(\Omega_1, \mathcal{A}_1)$ e existe uma função $\mathcal{A}$ mensurável $f_X: \Omega \rightarrow [0, \infty]$ que satisfaz

$$\nu(A) = \int_A f d\mu, \quad \text{para todo } A \in \mathcal{A},$$

então f é dita *densidade* de ν com respeito a μ . Note que, se isto valer, então

$$\mu(A) = 0, A \in \mathcal{A} \implies \nu(A) = 0. \quad (7.12.7)$$

- (b) Sempre que ν e μ satisfizerem 7.12.7, dizemos que ν é *absolutamente contínua* com respeito a μ e denotamos isto por $\nu \ll \mu$. O célebre teorema e Radon-Nikodym garante a recíproca do resultado apresentado em (a).

7.13 Medida de Probabilidade Produto

7.13.1 Vetores aleatórios

Definição 7.13.1 (σ -álgebra produto). Considere $(\Omega, \mathcal{A}), (\Omega_1, \mathcal{A}_1), \dots, (\Omega_n, \mathcal{A}_n)$ espaços mensuráveis e seja $X_i: \Omega \rightarrow \Omega_i$, $i = 1, \dots, n$. Definimos a σ -álgebra gerada por $X_1, X_2, \dots, X_n$ como a menor σ -álgebra $\mathcal{A}$ de subconjuntos de Ω para a qual X_i é $\mathcal{A} \setminus \mathcal{A}_i$ -mensurável para todo $i = 1, \dots, n$, isto é,

$$\sigma(X_1, X_2, \dots, X_n) = \sigma(\{X_i^{-1}(B_i) : B_i \in \mathcal{A}_i, i = 1, 2, \dots, n\}). \quad (7.13.1)$$

Teorema 7.13.1 (*Condição suficiente para vetor aleatório*). X é um vetor aleatório se

$$[X \in [-\infty, x_1] \times \cdots \times [-\infty, x_n]] \in \mathcal{A} \quad \text{para quaisquer } x_1, \dots, x_n \in \mathbb{R}. \quad (7.13.2)$$

Definição 7.13.2 (*Vetor aleatório*). Seja $(\Omega, \mathcal{A})$ um espaço mensurável. Uma função $X : \Omega \rightarrow \mathbb{R}^n$ é chamada de *vetor aleatório* se for $\mathcal{A} \setminus \mathcal{B}(\mathbb{R}^n)$ -mensurável, isto é,

$$[X \in B] = X^{-1}(B) \in \mathcal{A} \quad \text{para todo } B \in \mathcal{B}(\mathbb{R}^n). \quad (7.13.3)$$

Uma função $X : \Omega \rightarrow \mathbb{R}^n$ é $\mathcal{A} \setminus \mathcal{B}(\mathbb{R}^n)$ -mensurável também é chamada de vetor aleatório.

Teorema 7.13.2. Uma função $X = (X_1, \dots, X_n) : \Omega \rightarrow \mathbb{R}^n$ é um vetor aleatório se, e somente se, $X_1, \dots, X_n$ são variáveis aleatórias.

Definição 7.13.3 (*Distribuição de um vetor aleatório*). Dado um espaço de probabilidade $(\Omega, \mathcal{A}, \mathbb{P})$ e $X = (X_1, \dots, X_n)$ um vetor aleatório, definimos a **distribuição de X** como a medida de probabilidade $\mathbb{P}_X$ sobre $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ dada por

$$\mathbb{P}_X(B) = \mathbb{P}([X \in B]), \quad B \in \mathcal{B}(\mathbb{R}^n). \quad (7.13.4)$$

Definição 7.13.4.

- (1) *Projeção coordenada*: $\pi_i(\omega, \dots, \omega_n) = \omega_i$
- (2) *Cilindro unidimensional de base A_i* : $\pi_i^{-1}(A_i) = \{\omega \in \Omega : \pi_i(\omega) \in A_i\}$
- (3) *Classe dos cilindros unidimensionais*: $\mathcal{C} = \{\pi_i^{-1}(A_i) : A_i \in \mathcal{A}, i = 1, \dots, n\}$
- (4) *Classe dos retângulos mensuráveis*: $\mathcal{R} = \{A_1 \times \cdots \times A_n : A_i \in \mathcal{A}, i = 1, \dots, n\}$
- (5) σ -álgebra produto sobre Ω^n : $\bigotimes_{i=1}^n \mathcal{A}_i = \mathcal{A}_1 \otimes \cdots \otimes \mathcal{A}_n = \sigma(\mathcal{C}) = \sigma(\mathcal{R}) = \sigma(\pi_1, \dots, \pi_n)$
- (6) $\mathcal{B}(\mathbb{R}^n) = \bigotimes_{i=1}^n \mathcal{B}(\mathbb{R})$

7.13.2 Medida produto

Definição 7.13.5 (*Medida de probabilidade produto*). Para $(\Omega_1, \mathcal{A}_1, \mathbb{P}_1), \dots, (\Omega_n, \mathcal{A}_n, \mathbb{P}_n)$ espaços de probabilidade, uma medida de probabilidade $\mathbb{P}$ sobre $(\Omega_1 \times \cdots \times \Omega_n, \mathcal{A}_1 \otimes \cdots \otimes \mathcal{A}_n)$ é dita *medida de probabilidade produto* se satisfizer

$$\mathbb{P}(A_1 \times \cdots \times A_n) = \mathbb{P}_1(A_1) \times \cdots \times \mathbb{P}_n(A_n) \quad (7.13.5)$$

para todo $A_1 \in \mathcal{A}_1, \dots, A_n \in \mathcal{A}_n$. A medida produto $\mathbb{P}$ será denotada por $\mathbb{P}_1 \times \cdots \times \mathbb{P}_n$.

Teorema 7.13.3. Considere $\mathbb{P}_1$ uma probabilidade sobre $(\Omega_1, \mathcal{A}_1)$ e $K : \Omega_1 \times \mathcal{A}_2 \rightarrow [0, 1]$ uma função de transição. Seja $\mathbb{P}$ a probabilidade sobre o espaço produto $(\Omega, \mathcal{A})$ definida como

$$\mathbb{P}(E) = \int_{\Omega_1} K(x, E_x) \mathbb{P}_1(dx), \quad E \in \mathcal{A}. \quad (7.13.6)$$

- (a) Se $f : \Omega \rightarrow [0, +\infty]$ for uma função $\mathcal{A}$ -mensurável, então a função $g : \Omega_1 \rightarrow \mathbb{R}$ definida por

$$g(x) = \int_{\Omega_2} f(x, y) K(x, dy), \quad x \in \Omega_1, \quad (7.13.7)$$

é $\mathcal{A}_1$ -mensurável e $g(x) \geq 0$ para todo $x \in \Omega_1$. Além disso,

$$\int_{\Omega_1 \times \Omega_2} f(x, y) \mathbb{P}(dx, dy) = \int_{\Omega_1} g(x) \mathbb{P}_1(dx) = \int_{\Omega_1} \left[\int_{\Omega_2} f(x, y) K(x, dy) \right] \mathbb{P}_1(dx). \quad (7.13.8)$$

- (b) Se $f : \Omega \rightarrow \mathbb{R}$ for uma função $\mathcal{A}$ -mensurável e quase-integrável com respeito a $\mathbb{P}$, então a função $g : \Omega_1 \rightarrow \mathbb{R}$ dada pela expressão anterior é definida quase certamente, é $\mathcal{A}_1$ -mensurável e quase-integrável com respeito a $\mathbb{P}_1$. Além disso, a identidade continua válida.

Teorema 7.13.4 (*Fubini-Tonelli*). Considere $(\Omega_1, \mathcal{A}_1, \mathbb{P}_1)$ e $(\Omega_2, \mathcal{A}_2, \mathbb{P}_2)$ dois espaços de probabilidade. Seja $(\Omega, \mathcal{A}, \mathbb{P})$ o espaço de probabilidade produto, sendo $\Omega = \Omega_1 \times \Omega_2$, $\mathcal{A} = \mathcal{A}_1 \otimes \mathcal{A}_2$ e $\mathbb{P} = \mathbb{P}_1 \times \mathbb{P}_2$.

- (a) (*Tonelli*) Se $f : \Omega \rightarrow [0, +\infty]$ é uma função $\mathcal{A}$ -mensurável, então as funções $g : \Omega_1 \rightarrow \mathbb{R}$ e $h : \Omega_2 \rightarrow \mathbb{R}$ definidas como

$$g(x) = \int_{\Omega_2} f(x, y) \mathbb{P}_2(dy), \quad x \in \Omega_1, \quad (7.13.9)$$

$$h(y) = \int_{\Omega_1} f(x, y) \mathbb{P}_1(dx), \quad y \in \Omega_2, \quad (7.13.10)$$

são não negativas e $\mathcal{A}_1$ e $\mathcal{A}_2$ -mensuráveis, respectivamente. Além disso,

$$\int_{\Omega_1 \times \Omega_2} f(x, y) \mathbb{P}(dx, dy) = \int_{\Omega_1} \left[\int_{\Omega_2} f(x, y) \mathbb{P}_2(dy) \right] \mathbb{P}_1(dx) \quad (7.13.11)$$

$$= \int_{\Omega_2} \left[\int_{\Omega_1} f(x, y) \mathbb{P}_1(dx) \right] \mathbb{P}_2(dy). \quad (7.13.12)$$

- (b) (*Fubini*) Se $f : \Omega \rightarrow \mathbb{R}$ é uma função $\mathcal{A}$ -mensurável e quase-integrável com respeito a $\mathbb{P}$, então $g : \Omega_1 \rightarrow \mathbb{R}$ ($h : \Omega_2 \rightarrow \mathbb{R}$) dada em (7.13.9) ((7.13.10)) é $\mathcal{A}_1$ -mensurável ($\mathcal{A}_2$ -mensurável) e quase-integrável com respeito a $\mathbb{P}_1$ ($\mathbb{P}_2$). Além disso, as relações (7.13.11) e (7.13.12) permanecem válidas.

Teorema 7.13.5. Considere (X, Y) um vetor aleatório que possui densidade $f_{X,Y}(x, y)$ com respeito à medida de Lebesgue no plano.

- (a) X e Y possuem densidade com respeito à medida de Lebesgue na reta dadas, respectivamente, por

$$f_X(x) = \int_{\mathbb{R}} f_{X,Y}(x, y) d\lambda(y), \quad (7.13.13)$$

$$f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x, y) d\lambda(x). \quad (7.13.14)$$

- (b) X e Y são variáveis aleatórias independentes se, e somente se, $f_{X,Y}(x, y) = f_X(x)f_Y(y)$ para quase todo $(x, y) \in \mathbb{R}^2$.

Nota: λ designa ao mesmo tempo as medidas de Lebesgue na reta e no plano.

7.14 Independência

7.14.1 Eventos

Definição 7.14.1 (*Independência de eventos*). Os eventos $A_1, A_2, \dots, A_n$ são independentes se

$$\mathbb{P}\left(\bigcap_{i \in I} A_i\right) = \prod_{i \in I} \mathbb{P}(A_i) \quad (7.14.1)$$

para todo $I \subset \{1, \dots, n\}$. Ou, de forma equivalente,

$$\mathbb{P}\left(\bigcap_{i=1}^n C_i\right) = \prod_{i=1}^n \mathbb{P}(C_i) \quad (7.14.2)$$

para quaisquer $C_1, \dots, C_n$ tais que $C_i = A_i$ ou $C_i = \Omega$, $i = 1, \dots, n$.

Definição 7.14.2 (*Famílias de eventos*). Uma família de eventos $\{A_t : t \in T\}$ é independente se toda subcoleção finita $\{A_{t_1}, \dots, A_{t_n}\}$ for independente para qualquer escolha de $\{t_1, \dots, t_n\} \subset T$, com t_i 's todos distintos.

7.14.2 Classes de eventos

Definição 7.14.3 (*Independência de classe de eventos*). As classes de eventos $\mathcal{A}_1, \mathcal{A}_2, \dots, \mathcal{A}_n$ são independentes se os eventos $A_1, A_2, \dots, A_n$ são independentes para quaisquer escolhas de $A_1 \in \mathcal{A}_1, A_2 \in \mathcal{A}_2, \dots, A_n \in \mathcal{A}_n$.

Nota: As σ -álgebras $\mathcal{A}_1, \mathcal{A}_2$ são independentes se, e somente se,

$$\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1)\mathbb{P}(A_2), \quad (7.14.3)$$

para quaisquer $A_1 \in \mathcal{A}_1$ e $A_2 \in \mathcal{A}_2$.

Definição 7.14.4 (*Famílias de classes de eventos*).

- Uma família de eventos $\{\mathcal{A}_t : t \in T\}$ é independente se toda subcoleção finita $\{\mathcal{A}_{t_1}, \dots, \mathcal{A}_{t_n}\}$ for independente para quaisquer escolhas de $\{t_1, \dots, t_n\} \subset T$, com t_i 's todos distintos.
- De forma alternativa, $\{\mathcal{A}_t : t \in T\}$ é independente se, e somente se, toda família de eventos $\{A_t : t \in T\}$ for independente, em que $A_t \in \mathcal{A}_t$ para todo $t \in T$.

7.14.3 Variáveis aleatórias

Definição 7.14.5 (*Independência de variáveis aleatórias*).

- As variáveis aleatórias $X_1, X_2, \dots, X_n$ são independentes se, e somente se, as sigma-álgebras geradas $\sigma(X_1), \sigma(X_2), \dots, \sigma(X_n)$ são independentes.
- De forma alternativa, $X_1, X_2, \dots, X_n$ são independentes se, e somente se,

$$\mathbb{P}(X_1 \in B_1, \dots, X_n \in B_n) = \prod_{i=1}^n \mathbb{P}(X_i \in B_i) \quad (7.14.4)$$

para quaisquer $B_1, \dots, B_n \in \mathcal{B}(\mathbb{R})$.

Definição 7.14.6 (*Famílias de variáveis aleatórias*).

- Uma família de variáveis aleatórias $\{X_t : t \in T\}$ é independente se, e somente se, a família de suas σ -álgebras gerada $\{\sigma(X_t) : t \in T\}$ é independente.
- De forma alternativa, $\{X_t : t \in T\}$ é independente se, e somente se, toda subfamília finita $\{X_{t_1}, \dots, X_{t_n}\}$ for independente para quaisquer escolhas de $\{t_1, \dots, t_n\} \subset T$, com t_i 's todos distintos.

7.14.4 Teoremas

Teorema 7.14.1 (*Extensão da Independência 1*). Considere $\mathcal{A}_1 = \sigma(\mathcal{I}_1)$ e $\mathcal{A}_2 = \sigma(\mathcal{I}_2)$, em que $\mathcal{I}_1, \mathcal{I}_2$ são π -sistemas. Então, $\mathcal{A}_1$ e $\mathcal{A}_2$ são independentes se, e somente se $\mathcal{I}_1$ e $\mathcal{I}_2$ são independentes, isto é,

$$\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1)\mathbb{P}(A_2), \quad (7.14.5)$$

para quaisquer $A_1 \in \mathcal{I}_1$ e $A_2 \in \mathcal{I}_2$.

Teorema 7.14.2 (*Extensão da Independência 2*). Sejam $\mathcal{I}_1, \dots, \mathcal{I}_n$ π -sistemas. $\mathcal{I}_1, \dots, \mathcal{I}_n$ são independentes se, e somente se, $\sigma(\mathcal{I}_1), \dots, \sigma(\mathcal{I}_n)$ são independentes.

Corolário 7.14.1. As variáveis aleatórias $X_1, \dots, X_n$ são independentes se, e somente se,

$$\mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n) = \prod_{i=1}^n \mathbb{P}(X_i \leq x_i), \quad (7.14.6)$$

para quaisquer $x_i \in \mathbb{R}$, $i = 1, \dots, n$.

Teorema 7.14.3 (*Lema de Borel-Cantelli*). Seja $(A_n)_{n \geq 1}$ uma sequência de eventos.

- (1) Se $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$, então $\mathbb{P}([A_n \text{ i.v.}]) = 0$;
- (2) Se $\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty$ e $(A_n)_{n \geq 1}$ é independente, então $\mathbb{P}([A_n \text{ i.v.}]) = 1$.

7.15 Convergência

7.15.1 Definições

Definição 7.15.1 (*Quase certa*).

- $(X_n)_{n \geq 1}$ converge quase certamente para X , isto é, $X_n \xrightarrow{\text{q.c.}} X$ se

$$\mathbb{P}([X_n \rightarrow X]) = 1, \quad (7.15.1)$$

em que $[X_n \rightarrow X] = A^c = \{\omega \in \Omega : X_n(\omega) \rightarrow X(\omega)\}^c$.

- Ou seja, $(X_n)_{n \geq 1}$ converge quase certamente para X se existe $A \in \mathcal{A}$ tal que $\mathbb{P}(A) = 0$ e $X_n \rightarrow X$ em A^c , quando $n \rightarrow \infty$.
- Alternativamente, $(X_n)_{n \geq 1}$ converge quase certamente para X se, e somente se

$$\mathbb{P}([|X_n - X| \geq \epsilon \text{ i.v.}]) = \mathbb{P}(\limsup[|X_n - X| \geq \epsilon]) = 0. \quad (7.15.2)$$

Nota: A convergência quase certa permite que alguns pontos de Ω escapem do critério de convergência, mas o conjunto destes pontos precisa ser negligenciável em termos probabilísticos, isto é, sua probabilidade dever ser zero.

Definição 7.15.2 (*Em probabilidade*). $(X_n)_{n \geq 1}$ converge em probabilidade para X , isto é, $X_n \xrightarrow{P} X$ se, para todo $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| \geq \epsilon) = 0. \quad (7.15.3)$$

Definição 7.15.3 (*Em média p*). Considere $(X_n)_{n \geq 1} \subset L^p, p \geq 1$. $(X_n)_{n \geq 1}$ converge em média p para X , $X_n \xrightarrow{L^p} X$ se $\|X_n - X\|_p \rightarrow 0$ quando $n \rightarrow \infty$, ou seja,

$$\lim_{n \rightarrow \infty} \mathbb{E}[|X_n - X|^p] = 0. \quad (7.15.4)$$

7.15.2 Teoremas

Teorema 7.15.1. Considere $(X_n)_{n \geq 1}$ e $(Y_n)_{n \geq 1}$ duas seqüências de variáveis aleatórias, X e Y variáveis aleatórias.

- (1) $X_n \xrightarrow{\mathcal{P}} X \implies aX_n \xrightarrow{\mathcal{P}} aX$
 $X_n \xrightarrow{\text{q.c.}} X \implies aX_n \xrightarrow{\text{q.c.}} aX$
- (2) $X_n \xrightarrow{\mathcal{P}} X, Y_n \xrightarrow{\mathcal{P}} Y \implies X_n + Y_n \xrightarrow{\mathcal{P}} X + Y$
 $X_n \xrightarrow{\text{q.c.}} X, Y_n \xrightarrow{\text{q.c.}} Y \implies X_n + Y_n \xrightarrow{\text{q.c.}} X + Y$

Teorema 7.15.2 (*Condição necessária e suficiente para convergência q.c.*).

$$X_n \xrightarrow{\text{q.c.}} X \iff \mathbb{P}(|X_n - X| \geq \epsilon \text{ i.v.}) = 0, \forall \epsilon > 0 \quad (7.15.5)$$

Teorema 7.15.3 (*Condição suficiente para convergência q.c.*).

$$\sum_{n=1}^{\infty} \mathbb{P}(|X_n - X| \geq \epsilon) < \infty, \forall \epsilon > 0 \implies X_n \xrightarrow{\text{q.c.}} X \quad (7.15.6)$$

Teorema 7.15.4 (*Relações entre convergências*).

- (1) $X_n \xrightarrow{\text{q.c.}} X \implies X_n \xrightarrow{\mathcal{P}} X$
- (2) $X_n \xrightarrow{L^p} X \implies X_n \xrightarrow{\mathcal{P}} X$

Teorema 7.15.5 (*Fatos úteis*).

- (1) $\{|X_n - Y_n| \geq \epsilon\} \subseteq \{|X_n - X| \geq \epsilon/2\} \cup \{|Y_n - X| \geq \epsilon/2\}$

7.15.3 Desigualdades

Teorema 7.15.6 (*Desigualdades e igualdades importantes*).

- (1) Hölder: $\mathbb{E}[|XY|] \leq (\mathbb{E}[|X|^p])^{\frac{1}{p}} \mathbb{E}[|Y|^q]^{\frac{1}{q}}$, para $X \in L^p, Y \in L^q, p, q > 0, \frac{1}{p} + \frac{1}{q} = 1$
- (2) Lyapunov: $(\mathbb{E}[|X|^q])^{\frac{1}{q}} \leq (\mathbb{E}[|X|^p])^{\frac{1}{p}}$, se $X \in L^p$ e $0 < q \leq p$
- (3) Minkowski: $(\mathbb{E}[|X + Y|^p])^{\frac{1}{p}} \leq (\mathbb{E}[|X|^p])^{\frac{1}{p}} + (\mathbb{E}[|Y|^p])^{\frac{1}{p}}$, para $X, Y \in L^p, p \geq 1$
- (4) Markov: $\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}$ para $X > 0$
- (5) Tchebychev: $\mathbb{P}(|X - c| \geq \epsilon) \leq \frac{\mathbb{E}[|X - c|^p]}{\epsilon^p}, \forall \epsilon > 0$, se $X \in L^p, p > 0$

(6) Jensen: $\mathbb{E}[g(X)] \geq g(\mathbb{E}[X])$, onde $g : \mathbb{R} \rightarrow \mathbb{R}$ é Borel mensurável convexa e $X, g(X) \in L^1$

$$(a) \quad \mathbb{E}[X^2] \geq (\mathbb{E}[X])^2$$

(7) Cauchy-Schwarz: Se $X, Y \in L^2$, então $XY \in L^1$ e $\mathbb{E}[XY] \leq \mathbb{E}[|XY|] \leq \sqrt{\mathbb{E}[X^2] \mathbb{E}[Y^2]}$

$$(8) \quad \mathbb{E}[X] \leq \mathbb{E}[|X|]$$

$$(9) \quad |\mathbb{E}[X]| \leq \mathbb{E}[|X|]$$

$$(10) \quad \mathbb{E}[X] - \mu = \mathbb{E}[X - \mu]$$

7.15.4 Covariância e Variância

Definição 7.15.4. Para $X, Y \in L^2$, definimos a covariância entre X e Y como

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \quad (7.15.7)$$

$$= \mathbb{E}[XY] - \mathbb{E}[X] \mathbb{E}[Y] \quad (7.15.8)$$

Nota: Se $X, Y \in L^2$ são independentes, então X e Y são não correlacionadas.

7.15.5 Leis dos Grandes Números